
数值分析笔记

李铁军《数值分析》课程笔记

斑马数学 整理

2026 年 3 月

目录

第一章 Lagrange 插值	1
第二章 Newton 多项式插值	7
第三章 样条插值 (spline)	10
第四章 最小二乘拟合 (Least Squares Fitting)	16
第五章 其他论题	22
第六章 数值积分基础 (Numerical Integration/Quadrature)	24
第七章 Gauss 积分	30
第八章 自适应与谱精度	35
第九章 多维积分与数值微分	40
第十章 Monte Carlo 方法	44
第十一章 Metropolis 算法	49
第十二章 非线性方程数值解 (nonlinear equation)	52
第十三章 非线性方程组数值解	58
第十四章 快速 Fourier 变换 (FFT)	61
第十五章 FFT 的应用	66
第十六章 快速 Gauss 变换	70
第十七章 常微分方程数值解	73
第十八章 理论分析与稳定性	78
第十九章 Runge-Kutta 方法	84

第一章 Lagrange 插值

定义 1.1 Lagrange 插值

设 $n \in \mathbb{Z}_{\geq 0}$, 给定 $(x_i, y_i)_{0 \leq i \leq n}$, $x_i \neq x_j, \forall i \neq j$, 求

$$p(x) \in \mathcal{P}_n = \{q \mid \deg q \leq n\}, \quad p(x) = \sum_{k=0}^n a_k x^k,$$

使得 $p(x_i) = y_i, \forall 0 \leq i \leq n$, 记这样得到的 **Lagrange 插值多项式**为 $\Pi_n(x)$ 或 $L_n(x)$ 或 $\Pi_n f(x)$.

将 Π_n 理解为线性投影算子

$$\Pi_n : f \in C[a, b] \mapsto \Pi_n f \in C[a, b]$$

时, 显然有 $\Pi_n^2 = \Pi_n$.

由 $\Pi_n(x_i) = y_i, \forall 0 \leq i \leq n$ 得到

$$\sum_{k=0}^n a_k x_i^k = y_i, \quad \forall 0 \leq i \leq n,$$

从而得到线性方程组 $\mathbf{V}\mathbf{a} = \mathbf{y}$, 其中

$$\mathbf{a} = \begin{pmatrix} a_n \\ a_{n-1} \\ \vdots \\ a_0 \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \mathbf{V} = \begin{pmatrix} x_0^n & x_0^{n-1} & \cdots & 1 \\ x_1^n & x_1^{n-1} & \cdots & 1 \\ \vdots & \vdots & \cdots & \vdots \\ x_n^n & x_n^{n-1} & \cdots & 1 \end{pmatrix}.$$

由 Vandermonde 行列式得到

$$\det \mathbf{V} = \prod_{n \geq i > j \geq 0} (x_i - x_j) \neq 0,$$

因此 $\Pi_n(x)$ 存在且唯一.

同时, 我们通过**基函数 (basis function)** 求 $\Pi_n(x)$: 取 $\{l_j(x)\}_{0 \leq j \leq n}, l_j(x) \in \mathcal{P}_n$, 使得

$$l_j(x_k) = \delta_{jk} = \begin{cases} 1, & j = k, \\ 0, & j \neq k. \end{cases}$$

δ 也称为 **Kronecker 记号**, 此时我们有

$$\Pi_n(x) = \sum_{j=0}^n y_j l_j(x),$$

这是因为 $\forall 0 \leq k \leq n$, 都有

$$\Pi_n(x_k) = \sum_{j=0}^n y_j l_j(x_k) = \sum_{j=0}^n y_j \delta_{jk} = y_k,$$

并且易得基函数

$$l_j(x) = \frac{\prod_{k \neq j} (x - x_k)}{\prod_{k \neq j} (x_j - x_k)} = \frac{\omega_{n+1}(x)/(x - x_j)}{\omega'_{n+1}(x_j)}, \quad \omega_{n+1}(x) := \prod_{j=0}^n (x - x_j) \in \mathcal{P}_{n+1}.$$

我们也可记 $l_j(x)$ 为 $l_{n,j}(x)$. 易得 $l_j(x)$ 有如下性质:

$$\sum_{j=0}^n x_j^k l_j(x) \equiv x^k, \quad \forall 0 \leq k \leq n.$$

误差估计 (Error estimate)

设

$$a = x_0 < x_1 < \cdots < x_n = b, \quad f \in C^\infty[a, b], \quad E_n(x) := f(x) - \Pi_n f(x)$$

定理 1.1

$\forall x \in [a, b]$, 都存在 $\xi \in [a, b]$, 使得

$$E_n(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi).$$

证明.

不妨设 $x \notin \{x_j\}_{0 \leq j \leq n}$ (否则显然), 记

$$F(\xi) = (\Pi_n f(\xi) - f(\xi)) - \frac{\omega_{n+1}(\xi)}{\omega_{n+1}(x)} (\Pi_n f(x) - f(x)),$$

显然有 $F(x_j) = 0, \forall 0 \leq j \leq n$, 且 $F(x) = 0$. 由 Rolle 定理, 存在 $\xi \in [a, b]$, 使得 $F^{(n+1)}(\xi) = 0$, 因此

$$E_n(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi).$$

□

收敛性

考察 $E_n(x), n \rightarrow +\infty$ 的性质, 事实上, $f^{(n+1)}(x)$ 的性质可能极差. 取 $f(x) = (x - x_0)^{-1}$, 则

$$f^{(n+1)}(x) = (-1)^{n+1}(n+1)!(x - x_0)^{-(n+2)}.$$

数值稳定性 (Numerical stability)

设

$$\tilde{\Pi}_n(x) = \sum_{j=0}^n \tilde{y}_j l_j(x), \quad \tilde{y}_j = y_j + \varepsilon_j,$$

则

$$\begin{aligned} \tilde{\Pi}_n(x) - f(x) &= \tilde{\Pi}_n(x) - \Pi_n(x) + \Pi_n(x) - f(x) \\ &= \sum_{j=0}^n \varepsilon_j l_j(x) + E_n(x), \end{aligned}$$

事实上, $|l_j(x)|$ 可能很大, 取等距节点高次 Lagrange 插值

$$a = x_{-n} < x_{-n+1} < \cdots < x_{-1} < x_0 < x_1 < \cdots < x_n = b, \quad x_{i+1} - x_i = h = \frac{b-a}{2n},$$

取 $x = x_n - h/2$, 则计算可得

$$|l_0(x)| = \frac{(4n)!}{2^{4n}(n!)^2(2n)!} \cdot \frac{1}{2n-1},$$

当 $n \rightarrow +\infty$ 时, 由 Stirling 公式得

$$|l_0(x)| \sim \frac{(4n)^{4n+\frac{1}{2}} e^{-4n}}{2\pi \cdot 2^{4n} n^{2n+1} e^{-4n} (2n)^{2n+\frac{1}{2}}} \cdot \frac{1}{2n-1} = \frac{4^n}{2\pi n(2n-1)} \rightarrow +\infty.$$

一致收敛性

定义点列 $X = \{x_j^{(n)}\}_{0 \leq j \leq n}$, 则 $\Pi_n f(x; X) \in \mathcal{P}_n$, 并记 $E_n f(x; X) = \Pi_n f(x; X) - f(x)$, 定义**无穷范数 (norm)**:

$$\|f\|_\infty = \max_{x \in [a, b]} \{|f(x)|\},$$

考察当 $n \rightarrow +\infty$ 时, $\|E_n f\|_\infty \rightarrow 0$ 的收敛性.

定理 1.2

如果 f 在 $C_{r_0} = B_{r_0}(\frac{a+b}{2})$, $r_0 > \frac{3}{2}(b-a)$ 内解析, 则 $\|E_n f\|_\infty \rightarrow 0, \forall X$.

证明.

由于

$$E_n f(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi), \quad \xi \in [a, b],$$

且由 Cauchy 积分公式得

$$f^{(n+1)}(x) = \frac{(n+1)!}{2\pi i} \oint_{\partial C_{r_0}} \frac{f(\xi)}{(\xi-x)^{n+2}} d\xi, \quad x \in C_{r_0},$$

从而

$$\|E_n f\|_\infty \leq \frac{(b-a)^{n+1}}{2\pi} \cdot \frac{\max_{z \in \partial B_{r_0}} |f(z)|}{(r_0 - \frac{b-a}{2})^{n+2}} \cdot 2\pi r_0 = \mathcal{O} \left(\left(\frac{b-a}{r_0 - \frac{b-a}{2}} \right)^n \right) \rightarrow 0.$$

□

一般的收敛性理论

定义 **Lebesgue 函数**

$$\lambda_n(x; X) = \max_{\|f\|_\infty \leq 1} |\Pi_n f(x; X)|,$$

再记 $\Pi_n f(x; X) = \Pi_n^x f(X)$, 则有线性泛函

$$\Pi_n^x : f \in C[a, b] \mapsto \Pi_n^x f \in \mathbb{R},$$

从而 $\lambda_n(x; X)$ 即为 Π_n^x 的算子范数, 并且易证

$$\lambda_n(x; X) = \sum_{j=0}^n |l_{n,j}(x; X)|.$$

再定义 **Lebesgue 常数**

$$\Lambda_n(X) = \max_{\|f\|_\infty \leq 1} \|\Pi_n f(\cdot; X)\|_\infty = \|\Pi_n\|_\infty = \max_{x \in [a, b]} \lambda_n(x; X) = \left\| \sum_{j=0}^n |l_{n,j}(x)| \right\|_\infty$$

和

$$E_n(f; X) = \|f - \Pi_n f\|_\infty,$$

以及 p_n^* 为 f 的最佳一致逼近多项式, 即

$$p_n^* = \arg \inf_{p_n \in \mathcal{P}_n} \|p_n - f\|_\infty, \quad E_n^*(f) = \inf_{p_n \in \mathcal{P}_n} \|f - p_n\|_\infty,$$

则

$$\begin{aligned}
 E_n(f; X) &= \|f - p_n^* + p_n^* - \Pi_n f\|_\infty \\
 &\leq \|f - p_n^*\|_\infty + \|p_n^* - \Pi_n f\|_\infty \\
 &= \|f - p_n^*\|_\infty + \|\Pi_n(p_n^* - f)\|_\infty \\
 &\leq E_n^*(f) + \|\Pi_n\|_\infty E_n^*(f) \\
 &= E_n^*(f)(1 + \Lambda_n(X)).
 \end{aligned}$$

定理 1.3

$\forall X$, 都存在 $C(X) > 0$, 使得

$$\Lambda_n(X) > \frac{2}{\pi} \ln(n+1) - C(X), \quad \forall n \geq 1.$$

证明.

见 W. Gautschi, *Numerical Analysis*. □

定理 1.4

对 Chebyshev 点组 $T = \{x_j^{(n)}\}_{0 \leq j \leq n}$, 存在 $C_1 \in (0, 1)$, 使得

$$\frac{2}{\pi} \ln n + C_1 \leq \Lambda_n(T) \leq \frac{2}{\pi} \ln n + 1, \quad \forall n \geq 1.$$

证明.

见 Theodore J. Rivlin, *Chebyshev Polynomials*. □

定理 1.5

当 f 为 Lipschitz 连续或者 C^1 时, 存在 $C > 0$, 使得

$$E_n^*(f) \leq \frac{\pi}{n+1} C, \quad \forall n \geq 1.$$

证明.

见 Elliott Ward Cheney, *Introduction to Approximation Theory*. □

定义 1.2 Runge 函数 (现象)

考虑函数

$$f(x) = \frac{1}{1 + 25x^2} \in C^\infty[-1, 1]$$

以及等距节点 X , 则 Lagrange 插值不收敛.

如果考虑在 $[-0.726, 0.726]$ 上进行等距节点 Lagrange 插值, 则也收敛.

定理 1.6 Weierstrass 定理

$\forall f \in C[a, b]$, 都存在 $p_n \in \mathcal{P}_n$, 使得

$$\|p_n - f\|_{\infty} \rightarrow 0, \quad n \rightarrow +\infty.$$

定理 1.7 Chebyshev 定理

$\forall f \in C[a, b]$, 都存在点组 X , 使得

$$\|f - \Pi_n f\|_{\infty} \rightarrow 0, \quad n \rightarrow +\infty.$$

定理 1.8 Farbor 定理

$\forall X$, 都存在 $f \in C[a, b]$, 使得 $\|f - \Pi_n f\|_{\infty}$ 不收敛于 0.

第二章 Newton 多项式插值

定义 2.1 Newton 差商 (divided difference)

设 x_i 互不相同, 定义 **Newton 差商**

$$\begin{aligned} f[x_0] &= f(x_0), \\ f[x_0, x_1, \dots, x_k] &= \frac{f[x_1, x_2, \dots, x_k] - f[x_0, x_1, \dots, x_{k-1}]}{x_k - x_0}, \quad \forall k \geq 1. \end{aligned}$$

可用 $\mathcal{O}(n^2)$ 的运算量计算得到 **Newton 差商表**. 易知 $f[x_0, x_1, \dots, x_k]$ 是 $\{f_i = f(x_i)\}_{0 \leq i \leq n}$ 的线性组合, 且

$$f[x_0, x_1, \dots, x_k] = \sum_{j=0}^k \frac{f(x_j)}{\omega'_{k+1}(x_j)}, \quad \omega_{k+1}(x) := \prod_{i=0}^k (x - x_i),$$

从而有 $f[x_{\tau(0)}, x_{\tau(1)}, \dots, x_{\tau(k)}]$ 对任意置换 $\tau \in S_k$ 都不变.

如果 $f[x, x_0, x_1, \dots, x_k]$ 是关于 x 的 m 次多项式, 则

$$f[x, x_0, \dots, x_k, x_{k+1}] = \frac{f[x_0, \dots, x_{k+1}] - f[x, x_0, \dots, x_k]}{x_{k+1} - x} \in \mathcal{P}_{m-1}.$$

再注意到

$$\begin{aligned} f(x) &= f[x] \\ &= f[x_0] + (f[x] - f[x_0]) \\ &= f[x_0] + f[x, x_0](x - x_0) \\ &= f[x_0] + (f[x_0, x_1] + f[x, x_0] - f[x_0, x_1])(x - x_0) \\ &= f[x_0] + f[x_0, x_1](x - x_0) + f[x, x_0, x_1](x - x_1)(x - x_0) \\ &= \dots \\ &= \sum_{k=0}^n f[x_0, x_1, \dots, x_k] \omega_k(x) + f[x, x_0, \dots, x_n] \omega_{n+1}(x), \end{aligned}$$

并令

$$p_n(x) := \sum_{k=0}^n f[x_0, \dots, x_k] \omega_k(x) \in \mathcal{P}_n,$$

则 $p_n = \Pi_n f$. 事实上, 在上式中取 f 为 $\Pi_n f$, 则

$$(\Pi_n f)[x_0, \dots, x_k] = f[x_0, \dots, x_k],$$

并且分析多项式次数可得

$$(\Pi_n f)[x, x_0, \dots, x_n] = 0,$$

因此 $p_n = \Pi_n f$, 同时

$$f(x) = \Pi_n f(x) + f[x, x_0, \dots, x_n] \omega_{n+1}(x),$$

其中

$$\Pi_n f(x) = f[x_0] + f[x_0, x_1](x - x_0) + \dots + f[x_0, \dots, x_n](x - x_0) \cdots (x - x_{n-1})$$

因此每加一个点, 只需在最后多加一项, 运算量仅增加 $\mathcal{O}(n)$, 且基函数即为 $\omega_k(x)$. 我们实际上还得到

$$f[x, x_0, \dots, x_n] \omega_{n+1}(x) = f(x) - \Pi_n f(x) = E_n f(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x),$$

即

$$f[x, x_0, \dots, x_n] = \frac{f^{(n+1)}(\xi)}{(n+1)!}, \quad \xi \in [a, b].$$

定义 2.2 质心形式 (Barycentric form)

由于

$$l_{n,j}(x) = \frac{\omega_{n+1}(x)}{x - x_j} \cdot W_j, \quad W_j := \frac{1}{\prod_{k \neq j} (x_j - x_k)},$$

故

$$\Pi_n(x) = \omega_{n+1}(x) \cdot \sum_{j=0}^n \frac{y_j W_j}{x - x_j},$$

再结合

$$1 = \sum_{j=0}^n l_{n,j}(x) = \omega_{n+1}(x) \sum_{j=0}^n \frac{W_j}{x - x_j},$$

从而有质心形式

$$\Pi_n(x) = \frac{\sum_{j=0}^n \frac{W_j}{x - x_j} y_j}{\sum_{j=0}^n \frac{W_j}{x - x_j}}.$$

此时增加一个点, 运算量也仅增加 $\mathcal{O}(n)$. 见 Trefethen .

定义 2.3 Lagrange 分片插值 (piecewise Lagrange Interpolation)

记

$$[a, b] = \bigcup_{j=0}^{k-1} I_j, \quad I_j := [x_j, x_{j+1}], \quad h_j := |I_j|, \quad h := \max_j h_j.$$

并称 T_h 为分划 (partition, triangulation),

$$X_h^k := \{\Pi_h^k : \Pi_h^k|_{I_j} \in \mathcal{P}_k, \forall 0 \leq j \leq k-1\}.$$

$k=0$ 得到分片常数, $k=1$ 得到分片线性. 显然有 $\Pi_h^k \in C^0 \setminus C^1$.

对于分片线性的情形,

$$\Pi_h^1(x) = \sum_{j=0}^n y_j l_j(x), \quad l_j \in X_h^1, \quad l_j(x_k) = \delta_{jk},$$

$l_j(x)$ 被称为 **Tent function**, 显然有 $\text{supp}(l_j) \subseteq I_{j-1} \cup I_j$.

再定义

$$S_{ij} = (l'_i, l'_j), \quad m_{ij} = (l_i, l_j), \quad (f, g) := \int_a^b f(x)g(x) dx,$$

则 $S = (S_{ij}), m = (m_{ij})$ 为三对角矩阵.

再考虑收敛性, 有

$$\|f(x) - \Pi_h^k(x)\|_\infty \leq \frac{M_{k+1}}{(k+1)!} h^{k+1}, \quad \Pi_h^k \in X_h^k.$$

第三章 样条插值 (spline)

定义 3.1 二点 Hermite 插值

给定 $\{(x_j, y_j^{(k)})\}_{k,j=0,1}$, 构造 $H(x) \in \mathcal{P}_3$, 有基函数表示

$$H(x) = \sum_{j,k=0}^1 y_j^{(k)} h_j^{(k)}(x), \quad (h_j^{(k)})^{(l)}(x_m) = \delta_{kl} \delta_{jm}, \quad k, l, j, m = 0, 1,$$

其中 $h_j^{(k)}(x) \in \mathcal{P}_3$ 是基函数, 故

$$H^{(l)}(x_m) = \sum_{j,k=0}^1 y_j^{(k)} \delta_{kl} \delta_{jm} = y_m^{(l)}.$$

若记 $y_j^{(k)} := f^{(k)}(x_j)$, $f \in C^4[x_0, x_1]$, 则有误差估计:

$$H(x) - f(x) = \frac{f^{(4)}(\xi)}{4!} \Omega_4(x), \quad \Omega_4(x) := (x - x_0)^2 (x - x_1)^2.$$

定义 3.2 多点 Hermite 插值

给定 $\{(x_j, y_j^{(k)})\}_{\substack{0 \leq j \leq n \\ 0 \leq k \leq n_j}}$, 并记 $N := \sum_{j=0}^n (n_j + 1)$, 构造 $H(x) \in \mathcal{P}_N$.

有误差估计

$$H(x) - f(x) = \frac{f^{(N)}(\xi)}{N!} \Omega_N(x), \quad \Omega_N(x) := \prod_{i=0}^n (x - x_i)^{n_i}.$$

定义 3.3 分片 Hermite 插值

给定 $\{(x_j, y_j^{(k)})\}_{\substack{0 \leq j \leq n \\ 0 \leq k \leq 1}}$, 构造 $\Pi_h(x) \in X_h^3$, 则 $\Pi_h \in C^1$ (分片两点 Hermite).

有误差估计

$$\|\Pi_h - f\|_\infty \leq \frac{M_4}{4!} \max_{\substack{x \in [x_j, x_{j+1}] \\ 0 \leq j \leq n-1}} (x - x_j)^2 (x - x_{j+1})^2 \leq \frac{M_4}{4!} \left(\frac{h}{2}\right)^2, \quad M_4 := \max_{\xi \in [a, b]} |f^{(4)}(\xi)|.$$

定义 3.4 三次样条插值 (Cubic spline)

给定 $\{(x_j, y_j)\}_{0 \leq j \leq n}$, 构造 $S(x) \in X_h^3$ 满足:

$$S(x_j) = y_j, \quad 0 \leq j \leq n, \quad S(x) \in C^2[a, b],$$

并记构成的线性空间为 $\mathcal{S}_3$.

考察自由度:

$$4n - 2(n-1) - 2 - 2(n-1) = 2,$$

其中约束分别为内点插值条件, 边界插值条件, 内点 C^2 . 因此还需补充条件:

- (1) $S'(x_0) = d_0, S'(x_n) = d_n$ (完全样条).
- (2) $S''(x_0) = S''(x_n) = 0$ (自然样条).
- (3) 假定 $y_0 = y_n, S^{(k)}(x_0-) = S^{(k)}(x_n+), k = 1, 2$ (周期样条).

定理 3.1

$S(x) \in \mathcal{S}_3$ 存在且唯一.

证明.

由于 $S \in X_h^3 \cap C^2$, 故 S'' 为分片线性且 C^0 , 从而令

$$S''(x) = M_{j-1} \frac{x_j - x}{h_j} + M_j \frac{x - x_{j-1}}{h_j}, \quad x \in [x_{j-1}, x_j], \quad h_j := x_j - x_{j-1},$$

因此

$$S(x) = M_{j-1} \frac{(x_j - x)^3}{6h_j} + M_j \frac{(x - x_{j-1})^3}{6h_j} + C_{j-1}(x - x_{j-1}) + \tilde{C}_{j-1},$$

取 $x = x_{j-1}$ 可得

$$y_{j-1} - M_{j-1} \frac{h_j^2}{6} = \tilde{C}_{j-1},$$

再取 $x = x_j$ 可得

$$y_j - M_j \frac{h_j^2}{6} = C_{j-1}h_j + \tilde{C}_{j-1},$$

故

$$C_{j-1}(x - x_{j-1}) + \tilde{C}_{j-1} = (y_{j-1} - \frac{M_{j-1}}{6}h_j^2) \frac{x_j - x}{h_j} + (y_j - \frac{M_j}{6}h_j^2) \frac{x - x_{j-1}}{h_j}.$$

再结合 $S \in C^1$ 知 $S'(x_j-) = S'(x_j+)$, 从而

$$S'(x) = -M_{j-1} \frac{(x_j - x)^2}{2h_j} + M_j \frac{(x - x_{j-1})^2}{2h_j} + \frac{y_j - y_{j-1}}{h_j} - \frac{M_j - M_{j-1}}{6}h_j,$$

因此

$$\frac{h_j}{6}M_{j-1} + \frac{h_j + h_{j+1}}{3}M_j + \frac{h_{j+1}}{6}M_{j+1} = \frac{y_{j+1} - y_j}{h_{j+1}} - \frac{y_j - y_{j-1}}{h_j}.$$

两边除以 $\frac{h_j + h_{j+1}}{6}$, 并记

$$\lambda_j := \frac{h_{j+1}}{h_j + h_{j+1}}, \quad \mu_j := 1 - \lambda_j,$$

可得

$$\mu_j M_{j-1} + 2M_j + \lambda_j M_{j+1} = b_j, \quad b_j \approx f''(x_j).$$

另外的 3 种补充条件:

(1)

$$\begin{cases} 2M_0 + M_1 = \frac{6}{h_1} \left(\frac{y_1 - y_0}{h_1} - d_0 \right), \\ M_{n-1} + 2M_n = \frac{6}{h_n} \left(d_n - \frac{y_n - y_{n-1}}{h_n} \right). \end{cases}$$

(2)

$$M_0 = M_n = 0.$$

(3)

$$\begin{cases} M_0 = M_n, \\ -\frac{h_1}{3}M_0 - \frac{h_1}{6}M_1 + \frac{y_1 - y_0}{h_1} = \frac{h_n}{6}M_{n-1} + \frac{h_n}{3}M_n + \frac{y_n - y_{n-1}}{h_n}. \end{cases}$$

综上得到线性方程组 $\mathbf{A}\mathbf{M} = \mathbf{b}$:

(1)

$$\mathbf{M} = \begin{pmatrix} M_0 \\ M_1 \\ \vdots \\ M_n \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} 2 & 1 & & & \\ \mu_1 & 2 & \lambda_1 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-1} & 2 & \lambda_{n-1} \\ & & & 1 & 2 \end{pmatrix}.$$

(2)

$$\mathbf{M} = \begin{pmatrix} M_1 \\ M_2 \\ \vdots \\ M_{n-1} \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} 2 & \lambda_1 & & & \\ \mu_2 & 2 & \lambda_2 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-2} & 2 & \lambda_{n-2} \\ & & & \mu_{n-1} & 2 \end{pmatrix}.$$

(3)

$$\mathbf{M} = \begin{pmatrix} M_0 \\ M_1 \\ \vdots \\ M_{n-1} \end{pmatrix}, \quad \mathbf{A} = \begin{pmatrix} 2 & \lambda_0 & & \mu_0 \\ \mu_1 & 2 & \lambda_1 & \\ & \ddots & \ddots & \ddots \\ & & \mu_{n-2} & 2 & \lambda_{n-2} \\ \lambda_{n-1} & & & \mu_{n-1} & 2 \end{pmatrix}.$$

注意到上述三种情形都是严格对角占优矩阵, 故 $\det(\mathbf{A}) > 0$, 且利用求解三对角矩阵的追赶法可得求解计算复杂度为 $\mathcal{O}(n)$, 并且还可以得到 $\kappa(\mathbf{A}) = \mathcal{O}(1)$, 因此求解也是稳定的. $\square$

再考察样条基函数 $\{S_j\}_{0 \leq j \leq n}$, 使得 $S_j(x_k) = \delta_{jk}$, 但由于 S_j 是全局函数, 故 $(S_j, S_k)_{0 \leq j, k \leq n}$ 不为稀疏矩阵.

收敛性

设

$$f \in C^4[a, b], \quad h := \max_j h_j, \quad \beta = \frac{h}{\min_j h_j},$$

则

$$\|f^{(r)} - S^{(r)}\|_\infty \leq C_r(\beta) h^{4-r} \|f^{(4)}\|_\infty, \quad 0 \leq r \leq 3,$$

见 J. Appr. Theory 16(1976), 105.

最小能量性质

设 $S \in \mathcal{S}_3$, 则 $\forall g \in C^2[a, b]$ 满足插值条件, 都有

$$\int_a^b |S''(x)|^2 dx \leq \int_a^b |g''(x)|^2 dx, \quad a := x_0, \quad b := x_1.$$

事实上,

$$\begin{aligned} & \int_a^b |S'' - g''|^2 dx \\ &= \int_a^b S''^2 + g''^2 - 2S''g'' dx \\ &= \int_a^b -S''^2 + g''^2 + 2S''^2 - 2S''g'' dx, \end{aligned}$$

而

$$\begin{aligned} & \int_a^b 2S''^2 - 2S''g'' dx \\ &= 2 \int_a^b S''(S'' - g'') dx \end{aligned}$$

$$\begin{aligned}
&= 2 \sum_{j=0}^{n-1} \int_{x_j}^{x_{j+1}} S''(S'' - g'') \, dx \\
&= 2 \sum_{j=0}^{n-1} \int_{x_j}^{x_{j+1}} S'' \, d(S' - g') \\
&= 2 \sum_{j=0}^{n-1} \left(S''(S' - g') \Big|_{I_j} - \int_{I_j} S'''(S' - g') \, dx \right) \\
&= -2 \sum_{j=0}^{n-1} S''' \Big|_{I_j} \int_{I_j} d(S - g) = 0,
\end{aligned}$$

故

$$\int_a^b -S''^2 + g''^2 \, dx = \int_a^b |S'' - g''|^2 \, dx \geq 0.$$

定义杆的弯曲能为

$$E_b := \int_0^L \frac{1}{2} \kappa^2 \, ds, \quad (\text{曲率}) \, \kappa := \left| \frac{d\hat{\tau}}{ds} \right|, \quad \hat{\tau} := \frac{\tau}{|\tau|}, \quad \tau := (1, f'(x)), \quad ds := \sqrt{1 + f'^2} \, dx,$$

则计算可得

$$E_b = \frac{1}{2} \int_a^b \frac{f''^2}{(1 + f'^2)^3} \, dx,$$

如果 $|f'| \ll 1$, 则

$$E_b \approx \frac{1}{2} \int_a^b |f''|^2 \, dx,$$

因此三次样条为杆的弯曲能的最小值点.

定义 3.5 B 样条 (B-spline, B: basic, basis)

定义关于 y 的函数为

$$\begin{aligned}
M_k(y; x) &:= k((y - x)_+)^{k-1} \in C^{k-2}, \quad x_+ := \max\{x, 0\} = x \vee 0, \quad k \geq 1, \\
M_k(x) &:= M_k[x_0, x_1, \dots, x_k; x],
\end{aligned}$$

再定义规范化 k 次 B 样条基函数为

$$B_{i,k}(x) = \frac{x_{i+k+1} - x_i}{k+1} M_{k+1}[x_i, \dots, x_{i+k+1}; x], \quad k \geq 0.$$

由于

$$M_k(x) = \sum_{j=0}^k \frac{k(x_j - x)_+^{k-1}}{\omega'_{k+1}(x_j)}, \quad \omega_{k+1}(y) := \prod_{j=0}^k (y - x_j),$$

且 $M_k(y; x)$ 的分片 $\in \mathcal{P}_{k-1}$, 故易证 $M_k(x) = 0$ 当且仅当 $x \geq x_k$ (由截断) 或者 $x \leq x_0$ (由 Newton 差商与 $M_k \in \mathcal{P}_{k-1}$), 同时 $\text{supp } M_k \subseteq [x_0, x_k]$.

同理有 $\text{supp } B_{i,k} = [x_i, x_{i+k+1}]$, $B_{i,k} \in C^{k-1}$ 且分片 $\in \mathcal{P}_k$, 同时还线性无关.

定理 3.2

$M_k^{(m)}(x)$, $m \leq k-2$ 在 (x_0, x_k) 内恰有 m 个不同零点 (单重), 特别地, $M_k(x) > 0, \forall x \in (x_0, x_k)$.

定理 3.3 Schoenberg

当 $x_0, x_1, \dots, x_k$ 等距, 步长为 1 时, 有

$$M_k(x) = \frac{1}{(k-1)!} \delta^k x_+^{k-1}, \quad k \geq 1, \quad \delta f(x) := f(x + \frac{1}{2}) - f(x - \frac{1}{2}), \quad \delta^k f(x) = \delta(\delta^{k-1} f(x)).$$

定理 3.4 Cox-de Boor 递推式

$B_{i,k}(x)$ 满足如下递推式:

$$B_{i,0}(x) = \begin{cases} 1, & x \in [x_i, x_{i+1}], \\ 0, & \text{其他}, \end{cases}$$

$$B_{i,k}(x) = \frac{x - x_i}{x_{i+k} - x_i} B_{i,k-1}(x) + \frac{x_{i+k+1} - x}{x_{i+k+1} - x_{i+1}} B_{i+1,k-1}(x), \quad k \geq 1.$$

定义 3.6 k 次样条

由于

$$\dim \mathcal{S}_k = n \cdot (k+1) - k(n-1) = n+k,$$

故给定 $n+1$ 个插值后自由度为

$$n+k - (n+1) = k-1.$$

引入 $2k$ 个虚拟点:

$$x_{-k} \leq x_{-k+1} \leq \dots \leq x_0 = a, \quad b = x_n \leq x_{n+1} \leq \dots \leq x_{n+k},$$

则 $n+k$ 个 k 次样条基函数为 $B_{i,k}, i \in S_k := \{-k, \dots, n-1\}$. 典型取法为

$$x_{-k} = \dots = x_0, \quad x_n = \dots = x_{n+k}.$$

而 $B_{i,k}$ 是紧支的基函数, 故求解基函数的系数所对应的系数矩阵为稀疏矩阵.

第四章 最小二乘拟合 (Least Squares Fitting)

定义 4.1 拟合 (Fitting)

给定 $\{(x_i, y_i)\}_{1 \leq i \leq n}$, 求解

$$\min_{\theta} \sum_{i=1}^n d(f(x_i; \theta), y_i).$$

$d(\cdot, \cdot)$ 的取法:

$$d(y_1, y_2) = \|y_1 - y_2\|_2^2 \quad (\ell^2 \text{ 距离}) \quad \text{Least Squares Fitting,}$$

$$d(y_1, y_2) = \|y_1 - y_2\|_{\infty} \quad (\ell^{\infty} \text{ 距离}) \quad \text{Uniform,}$$

$$d(y_1, y_2) = \|y_1 - y_2\|_p^p \quad (\ell^p \text{ 距离}).$$

对于拟合

$$\min_{\theta} L(\theta) = \sum_{i=1}^n |f(x_i; \theta) - y_i|^2,$$

(1) 若 $x, y \in \mathbb{R}$, 取

$$f(x; \theta) = kx + b, \quad \theta = (k, b).$$

(2) 若 $\mathbf{x} \in \mathbb{R}^d, y \in \mathbb{R}$, 取

$$f(\mathbf{x}; \theta) = \sum_{i=1}^d \beta_i x_i + \beta_0, \quad \theta = (\beta_0, \dots, \beta_d).$$

(3) 若 $\mathbf{x} \in \mathbb{R}^d$, 取 $\theta = \{\mathbf{e}_{\alpha}\}_{1 \leq \alpha \leq k}$, 求解

$$\min_{\{\mathbf{e}_{\alpha}\}_{\alpha}} \left\| \mathbf{x}_i - \sum_{\alpha=1}^k (\mathbf{x}_i \cdot \mathbf{e}_{\alpha}) \mathbf{e}_{\alpha} \right\|_2^2 \quad (\text{主成分分析 Principal Component Analysis}).$$

还有 $x \cdot \ln y$ 和 $\ln x \cdot \ln y$ 等拟合方式.

考虑统计模型

$$\mathbf{y} = \mathbf{f}(\mathbf{x}; \theta) + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 \mathbf{I}) \quad (\text{Noise}),$$

及其似然函数 (Likelihood)

$$\mathcal{L}(\mathcal{D} \mid \theta) = \prod_{i=1}^n \frac{1}{Z} e^{-\frac{1}{2\sigma^2} \|\mathbf{y}_i - \mathbf{f}(\mathbf{x}_i; \theta)\|^2},$$

对应的极大似然估计 (MLE)

$$\max_{\theta} \log \mathcal{L}(\mathcal{D} \mid \theta) \iff \min_{\theta} \sum_{i=1}^n \frac{1}{2\sigma^2} \|\mathbf{y}_i - \mathbf{f}(\mathbf{x}_i; \theta)\|^2,$$

对于一般情形, 协方差矩阵不确定, 则为

$$\min_{\theta} \sum_{i=1}^n (\mathbf{y}_i - \mathbf{f}(\mathbf{x}_i; \theta))^T \Sigma^{-1} (\mathbf{y}_i - \mathbf{f}(\mathbf{x}_i; \theta)).$$

最小二乘法 (LSM)

考虑法方程, 定义内积

$$(f, g)_{\omega} := \int_a^b \omega(x) f(x) g(x) dx,$$

其中权函数 $\omega(x)$ 须满足:

$$\omega(x) \geq 0, \quad (f, f)_{\omega} = 0 \implies f \equiv 0.$$

再定义范数 $\|f\|_{\omega} = \sqrt{(f, f)_{\omega}}$. 我们要求解

$$\min_{\varphi \in S} \|f - \varphi\|_{\omega}^2, \quad \dim S = m.$$

先给出基底 $\{\varphi_i\}_{1 \leq i \leq n}$, 以及基底表示

$$\varphi(x) = \sum_{i=1}^m \alpha_i \varphi_i(x),$$

则

$$\begin{aligned} \mathcal{L} &= \left\| f - \sum_{i=1}^m \alpha_i \varphi_i \right\|_{\omega}^2 \\ &= \left(f - \sum_i \alpha_i \varphi_i, f - \sum_j \alpha_j \varphi_j \right)_{\omega} \\ &= (f, f) - \left(\sum_i \alpha_i \varphi_i, f \right) - \left(f, \sum_j \alpha_j \varphi_j \right) + \left(\sum_i \alpha_i \varphi_i, \sum_j \alpha_j \varphi_j \right) \\ &= \|f\|_{\omega}^2 - 2 \sum_i \alpha_i (\varphi_i, f)_{\omega} + \sum_{i,j} \alpha_i \alpha_j (\varphi_i, \varphi_j)_{\omega} \end{aligned}$$

若再记

$$\boldsymbol{\alpha} := \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix}, \quad \boldsymbol{F} := \begin{pmatrix} (\varphi_1, f)_\omega \\ \vdots \\ (\varphi_m, f)_\omega \end{pmatrix}, \quad \boldsymbol{G} := (\varphi_i, \varphi_j)_\omega$$

则上式即为

$$\|f\|_\omega^2 - 2\boldsymbol{\alpha}^\mathrm{T} \boldsymbol{F} + \boldsymbol{\alpha}^\mathrm{T} \boldsymbol{G} \boldsymbol{\alpha},$$

求导得

$$\frac{\partial \mathcal{L}}{\partial \alpha_i} = -2F_i + 2 \sum_j g_{i,j} \alpha_j = 0,$$

故 $\boldsymbol{G}\boldsymbol{\alpha} = \boldsymbol{F}$, 其中度量矩阵 (Gram 矩阵) $\boldsymbol{G}$ 对称正定, 事实上,

$$\boldsymbol{\alpha}^\mathrm{T} \boldsymbol{G} \boldsymbol{\alpha} = \left\| \sum_i \alpha_i \varphi_i \right\|_\omega^2 \geq 0,$$

且

$$\boldsymbol{\alpha}^\mathrm{T} \boldsymbol{G} \boldsymbol{\alpha} = 0 \iff \sum_i \alpha_i \varphi_i = 0 \iff \alpha_i = 0, \forall i.$$

因此 $\boldsymbol{\alpha}^* = \boldsymbol{G}^{-1} \boldsymbol{F}$ 存在且唯一.

解的性质

(1) 解为投影: 令

$$\varphi^* = \sum_i \alpha_i^* \varphi_i,$$

则

$$(f - \varphi^*, \varphi)_\omega = 0, \quad \forall \varphi \in S.$$

事实上, 只需

$$(f - \varphi^*, \varphi_i)_\omega = 0, \quad \forall i,$$

而

$$(f - \varphi^*, \varphi_i)_\omega = (f, \varphi_i) - \sum_j \alpha_j^* (\varphi_j, \varphi_i) = 0.$$

(2) 最优性:

$$\|f - \varphi\|_{\omega}^2 \geq \|f - \varphi^*\|_{\omega}^2, \quad \forall \varphi \in S.$$

事实上, 有

$$\|f - \varphi\|_{\omega}^2 = \|f - \varphi^*\|_{\omega}^2 + \|\varphi^* - \varphi\|_{\omega}^2.$$

如果取

$$\omega(x) = 1, \quad [a, b] = [0, 1], \quad S = \mathcal{P}_{n-1}, \quad \varphi_i = x^i,$$

则 G 即为 **Hilbert 矩阵**: $g_{ij} = 1/(i+j-1), \forall 1 \leq i, j \leq n$, 对应的 $\kappa_2(G) \gg 1$.

定义 4.2 正交多项式 (orthogonal polynomial)

对于基底 $\{\varphi_k\}_{1 \leq k \leq n}$ 和内积 $(\cdot, \cdot)$, 定义 $\|\varphi\| = \sqrt{(\varphi, \varphi)}$. 进行如下 **Gram-Schmidt 正交化**:

- (1) $\psi_1 = \varphi_1, k = 1$.
- (2) $u_k = \psi_k / \|\psi_k\|$.
- (3) $\psi_{k+1} = \varphi_{k+1} - \sum_{j=1}^k (\varphi_{k+1}, u_j) u_j$.
- (4) 如果 $k+1 < n$, 则返回 (1).

对于 $\varphi_k(x) = x^k, 0 \leq k \leq n$, 有 $\varphi_k, \psi_k \in \mathcal{P}_k$ 且 ψ_{k+1} 首一, 故

$$\psi_{k+1} = x\psi_k + \sum_{j=0}^k a_j \psi_j,$$

两边与 ψ_m 内积, 则 $\forall 0 \leq m \leq k-2$, 都有 $(x\psi_k, \psi_m) = (\psi_k, x\psi_m) = 0$, 故 $a_m = 0$. 从而得到三项递归式

$$\psi_{k+1} = (x + \alpha_{k+1})\psi_k + \beta_{k+1}\psi_{k-1},$$

其中系数 $\alpha_{k+1}, \beta_{k+1}$ 由如下计算可得. 两边与 ψ_{k-1} 内积得

$$(x\psi_k, \psi_{k-1}) + \beta_{k+1}\|\psi_{k-1}\|^2 = 0,$$

即

$$\beta_{k+1} = -\frac{(x\psi_k, \psi_{k-1})}{(\psi_{k-1}, \psi_{k-1})} = -\frac{(\psi_k, x\psi_{k-1})}{(\psi_{k-1}, \psi_{k-1})} = -\frac{(\psi_k, \psi_k)}{(\psi_{k-1}, \psi_{k-1})}.$$

两边再与 ψ_k 内积同理可得

$$\alpha_{k+1} = -\frac{(x\psi_k, \psi_k)}{(\psi_k, \psi_k)}.$$

Legendre 多项式: 取

$$\omega(x) = 1, \quad [a, b] = [-1, 1],$$

Rodergue(1814) 给出表达式

$$P_n(x) = \frac{1}{2^n n!} \frac{d^n}{dx^n} (x^2 - 1)^n.$$

Chebyshev 多项式: 取

$$\omega(x) = (1 - x^2)^{-1/2}, \quad [a, b] = [-1, 1],$$

有表达式

$$P_n(x) = \cos(n \arccos x), \quad |x| \leq 1.$$

Laguerre 多项式: 取

$$\omega(x) = e^{-x}, \quad [a, b] = [0, +\infty),$$

有表达式

$$P_n(x) = e^x \frac{d^n}{dx^n} (x^n e^{-x}).$$

Hermite 多项式: 取

$$\omega(x) = e^{-x^2}, \quad (a, b) = \mathbb{R},$$

有表达式

$$P_n(x) = (-1)^n e^{x^2} \frac{d^n}{dx^n} (e^{-x^2}).$$

定义 4.3 线性最小二乘

给定 $\{(x_j, y_j)\}_{1 \leq j \leq m}$, 进行拟合

$$f(x; \theta) = \sum_{k=1}^n a_k \varphi_k(x),$$

需要对于 $\{a_k\}$ 最小化

$$\sum_{j=1}^m \left| \sum_{k=1}^n a_k \varphi_k(x_j) - y_j \right|^2 := \|\mathbf{A}\mathbf{x} - \mathbf{b}\|^2,$$

其中

$$\mathbf{x} = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}, \quad \mathbf{A} \in \mathbb{R}^{m \times n}.$$

从而只需求解

$$\min_{\mathbf{x}} \frac{1}{2} (\mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} - 2 \mathbf{b}^T \mathbf{A} \mathbf{x} + \mathbf{b}^T \mathbf{b}) := \min_{\mathbf{x}} L(\mathbf{x}),$$

由 $\nabla_{\mathbf{x}} L = 0$ 可得 $\mathbf{A}^T \mathbf{A} \mathbf{x} = \mathbf{A}^T \mathbf{b}$.

(1) 若 $m \gg n$, $r(\mathbf{A}) = n$, 则 $r(\mathbf{A}^T \mathbf{A}) = n$ (超定 Overdetermined), 则

$$\mathbf{x} = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b} := \mathbf{A}^+ \mathbf{b}, \quad \mathbf{A}^+ \text{ 广义逆.}$$

(2) 若 $m < n$, $m \sim \mathcal{O}(n)$ (欠定 Underdetermined), 有解当且仅当 $r([\mathbf{A}^T \mathbf{A}, \mathbf{A}^T \mathbf{b}]) = r(\mathbf{A}^T \mathbf{A})$, 此时解存在但不唯一. 因此还需正则化 (Regularization), 引入罚函数:

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{A} \mathbf{x} - \mathbf{b}\|^2 + \lambda \|\mathbf{x}\|^2 := \min_{\mathbf{x}} L(\mathbf{x}), \quad \lambda > 0,$$

由 $\nabla_{\mathbf{x}} L = 0$ 可得

$$(\lambda \mathbf{I} + \mathbf{A}^T \mathbf{A}) \mathbf{x} = \mathbf{A}^T \mathbf{A} \mathbf{x} + \lambda \mathbf{x} = \mathbf{A}^T \mathbf{b},$$

因此得到正则化最小二乘解

$$\mathbf{x} = (\lambda \mathbf{I} + \mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}.$$

事实上, 从统计学来看罚函数是最大似然估计中的参数的先验分布, 此处即为正态分布.

对于 Laplace 先验: $e^{-\lambda \|\mathbf{x}\|_1}$, 定义了压缩感知问题 (Lasso):

$$\min_{\mathbf{x}} \frac{1}{2} \|\mathbf{A} \mathbf{x} - \mathbf{b}\|_2^2 + \lambda \|\mathbf{x}\|_1.$$

第五章 其他论题

考虑**最佳一致逼近** (BUAP), Uniform Approximation, $L^\infty[a, b]$.

定理 5.1 Weierstrass 定理

$\forall f \in C[a, b]$, 存在 $\{p_n\}_{n \geq 0} \subseteq \mathcal{P}_n$, 使得 $\lim_{n \rightarrow +\infty} \|p_n - f\|_\infty = 0$.

证明.

不妨设 $f \in C[0, 1]$, 定义 **Bernstein 多项式**:

$$B_n^f(x) := \sum_{k=0}^n f\left(\frac{k}{n}\right) \binom{n}{k} x^k (1-x)^{n-k} \in \mathcal{P}_n,$$

那么如果定义随机变量 $X_n \sim B(n, x)$, 则 $B_n^f(x) = \mathbb{E}f(X_n)$. 由**大数定律**知 $X_n \rightarrow x$.

(1) 若 $|X_n - x| \leq \delta$, 利用 f 的一致连续性.

(2) 若 $|X_n - x| > \delta$, 利用 **Chebyshev 不等式**. □

定义 5.1 偏差

定义**偏差**:

$$E_n = E_n(f) := \inf_{p \in \mathcal{P}_n} \Delta(p), \quad \Delta(p) := \|p - f\|_\infty.$$

显然有 E_n 单调减小且趋于 0 .

下面考虑是否存在唯一的 p_n^* , 使得 $\Delta(p_n^*) = E_n$.

定理 5.2 Borel 存在定理

p_n^* 存在.

证明.

由定义, 存在 $\{p_k\} \subseteq \mathcal{P}_n$, 使得 $\|p_k - f\|_\infty \rightarrow E_n$, 故 $\|p_k\|_\infty \leq C$. 设

$$p_k(x) = \sum_{j=0}^n a_j^{(k)} x^j, \quad \vec{a}^{(k)} := (a_0^{(k)}, \dots, a_n^{(k)}),$$

再定义 $f(\vec{a}) = \|p - f\|_\infty$, 显然 f 关于 $\vec{a}$ 连续. 再注意到 $\|p_k\|_\infty$ 与 $\|a^{(k)}\|_\infty$ 等价 (范数等价即为相互可被

常数倍控制), 故 $\|a^{(k)}\|_\infty$ 也有界, 因此存在子列收敛于 a^* , 此时取

$$p_k^*(x) := \sum_{j=0}^n a_j^* x^j,$$

则

$$\|p_k^* - f\|_\infty = \lim_{k \rightarrow +\infty} \|p_k - f\|_\infty = E_n.$$

□

定理 5.3 Chebyshev 定理

$\mathcal{P}_n$ 中 BUAP 存在且唯一, 且 $p(x)$ 为 BUAP 当且仅当 $\varepsilon(x) = p(x) - f(x)$ 在 $[a, b]$ 上点数不少于 $n+2$ 的点列 $x_1 < \cdots < x_N (N \geq n+2)$ 上正负交错的, 取到 $\Delta(p)$.

定义 5.2 最小零偏差多项式

要求 $\min_{p \in \mathcal{P}_n} \|p\|_\infty$, 其中 p 的 n 次项系数为 1. 事实上就是要求 $\min_{p \in \mathcal{P}_{n-1}} \|x^n - p(x)\|_\infty$. 再不妨设 $[a, b] = [-1, 1]$, 则可以证明最小零偏差多项式恰为 $\cos(n \arccos x)/2^{n-1}$.

BUAP 还可以理解为

$$\min_{p \in \mathcal{P}_n} \max_{x \in [a, b]} |p(x) - f(x)|.$$

对应特征值问题 $\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$, 特征值满足:

$$\lambda_1 > \lambda_2 \geq \cdots \geq \lambda_n \subseteq [\alpha, \beta],$$

用**幂法**求解时, 将 $\mathbf{A}$ 替代为 $p_k(\mathbf{A})$, 使得

$$\min_{p_k \in \mathcal{P}_k, p_k(\lambda_1)=1} \max_{\lambda \in [\alpha, \beta]} p_k(\lambda),$$

这即为最小零偏差多项式, 这称为 **Chebyshev 加速**, 见 Y. Saad. Numer. Methods for Large Eigenvalues Prob.

第六章 数值积分基础 (Numerical Integration/Quadrature)

我们在求解低/高维积分、PDE、IE 等场景中都需要进行数值积分.

定义 6.1 Lagrange 插值积分

记

$$I(f) := \int_a^b f(x) dx.$$

我们有中点公式 (Midpoint)

$$f \approx l_0(x) \in \mathcal{P}_0, \quad I(f) \approx I(l_0) = I_0(f) = f\left(\frac{a+b}{2}\right)(b-a);$$

以及梯形公式 (Trapezoidal rule)

$$f \approx l_1(x) \in \mathcal{P}_1, \quad I(f) \approx I(l_1) = I_1(f) = \frac{f(a) + f(b)}{2}(b-a);$$

一般情形有

$$\begin{aligned} l_n(x) &= \sum_{k=0}^n y_k l_{n,k}(x), \quad y_k = f(x_k), \quad x_k = a + kh, \quad h = \frac{b-a}{n}, \\ l_{n,k}(x) &= \frac{\prod_{j \neq k} (x - x_j)}{\prod_{j \neq k} (x_k - x_j)} = \frac{\omega_{n+1}(x)}{(x - x_k)\omega'_{n+1}(x_k)}, \\ I(f) &\approx I(l_n) = I_n(f), \end{aligned}$$

如果作变量替换

$$x \in [a, b] \mapsto t = \frac{x-a}{h} \in [0, n], \quad x_j \mapsto j,$$

则

$$l_{n,k}(x) = \frac{\prod_{j \neq k} (t - j)}{\prod_{j \neq k} (k - j)} := \tilde{l}_{n,k}(t),$$

从而

$$I_n(f) = \int_a^b l_n(x) dx = \int_0^n \sum_{k=0}^n f(x_k) \tilde{l}_{n,k}(t) h dt = \sum_{k=0}^n f(x_k) C_k^{(n)} (b-a),$$

其中

$$C_k^{(n)} = \frac{1}{n} \int_0^n \tilde{l}_{n,k}(t) dt = \frac{(-1)^{n-k}}{nk!(n-k)!} \int_0^n \prod_{j \neq k} (t-j) dt,$$

此时 $I_n(f)$ 又被称为 **Newton-Cotes 求积公式**, $C_k^{(n)}$ 也称为 **Newton-Cotes 求积系数**, 并且易知

$$\sum_{k=0}^n C_k^{(n)} = 1,$$

当 $n=2$ 时又被称为 **Simpson 公式**; 当 $n=4$ 时又被称为 **Cotes 公式**.

注意到当 $n \geq 8$ 时, $C_k^{(n)}$ 有正有负, 且

$$\sum_{k=0}^n |C_k^{(n)}| \rightarrow +\infty \quad (n \rightarrow +\infty),$$

数值不稳定. 事实上, 如果 $\tilde{f}(x_k) = f(x_k) + \varepsilon_k, \varepsilon_k \sim N(0, \varepsilon)$, 则

$$I_n(f) \sim \sum_k C_k^{(n)} f(x_k), \quad \tilde{I}_n(f) \sim \sum_k C_k^{(n)} \tilde{f}(x_k),$$

故

$$|I_n(f) - \tilde{I}_n(f)| \leq \sum_k |C_k^{(n)}| \max_k |\varepsilon_k|,$$

其中 $\max_k |\varepsilon_k| \sim \mathcal{O}(\varepsilon) \ll 1$. 如果 $C_k^{(n)} \geq 0$, 则

$$\sum_k |C_k^{(n)}| = \sum_k C_k^{(n)} = 1;$$

如果 $C_k^{(n)} < 0$, 则 $\sum_k |C_k^{(n)}|$ 可能很大.

定义 6.2 复合数值积分 (Composite Integration)

利用分片多项式插值:

复合中点公式:

$$M_n = \sum_{k=1}^n f(x_{k-1/2})h, \quad x_{k-1/2} := \left(k - \frac{1}{2}\right)h + a;$$

复合梯形公式:

$$T_n = \sum_{k=0}^{n-1} \frac{f(x_k) + f(x_{k+1})}{2} h;$$

复合 Simpson 公式:

$$S_n = \sum_{k=0}^{n-1} \frac{f(x_k) + 4f(x_{k+1/2}) + f(x_{k+1})}{6} h.$$

注意到

$$\begin{aligned} T_{2n} &= \sum_{k=0}^{n-1} \left(\frac{f(x_k) + f(x_{k+1/2})}{2} \cdot \frac{h}{2} + \frac{f(x_{k+1/2}) + f(x_{k+1})}{2} \cdot \frac{h}{2} \right) \\ &= \frac{h}{4} \sum_{k=0}^{n-1} (f(x_k) + 2f(x_{k+1/2}) + f(x_{k+1})) \\ &= \frac{1}{2} M_n + \frac{1}{2} T_n, \end{aligned}$$

故 $M_n = 2T_{2n} - T_n$. 类似地, 有

$$S_n = \frac{1}{3} T_n + \frac{2}{3} M_n = \frac{1}{3} T_n + \frac{2}{3} (2T_{2n} - T_n) = \frac{1}{3} (4T_{2n} - T_n),$$

以及

$$C_n = \frac{4^2 S_{2n} - S_n}{4^2 - 1}.$$

定义 6.3 Richardson 外推

设 $h \ll 1$,

$$f(h) = f(0) + c_1 h^{p_1} + c_2 h^{p_2} + \cdots, \quad \mathbb{N} \ni p_1 < p_2 < \cdots,$$

故

$$f(h/2) = f(0) + c_1 (h/2)^{p_1} + c_2 (h/2)^{p_2} + \cdots,$$

从而

$$\frac{1}{2^{p_1}} f(h) - f(h/2) = \left(\frac{1}{2^{p_1}} - 1 \right) f(0) + \tilde{c}_2 h^{p_2} + \cdots,$$

因此

$$\tilde{f}(h) := \frac{\frac{1}{2^{p_1}} f(h) - f(h/2)}{\frac{1}{2^{p_1}} - 1} = \frac{2^{p_1} f(h/2) - f(h)}{2^{p_1} - 1},$$

则

$$\tilde{f}(h) = f(0) + \tilde{c}_2 h^{p_2} + \cdots.$$

由 Richardson 外推可得 **Euler-Maclaurin 公式**

$$T(h) = I(f) + c_1 h^2 + c_2 h^4 + c_3 h^6 + \cdots.$$

定义 6.4 Romberg 积分

定义

$$\begin{cases} T_1^{(l)} = T_{2^l}, & l \geq 0, \\ T_{m+1}^{(k-1)} = \frac{4^m T_m^{(k)} - T_m^{(k-1)}}{4^m - 1}, & 1 \leq m \leq l, \quad 1 \leq k \leq l - m, \end{cases}$$

最终得到 $T_l^{(0)}$ 的精度极高.

误差分析

对于 Lagrange 插值积分, 注意到

$$f(x) - l_n(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi),$$

从而有

(1) 中点公式:

$$\begin{aligned} e_M &= \int_a^b f(x) dx - (b-a)f\left(\frac{a+b}{2}\right) \\ &= \int_a^b (f(x) - l_0(x)) dx \\ &= \int_a^b \omega_1(x) f'(\xi_x) dx \sim \mathcal{O}(h^2), \quad (|b-a| \sim \mathcal{O}(h)), \end{aligned}$$

同时, 由于

$$f(x) = f\left(\frac{a+b}{2}\right) + f'\left(\frac{a+b}{2}\right)\left(x - \frac{a+b}{2}\right) + \frac{f''(\xi_x)}{2!}\left(x - \frac{a+b}{2}\right)^2,$$

从而

$$e_M = \int_a^b \frac{f''(\xi_x)}{2} \left(x - \frac{a+b}{2}\right)^2 dx = \frac{f''(\xi)}{2} \cdot \frac{1}{12} (b-a)^3 = \frac{f''(\xi)}{24} (b-a)^3 \sim \mathcal{O}(h^3).$$

(2) 梯形公式:

$$e_T = \int_a^b f(x) - l_1(x) dx = \int_a^b \frac{f''(\xi_x)}{2} (x-a)(x-b) dx = -\frac{f''(\xi)}{12} (b-a)^3.$$

(3) Simpson 公式:

$$e_S = \int_a^b (f(x) - l_2(x)) dx.$$

取 $p_3(x) \in \mathcal{P}_3$ 为 Hermite 插值多项式, 则

$$p_3(a) = f(a), \quad p_3(b) = f(b), \quad p_3\left(\frac{a+b}{2}\right) = f\left(\frac{a+b}{2}\right), \quad p_3'\left(\frac{a+b}{2}\right) = f'\left(\frac{a+b}{2}\right),$$

故

$$\begin{aligned} e_S &= \int_a^b (f(x) - p_3(x)) dx = \int_a^b \frac{f^{(4)}(\xi_x)}{4!} \Omega_4(x) dx, \quad \Omega_4(x) := (x-a) \left(x - \frac{a+b}{2}\right)^2 (x-b) \\ &= \frac{f^{(4)}(\xi)}{2880} (b-a)^5 \sim \mathcal{O}(h^5). \end{aligned}$$

定理 6.1 一般 Lagrange 插值积分误差

当 n 为奇数时,

$$E_n = \frac{K_n}{(n+1)!} (b-a)^{n+2} f^{(n+1)}(\xi);$$

当 n 为偶数时,

$$E_n = \frac{M_n}{(n+2)!} (b-a)^{n+3} f^{(n+2)}(\xi),$$

其中 n 为插值多项式的次数,

$$K_n := \int_0^n \Pi_{n+1}(t) dt, \quad M_n := \int_0^n t \Pi_{n+1}(t) dt, \quad \Pi_{n+1}(t) := \prod_{i=0}^n (t-i).$$

对于分片 Lagrange 插值积分: 设

$$a = x_0 < x_1 < x_2 < \cdots < x_n = b, \quad h_j = x_{j+1} - x_j, \quad h = \max_{0 \leq j \leq n-1} h_j,$$

则

$$I_h(f) = \sum_{j=0}^{n-1} \int_{x_j}^{x_{j+1}} f(x) dx \approx \sum_{j=0}^{n-1} I(p_k^j), \quad p_k^{(j)} \in \mathcal{P}_k,$$

再记 $e_h := I(f) - I_h(f)$. 故

$$|e_h| \leq \begin{cases} \frac{K_n}{(n+1)!} h^{n+1} L_{n+1} \sum_{j=0}^{n-1} h_j = \frac{K_n}{(n+1)!} h^{n+1} L_{n+1} (b-a), & n \text{ 为奇数;} \\ \frac{M_n}{(n+2)!} h^{n+2} L_{n+2} \sum_{j=0}^{n-1} h_j = \frac{M_n}{(n+2)!} h^{n+2} L_{n+2} (b-a), & n \text{ 为偶数.} \end{cases}$$

其中

$$L_{n+1} := \max_{x \in [a, b]} |f^{(n+1)}(x)|.$$

定义 6.5 逼近阶 (Convergence order)

若 $|e_h| \leq c \cdot h^p$, 则称为 p 阶收敛.

因此 (1) 复合 Midpoint 公式 $e_h \sim \mathcal{O}(h^2)$; (2) 复合 Trapezoidal 公式 $e_h \sim \mathcal{O}(h^2)$; (3) 复合 Simpson 公式 $e_h \sim \mathcal{O}(h^4)$.

如果 $e_h \sim c \cdot h^p$, 则

$$\ln \left(\frac{|e_h|}{|e_{h/2}|} \right) \sim p \ln 2,$$

故

$$p \approx \ln \left(\frac{|e_h|}{|e_{h/2}|} \right) / \ln 2.$$

第七章 Gauss 积分

定义 7.1 代数精度 (degree of exactness, DOE)

设

$$I(f) := \int_a^b f(x) dx, \quad I_n(f) := \sum_{k=0}^n f(x_k) A_k^{(n)}, \quad E_n(f) := I(f) - I_n(f), \quad A_k^{(n)} := C_k^{(n)}(b-a).$$

称 x_k 为节点, $A_k^{(n)}, C_k^{(n)}$ 为求积系数. 称代数精度为 k , 如果 $E_n(f) = 0, \forall f \in \mathcal{P}_k$.

定义 7.2 插值型积分 (interpolatory)

取

$$I_n(f) = I(L_n(f)) = I\left(\sum_{k=0}^n f(x_k) l_{n,k}(x)\right) = \sum_{k=0}^n f(x_k) \int_a^b l_{n,k}(x) dx := \sum_{k=0}^n f(x_k) A_k^{(n)}.$$

命题 7.1

数值积分为插值型的 $\iff$ 代数精度 $\geq n \iff A_k^{(n)} = \int_a^b l_{n,k}(x) dx$.

证明.

后一个充分必要性显然, 下面证明前一个充分必要性.

若数值积分为插值型的, 只需证: $\forall f \in \mathcal{P}_n$, 都有 $I(f) = I_n(f)$. 事实上, 由于 $f \in \mathcal{P}_n$, 故 $f = L_n(f)$, 从而

$$I(f) = I(L_n(f)) = I_n(f).$$

若代数精度 $\geq n$, 只需证: $I_n(f) = I(L_n(f))$. 事实上, 由于 $L_n(f) \in \mathcal{P}_n$, 故

$$I(L_n(f)) = I_n(L_n(f)) = \sum_{k=0}^n L_n(f)(x_k) A_k^{(n)} = \sum_{k=0}^n f(x_k) A_k^{(n)} = I_n(f).$$

□

如果代数精度 $\geq n$, 则

$$A_j^{(n)} = \int_a^b l_{n,j}(x) dx,$$

再取 $f = x^k$, 则

$$\int_a^b x^k dx = \sum_{j=0}^n x_j^k A_j^{(n)}, \quad \forall k \geq 0.$$

定理 7.1

$\forall 0 \leq k \leq n+1$, 数值积分具有 $d = n+k$ 次代数精度 $\iff$ 数值积分为插值型的, 且 $\omega_{n+1}(x)$ 满足:

$$\int_a^b \omega_{n+1}(x)p(x) dx = 0, \quad \forall p \in \mathcal{P}_{k-1}, \quad \omega_{n+1}(x) := \prod_{j=0}^n (x - x_j).$$

证明.

必要性: 前一条显然, 下证后一条. 事实上, $\forall f \in \mathcal{P}_{n+k}$, 设

$$f(x) = \omega_{n+1}(x)q(x) + r(x), \quad r \in \mathcal{P}_n, \quad q \in \mathcal{P}_{k-1},$$

则

$$I_n(f) = I(f) = I(\omega_{n+1}q) + I(r) = I(\omega_{n+1}q) + I_n(r),$$

故

$$I(\omega_{n+1}q) = I_n(f) - I_n(r) = 0,$$

这是因为 $f(x_j) = r(x_j), 0 \leq j \leq n$. 必要性得证.

充分性由必要性易证. □

推论 7.2

当 n 为偶数时, 等距节点 Lagrange 插值积分具有 $d = n+1$ 次代数精度.

证明.

由于

$$\omega_{n+1}(x) = \prod_{j=0}^n (x - x_j), \quad x_j = a + jh,$$

故只需证

$$\int_a^b \omega_{n+1}(x) dx = 0.$$

事实上, 令 $x = a + th, n = 2m, \tilde{t} = t - m$, 则

$$\int_a^b \omega_{n+1}(x) dx = \int_0^n \prod_{j=0}^n (t - j) dt \cdot h = h \int_{-m}^m \prod_{j=-m}^m (\tilde{t} - j) d\tilde{t} = h \int_{-m}^m \tilde{t} \prod_{j=1}^m (\tilde{t}^2 - j^2) d\tilde{t} = 0.$$

由此可得

$$I(p_3) = I(L_2(f)),$$

事实上,

$$I(p_3) = I_2(p_3) = I_2(L_2(f)) = I(L_2(f)).$$

定义 7.3 Gauss 积分

如果 $E_n(f) = 0, \forall f \in \mathcal{P}_{2n+1}$, 即代数精度为 $2n+1$, 则称该数值积分为 **Gauss 积分**.

显然 Gauss 积分 $\iff$

$$\int_a^b \omega_{n+1}(x)p(x) dx = 0, \quad \forall p \in \mathcal{P}_n.$$

由正交多项式可得 $\{x_j\}_{0 \leq j \leq n}$ 经过平移和缩放后为 $n+1$ 次 Legendre 多项式的零点.

定理 7.2

n 次正交多项式恰有 n 个不同的实零点.

证明.

先考虑无复根的情形, 假设有实的重根, 设

$$p_n(x) = (x - x_{i_1})^{m_1} \cdots (x - x_{i_k})^{m_k} \in \mathcal{P}_n, \quad x_{i_j} \text{ 互不相等},$$

不妨设 $m_1, m_2, \dots, m_k$ 均为奇数, 取

$$q(x) = (x - x_{i_1}) \cdots (x - x_{i_k}), \quad \deg q = k < n,$$

则

$$\int_a^b p_n q dx = \int_a^b (x - x_{i_1})^{m_1+1} \cdots (x - x_{i_k})^{m_k+1} dx > 0,$$

其他情形类似可证.

□

推论 7.3

Gauss 积分可通过正交多项式的零点来构造.

命题 7.4

Gauss 积分具有最高的代数精度.

证明.

反证: 如果数值积分

$$I_n(f) = \sum_{j=0}^n f(x_j) A_j^{(n)}$$

具有 $2n+2$ 次代数精度, 则取 $f(x) = \omega_{n+1}^2(x) \in \mathcal{P}_{2n+2}$, 故

$$I(f) = \int_a^b \omega_{n+1}^2(x) dx > 0,$$

但 $I_n(f) = 0$, 矛盾. □

命题 7.5

Gauss 积分中 $A_k^{(n)}, C_k^{(n)} > 0$, 且 $\sum_{k=0}^n C_k^{(n)} = 1$.

证明.

取

$$f_k(x) = \left(\frac{\omega_{n+1}(x)}{x - x_k} \right)^2 \in \mathcal{P}_{2n},$$

则

$$0 < \int_a^b \left(\frac{\omega_{n+1}(x)}{x - x_k} \right)^2 dx = I(f_k) = I_n(f_k) = \sum_{j=0}^n f_k(x_j) A_j^{(n)} = f_k(x_k) A_k^{(n)},$$

故 $A_k^{(n)} > 0$, 且取 $f(x) \equiv 1$ 可得 $\sum_{k=0}^n C_k^{(n)} = 1$. □

常见的 Gauss 节点: $[-1, 1], \rho(x) \equiv 1$ (**Gauss-Legendre**)

$$n = 0: \quad x_0 = 0, \quad C_0^{(0)} = 1;$$

$$n = 1: \quad x_{0,1} = \pm \frac{1}{\sqrt{3}}, \quad C_{0,1}^{(1)} = \frac{1}{2};$$

$$n = 2: \quad x_0 = 0, \quad x_{\pm} = \pm \sqrt{\frac{3}{5}}, \quad C_0^{(2)} = \frac{4}{9}, \quad C_{\pm}^{(2)} = \frac{5}{18}.$$

下面进行误差估计. 设 $f \in C^{2n+2}[a, b]$, 则 Gauss 积分对应的

$$E_n(f) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_a^b \omega_{n+1}^2(x) dx = \mathcal{O}(h^{2n+2}).$$

事实上,

$$E_n(f) = I(f) - I(L_n(f)) = I(f) - I(H_n(f)),$$

其中 Hermite 插值多项式 $H_n(f) \in \mathcal{P}_{2n+1}$ 满足:

$$H(x_k) = f(x_k), \quad H'(x_k) = f'(x_k), \quad \forall 0 \leq k \leq n.$$

从而再由 Hermite 插值多项式的误差估计可得

$$E_n(f) = I(f - H_n(f)) = \int_a^b \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!} \omega_{n+1}^2(x) \, dx.$$

第八章 自适应与谱精度

自适应 (adaptivity)

对积分 $I(f) = \int_a^b f(x) dx$ 求数值积分

$$I_h(f), \quad a = x_0 < x_1 < \cdots < x_k < \cdots < x_n = b$$

时, 为提高精度, 网格是自由度.

我们采取**误差等分布原则 (Equi-distribution of error)**: 为使 $|I(f) - I_h(f)| \leq \varepsilon$, 只需

$$\left| \int_{x_k}^{x_{k+1}} f(x) dx - I_h(f; [x_k, x_{k+1}]) \right| \leq \frac{x_{k+1} - x_k}{b - a} \varepsilon.$$

以复合 Simpson 为例:

$$I(f) \approx \sum_k (S_k + e_k),$$

其中 S_k 为 Simpson 公式在 $[x_k, x_{k+1}]$ 上的积分, 则

$$S_k - \int_{x_k}^{x_{k+1}} f(x) dx = C(x_{k+1} - x_k)^5 f^{(4)}(\xi_1) := -e_k, \quad \xi_1 \in (x_k, x_{k+1}), \quad h_k := x_{k+1} - x_k,$$

步长折半后为

$$\int_{x_k}^{x_{k+1}} f(x) dx = \left(\int_{x_k}^{x_{k+1/2}} + \int_{x_{k+1/2}}^{x_{k+1}} \right) f(x) dx \approx S_k^{(1)} + S_k^{(2)} + C \left(\frac{h}{2} \right)^5 \left(f^{(4)}(\tilde{\xi}_1) + f^{(4)}(\tilde{\xi}_2) \right),$$

这即为**折中 (trade-off)**. 假设 $f^{(4)}(\xi) \approx f^{(4)}(\tilde{\xi}_1) = f^{(4)}(\tilde{\xi}_2)$, 则

$$S_k + e_k = \int_{x_k}^{x_{k+1}} f(x) dx = \left(\int_{x_k}^{x_{k+1/2}} + \int_{x_{k+1/2}}^{x_{k+1}} \right) f(x) dx = S_k^{(1)} + S_k^{(2)} + \frac{e_k}{16},$$

故

$$e_k = \frac{16}{15} \left[(S_k^{(1)} + S_k^{(2)}) - S_k \right] \approx \frac{h_k}{b - a} \varepsilon,$$

从而

$$\tilde{e}_k = \frac{e_k}{16} = \frac{1}{15} \left[(S_k^{(1)} + S_k^{(2)}) - S_k \right],$$

保守处理: 如果

$$\frac{1}{10} \left(S_k^{(1)} + S_k^{(2)} - S_k \right) \leq \varepsilon \cdot \frac{h_k}{b-a},$$

则通过检验.

算法描述: 记 A : 正在估计的区间 (Active interval); S : 已经通过检验的区间 (Safe), 积分值为 $I_S(f)$; N : 未处理的区间 (Not examined). 初始化: $S = \emptyset$, $A = N = [a, b]$; 循环: 设 $A = [\alpha, \beta]$.

(1) 若 A 通过检验, 则 $S \leftarrow S \cup A, A = N$; (2) 若未通过检验, 则 $A = [\alpha, \frac{\alpha+\beta}{2}], N = [\frac{\alpha+\beta}{2}, \beta] \cup N$.

Euler-Maclaurin 公式

定义 8.1 Bernoulli 多项式

令 $B_0(x) = 1$, $\forall n \geq 1$, 取 $B_n \in \mathcal{P}_n$, 使得

$$B'_n = B_{n-1}, \quad \int_0^1 B_n(x) dx = 0.$$

直接计算可得

$$B_1(x) = x - \frac{1}{2}, \quad B_2(x) = \frac{1}{2}x^2 - \frac{1}{2}x + \frac{1}{12},$$

并且显然有 $B_n(0) = B_n(1), \forall n \geq 2$.

定义 8.2 Bernoulli 数

定义 $b_n := n!B_n(0), \forall n \geq 0$.

引理 8.1

$$B_n(x) = (-1)^n B_n(1-x), \quad \forall x \in \mathbb{R}, \forall n \geq 0.$$

推论 8.2

对 $B_n(x)$ 在 $[0, 1]$ 外作周期延拓, 则当 n 为偶数时, $\tilde{B}_n$ 为偶函数; 当 n 为奇数时, $\tilde{B}_n$ 为奇函数.

引理 8.3

$B_{2m+1}(x), m \geq 1$ 在 $[0, 1]$ 上有且仅有 3 个根 $x = 0, 1/2, 1$; $B_{2m}(x), m \geq 0$ 满足: $B_{2m}(0) \neq 0$.

证明.

由 $B_{2m+1}(0) = B_{2m+1}(1), m \geq 1$ 以及 $B_{2m+1}(0) = -B_{2m+1}(1)$ 可得 $B_{2m+1}(0) = B_{2m+1}(1) = 0$. 再由 $B_{2m+1}(1/2) = -B_{2m+1}(1/2)$ 可得 $B_{2m+1}(1/2) = 0$.

下证仅有 3 个根. 对 B_3 显然, 假设存在 $x_0 \in (0, 1/2)$, 使得 $B_{2m+1}(x_0) = 0$. 由 Rolle 定理, $B_{2m-1}(x)$ 在 $(0, 1/2)$ 中有根, 由归纳法知矛盾.

对 $B_{2m}(x)$: 由于 $B_{2m+1}(x)$ 在 $x = 0, 1/2, 1$ 上为 0, 故 $B_{2m}(x)$ 在 $(0, 1/2)$ 上有一点为 0. 如果还有

$B_{2m}(0) = B_{2m}(1) = 0$, 则 $B_{2m-1}(x)$ 在 $(0, 1/2)$ 上有根, 矛盾. $\square$

命题 8.4

$$\begin{aligned}\tilde{B}_{2m}(x) &= 2(-1)^{m-1} \sum_{k=1}^{+\infty} \frac{\cos 2\pi kx}{(2\pi k)^{2m}}, \\ \tilde{B}_{2m+1}(x) &= 2(-1)^{m+1} \sum_{k=1}^{+\infty} \frac{\sin 2\pi kx}{(2\pi k)^{2m+1}}.\end{aligned}$$

由 $B_{2m}(0) \neq 0$ 可得 $b_{2m} \neq 0, \forall m \geq 0$.

定理 8.1 Euler-Maclaurin 公式

取数值积分为等距节点的复合梯形公式, 则

$$I(f) - I_T(f) = - \sum_{j=1}^{[m/2]} \frac{b_{2j} h^{2j}}{(2j)!} (f^{(2j-1)}(b) - f^{(2j-1)}(a)) + (-1)^m h^m \int_a^b \tilde{B}_m\left(\frac{x-a}{h}\right) f^{(m)}(x) dx.$$

证明.

注意到

$$\int_0^1 B_1(z) g'(z) dz = \int_0^1 \left(z - \frac{1}{2}\right) g'(z) dz = \int_0^1 z dg - \frac{1}{2} (g(1) - g(0)) = \frac{1}{2} (g(0) + g(1)) - \int_0^1 g dz,$$

并且

$$\int_0^1 B_1(z) g'(z) dz = \int_0^1 g'(z) dB_2 = g' B_2 \Big|_0^1 - \int_0^1 B_2 g'' dz = b_2 (g'(1) - g'(0)) - \int_0^1 B_2 g'' dz,$$

不断重复上述步骤可得上式等于

$$\sum_{j=2}^m (-1)^j B_j(0) (g^{(j-1)}(1) - g^{(j-1)}(0)) - (-1)^m \int_0^1 B_m(z) g^{(m)}(z) dz,$$

因此

$$\int_0^1 g(z) dz = \frac{1}{2} (g(0) + g(1)) - \sum_{j=1}^{[m/2]} \frac{b_{2j}}{(2j)!} (g^{(2j-1)}(1) - g^{(2j-1)}(0)) + (-1)^m \int_0^1 B_m(z) g^{(m)}(z) dz,$$

设 $x = x_k + hz, g(z) = f(x_k + hz)$, 代入可得 $\int_{x_k}^{x_{k+1}} f(x) dx$ 的估计, 再对 k 求和即可得证. $\square$

推论 8.5

设 $f \in C^{2m+1}$ 且以 2π 为周期, 则

$$|E_T(f)| \leq Ch^{2m+1} \int_0^{2\pi} |f^{(2m+1)}(z)| dz.$$

谱收敛 (Spectral Convergence)

设 $f: \mathbb{R} \rightarrow \mathbb{R}$ 实解析 (任意一点 x 处 Taylor 展开式, 都存在邻域 $B_{r(x)}(x)$ 在复域上收敛), 且以 2π 为周期.

引理 8.6

$$\left(\int_{i\alpha}^{i\alpha+2\pi} - \int_{-i\alpha}^{-i\alpha+2\pi} \right) \cot\left(\frac{nz}{2}\right) f(z) dz = -\frac{4\pi i}{n} \sum_{k=1}^n f\left(\frac{2k\pi}{n}\right).$$

证明.

由于

$$\cot\left(\frac{nz}{2}\right) = \frac{\cos\left(\frac{nz}{2}\right)}{\sin\left(\frac{nz}{2}\right)},$$

故 $z = 2k\pi/n$ 为其一阶极点, 再结合留数定理即证. □

推论 8.7

$$\operatorname{Re} \left(\int_{i\alpha}^{i\alpha+2\pi} i \cot\left(\frac{nz}{2}\right) f(z) dz \right) = \frac{2\pi}{n} \sum_{k=1}^n f\left(\frac{2k\pi}{n}\right).$$

引理 8.8

$$\operatorname{Re} \left(\int_{i\alpha}^{i\alpha+2\pi} f(z) dz \right) = \int_0^{2\pi} f(x) dx.$$

证明.

由留数定理,

$$\left(\int_0^{i\alpha} + \int_{i\alpha}^{i\alpha+2\pi} - \int_{2\pi}^{i\alpha+2\pi} - \int_0^{2\pi} \right) f(z) dz = 0,$$

再由周期性可得

$$\int_0^{i\alpha} f(x) dz = \int_{2\pi}^{i\alpha+2\pi} f(z) dz,$$

故

$$\int_{i\alpha}^{i\alpha+2\pi} f(z) dz = \int_0^{2\pi} f(z) dz.$$

同理可得

$$\int_{-i\alpha}^{-i\alpha+2\pi} f(z) dz = \int_0^{2\pi} f(z) dz,$$

再由解析延拓的唯一性可得 $f(\bar{z}) = \overline{f(z)}$, 从而

$$\int_{-i\alpha}^{-i\alpha+2\pi} f(z) dz = \overline{\int_{i\alpha}^{i\alpha+2\pi} f(z) dz},$$

因此

$$\int_0^{2\pi} f(x) dx = \frac{1}{2} \left(\int_{i\alpha}^{i\alpha+2\pi} f(z) dz + \int_{-i\alpha}^{-i\alpha+2\pi} f(z) dz \right) = \operatorname{Re} \left(\int_{i\alpha}^{i\alpha+2\pi} f(z) dz \right).$$

□

定理 8.2

如果存在 $D_\alpha = \mathbb{R} \times (-\alpha, \alpha) \subseteq \mathbb{C}, \alpha > 0$, 使得 f 在 D_α 上解析, 则

$$|E_T(f)| \leq \frac{4\pi M}{e^{n\alpha} - 1}, \quad M := \max_{z \in D_\alpha} |f(z)|, \quad h = \frac{2\pi}{n}.$$

证明.

由上述引理可得

$$E_n(f) = \operatorname{Re} \left(\int_{i\alpha}^{i\alpha+2\pi} \left(1 - i \cot \frac{nz}{2} \right) f(z) dz \right),$$

而

$$\cot z = i \cdot \frac{e^{iz} + e^{-iz}}{e^{iz} - e^{-iz}} = i \cdot \frac{e^{2iz} + 1}{e^{2iz} - 1},$$

故

$$\begin{aligned} E_n(f) &= \operatorname{Re} \left(\int_0^{2\pi} \left(1 + \frac{e^{2i(i\alpha+\theta)\frac{n}{2}} + 1}{e^{2i(i\alpha+\theta)\frac{n}{2}} - 1} \right) f(i\alpha + \theta) d\theta \right) \\ &= \operatorname{Re} \left(\int_0^{2\pi} \frac{2e^{-n\alpha} e^{in\theta}}{e^{-n\alpha} e^{in\theta} - 1} f(i\alpha + \theta) d\theta \right), \end{aligned}$$

从而

$$|E_n(f)| \leq \int_0^{2\pi} \frac{2e^{-n\alpha}}{1 - e^{-n\alpha}} M d\theta = \frac{4\pi M}{e^{n\alpha} - 1}.$$

□

第九章 多维积分与数值微分

多维数值积分 (multi-dimensional)

积分约化

考察积分

$$I(f) = \iint_{\Omega} f(x, y) \, dx \, dy,$$

其中

$$\Omega = \{(x, y) \mid a \leq x \leq b, \phi_1(x) \leq y \leq \phi_2(x)\},$$

则

$$I(f) = \int_a^b dx \int_{\phi_1(x)}^{\phi_2(x)} f(x, y) \, dy := \int_a^b F(x) \, dx \approx \sum_{i=1}^{N^x} \alpha_i F(x_i) = \sum_{i=1}^{N^x} \alpha_i \sum_{j=1}^{n_i^y} \beta_j^i f(x_i, y_j^i).$$

复合求积

做单纯形剖分

$$\Omega = \bigcup_{T \in \mathcal{T}_h} T,$$

则

$$\iint_{\Omega} f(x, y) \, dx \, dy = \sum_{T \in \mathcal{T}_h} \iint_T f(x, y) \, dx \, dy \approx \sum_{T \in \mathcal{T}_h} \sum_{j=0}^{d_T-1} \alpha_j^T f(\vec{x}_j^T),$$

其中

$$\iint_T f(x, y) \, dx \, dy \approx \iint_T \sum_{j=0}^{d_T-1} f(\vec{x}_j^T) l_j(x, y) \, dx \, dy = \sum_{j=0}^{d_T-1} f(\vec{x}_j^T) \iint_T l_j(x, y) \, dx \, dy.$$

再作仿射变换 A_T , 使得 $A_T(T) = \hat{T}$, 其中 $\hat{T}$ 是以 $(0, 0), (0, 1), (1, 0)$ 为顶点的三角形, 故上式等于

$$\sum_{j=0}^{d_T-1} f(\vec{x}_j^T) \iint_{\hat{T}} \hat{l}_j(\hat{x}, \hat{y}) \frac{\partial(x, y)}{\partial(\hat{x}, \hat{y})} \, d\hat{x} \, d\hat{y} = 2|T| \sum_{j=0}^{d_T-1} f(\vec{x}_j^T) \iint_{\hat{T}} \hat{l}_j(\hat{x}, \hat{y}) \, d\hat{x} \, d\hat{y},$$

可类似推广到多维.

对于 2 维情形中的特例:

(1) 若 $d_T = 1, k = 0$, 则

$$I_h^0(f) = \sum_{T \in \mathcal{T}_h} f(\bar{x}_0^T) |T|,$$

其中 $\bar{x}_0^T$ 的典型取法为 T 的重心.

(2) 若 $d_k = 3, k = 1$, 则

$$I_h^1(f) = \sum_{T \in \mathcal{T}_h} \sum_{j=0}^2 f(\bar{x}_j^T) \frac{|T|}{3},$$

其中 $\bar{x}_j^T, 0 \leq j \leq 2$ 为 T 的 3 个顶点.

数值微分

基本做法

设 $f(x)$ 的 Lagrange 插值多项式为 $L_n(x)$, 则 $f'(x) \approx L'_n(x)$. 在 $x = x_0$ 处

$$f(x) = L_n(x) + R_n(x),$$

$$L_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + \cdots + f[x_0, \cdots, x_n]\omega_n(x),$$

$$R_n(x) = f[x_0, \cdots, x_n, x]\omega_{n+1}(x),$$

从而

$$f'(x_0) = L'_n(x_0) + R'_n(x_0),$$

$$L'_n(x_0) = f[x_0, x_1] + \cdots + f[x_0, \cdots, x_n](x_0 - x_1) \cdots (x_0 - x_{n-1}),$$

$$R'_n(x_0) = f[x_0, \cdots, x_n, x_0](x_0 - x_1) \cdots (x_0 - x_n) = \frac{f^{(n+1)}(\xi)}{(n+1)!} (x_0 - x_1) \cdots (x_0 - x_n).$$

当 $n = 1$ 时, 取 $x_1 = x_0 + h$, 则

$$f'(x_0) \approx \frac{f(x_1) - f(x_0)}{x_1 - x_0}, \quad e_h = \frac{f''(\xi)}{2} h.$$

当 $n = 2$ 时, 取 $x_k = x_0 + kh, k = 1, 2$, 则

$$f'(x_0) \approx \frac{f(x_1) - f(x_0)}{h} - \frac{f(x_2) - 2f(x_1) + f(x_0)}{2h} = \frac{-f(x_2) + 4f(x_1) - 3f(x_0)}{2h}, \quad e_h = \mathcal{O}(h^2).$$

如果改成取 $x_k = x_0 + kh, k = -1, 1$, 则得到**中心差商 (Central difference)**

$$f'(x_0) \approx \frac{f(x_1) - f(x_{-1}))}{2h}, \quad e_h = \mathcal{O}(h^2).$$

我们还可定义**谱导数 (pseudo-spectral derivative)**: 取 $L_n(x)$ 为 Gauss 点上的 Lagrange 插值.

以上的本质为 Taylor 展开, 注意到

$$\begin{aligned} f(x_1) &= f(x_0) + f'(x_0)h + \frac{1}{2}f''(x_0)h^2 + \cdots, \\ f(x_{-1}) &= f(x_0) - f'(x_0)h + \frac{1}{2}f''(x_0)h^2 + \cdots, \end{aligned}$$

适当选取 $\alpha_{-1}, \alpha_0, \alpha_1$, 使得

$$\sum_{i=-1}^1 \alpha_i f(x_i) = f'(x_0)\beta_1 h + f''(x_0)\beta_2 h^2 + \cdots.$$

数值稳定性

以中心差商为例, 记

$$f' \approx \frac{f(x_1) - f(x_{-1})}{2h} := f'_h,$$

则

$$|f'_h - f'| \leq Ch^2,$$

但数值上

$$\tilde{f}'_h = \frac{\tilde{f}(x_1) - \tilde{f}(x_{-1})}{2h}, \quad \tilde{f}(x_k) = f(x_k) + \varepsilon_k, \quad |\varepsilon_k| \leq \varepsilon, \quad k = \pm 1,$$

从而

$$\begin{aligned} |\tilde{f}'_h - f'| &= |\tilde{f}'_h - f'_h + f'_h - f_h| \\ &\leq |\tilde{f}'_h - f'_h| + |f'_h - f'| \\ &= \left| \frac{\varepsilon_1 - \varepsilon_{-1}}{2h} \right| + Ch^2 \\ &\leq \frac{\varepsilon}{h} + Ch^2, \end{aligned}$$

两项分别对应**噪声 (noise)** 和**偏差 (bias)**. 当 $h = \sqrt[3]{\varepsilon/2C}$ 时, $\varepsilon/h + Ch^2$ 最小, 二者达到**折中 (Trade-off)**, 此时

$$|\tilde{f}'_h - f'| \leq \frac{3}{2\sqrt[3]{2C}} \varepsilon^{2/3}.$$

紧致格式 (Compact scheme)

采用**基架 (stencil)**, 求解如下线性方程组

$$h \sum_{k=-m}^m \alpha_k f'_{i-k} = \sum_{k=-m'}^{m'} \beta_k f(x_{i-k}).$$

以 $m = m' = 1$ 为例, 此时得到

$$f'_i + e_h = \alpha f'_{i-1} + \alpha f'_{i+1} + \frac{\beta}{2h}(f_{i+1} - f_{i-1}),$$

设置 α, β 使得 e_h 尽可能高阶.

第十章 Monte Carlo 方法

我们希望计算高维积分

$$I(f) = \int_{\mathbb{R}^d} f(\vec{x}) \, d\vec{x}, \quad d \gg 1.$$

基本思想

以 1 维为例. 设

$$I(f) = \int_0^1 f(x) \, dx,$$

记中点公式

$$I_N^{(1)} := h \sum_{j=1}^N f(x_{j-1/2}), \quad x_{j-1/2} = (j-1/2)h, \quad h = 1/N,$$

则

$$e_N^{(1)} \sim \mathcal{O}(h^2) = \mathcal{O}(N^{-2}).$$

由于

$$I(f) = \mathbb{E}f(X), \quad X \sim \mathcal{U}(0, 1),$$

故

$$I_N^{(2)} := \frac{1}{N} \sum_{j=1}^N f(X_j), \quad X_j \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}(0, 1),$$

由**强大数定律 (SLLN)** 可得 $I_N^{(2)} \xrightarrow{\text{a.s.}} \mathbb{E}f(X), N \rightarrow +\infty$, 此时

$$\begin{aligned} \mathbb{E} \left| e_N^{(2)} \right|^2 &= \mathbb{E} \left| I(f) - \frac{1}{N} \sum_{j=1}^N f(X_j) \right|^2 \\ &= \mathbb{E} \left(\frac{1}{N} \sum_{j=1}^N (f(X_j) - I(f)) \right)^2 \end{aligned}$$

$$\begin{aligned}
&= \frac{1}{N^2} \sum_{i,j=1}^N \mathbb{E}(f(X_i) - I(f))(f(X_j) - I(f)) \\
&= \frac{1}{N^2} \sum_{i=1}^n \mathbb{E}(f(X_i) - I(f))^2 \\
&= \frac{1}{N} \mathbb{E}(f(X) - I(f))^2 \\
&= \frac{\text{Var}_X(f)}{N},
\end{aligned}$$

再由 Hölder 不等式可得

$$\mathbb{E}|fg| \leq (\mathbb{E}|f|^p)^{1/p} (\mathbb{E}|g|^q)^{1/q}, \quad p, q \geq 1, \quad \frac{1}{p} + \frac{1}{q} = 1,$$

从而

$$\mathbb{E}|e_N^{(2)}| \leq \left(\mathbb{E}|e_N^{(2)}|^2 \right)^{1/2} = N^{-1/2} \sigma_f, \quad \sigma_f := \sqrt{\text{Var}_X(f)}.$$

对于高维 (d 维) 情形

$$I(f) = \int_{[0,1]^d} f(x) \, dx,$$

有中点公式

$$I_N^{(1)} := h^d \sum_{j=1}^{M^d} f(\vec{x}_j), \quad h = 1/M,$$

且

$$e_N^{(1)} \sim \mathcal{O}(h^2) = \mathcal{O}(M^{-2}).$$

同时

$$I_N^{(2)} := \frac{1}{N} \sum_{j=1}^N f(X_j), \quad X_j \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}((0,1)^d),$$

同理有

$$\mathbb{E}|e_N^{(2)}| \leq N^{-1/2} \sigma_f.$$

在相同的计算代价下 $N = M^d$, 即 $M = N^{1/d}$, 故 $e_N^{(1)} \sim \mathcal{O}(N^{-2/d})$, 当 $d = 4$ 时二者收敛阶相同.

因此, 当 $d \gg 1$ 时, Monte Carlo 比确定性数值积分更有效, 并且 Monte Carlo 的精度为 $\mathcal{O}(N^{-1/2})$, 不依赖于维数 d , 但依赖于 σ_f , 以及 Monte Carlo 天然可并行, 结果是随机的 (**大偏差理论, LDT**).

一般来说,

$$I(f) = \int_{\mathbb{R}^d} f(x) p(x) \, dx = \mathbb{E}f(X), \quad X \sim p(x),$$

取 Gibbs 分布

$$p(x) = \frac{1}{Z} e^{-H(x)}, \quad Z = \int_{\mathbb{R}^d} e^{-H(x)} dx,$$

即 $H(x) = -\ln p(x) + C$.

方差减小技术 (Variance Reduction)

重要性抽样 (Importance Sampling)

由于

$$\begin{aligned} I(f) &= \int_0^1 f(x) dx = \mathbb{E}f(X), \quad X \sim \mathcal{U}(0, 1), \\ &= \int_0^1 \frac{f}{p}(x) p(x) dx = \mathbb{E} \frac{f}{p}(Y), \quad Y \sim p(y), \end{aligned}$$

故定义

$$\tilde{I}_N := \frac{1}{N} \sum_{j=1}^N \frac{f}{p}(Y_j), \quad Y_j \stackrel{\text{i.i.d.}}{\sim} p(y),$$

从而

$$\mathbb{E}|\tilde{e}_N| \leq N^{-1/2} \sigma_{f/p},$$

其中

$$\begin{aligned} \sigma_{f/p}^2 &= \mathbb{E} \left(\frac{f}{p}(Y) - I \right)^2 \\ &= \int_0^1 \left(\frac{f}{p}(y) - I \right)^2 p(y) dy \\ &= \int_0^1 \frac{f^2}{p}(y) dy - I^2, \end{aligned}$$

且

$$\sigma_f^2 = \int_0^1 f^2(x) dx - I^2.$$

因此要求

$$\min_{p \geq 0, \int_0^1 p(y) dy = 1} \int_0^1 \frac{f^2}{p}(y) dy,$$

不妨设 $f > 0$, 由于

$$I = \int_0^1 \frac{f}{\sqrt{p}}(y) \sqrt{p(y)} dy \leq \left(\int_0^1 \frac{f^2}{p} dy \right)^{1/2} \left(\int_0^1 p(y) dy \right)^{1/2} = \left(\int_0^1 \frac{f^2}{p} dy \right)^{1/2},$$

即

$$I^2 \leq \int_0^1 \frac{f^2}{p}(y) \, dy.$$

取等条件:

$$\frac{f}{\sqrt{p}}(y) = C\sqrt{p(y)} \iff f(y) = Cp(y) \iff p(y) = f(y)/C, \quad C = I(f).$$

控制变量法 (Control Variables)

考虑

$$\begin{aligned} I(f) &= \int_0^1 f(x) \, dx + \alpha \left(\int_0^1 g(x) \, dx - I(g) \right) \\ &= \int_0^1 (f(x) - \alpha g(x)) \, dx + \alpha I(g), \end{aligned}$$

其中 $g(x)$ 为**控制变量**, 故定义

$$\hat{I}_N := \frac{1}{N} \sum_{j=1}^N ((f - \alpha g)(X_j)) + \alpha I(g), \quad X_j \stackrel{\text{i.i.d.}}{\sim} \mathcal{U}(0, 1),$$

此时

$$\mathbb{E}|\hat{e}_N| \leq N^{-1/2} \sigma_{f-\alpha g},$$

其中

$$\begin{aligned} \sigma_{f-\alpha g}^2 &= \int_0^1 [(f - I(f)) + \alpha(g - I(g))]^2 \, dx \\ &= \sigma_f^2 + \alpha^2 \sigma_g^2 + 2\alpha \int_0^1 (f - I(f))(g - I(g)) \, dx, \end{aligned}$$

取

$$\alpha^* = - \frac{\int_0^1 (f - I(f))(g - I(g)) \, dx}{\sigma_g^2},$$

则

$$\begin{aligned} \sigma_{f-\alpha^* g}^2 &= \sigma_f^2 - \frac{\left(\int_0^1 (f - I(f))(g - I(g)) \, dx \right)^2}{\sigma_g^2} \\ &= \sigma_f^2 - \frac{\text{Cov}^2(f, g)}{\sigma_g^2} \\ &= (1 - \rho_{f,g}^2) \sigma_f^2 \leq \sigma_f^2, \end{aligned}$$

其中

$$\rho_{f,g} = \frac{\text{Cov}(f,g)}{\sigma_f \sigma_g}, \quad |\rho_{f,g}| \leq 1.$$

如果 $\rho_{f,g} = \pm 1 \iff f = cg$, 则 $\sigma_{f-\alpha^*g} = 0$.

相对误差

对于数值积分 $I_N \approx I$, 我们希望相对误差尽可能小:

$$\frac{|I - I_N|}{|I|} \ll 1 \iff \frac{N^{-1/2}\sigma_f}{|I|} \leq \varepsilon_0,$$

其中 $I \sim \mathcal{O}(1)$. 如果取 $X \sim \mathcal{U}[0, 1]$,

$$f(x) = \begin{cases} 1/\varepsilon, & x \in [a, a + \varepsilon], \\ 0, & \text{其他}, \end{cases}$$

则 $\sigma_f = \mathbb{E}f^2(X) - I^2 = \mathcal{O}(\varepsilon^{-1})$, 故此时 $N \geq \mathcal{O}(\varepsilon_0^{-2}\varepsilon^{-2})$.

第十一章 Metropolis 算法

Metropolis 算法首次发表于 The Journal of Chemical Physics (JCP), 论文作者为 Metropolis, Rosenbluth, Rosenbluth, Teller, Teller (MR²T²).

我们希望计算高维积分

$$I(f) = \int_{\mathbb{R}^d} f(\vec{x}) p(\vec{x}) d\vec{x},$$

其中 $p(\vec{x}) = \frac{1}{Z} e^{-\beta U(\vec{x})}$ 是 **Gibbs 分布 (正则分布, Canonical distribution)**, $Z = \int_{\mathbb{R}^d} e^{-\beta U(\vec{x})} d\vec{x}$, $\beta > 0$ 是**逆温度**.

记 $U(x) = -\beta^{-1} \ln p(x) - \beta^{-1} \ln Z$ 为**势函数**. 考虑 Monte Carlo 方法:

$$I_N = \frac{1}{N} \sum_{j=1}^N f(X_j), \quad X_j \stackrel{\text{i.i.d.}}{\sim} p(\vec{x}).$$

Metropolis 算法实际为 **Markov Chain Monte Carlo 算法 (MCMC)**. 设置 $\vec{x} \in \mathcal{S} = \{1, 2, \dots, M\}$, 令

$$p(\vec{x}) \mapsto \vec{\pi} = (\pi_1, \dots, \pi_M), \quad \pi_i := p(i) = \frac{1}{Z} e^{-\beta U_i} \geq 0, \quad \sum_{i=1}^M \pi_i = 1,$$

则

$$I(f) = \sum_{i=1}^M f(i) \pi_i \approx \frac{1}{N} \sum_{j=1}^N f(X_j), \quad X_j \sim \vec{\pi}.$$

考虑 **Markov 过程 (Markov 链)** 的离散时间转移概率矩阵 $P = (p_{ij})_{i,j \in \mathcal{S}}$, 其中

$$p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i), \quad \sum_{j \in \mathcal{S}} p_{ij} = 1, \quad \forall i \in \mathcal{S}.$$

再定义

$$\mu_n(i) := \mathbb{P}(X_n = i), \quad \sum_{i \in \mathcal{S}} \mu_n(i) = 1,$$

则

$$\mu_{n+1}(j) = \sum_{i \in \mathcal{S}} \mathbb{P}(X_n = i) \mathbb{P}(X_{n+1} = j \mid X_n = i) = \sum_{i \in \mathcal{S}} \mu_n(i) p_{ij},$$

即 $\vec{\mu}_{n+1} = \vec{\mu}_n P$, 其中 $\vec{\mu}_n \in \mathbb{R}^{1 \times M}$, $P \in \mathbb{R}^{M \times M}$, 我们希望 $\vec{\mu}_n \rightarrow \vec{\pi}$, $n \rightarrow +\infty$, 从而得到必要条件 $\vec{\pi} = \vec{\pi} P$ (**GBC**), 其中 $\vec{\pi}$ 称为**不变分布**, 并且 P 还满足 $P\vec{1} = \vec{1}$, $p_{ij} \geq 0$.

我们可以取 **DBC(细致平衡条件)**:

$$\pi_i p_{ij} = \pi_j p_{ji} \iff \frac{p_{ij}}{p_{ji}} = \frac{\pi_j}{\pi_i} = \frac{e^{-\beta U_j}}{e^{-\beta U_i}} = e^{-\beta \Delta U_{ij}}, \quad \Delta U_{ij} := U_j - U_i, \quad \forall i, j.$$

选择 1 (**Metropolis 策略**): 取

$$p_{ij} = 1 \wedge e^{-\beta \Delta U_{ij}} = \min(1, e^{-\beta \Delta U_{ij}}),$$

则

$$\frac{p_{ij}}{p_{ji}} = \frac{\min(1, e^{-\beta \Delta U_{ij}})}{\min(1, e^{-\beta \Delta U_{ji}})} = e^{-\beta \Delta U_{ij}}.$$

选择 2 (**Glauber 策略**): 取

$$p_{ij} = \frac{1}{1 + e^{\beta \Delta U_{ij}}},$$

则

$$\frac{p_{ij}}{p_{ji}} = \frac{1 + e^{\beta \Delta U_{ji}}}{1 + e^{\beta \Delta U_{ij}}} = e^{-\beta \Delta U_{ij}}.$$

从而 P 的最终设置为

$$p_{ij} = \begin{cases} Q_{ij} A_{ij}, & i \neq j, \\ 1 - \sum_{k \neq i} Q_{ik} A_{ik}, & i = j, \end{cases}$$

其中 $A_{ij} := 1 \wedge e^{-\beta \Delta U_{ij}}$, 称为**决策矩阵 (Decision Matrix)**, $Q_{ij} = Q_{ji}$, $Q\vec{1} = \vec{1}$, $Q_{ij} \geq 0$, 称为**预选矩阵 (Proposal Matrix)**, 此时显然有

$$\frac{p_{ij}}{p_{ji}} = \frac{Q_{ij} A_{ij}}{Q_{ji} A_{ji}} = e^{-\beta \Delta U_{ij}}, \quad \forall i \neq j.$$

接受: $X_{n+1} = j$; 拒绝: $X_{n+1} = i$. Q 还可以取成非对称的 (**Metropolis-Hastings 算法**), 此时

$$A_{ij} = 1 \wedge \left(\frac{Q_{ij}}{Q_{ji}} e^{-\beta \Delta U_{ij}} \right).$$

Q 可选取为

$$Q = \begin{pmatrix} 0 & \frac{1}{M-1} & \cdots & \frac{1}{M-1} \\ \frac{1}{M-1} & 0 & \cdots & \frac{1}{M-1} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{M-1} & \frac{1}{M-1} & \cdots & 0 \end{pmatrix}.$$

Ising 模型 (1 维)

定义 11.1 Ising 模型 (1 维)

考虑 $\vec{\sigma} \in \mathcal{S} = \{\pm 1\}^M$, $|\mathcal{S}| = 2^M$, 给出如下定义

(1) 能量:

$$H(\vec{\sigma}) = - \sum_{\langle i, j \rangle} \sigma_i \sigma_j, \quad \langle i, j \rangle \iff |i - j| = 1.$$

(2) Gibbs 分布:

$$\pi(\vec{\sigma}) = \frac{1}{Z_\beta} e^{-\beta H(\vec{\sigma})}.$$

(3) 内能:

$$\langle H \rangle = \mathbb{E} H(\vec{\sigma}) = \sum_{\vec{\sigma} \in \mathcal{S}} H(\vec{\sigma}) \cdot \frac{1}{Z_\beta} e^{-\beta H(\vec{\sigma})} := U(\beta).$$

(4) 比热:

$$\text{Var}(H) = \langle H^2 \rangle - \langle H \rangle^2 := C(\beta).$$

令 $u = U/M, c = C/M$, 则可得到 u 和 c 与 β 的关系. 此时 Q 有如下 2 种选取方法:

取法 1: $Q \in \mathbb{R}^{2^M \times 2^M}$ 满足: 对任意两个状态 σ 和 σ' , 如果它们不同, 则 $Q_{\sigma, \sigma'} = 1/(2^M - 1)$, 否则 $Q_{\sigma, \sigma'} = 0$.

取法 2: (**Gibbs 抽样**) $Q \in \mathbb{R}^{2^M \times 2^M}$ 满足: 对任意两个状态 σ 和 σ' , 如果它们之间恰有一个自旋不同, 则 $Q_{\sigma, \sigma'} = 1/M$, 否则 $Q_{\sigma, \sigma'} = 0$.

第十二章 非线性方程数值解 (nonlinear equation)

我们下面来求解非线性方程 $\vec{F}(\vec{x}) = \vec{0}$, 其中 $\vec{F} : \mathbb{R}^n \rightarrow \mathbb{R}^n$, 设 $\vec{F}(\vec{x}^*) = \vec{0}$. 先考虑 $n = 1$ 的情形, 对于一般迭代法 $\{x_k\}_{k \geq 1} \rightarrow x^*$, 记 $\varepsilon_k = |x_k - x^*|$.

定义 12.1 收敛阶 (Convergence order)

线性收敛 (linear conv)

$$\lim_{n \rightarrow +\infty} \frac{\varepsilon_{n+1}}{\varepsilon_n} = C < 1.$$

超线性收敛 (superlinear conv)

$$\lim_{n \rightarrow +\infty} \frac{\varepsilon_{n+1}}{\varepsilon_n} = 0.$$

p 阶收敛

$$\lim_{n \rightarrow +\infty} \frac{\varepsilon_{n+1}}{\varepsilon_n^p} = C > 0, \quad p > 1.$$

超 p 阶收敛

$$\lim_{n \rightarrow +\infty} \frac{\varepsilon_{n+1}}{\varepsilon_n^p} = 0, \quad p > 1.$$

此处 p 阶收敛与数值积分 p 阶收敛不同, 事实上, 对于后者, $|I - I_N| = \mathcal{O}(N^{-p})$.

设从 n_0 开始, 设 $\varepsilon_{n_0+k} = \varepsilon_{n_0} \cdot 10^{-\delta_k}$:

(1) 线性收敛: $\varepsilon_{n_0+k} = \varepsilon_{n_0} C^k$, 故

$$C^k = 10^{-\delta_k} \implies \delta_k = k \log_{10} C^{-1}.$$

(2) p 阶收敛: $\varepsilon_{n_0+k} = \varepsilon_{n_0}^p C^{\frac{p^k-1}{p-1}}$, 故

$$\begin{aligned} \varepsilon_{n_0}^{p^k-1} C^{\frac{p^k-1}{p-1}} = 10^{-\delta_k} &\implies (p^k - 1) \log_{10} \varepsilon_{n_0}^{-1} - \frac{p^k - 1}{p - 1} \log_{10} C = \delta_k, \\ &\implies p^k \left((1 - p^{-k}) \log_{10} \varepsilon_{n_0}^{-1} - \frac{1 - p^{-k}}{p - 1} \log_{10} C \right) = \delta_k \\ &\implies \delta_k = \mathcal{O}(p^k). \end{aligned}$$

对于非线性方程 $f(x) = 0$.

二分法 (bisection)

若 $f(a)f(b) < 0$, 则考虑 $\frac{1}{2}(a+b)$. 此时是线性收敛, 全局收敛 (Global).

不动点迭代 (fixed point iteration)

考虑 $x_{k+1} = \varphi(x_k)$, 其中 φ 连续, 分析 $x_k \rightarrow x^*$.

定理 12.1 压缩映像原理 (contraction mapping principle)

如果 $\{x_k\}_{k \geq 1} \subseteq [a, b]$, $\varphi : [a, b] \rightarrow [a, b]$ 满足

$$|\varphi(x) - \varphi(y)| \leq L|x - y|, \quad L < 1,$$

则 $\forall x_0 \in [a, b]$, 都有

$$|x_k - x^*| \leq \frac{L^k}{1 - L}|x_1 - x_0|.$$

证明.

由于 $|x_{n+k} - x_{n+k-1}| \leq L^k|x_{n+1} - x_n|$, 故

$$|x_{n+k} - x_n| \leq (L^k + \cdots + L + 1)|x_{n+1} - x_n| \leq \frac{L^n - L^{n+k+1}}{1 - L}|x_1 - x_0|,$$

故 $\{x_k\}$ 为 Cauchy 列, 设 $\{x_k\} \rightarrow x^*$, 则

$$|x^* - x_n| \leq \frac{L^n}{1 - L}|x_1 - x_0|.$$

□

局部收敛性

定义 12.2 局部收敛

如果存在 x^* 的邻域 $B_\delta(x^*)$, 使得 $x_{k+1} = \varphi(x_k)$ 对 $\forall x_0 \in B_\delta(x^*)$ 都收敛, 则称迭代法在 x^* 处局部收敛.

定理 12.2

设 x^* 为 φ 的不动点, $\varphi'(x)$ 在 x^* 邻域内连续, 如果 $|\varphi'(x^*)| < 1$, 则迭代法局部收敛.

证明.

取 δ 充分小, 使得 $|\varphi'(x)| \leq L < 1, \forall x \in B_\delta(x^*)$, 则

$$|\varphi(x) - \varphi(x^*)| = |\varphi'(\xi)||x - x^*| \leq |\varphi'(\xi)|\delta \leq L\delta < \delta,$$

且

$$|\varphi(x) - \varphi(y)| = |\varphi'(\xi)||x - y| \leq L|x - y|, \quad \forall x, y \in B_\delta(x^*).$$

□

Newton 法

由于 $f(x) \approx f(x_k) + f'(x_k)(x - x_k) = 0$, 故

$$x_{k+1} = x_k - \frac{f(x_k)}{f'(x_k)},$$

此时

$$\varphi(x) = x - \frac{f(x)}{f'(x)},$$

设 $f(x^*) = 0$ 且 $f'(x^*) \neq 0$. 注意到

$$\varphi'(x) = 1 - \frac{f'(x)^2 - f(x)f''(x)}{f'(x)^2},$$

故 $\varphi'(x^*) = 0$.

定理 12.3

对于 $x_{k+1} = \varphi(x_k)$, 如果 $\forall m \leq p$, $\varphi^{(m)}(x)$ 都在 x^* 处连续, 并且 $\forall 1 \leq m \leq p-1$, 都有 $\varphi^{(m)}(x^*) = 0$, 以及 $\varphi^{(p)}(x^*) \neq 0$, 则 $\{x_k\}$ 为 p 阶收敛.

证明.

注意到

$$x_{k+1} - x^* = \varphi(x_k) - \varphi(x^*) = \sum_{m=1}^{p-1} \frac{\varphi^{(m)}(x^*)}{m!} (x_k - x^*)^m + \frac{\varphi^{(p)}(\xi)}{p!} (x_k - x^*)^p = \frac{\varphi^{(p)}(\xi)}{p!} (x_k - x^*)^p,$$

故

$$\lim_{k \rightarrow +\infty} \frac{\varepsilon_{k+1}}{\varepsilon_k^p} = \frac{|\varphi^{(p)}(x^*)|}{p!} \neq 0.$$

□

对于 Newton 法而言,

$$\varphi'(x) = \frac{f(x)f''(x)}{f'(x)^2}, \quad \varphi''(x) = \frac{(f(x)f''(x))'f'(x)^2 - f(x)f''(x)(f'(x)^2)'}{f'(x)^4},$$

故

$$\varphi''(x^*) = \frac{f''(x^*)}{f'(x^*)},$$

从而如果 $f'(x^*), f''(x^*) \neq 0$, 则 Newton 法 2 阶收敛.

如果 $f'(x^*) = 0$ 或者 $f'(x^*) \approx 0$, 则 Newton 法可能不收敛, 或者退化为线性收敛.

割线法 (Secant)

用差商代替微商可得

$$x_{k+1} = x_k - \frac{f(x_k)(x_k - x_{k-1})}{f(x_k) - f(x_{k-1})}.$$

定理 12.4

设 $f(x)$ 在 $B_\delta(x^*)$ 内 C^2 , 且 $\forall x \in B_\delta(x^*)$, 都有 $f'(x) \neq 0$, 则当 δ 充分小时, 割线法以 $p = \frac{\sqrt{5}+1}{2}$ 阶收敛.

证明.

首先证明局部收敛. 记

$$p_1(x) = f(x_k) \frac{x - x_{k-1}}{x_k - x_{k-1}} + f(x_{k-1}) \frac{x - x_k}{x_{k-1} - x_k},$$

则

$$f(x) - p_1(x) = \frac{f''(\xi_x)}{2!} (x - x_k)(x - x_{k-1}),$$

再取 $x = x^*$ 可得

$$p_1(x^*) = -\frac{f''(\xi_1)}{2} (x^* - x_k)(x^* - x_{k-1}).$$

又

$$-p_1(x^*) = p_1(x_{k+1}) - p_1(x^*) = \frac{f(x_k) - f(x_{k-1})}{x_k - x_{k-1}} (x_{k+1} - x^*) = f'(\xi_2)(x_{k+1} - x^*),$$

故

$$x_{k+1} - x^* = \frac{f''(\xi_1)}{2f'(\xi_2)} (x_k - x^*)(x_{k-1} - x^*).$$

再令

$$M_\delta = \frac{\max_{x \in B_\delta(x^*)} |f''(x)|}{\min_{x \in B_\delta(x^*)} 2|f'(x)|},$$

从而 $|x_{k+1} - x^*| \leq M_\delta \delta^2$, 只需 $M_\delta \delta < 1$, 即可保证 $|x_{k+1} - x^*| \leq \delta$, 这即为封闭性. 最后由

$$|x_{k+1} - x^*| \leq |x_k - x^*| \cdot M_\delta \delta$$

可得局部收敛性.

对于收敛阶, 考察

$$e_{k+1} = ce_k e_{k-1},$$

令 $\tilde{e}_k = \ln(ce_k)$, 则 $\tilde{e}_{k+1} = \tilde{e}_k + \tilde{e}_{k-1}$, 由此可得 $p = \frac{\sqrt{5}+1}{2}$ 阶收敛. □

代数多项式求根

考察

$$p_n(x) = \sum_{k=0}^n a_k x^k = 0,$$

采用 Newton 法

$$x_{k+1} = x_k - \frac{p_n(x_k)}{p'_n(x_k)},$$

多项式求值可采用**秦九昭算法**高效计算: 设

$$p_n(x) = (\cdots((a_n x + a_{n-1})x + a_{n-2})x + \cdots)x + a_0,$$

令

$$\begin{cases} b_n = a_n, \\ b_k = a_k + b_{k+1}z, \quad k = n-1, \cdots, 1, 0, \end{cases}$$

则 $b_0 = p_n(z)$, 且易证 $p_n(x) = b_0 + (x - z)q_{n-1}(x; z)$, 其中

$$q_{n-1}(x; z) = \sum_{k=1}^n b_k x^{k-1},$$

称为 p_n 的**关联多项式**, 同时 $p'_n(z) = q_{n-1}(z; z)$.

依此类推可以求出 $p_n(x)$ 的所有根, 这称为**降阶法 (Deflation)**.

考虑高维非线性方程 $\vec{F}(\vec{x}^*) = \vec{d}$, 其中 $\vec{F}: \mathbb{R}^d \rightarrow \mathbb{R}^d$.

稳定性 (条件数)

设 $\vec{F}(\vec{x}^* + \delta\vec{x}) = \vec{d} + \delta\vec{d}$, 我们需要考察

$$K_{\text{rel}} := \frac{\|\delta\vec{x}\|/\|\vec{x}^*\|}{\|\delta\vec{d}\|/\|\vec{d}\|}$$

的有界性. 设 Jacobi 矩阵 $J_F = J_F(\vec{x}^*) = \partial_{\vec{x}} \vec{F}$, 则

$$\vec{F}(\vec{x}^*) + J_F \delta\vec{x} \approx \vec{d} + \delta\vec{d},$$

即 $J_F \delta \vec{x} \approx \delta \vec{d}$. 设 J_F^{-1} 存在, 则

$$K_{\text{rel}} \approx \frac{\|J_F^{-1}\| \|\vec{d}\|}{\|\vec{x}^*\|}.$$

对于线性方程 $Ax = b$ 而言, 有 $A\delta x = \delta b$, 故

$$K_{\text{rel}} = \frac{\|\delta \vec{x}\| / \|\vec{x}\|}{\|\delta \vec{b}\| / \|\vec{b}\|} \leq \frac{\|A^{-1}\| \|\vec{b}\|}{\|\vec{x}\|} \leq \|A\| \|A^{-1}\|,$$

这即为条件数.

停机条件

设 $\vec{F}(\vec{x}) = \vec{0}$.

条件 1: $\|\vec{F}(\vec{x}_k)\| \leq \varepsilon$. 设 $\vec{x}_k - \vec{x}^* = \vec{e}_k$, 则

$$\vec{F}(\vec{x}_k) = \vec{F}(\vec{x}_k) - \vec{F}(\vec{x}^*) \approx J_F(\vec{x}_k - \vec{x}^*) = J_F \vec{e}_k$$

故 $\|J_F\| \|\vec{e}_k\| \approx \|J_F \vec{e}_k\| \leq \varepsilon$, 从而

$$\frac{\|\vec{e}_k\|}{\|\vec{x}^*\|} \leq \|J_F\|^{-1} \varepsilon.$$

条件 2: $\|\vec{x}_{k+1} - \vec{x}_k\| \leq \varepsilon$. 设 $\vec{x}_{k+1} = \vec{\varphi}(\vec{x}_k)$, 则

$$\vec{e}_{k+1} = \vec{x}_{k+1} - \vec{x}^* = \vec{\varphi}(\vec{x}_k) - \vec{\varphi}(\vec{x}^*) \approx J_{\varphi} \vec{e}_k,$$

故

$$\|\vec{x}_{k+1} - \vec{x}_k\| = \|\vec{e}_{k+1} - \vec{e}_k\| \approx \|J_{\varphi} \vec{e}_k - \vec{e}_k\| \leq \|J_{\varphi} - I\| \|\vec{e}_k\|,$$

从而

$$\frac{\|\vec{e}_k\|}{\|\vec{x}^*\|} \approx \frac{\varepsilon}{\|J_{\varphi} - I\|} \frac{1}{\|\vec{x}^*\|}.$$

第十三章 非线性方程组数值解

考虑 $F(X) = 0$, 其中 $F: \mathbb{R}^d \rightarrow \mathbb{R}^d$, 采用迭代法 $X_{k+1} = \varphi(X_k)$. 由于

$$F(X) \approx F(X_k) + J_F(X_k)(X - X_k) = 0,$$

故

$$X_{k+1} = X_k - J_F(X_k)^{-1}F(X_k),$$

这即为 Newton 法. 再设 $\varphi: B_\delta^* \rightarrow B_\delta^*$ 满足 $\|\varphi(X) - \varphi(Y)\| \leq L\|X - Y\|$, 其中 $L < 1$ 且 B_δ^* 为有界闭集, 则

$$\|X_k - X^*\| \leq \frac{L^k}{1-L} \|X_1 - X_0\|.$$

引理 13.1

如果谱半径 $\rho(J_\varphi(X^*)) = \sigma < 1$, 则存在 $\delta > 0$, 使得 $\forall X_0 \in B_\delta(X^*)$, 迭代法都局部收敛.

证明.

由于 $\rho(J_\varphi(X^*)) = \sigma < 1$, 故存在范数 $\|\cdot\|$, 使得 $\|J_\varphi(X^*)\| \leq \sigma + \varepsilon < 1$ (见 Horn-Johnson: Matrix Analysis), 从而

$$\begin{aligned} \|X_{k+1} - X^*\| &= \|\varphi(X_k) - \varphi(X^*)\| \\ &= \left\| \int_0^1 d\varphi(tX_k + (1-t)X^*) \right\| \\ &= \left\| \int_0^1 J_\varphi(tX_k + (1-t)X^*)(X_k - X^*) dt \right\| \\ &\leq \left\| \int_0^1 J_\varphi(tX_k + (1-t)X^*) dt \right\| \cdot \|X_k - X^*\| \\ &\leq \int_0^1 \|J_\varphi(tX_k + (1-t)X^*)\| dt \cdot \|X_k - X^*\|, \end{aligned}$$

而 $\|J_\varphi(X^*)\| < 1$, 故存在 $\delta > 0$, 使得 $\forall X \in B_\delta(X^*)$, 都有 $\|J_\varphi(X)\| \leq L < 1$, 因此

$$\|X_{k+1} - X^*\| \leq L\|X_k - X^*\|,$$

进而 $\|X_k - X^*\| \leq L^k\|X_0 - X^*\| \rightarrow 0$.

□

Newton 法的收敛性

设 $J_F(X^*)$ 可逆, 则

$$X^* = X^* - J_F(X^*)^{-1}F(X^*),$$

即 $F(X^*) = 0$. 再设 $F \in C^2$, 并且

$$\varphi(X) = X - J_F(X)^{-1}F(X),$$

则 $J_\varphi(X^*) = I - I = O$, 故 Newton 法局部收敛.

定理 13.1

如果 $J_F(X^*)$ 非奇异, $F \in C^2$, 则 Newton 法二阶收敛.

证明.

注意到

$$\begin{aligned} X_{k+1} - X^* &= X_k - J_F(X_k)^{-1}F(X_k) - X^* \\ &= X_k - X^* - J_F(X_k)^{-1}(F(X_k) - F(X^*)) \\ &= -J_F(X_k)^{-1}(F(X_k) - F(X^*) - J_F(X_k)(X_k - X^*)) \\ &= -J_F(X_k)^{-1} \left[\int_0^1 dF(tX_k + (1-t)X^*) - \int_0^1 J_F(X_k) dt (X_k - X^*) \right] \\ &= -J_F(X_k)^{-1} \int_0^1 [J_F(tX_k + (1-t)X^*) - J_F(X_k)] dt \cdot (X_k - X^*), \end{aligned}$$

其中

$$J_F(tX_k + (1-t)X^*) - J_F(X_k) = - \int_t^1 dJ_F(sX_k + (1-s)X^*) ds = \mathcal{O}(\|X_k - X^*\|),$$

故 $\|X_{k+1} - X^*\| = \mathcal{O}(\|X_k - X^*\|^2)$, 从而 Newton 法二阶收敛. $\square$

逆 Newton 法 (quasi-Newton)

由于计算 $J_F(X_k) \in \mathbb{R}^{d \times d}$ 的代价过大, 其中 $J_F(X) = (\partial_i F_j)_{1 \leq i, j \leq d}$, 故采用逆 Newton 法, 具体而言, 利用 Broyden 方法

$$X_{k+1} = X_k - A_k^{-1}F(X_k),$$

其中 $A_k \approx J_F(X_k)$, 希望满足“割线条件” $A_k(X_k - X_{k-1}) = F(X_k) - F(X_{k-1})$. 记

$$Y_{k-1} = \Delta X_{k-1} = X_k - X_{k-1}, \quad g_{k-1} = \Delta F(X_{k-1}) = F(X_k) - F(X_{k-1}).$$

采用低秩修正. 秩 1 修正: $A_k = A_{k-1} + vw^T$, 令

$$(A_{k-1} + vw^T)Y_{k-1} = g_{k-1},$$

则

$$\begin{aligned}
 v &= \frac{1}{w^T Y_{k-1}} (g_{k-1} - A_{k-1} Y_{k-1}) \\
 &= \frac{1}{w^T Y_{k-1}} (F(X_k) - F(X_{k-1}) - A_{k-1} (X_k - X_{k-1})) \\
 &= \frac{1}{w^T Y_{k-1}} (F(X_k) - F(X_{k-1}) + F(X_{k-1})) \\
 &= \frac{F(X_k)}{w^T Y_{k-1}}.
 \end{aligned}$$

选取 1: 取 $w = Y_{k-1}$, 则 $v = F(X_k) / \|Y_{k-1}\|_2^2$.

选取 2: 取 $\omega = F(X_k)$, 则 vw^T 对称, 故 A_k 也对称, 此时对 $F(X) = \nabla f(X)$ 适用, $J_F(X) = \nabla^2 f(X)$ 也对称.

定理 13.2 Sherman-Morrison 公式

秩 1 修正有如下求逆公式

$$(A + vw^T)^{-1} = A^{-1} - \frac{A^{-1}v \cdot w^T A^{-1}}{1 + w^T A^{-1}v}.$$

由此可得每次计算 A_k^{-1} 只需 $\mathcal{O}(d^2)$ 的代价.

定理 13.3 Dennis-Schnabel

Broyden 局部超线性收敛.

第十四章 快速 Fourier 变换 (FFT)

设 $f(x)$ 以 2π 为周期, 考虑

$$\int_0^{2\pi} f(x) e^{-ikx} dx \approx \sum_{j=0}^{N-1} f(x_j) e^{ikx_j} h,$$

其中 $x_j = jh$, $h = 2\pi/N$, 并记 $f_j := f(x_j)$. 令

$$\hat{f}_k := \sum_{j=0}^{N-1} f_j e^{i \frac{jk}{N} 2\pi}, \quad 0 \leq k \leq N-1,$$

这称为**离散 Fourier 变换 (DFT)**. 平凡的算法的计算复杂度为 $\mathcal{O}(N^2)$, 而 **FFT** 可以将计算复杂度改进为 $\mathcal{O}(N \log N)$.

Fourier 变换

设 $f \in L^1(\mathbb{R})$, 定义 $f(x)$ 的 **Fourier 变换**为

$$\hat{f}(k) = \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} f(x) e^{-ikx} dx,$$

以及 $g(k)$ 的**逆 Fourier 变换**为

$$\check{g}(x) := \frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} g(k) e^{ikx} dk,$$

则如果 $f \in L^1 \cap L^2$, 则 $\check{\hat{f}}(x) = f(x)$. 类似可推广到 $\mathbb{R}^d$.

Fourier 变换有如下基本性质:

- (1) $(f')^\wedge(k) = ik \hat{f}(k)$;
- (2) $(f(x-a))^\wedge = e^{-ika} \hat{f}(k)$;
- (3) 如果 $f, g \in L^2$, 则 $(f * g)^\wedge = \hat{f}(k) \cdot \hat{g}(k)$;
- (4) 如果 $f \in L^2$, 则 $\|f\|_{L^2} = \|\hat{f}\|_{L^2}$.

事实上,

(1)

$$\int_{\mathbb{R}} f'(x) e^{-ikx} dx = - \int_{\mathbb{R}} f(x) e^{-ikx} (-ik) dx = ik \hat{f}(k);$$

(2)

$$\int_{\mathbb{R}} f(x-a)e^{-ikx} dx = \int_{\mathbb{R}} f(y)e^{-ik(y+a)} dy = e^{-ika} \hat{f}(k);$$

(3) 由于 $f * g(x) = \int_{\mathbb{R}} f(x-y)g(y) dy$, 故

$$(f * g)^{\wedge} = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x-y)g(y) dy e^{-ikx} dx = \int_{\mathbb{R}} \int_{\mathbb{R}} f(x-y)g(y) e^{-ik(x-y)-iky} dy dx = \hat{f}(k)\hat{g}(k);$$

(4)

$$\begin{aligned} \|f\|_{L^2}^2 &= \int_{\mathbb{R}} f(x)f^*(x) dx \\ &= \int_{\mathbb{R}} \left(\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \hat{f}(k)e^{ikx} dk \right) \left(\frac{1}{\sqrt{2\pi}} \int_{\mathbb{R}} \hat{f}^*(j)e^{-ijx} dj \right) dx \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} \hat{f}(k)\hat{f}^*(j) \frac{1}{2\pi} \left(\int_{\mathbb{R}} e^{i(k-j)x} dx \right) dk dj \\ &= \int_{\mathbb{R}} \int_{\mathbb{R}} \hat{f}(k)\hat{f}^*(j)\delta(k-j) dk dj \\ &= \int_{\mathbb{R}} \hat{f}(k)\hat{f}^*(k) dk = \|\hat{f}\|_{L^2}^2. \end{aligned}$$

Fourier 级数

设 f 以 2π 为周期, 并且 $f \in L^2[0, 2\pi]$, 令

$$\hat{f}_k := \frac{1}{\sqrt{2\pi}} \int_0^{2\pi} f(x)e^{-ikx} dx, \quad k \in \mathbb{Z},$$

以及 **Fourier 级数**为

$$f_N(x) := \frac{1}{\sqrt{2\pi}} \sum_{k=-N}^N \hat{f}_k e^{ikx}.$$

Fourier 级数有如下基本性质:

- (1) $(f')_k^{\wedge} = ik\hat{f}_k$;
- (2) $(f(x-a))_k^{\wedge} = e^{-ika}\hat{f}_k$;
- (3) 如果 $f, g \in L^2[0, 2\pi]$ 并且以 2π 为周期, $f * g(x) := \int_0^{2\pi} f(x-y)g(y) dy$, 则 $(f * g)_k^{\wedge} = \hat{f}_k \cdot \hat{g}_k$;
- (4) 如果 $f \in L^2[0, 2\pi]$, 则

$$\|f\|_{L^2[0, 2\pi]}^2 = \sum_{k \in \mathbb{Z}} |\hat{f}_k|^2;$$

- (5) $\|f - f_N\|_{L^2} \rightarrow 0, N \rightarrow +\infty$;
- (6) **Gibbs 现象**: 对于间断函数 $f(x)$, 在间断点附近 $f_N(x)$ 可能会形成**过冲 (overshoot)**;
- (7) 如果 $f \in C^s[0, 2\pi]$, 其中 $s \geq 1$, 则

$$\|f - f_N\|_{L^\infty} \leq CN^{\frac{1}{2}-s} \|f\|_{H^s}, \quad \|f\|_{H^s} := \left(\sum_{k=0}^s \|f^{(k)}\|_{L^2}^2 \right)^{1/2};$$

(8) 如果 f 实解析, 则

$$\|f - f_N\|_{L^\infty} \leq e^{-\alpha N}, \quad \alpha > 0;$$

(9) 如果 f 间断, 则 $\|f - f_N\|_{L^\infty} \not\rightarrow 0$, 并且对于非间断点 x , 有 $|f(x) - f_N(x)| \sim \mathcal{O}(1/N)$, 同时对于间断点 x , 有 $f_N(x) \rightarrow (f(x+0) + f(x-0))/2$ (可采用 filtering 技术消除 Gibbs 现象, 见 Gottlieb-Shu, SIAM Review 39(1997),644)

DFT

我们需要计算

$$\hat{a}_k := c_k = \sum_{j=0}^{N-1} a_j e^{-jk \frac{2\pi i}{N}}, \quad 0 \leq k \leq N-1,$$

即 DFT: $\{a_j\}_{0 \leq j \leq N-1} \rightarrow \{c_k\}_{0 \leq k \leq N-1}$. 定义卷积

$$(f * g)_j := \sum_{\ell=0}^{N-1} f_{j-\ell} g_\ell, \quad 0 \leq j \leq N-1,$$

其中指标以 N 为周期, 则

$$\begin{aligned} (f * g)_k^\wedge &= \sum_{j=0}^{N-1} (f * g)_j e^{-jk \frac{2\pi i}{N}} \\ &= \sum_{j=0}^{N-1} \left(\sum_{\ell=0}^{N-1} f_{j-\ell} g_\ell \right) e^{-(j-\ell)k \frac{2\pi i}{N} - \ell k \frac{2\pi i}{N}} \\ &= \hat{f}_k \cdot \hat{g}_k, \end{aligned}$$

并且

$$\begin{aligned} \sum_{k=0}^{N-1} |\hat{f}_k|^2 &= \sum_{k=0}^{N-1} \hat{f}_k^* \hat{f}_k \\ &= \sum_{k=0}^{N-1} \left(\sum_{j=0}^{N-1} f_j^* e^{jk \frac{2\pi i}{N}} \right) \left(\sum_{\ell=0}^{N-1} f_\ell e^{-\ell k \frac{2\pi i}{N}} \right) \\ &= \sum_{k,j,\ell=0}^{N-1} f_j^* f_\ell e^{k(j-\ell) \frac{2\pi i}{N}} \\ &= N \sum_{j,\ell=0}^{N-1} f_j^* f_\ell \delta_{j,\ell} \\ &= N \sum_{j=0}^{N-1} f_j^* f_j = N \sum_{j=0}^{N-1} |f_j|^2. \end{aligned}$$

再定义 **IDFT**:

$$a_j := \frac{1}{N} \sum_{k=0}^{N-1} c_k e^{jk \frac{2\pi i}{N}}, \quad 0 \leq j \leq N-1,$$

事实上,

$$\begin{aligned} \frac{1}{N} \sum_{k=0}^{N-1} c_k e^{jk \frac{2\pi i}{N}} &= \frac{1}{N} \sum_{k=0}^{N-1} \left(\sum_{\ell=0}^{N-1} a_\ell e^{-\ell k \frac{2\pi i}{N}} \right) e^{jk \frac{2\pi i}{N}} \\ &= \frac{1}{N} \sum_{k,\ell=0}^{N-1} a_\ell e^{k(j-\ell) \frac{2\pi i}{N}} = a_j. \end{aligned}$$

FFT

令 $F = (f_{jk})_{0 \leq j, k \leq N-1}$, 其中 $f_{jk} = e^{-jk \frac{2\pi i}{N}}$, 则 $F^T = F$, 并且 $\bar{F} = NF^{-1}$, 以及 $\vec{a} = \frac{1}{N} \bar{F} \vec{c} = F^{-1} \vec{c}$.
当 $N = 2$ 时,

$$F = \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix}, \quad F \vec{a} = \begin{pmatrix} a_0 + a_1 \\ a_0 - a_1 \end{pmatrix};$$

当 $N = 4$ 时,

$$F = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & -i & -1 & i \\ 1 & -1 & 1 & -1 \\ 1 & i & -1 & -i \end{pmatrix}, \quad F \vec{a} = \begin{pmatrix} a_0 + a_2 + (a_1 + a_3) \\ a_0 - a_2 - i(a_1 - a_3) \\ a_0 + a_2 - (a_1 + a_3) \\ a_0 - a_2 + i(a_1 - a_3) \end{pmatrix}.$$

取 $N = 2^m$, 考虑计算

$$c_k = \sum_{j=0}^{N-1} a_j e^{-jk \frac{2\pi i}{N}}, \quad \forall 0 \leq k \leq N-1,$$

采用 **Danielson-Lanczos 表述**: 由于

$$p(x) = a_0 + a_1 x + \cdots + a_{N-1} x^{N-1} = p_e(x^2) + x p_o(x^2),$$

其中

$$p_e(t) = a_0 + a_2 t + \cdots + a_{N-2} t^{\frac{N}{2}-1}, \quad p_o(t) = a_1 + a_3 t + \cdots + a_{N-1} t^{\frac{N}{2}-1},$$

再令 N 次单位根 $\omega_N = e^{\frac{2\pi i}{N}}$, 取 $x = \omega_N^{-k}$. $\forall 0 \leq k \leq N/2 - 1$, 由于

$$c_k = p(\omega_N^{-k}) = p_e(\omega_N^{-2k}) + \omega_N^{-k} p_o(\omega_N^{-2k}),$$

并且 $\omega_N^{-2k} = e^{\frac{2\pi i}{N/2} \cdot (-k)} = \omega_{N/2}^{-k}$, 故

$$c_k = p_e(\omega_{N/2}^{-k}) + \omega_N^{-k} p_o(\omega_{N/2}^{-k});$$

$\forall N/2 \leq k \leq N-1$, 令 $k = N/2 + \tilde{k}$, 其中 $0 \leq \tilde{k} \leq N/2 - 1$, 则

$$c_k = p_e(\omega_{N/2}^{-(N/2+\tilde{k})}) + \omega_N^{-(N/2+\tilde{k})} p_o(\omega_{N/2}^{-(N/2+\tilde{k})}) = p_e(\omega_{N/2}^{-\tilde{k}}) - \omega_N^{-\tilde{k}} p_o(\omega_{N/2}^{-\tilde{k}}).$$

因此 $p_e(t)$ 和 $p_o(t)$ 分别实现了 $N/2$ 情形的 DFT:

$$(a_0, a_2, \dots, a_{N-2})^T \mapsto c^{(1)}, \quad (a_1, a_3, \dots, a_{N-1})^T \mapsto c^{(2)}.$$

我们通过递归实现了 FFT, 下面分析复杂度. 设 N 情形下 FFT 使用的乘法次数为 M_N , 加法次数为 A_N , 则

$$M_N = 2M_{N/2} + N/2, \quad M_1 = 0; \quad A_N = 2A_{N/2} + N, \quad A_1 = 0,$$

故

$$M_N = \frac{1}{2} N \log_2 N, \quad A_N = N \log_2 N.$$

实际操作中, 以 $N = 8$ 为例: 设 $a = (a_0, a_1, \dots, a_7)$, 先依次进行分割

- (1) $a_e = (a_0, a_2, a_4, a_6), a_o = (a_1, a_3, a_5, a_7)$;
- (2) $a_{ee} = (a_0, a_4), a_{eo} = (a_2, a_6), a_{oe} = (a_1, a_5), a_{oo} = (a_3, a_7)$;
- (3) $a_{eee} = a_0, a_{eeo} = a_4, \dots, a_{ooo} = a_7$,

这里令 $e \rightarrow 0, o \rightarrow 1$, 实际上为 2 进制的反序, 然后再依次进行组装

$$c_{ee} = (a_0 + \omega_2^0 a_4, a_0 - \omega_2^0 a_4), \quad \dots, \quad c_{oo} = (a_3 + \omega_2^0 a_7, a_3 - \omega_2^0 a_7),$$

后面类似.

第十五章 FFT 的应用

DST(Discrete Sine Transform)

给定 $\{a_j\}_{1 \leq j \leq N-1}$, 并且 $a_0 = 0$, 需要计算

$$c_k = \sum_{j=1}^{N-1} a_j \sin\left(\frac{jk\pi}{N}\right), \quad \forall 1 \leq k \leq N-1.$$

先作奇延拓, 再作周期延拓, 将 $\{a_j\}_{0 \leq j \leq N-1}$ 延拓为 $\{\tilde{a}_j\}_{0 \leq j \leq 2N-1}$, 其中 $a_N = 0$, 并且

$$\tilde{a}_j = \begin{cases} a_j, & 0 \leq j \leq N-1; \\ -\tilde{a}_{-j} = -\tilde{a}_{2N-j} = -a_{2N-j}, & N \leq j \leq 2N-1. \end{cases}$$

故 $\forall 0 \leq k \leq N-1$, 都有

$$\begin{aligned} \tilde{c}_k &= \sum_{j=0}^{2N-1} \tilde{a}_j e^{-jk \frac{2\pi i}{2N}} \\ &= \sum_{j=1}^{N-1} a_j e^{-jk \frac{\pi i}{N}} + \sum_{j=N+1}^{2N-1} -a_{2N-j} e^{-jk \frac{\pi i}{N}} \\ &= \sum_{j=1}^{N-1} a_j e^{-jk \frac{\pi i}{N}} - \sum_{j=1}^{N-1} a_j e^{-(2N-j)k \frac{\pi i}{N}} \\ &= \sum_{j=1}^{N-1} a_j \left(e^{-jk \frac{\pi i}{N}} - e^{jk \frac{\pi i}{N}} \right) \\ &= -2 \sum_{j=1}^{N-1} a_j \sin\left(\frac{jk\pi}{N}\right), \end{aligned}$$

从而通过延拓和 $2N$ 情形的 FFT 实现了**快速正弦变换 (FST)**.

再定义 **IDST**:

$$a_j = \frac{2}{N} \sum_{k=1}^{N-1} c_k \sin\left(\frac{jk\pi}{N}\right), \quad \forall 1 \leq j \leq N-1.$$

我们还有 **DCT**:

$$c_k = \frac{1}{2}(a_0 + (-1)^k a_N) + \sum_{j=1}^{N-1} a_j \cos\left(\frac{jk\pi}{N}\right), \quad \forall 0 \leq k \leq N,$$

以及 **Q-DCT(Quarter-wave DCT)**:

$$c_k = \sum_{j=0}^{N-1} a_j \cos \left(\frac{(j + \frac{1}{2})k\pi}{N} \right), \quad \forall 0 \leq k \leq N-1.$$

多维 FFT

考虑

$$c_{\vec{k}} = \sum_{j_1=0}^{N_1-1} \cdots \sum_{j_d=0}^{N_d-1} a_{\vec{j}} e^{-\left(j_1 k_1 \frac{2\pi i}{N_1} + \cdots + j_d k_d \frac{2\pi i}{N_d}\right)}, \quad \vec{j} = (j_1, \cdots, j_d), \quad \vec{k} = (k_1, \cdots, k_d).$$

定义 $\vec{N} = (N_1, \cdots, N_d)$, 以及 $N = \prod_{j=1}^d N_j$, 则直接计算的计算复杂度为 $\mathcal{O}(N^2)$. 如果在各个维度上分别采用 FFT, 以 2 维为例, 由于

$$N_1 \cdot N_2 \log_2 N_2 + N_2 \cdot N_1 \log_2 N_1 = N \log_2 N,$$

故计算复杂度为 $\mathcal{O}(N \log_2 N)$.

卷积

考虑计算 $\{(f * g)_j\}$, 由于

$$(f * g) = ((f * g)^\wedge)^\vee = (\hat{f}_k \hat{g}_k)^\vee,$$

故计算复杂度为 $3N \log_2 N + N$.

循环矩阵方程组

考虑求解 $CX = b$, 其中

$$C = \begin{pmatrix} c_0 & c_{N-1} & \cdots & c_1 \\ c_1 & c_0 & \cdots & c_2 \\ \vdots & \vdots & \ddots & \vdots \\ c_{N-1} & c_{N-2} & \cdots & c_0 \end{pmatrix},$$

即 $C_{ij} = c_{i-j}, \forall 0 \leq i, j \leq N-1$, 其中 c_j 对下标以 N 为周期. 注意到

$$b_i = \sum_{j=0}^{N-1} c_{ij} x_j = \sum_{j=0}^{N-1} c_{i-j} x_j = (c * X)_i,$$

故作用一次 DFT 可得 $\hat{c}_k \hat{x}_k = \hat{b}_k, \forall 0 \leq k \leq N-1$, 从而 $\hat{x}_k = \hat{b}_k / \hat{c}_k$, 再作用一次 IDFT 可得 x .

下面再考察循环矩阵的特征系. 注意到

$$c * X = CX = \lambda X,$$

故 $\hat{c}_k \hat{x}_k = \lambda \hat{x}_k$, 从而

$$\begin{cases} \lambda_{k_0} = \hat{c}_{k_0}, & \forall 0 \leq k_0 \leq N-1, \\ \hat{x}_k^{(k_0)} = \delta_{kk_0}, & \forall 0 \leq k \leq N-1, \end{cases}$$

因此 $(\vec{X}_{k_0})_j = e^{-jk_0 \frac{2\pi i}{N}}$.

求解微分方程

考虑 1 维 Poisson 方程

$$\begin{cases} u'' = f, & x \in (0, \pi), \\ u(0) = u(\pi) = 0, \end{cases}$$

取 $h = \pi/N$, 记 $u_j \approx u(jh)$, 则

$$\begin{cases} u_{j+1} - 2u_j + u_{j-1} = h^2 f_j, & 1 \leq j \leq N-1, \\ u_0 = u_N = 0. \end{cases}$$

采用 DST:

$$U_k = \sum_{j=1}^{N-1} u_j \sin\left(\frac{jk\pi}{N}\right) \iff u_j = \frac{2}{N} \sum_{k=1}^{N-1} U_k \sin\left(\frac{jk\pi}{N}\right),$$

代入方程可得

$$\sum_{k=1}^N U_k \left(\sin\left(\frac{(j+1)k\pi}{N}\right) - 2\sin\left(\frac{jk\pi}{N}\right) + \sin\left(\frac{(j-1)k\pi}{N}\right) \right) = h^2 \sum_{k=1}^N F_k \sin\left(\frac{jk\pi}{N}\right), \quad \forall 1 \leq j \leq N-1,$$

故

$$\sum_{k=1}^N U_k \left(-4 \sin^2\left(\frac{k\pi}{2N}\right) \right) \sin\left(\frac{jk\pi}{N}\right) = \sum_{k=1}^N h^2 F_k \sin\left(\frac{jk\pi}{N}\right),$$

从而

$$U_k = -F_k \cdot \frac{\left(\frac{\pi}{N}\right)^2}{4 \sin^2\left(\frac{k\pi}{2N}\right)}, \quad \forall 1 \leq k \leq N-1,$$

即

$$U_k \left(-4 \frac{\sin^2\left(\frac{k\pi}{2N}\right)}{\left(\frac{\pi}{N}\right)^2} \right) = F_k,$$

其中

$$-4 \frac{\sin^2\left(\frac{k\pi}{2N}\right)}{\left(\frac{\pi}{N}\right)^2} \rightarrow -k^2, \quad N \rightarrow +\infty.$$

下面再考虑该方程的特征系

$$\begin{cases} u'' = \lambda u, & x \in (0, \pi), \\ u(0) = u(\pi) = 0, \end{cases}$$

离散得到

$$\begin{cases} \frac{u_{j+1} - 2u_j + u_{j-1}}{h^2} = \lambda u_j, \\ u_0 = u_N = 0, \end{cases}$$

故 $(\hat{U}_{k_0})_k = \delta_{kk_0}$, 并且

$$\lambda_{k_0} = -4 \frac{\sin^2 \left(\frac{k\pi}{2N} \right)}{\left(\frac{\pi}{N} \right)^2}, \quad 1 \leq k_0 \leq N-1.$$

第十六章 快速 Gauss 变换

我们需要计算

$$u_k = \sum_{j=1}^N w_j K(x_j, y_k), \quad \forall 1 \leq k \leq M,$$

即 $w = (w_j) \mapsto u = (u_k)$, 其中 $K(x, y)$ 为核函数.

- (1) 从源 (source) 到靶 (target) 的引力或电场的势 (potential): $K(x, y) = \frac{1}{|x-y|}$, $x, y \in \mathbb{R}^3$.
- (2) 热核: $K(x, y) = e^{-\frac{|x-y|^2}{2\sigma^2}}$, $x, y \in \mathbb{R}^3$.
- (3) 力场: $\vec{K}(x, y) = \frac{x-y}{|x-y|^3}$, $x, y \in \mathbb{R}^3$.

直接计算的计算复杂度为 $\mathcal{O}(MN)$. FFT 的基于代数的 (Algebra-based) 快速算法无法使用, 需要使用基于分析的 (Analysis-based) FGT/FMM.

采用**低秩逼近**.

- (1) 如果 $K(x, y) = K_1(x)K_2(y)$, 则秩一, 此时

$$u_k = \sum_{j=1}^N w_j K_1(x_j) K_2(y_k) = M \cdot K_2(y_k),$$

其中 $M = \sum_{j=1}^N w_j K_1(x_j)$ 称为**矩 (moment)**, 计算复杂度为 $\mathcal{O}(M + N)$.

- (2) 如果 $K(x, y) = \sum_{n=1}^p K_{n,1}(x) K_{n,2}(y)$, 则秩 p , 此时

$$u_k = \sum_{n=1}^p \sum_{j=1}^N w_j K_{n,1}(x_j) K_{n,2}(y_k) = \sum_{n=1}^p M_n \cdot K_{n,2}(y_k),$$

计算复杂度为 $\mathcal{O}((M + N)p)$, 其中 $p = \mathcal{O}(1)$.

- (3) 低秩逼近: 取 $f(x) = e^{-x^2}$, 在 $x_0 = 0$ 处 Taylor 展开可得

$$\begin{aligned} e^{-(x-x_0)^2} &= f(x - x_0) \\ &= \sum_{n=0}^{+\infty} \frac{x_0^n}{n!} \frac{d^n}{dx_0^n} f(x - x_0) \Big|_{x_0=0} \\ &= \sum_{n=0}^{+\infty} (-1)^n \frac{x_0^n}{n!} \frac{d^n}{dx^n} f(x - x_0) \Big|_{x_0=0} \\ &= \sum_{n=0}^{+\infty} \frac{x_0^n}{n!} h_n(x), \end{aligned}$$

其中 Hermite 函数 $h_n(x) = e^{-x^2} H_n(x)$, Hermite 多项式

$$H_n(x) = (-1)^n e^{x^2} \frac{d^n}{dx^n} e^{-x^2}.$$

对于二维情形: 设 $\vec{x} = (x, y)$, $\vec{x}_0 = (x_0, y_0)$, 则

$$e^{-|\vec{x}-\vec{x}_0|^2} = \sum_{n_1=0}^{+\infty} \sum_{n_2=0}^{+\infty} \frac{x_0^{n_1}}{n_1!} \frac{y_0^{n_2}}{n_2!} h_{n_1}(x) h_{n_2}(y),$$

考虑平移也有

$$e^{-|\vec{x}-\vec{x}_0|^2} = \sum_{n_1=0}^{+\infty} \sum_{n_2=0}^{+\infty} \frac{(x_0 - c_x)^{n_1}}{n_1!} \frac{(y_0 - c_y)^{n_2}}{n_2!} h_{n_1}(x - c_x) h_{n_2}(y - c_y).$$

定理 16.1

对于 d 维情形, 如果 $|\vec{x}_j - \vec{c}| \leq r\sqrt{2\delta}$, $r = \mathcal{O}(1)$, 则

$$\left| e^{-|\vec{x}-\vec{x}_j|^2/\delta} - \sum_{n_1, \dots, n_d=0}^{p-1} \Phi_{\vec{n}}(\vec{x} - \vec{c}) \Psi_{\vec{n}}(\vec{x}_j - \vec{c}) \right| \leq \sum_{m=1}^d \binom{d}{m} \left(K p^{-\frac{1}{4}} \frac{r_p^p}{1 - r_p} \right)^m,$$

要求 $r_p = r\sqrt{e/p} < 1$, 其中

$$\Phi_{\vec{n}}(\vec{x}) = h_{\vec{n}}\left(\frac{\vec{x}}{\sqrt{\delta}}\right) := \prod_{k=1}^d h_{n_k}\left(\frac{x_k}{\sqrt{\delta}}\right), \quad \Psi_{\vec{n}}(\vec{x}) = \frac{1}{n!} \left(\frac{\vec{x}}{\sqrt{\delta}}\right)^{\vec{n}} := \prod_{k=1}^d \frac{1}{n_k!} \left(\frac{x_k}{\sqrt{\delta}}\right)^{n_k}.$$

见 X.Wan(G.Karniadakis), JCP 219(2006),7.

注意到

$$\left(K p^{-\frac{1}{4}} \frac{r_p^p}{1 - r_p} \right)^m = \mathcal{O}\left(\left(p^{-\frac{1}{4}} \cdot p^{-\frac{p}{2}}\right)^m\right).$$

对于情形 1: 所有 source 都在 $\vec{c}$ 的 $r\sqrt{2\delta}$ 的邻域内, 则

$$\begin{aligned} u_k &= \sum_{j=1}^N w_j K(\vec{x}_j, \vec{y}_k) \\ &\approx \sum_{j=1}^N w_j \sum_{n_1, n_2=0}^{p-1} \Phi_{n_1, n_2}(\vec{y}_k - \vec{c}) \Psi_{n_1, n_2}(\vec{x}_j - \vec{c}) \\ &= \sum_{n_1, n_2=0}^{p-1} \Phi_{n_1, n_2}(\vec{y}_k - \vec{c}) \sum_{j=1}^N w_j \Psi_{n_1, n_2}(\vec{x}_j - \vec{c}) \\ &= \sum_{n_1, n_2=0}^{p-1} \Phi_{n_1, n_2}(\vec{y}_k - \vec{c}) M_{n_1, n_2}, \end{aligned}$$

计算复杂度为 $\mathcal{O}((M+N)p^2)$.

对于情形 2: 一般情形, 由于 Gauss 核为短程相互作用, 故以边长 $\ell = 2r\sqrt{\delta}$ 进行网格划分, 对于每个

u_k , 只考虑以 u_k 为中心的边长为 $(2n+1)\ell$ 的大方形邻域 N_k^n , 其余的 $|\vec{y}_k - \vec{x}_j|^2/\delta > (2nr)^2$, 从而

$$\begin{aligned}
u_k &= \sum_{j=1}^N w_j e^{-|\vec{y}_k - \vec{x}_j|^2/\delta} \\
&= \sum_{x_j \in N_k^n} w_j e^{-|\vec{y}_k - \vec{x}_j|^2/\delta} + \mathcal{O}(e^{-4n^2 r^2}) \\
&\approx \sum_{B \in N_k^n} \left(\sum_{x_j \in B} w_j \sum_{n_1, n_2=0}^{p-1} \Phi_{n_1, n_2}(\vec{y}_k - c_B) \Psi_{n_1, n_2}(\vec{x}_j - c_B) \right) \\
&= \sum_{B \in N_k^n} \left(\sum_{n_1, n_2=0}^{p-1} \Phi_{n_1, n_2}(\vec{y}_k - c_B) \sum_{x_j \in B} w_j \Psi_{n_1, n_2}(\vec{x}_j - c_B) \right) \\
&= \sum_{B \in N_k^n} \left(\sum_{n_1, n_2=0}^{p-1} \Phi_{n_1, n_2}(\vec{y}_k - c_B) M_B \right),
\end{aligned}$$

其中 M_B 的计算复杂度为 $\mathcal{O}(Np^2)$, u_k 的计算复杂度为 $\mathcal{O}(Mp^2(2n+1)^2)$, 并且 $p, n = \mathcal{O}(1)$, 因此总计算复杂度为 $\mathcal{O}(M+N)$.

第十七章 常微分方程数值解

考虑 ODE:

$$\vec{y}' = \vec{f}(t, \vec{y}), \quad \vec{y}|_{t=0} = \vec{y}_0,$$

其中 $\vec{f}$ 满足 Lipschitz 条件

$$|\vec{f}(t, \vec{y}_1) - \vec{f}(t, \vec{y}_2)| \leq L|\vec{y}_1 - \vec{y}_2|,$$

解在大范围存在唯一.

ODE 的背景

- (1) Newton 方程: $\vec{F} = m\vec{a}$.
- (2) Hamilton 形式: $H(t) \equiv C$.
- (3) Lagrange 形式 (作用量极小, E-L 方程).
- (4) 化学反应 (刚性).
- (5) PDE 的离散.

求解思路

- (1) 时间导数离散为差分方程 (BDF 方法).
- (2) 微分转化为积分 (Adams 方法):

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y) dt.$$

- (3) Taylor 展开.

核心

- (1) Runge-Kutta 方法.
- (2) 刚性方程数值方法.
- (3) 试验方程 (Test equation).

基本构造

(1) 前向/显式 (Explicit) Euler:

$$\frac{y_{n+1} - y_n}{h} \approx y'(t_n) = f(t_n, y_n),$$

即

$$y_{n+1} = y_n + hf(t_n, y_n);$$

(2) 后向/隐式 (Implicit) Euler:

$$\frac{y_{n+1} - y_n}{h} \approx y'(t_{n+1}) = f(t_{n+1}, y(t_{n+1})) \approx f(t_{n+1}, y_{n+1}),$$

即

$$y_{n+1} = y_n + hf(t_{n+1}, y_{n+1}),$$

求解该非线性方程可以通过迭代:

$$\begin{cases} y_{n+1}^{(k+1)} = y_n + hf(t_{n+1}, y_{n+1}^{(k)}), \\ y_{n+1}^{(0)} = y_n, \end{cases}$$

或者 Newton 迭代;

(3) 梯形公式 (Trapezoidal rule):

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y) dt,$$

故

$$y_{n+1} = y_n + \frac{h}{2}(f(t_n, y_n) + f(t_{n+1}, y_{n+1})),$$

这是隐格式.

局部截断误差 (Local Truncation Error, LTE)

设 $y_n = y(t_n)$, 称 $\tau(h) := y(t_{n+1}) - y_{n+1}$ 为**局部截断误差**. 以上格式都是单步法 (Single-step).

相容性 (Consistency)

如果

$$\lim_{h \rightarrow 0+} \frac{\tau(h)}{h} = 0,$$

则称该格式为**相容的**.

对于格式

$$y_{n+1} = y_n + h\Phi(t_n, y_n; h),$$

有

$$\frac{\tau(h)}{h} = \frac{y(t_{n+1}) - y_{n+1}}{h} = \frac{y(t_n) + hf(t_n, y(t_n)) + \mathcal{O}(h^2) - y(t_n) - h\Phi(t_n, y(t_n); h)}{h},$$

故由相容性可得

$$\lim_{h \rightarrow 0+} \Phi(t_n, y(t_n); h) = f(t_n, y(t_n)).$$

称格式具有 $p+1$ 阶 **LTE**, 或称为 p 阶**相容**, 如果

$$\tau(h) = \mathcal{O}(h^{p+1}).$$

对于显式 Euler,

$$\tau(h) = y(t_{n+1}) - y_{n+1} = y(t_{n+1}) - [y(t_n) + hf(t_n, y(t_n))] = \mathcal{O}(h^2),$$

故为 1 阶相容.

对于梯形公式, 由 Taylor 展开可得

$$f(t_{n+1}, y_{n+1}) = f(t_n, y(t_n)) + \partial_t f \cdot h + \partial_y f \cdot \frac{h}{2} [f(t_n, y(t_n)) + f(t_{n+1}, y_{n+1})] + \mathcal{O}(h^2),$$

其中 $\partial_t f := \partial_t f|_{(t,y)=(t_n,y(t_n))}$, 故

$$\begin{aligned} y_{n+1} &= y(t_n) + \frac{h}{2}(f(t_n, y(t_n)) + f(t_{n+1}, y_{n+1})) \\ &= y(t_n) + \frac{h}{2} [2f(t_n, y(t_n)) + \partial_t f \cdot h + \partial_y f \cdot f \cdot h + \mathcal{O}(h^2)] \\ &= y(t_n) + hf + \frac{h^2}{2}(\partial_t f + \partial_y f \cdot f) + \mathcal{O}(h^3), \end{aligned}$$

从而

$$\begin{aligned} \tau(h) &= y(t_{n+1}) - y_{n+1} \\ &= y(t_n) + hy'(t_n) + \frac{h^2}{2}y''(t_n) + \mathcal{O}(h^3) - y_{n+1} \\ &= y(t_n) + hf + \frac{h^2}{2}(\partial_t f + \partial_y f \cdot f) + \mathcal{O}(h^3) - y_{n+1} \\ &= \mathcal{O}(h^3), \end{aligned}$$

因此为 2 阶相容.

再考虑**预估-校正 (Predictor-Corrector)**:

$$\begin{cases} \bar{y}_{n+1} = y_n + hf(t_n, y_n), \\ y_{n+1} = y_n + \frac{h}{2}(f(t_n, y_n) + f(t_{n+1}, \bar{y}_{n+1})), \end{cases}$$

这是显格式, 可以证明该格式为 2 阶相容.

线性多步法的构造 (Linear Multi-step Method, LMM)

(1) Adams 方法:

$$y(t_{n+1}) = y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y) dt.$$

Adams-Bashforth 方法 (AB, 显格式): 取 $p_r(t_{n+m}) = f(t_{n+m}, y_{n+m})$ 为 r 次插值多项式, $-r \leq m \leq 0$. 如果 $r = 0$, 即为显式 Euler; 如果 $r = 1$, 则

$$y_{n+1} = y_n + \frac{h}{2}(3f(t_n, y_n) - f(t_{n-1}, y_{n-1})).$$

Adams-Moulton 方法 (AM, 隐格式): $-r + 1 \leq m \leq 1$. 如果 $r = 0$, 即为隐式 Euler; 如果 $r = 1$, 即为梯形公式; 如果 $r = 2$, 则

$$y_{n+1} = y_n + \frac{h}{12}(5f(t_{n+1}, y_{n+1}) + 8f(t_n, y_n) - f(t_{n-1}, y_{n-1})).$$

(2) BDF 方法 (Backward Differentiation Formula): 取 $p_r(t_{n+m}) = y_{n+m}$ 为 r 次 Lagrange 插值多项式, $-r + 1 \leq m \leq 1$, 在 $t = t_{n+1-k}$ 处取值. 如果 $k = 1$, 为显格式, $p'_r(t)|_{t=t_n} = f(t_n, y_n)$, 进一步, 如果 $r = 1$, 则为显式 Euler, 如果 $r = 2$, 则有中点公式 (等距节点):

$$y_{n+1} = y_{n-1} + 2hf(t_n, y_n).$$

需要注意: 当 $r > 3$ 时, 显式 BDF 方法不稳定, 不可用. 如果 $k = 0$, 为隐格式, 进一步, 如果 $r = 1$, 则为隐式 Euler, 如果 $r = 2$, 则有

$$\frac{3}{2}y_{n+1} - 2y_n + \frac{1}{2}y_{n-1} = hf(t_{n+1}, y_{n+1}).$$

同样需要注意: 当 $r > 6$ 时, 隐式 BDF 方法不稳定, 不可用.

单步法收敛性分析

对于格式

$$\begin{cases} y_{n+1} = y_n + h\Phi(t_n, y_n; h), \\ y_0 = y(t_0), \end{cases}$$

设 LTE 为 $\tau(h) = \mathcal{O}(h^{p+1})$, 且

$$|\Phi(t, y; h) - \Phi(t, \tilde{y}; h)| \leq L|y - \tilde{y}|,$$

则

$$|y(t_n) - y_n| \leq Ch^p, \quad \forall t_n \in [0, T].$$

事实上, 引入

$$\bar{y}_{n+1} = y(t_n) + h\Phi(t_n, y(t_n); h),$$

则得到稳定性

$$|\bar{y}_{n+1} - y_{n+1}| \leq |y_n - y(t_n)| + Lh|y_n - y(t_n)| = (1 + Lh)|y_n - y(t_n)|,$$

故

$$\begin{aligned} & |y(t_{n+1}) - y_{n+1}| \\ &= |y(t_{n+1}) - \bar{y}_{n+1} + \bar{y}_{n+1} - y_{n+1}| \\ &\leq |y_{n+1} - \bar{y}_{n+1}| + |\bar{y}_{n+1} - y_{n+1}| \\ &\leq Ch^{p+1} + (1 + Lh)|y_n - y(t_n)|, \end{aligned}$$

再记 $e_n = |y_n - y(t_n)|$, 则

$$e_{n+1} \leq (1 + Lh)e_n + Ch^{p+1},$$

从而

$$\begin{aligned} e_n &\leq (1 + Lh)^n e_0 + Ch^{p+1} [1 + (1 + Lh) + \cdots + (1 + Lh)^{n-1}] \\ &\leq e^{Lh \cdot n} e_0 + Ch^{p+1} \frac{(1 + Lh)^n - 1}{(1 + Lh) - 1} \\ &= e^{Lt_n} e_0 + \frac{C}{L} (e^{Lt_n} - 1) h^p \\ &\leq e^{LT} e_0 + \frac{C}{L} (e^{LT} - 1) h^p, \end{aligned}$$

只要 $e_0 \leq Ch^p$, 则 $e_n \leq Ch^p$, 因此为 p 阶收敛.

第十八章 理论分析与稳定性

考察 ODE: $y' = f(t, y)$, $y|_{t=0} = y_0$.

线性多步法 (LMM) 相容性与 LTE

考虑 $r+1$ 步格式

$$\begin{cases} y_{n+1} = \sum_{j=0}^r \alpha_j y_{n-j} + h \sum_{j=-1}^r \beta_j f_{n-j}, & n \geq r, \\ y_k, & 0 \leq k \leq r. \end{cases}$$

如果 $\beta_{-1} = 0$, 则为显格式; 如果 $\beta_{-1} \neq 0$, 则为隐格式. 我们要求 α_r 与 β_r 不同时为 0 (否则为 r 步方法). 分析相容性: 如果 $y_{n-j} = y(t_{n-j})$, $0 \leq j \leq r$, 则 LTE 为 $\tau(h) = y(t_{n+1}) - y_{n+1}$. 如果 $\tau(h) = \mathcal{O}(h^{p+1})$, 称为 p 阶相容.

命题 18.1

等距节点的情形下, LTE 的阶可由

$$\mathcal{L}(y; h) := y(t+h) - \sum_{j=0}^r \alpha_j y(t-jh) - h \sum_{j=-1}^r \beta_j f(t-jh, y(t-jh))$$

的阶决定, 即如果 $\mathcal{L}(y; h) = \mathcal{O}(h^{p+1})$, 则 $\tau(h) = \mathcal{O}(h^{p+1})$.

阶条件 (order condition)

相容性: $\tau(h)/h \rightarrow 0$ ($h \rightarrow 0+$), 即 $p \geq 1$, 比较常数项系数可得

$$\sum_{j=0}^r \alpha_j = 1,$$

再比较 h 的系数可得

$$-\sum_{j=0}^r j\alpha_j + \sum_{j=-1}^r \beta_j = 1,$$

因此相容性等价于

$$\sum_{j=0}^r \alpha_j = 1, \quad -\sum_{j=0}^r j\alpha_j + \sum_{j=-1}^r \beta_j = 1.$$

一般地, 对于 $\mathcal{O}(h^{p+1})$, 有阶条件

$$\sum_{j=0}^r (-j)^k \alpha_j + \sum_{j=-1}^r (-j)^{k-1} \beta_j = 1, \quad \forall 2 \leq k \leq p.$$

可以证明:

- (1) 对于 AB 的 $r+1$ 步方法, 最多 $\tau(h) \sim \mathcal{O}(h^{r+2})$;
- (2) 对于 AM 的 $r+1$ 步方法, 最多 $\tau(h) \sim \mathcal{O}(h^{r+3})$;
- (3) 对于 BDF 的 $r+1$ 步方法, 最多 $\tau(h) \sim \mathcal{O}(h^{r+2})$.

稳定性 (零稳定, zero-stability)

对于单步法,

$$\begin{cases} y_{n+1} = y_n + h\Phi(t_n, y_n; h), \\ y_0 = y_0, \end{cases}$$

考虑其扰动

$$\begin{cases} z_{n+1} = z_n + h(\Phi(t_n, z_n; h) + \delta_n), \\ z_0 = y_0 + \delta_0, \end{cases}$$

设 $\max_{0 \leq k \leq n} |\delta_k| \leq \varepsilon$. 如果存在 $h_0 > 0$, 使得 $\forall h \leq h_0$, 都有 $\max_{0 \leq k \leq n} |y_k - z_k| \leq C\varepsilon$, 则称单步法具有**零稳定性**.
推广到 LMM:

$$\begin{cases} z_{n+1} = \sum_{j=0}^r \alpha_j z_{n-j} + h \left(\sum_{j=-1}^r \beta_j f_{n-j} + \delta_n \right), \\ z_k = y_k + \delta_k, \end{cases}$$

如果存在 $h_0 > 0$, 使得 $\forall h \leq h_0$, 都有 $\max_{0 \leq k \leq n} |y_k - z_k| \leq C\varepsilon$, 则称多步法具有**零稳定性**.

下面具体分析单步法的稳定性. 设 $e_k = y_k - z_k$, 则

$$\begin{cases} e_{n+1} = e_n + h(\Phi(t_n, y_n; h) - \Phi(t_n, z_n; h) + \delta_n), \\ e_0 = \delta_0, \end{cases}$$

故

$$\begin{cases} |e_{n+1}| \leq |e_n| + Lh|e_n| + h|\delta_n| = (1 + Lh)|e_n| + h|\delta_n|, \\ |e_0| = \delta_0, \end{cases}$$

从而

$$|e_n| \leq (1 + Lh)^n |e_0| + h\varepsilon \frac{(1 + Lh)^n - 1}{(1 + Lh) - 1} \leq e^{LT} \varepsilon + \frac{1}{L}(e^{LT} - 1)\varepsilon = C\varepsilon,$$

因此单步法零稳定.

对于 LMM: 首先取 $f = 0$, 则对应的 ODE 为 $y' = 0$, LMM 为

$$\begin{cases} y_{n+1} = \sum_{j=0}^r \alpha_j y_{n-j}, \\ y_k, \end{cases}$$

将 $y_n = x^n$ 代入可得特征方程:

$$\rho(x) := x^{r+1} - \sum_{j=0}^r \alpha_j x^{r-j} = 0,$$

设 $x_j \in \mathbb{C}, 1 \leq j \leq r+1$ 为根, 且无重根, 则

$$y_n = \sum_{j=1}^{r+1} a_j x_j^n,$$

其中 a_j 为待定系数, 由初值决定. 如果 x_j 为 m_j 重根, 则 $x_j^n n^k, 0 \leq k \leq m_j - 1$ 也满足递推式, 故

$$y_n = \sum_{j=1}^s \sum_{k=0}^{m_j-1} a_{jk} x_j^n n^k.$$

定义 18.1 根条件, root condition

如果 $\rho(x)$ 的根满足 $|x_j| \leq 1, 0 \leq j \leq r$, 并且如果 $|x_j| = 1$, 则 $\rho'(x_j) \neq 0$ (即单重).

定理 18.1

零稳定当且仅当根条件成立.

证明.

必要性已得证, 充分性见 Hairer-Wanner. □

对于单步法: $\rho(x) = x - 1$, 根条件成立, 稳定.

相容性成立时, $\rho(1) = 0$, 则 1 必须为单根.

对于 Adams 方法:

$$y_{n+1} = y_n + h \sum_{j=-1}^r \beta_j f_{n-j},$$

故 $\rho(x) = x^{r+1} - x^r = x^r(x - 1)$, 满足根条件.

对于 BDF 方法的中点公式: $y_{n+1} = y_{n-1} + 2hf_n$, 故 $\rho(x) = x^2 - 1$, 满足根条件, 零稳定.

定理 18.2

k 步隐式 BDF, $k \leq 6$ 时零稳定; k 步显式 BDF, $k \leq 3$ 时零稳定.

定理 18.3 1st Dahlquist barrier(Dahlquist, 1963)

如果 r 为奇数, 则零稳定的 r 步 LMM 方法的阶不超过 $r+1$; 如果 r 为偶数, 则零稳定的 r 步 LMM 方法的阶不超过 $r+2$.

收敛性

对于 LMM:

$$\begin{cases} y_{n+1} = \sum_{j=0}^r \alpha_j y_{n-j} + h \sum_{j=-1}^r \beta_j f_{n-j}, \\ y_k = y(t_k) + \delta_k(h), \end{cases}$$

其中 $\delta_k(h) \sim o(1)$. 如果 $\max_n |y_n - y(t_n)| \rightarrow 0 (h \rightarrow 0+)$, 则称为**收敛**; 如果 $\max_n |y_n - y(t_n)| \leq Ch^p$, 则称为 p 阶**收敛**.

定理 18.4 Dahlquist, 1956

相容性 + 零稳定等价于收敛性, 其中相容性等价于

$$\sum_{j=0}^r \alpha_j = 1, \quad -\sum_{j=0}^r j\alpha_j + \sum_{j=-1}^r \beta_j = 1,$$

零稳定等价于根条件.

对于数值 PDE 的收敛性, 类似地有 Lax-Richtmyer, 1956.

证明.

先证充分性. 首先考察稳定性. 取 $f = 0, y(0) = 0$, 即 $y' = 0, y(0) = 0$, 则 $y(t) \equiv 0$. 由递推通项及收敛可得根条件成立. 再考察相容性. 取 $\delta_k(h) = 0, f = 0, y(0) = 1$, 则 $y(t) \equiv 1$. 由 $y_n \rightarrow y(t_n) = 1$ 可得

$$\sum_{j=0}^r \alpha_j = 1.$$

再取 $f = 1, y(0) = 0$, 则 $y(t) = t$, 并且

$$\begin{cases} y_{n+1} = \sum_{j=0}^r \alpha_j y_{n-j} + h \sum_{j=-1}^r \beta_j, \\ y_k = kh + \delta_k(h). \end{cases}$$

令 $z_n = C \cdot nh$, 其中

$$C = \frac{\sum_{j=-1}^r \beta_j}{1 + \sum_{j=0}^r \alpha_j j},$$

则

$$\begin{cases} z_{n+1} = \sum_{j=0}^r \alpha_j z_{n-j} + h \sum_{j=-1}^r \beta_j, \\ z_k = C \cdot kh = kh + (C-1)kh, \quad 0 \leq k \leq r, \end{cases}$$

事实上

$$C(n+1)h - C \sum_{j=0}^r \alpha_j(n-j)h = Ch + \sum_{j=0}^r \alpha_j jh \cdot C = Ch \left(1 + \sum_{j=0}^r \alpha_j j \right) = h \sum_{j=-1}^r \beta_j.$$

由收敛性可得稳定性, 进而

$$\max_n |y_n - z_n| \leq \tilde{C} \max_{0 \leq k \leq r} |\delta_k(h) - (C-1)kh|,$$

其中 $y_n \rightarrow nh, z_n = Cnh$, 从而 $y_n - z_n \rightarrow (1-C)nh, nh \leq T$, 且

$$\max_{0 \leq k \leq r} |\delta_k(h) - (C-1)kh| \rightarrow 0, \quad h \rightarrow 0+,$$

因此 $C = 1$.

再证必要性. 由相容性可得

$$\begin{cases} y(t_{n+1}) = \sum_{j=0}^r \alpha_j y(t_{n-j}) + h \left(\sum_{j=-1}^r \beta_j f(t_{n-j}, y(t_{n-j})) + \frac{\tau(h)}{h} \right), \\ y(t_k) = y(t_k), \end{cases} \quad \frac{\tau(h)}{h} \rightarrow 0,$$

而

$$\begin{cases} y_{n+1} = \sum_{j=0}^r \alpha_j y_{n-j} + h \sum_{j=-1}^r \beta_j f_{n-j}, \\ y_k = y(t_k) + \delta_k(h), \end{cases}$$

将 $y(t_{n+1})$ 看作 z_{n+1} , 由稳定性可得

$$\max_n |y(t_n) - y_n| \leq C \max\{|\tau(h)/h|, \delta_k(h)\} \rightarrow 0, \quad h \rightarrow 0+.$$

□

绝对稳定性 (Absolute stability)

定义 18.2 Dahlquist 试验方程 (Test equation)

考察 ODE:

$$\begin{cases} y' = \lambda y, \\ y(0) = y_0 \end{cases}, \quad \operatorname{Re}(\lambda) \leq 0,$$

如果 $\operatorname{Re}(\lambda) < 0$, 则 $|y(t)| \xrightarrow{t \rightarrow +\infty} 0$; 如果 $\operatorname{Re}(\lambda) \leq 0$, 则 $|y(t)| \leq C$. 设单步法满足 $y_{n+1} = R(z)y_n$, 其中 $z = \lambda h$, $R(z)$ 为放大因子. 定义绝对稳定性为当 $\operatorname{Re}(\lambda) < 0$ 时, 有 $|y_n| \xrightarrow{n \rightarrow +\infty} 0$; 绝对稳定域 (Absolute Stability Domain) 为 $A = \{z \mid |R(z)| < 1\}$; A 稳定为 $\mathbb{C}^- \subseteq A$.

对于显式 Euler, 有

$$y_{n+1} = y_n + hf(t_n, y_n) = y_n + \lambda h y_n = (1 + \lambda h)y_n = (1 + z)y_n, \quad \operatorname{Re}(z) < 0,$$

故 $R(z) = 1 + z, A = \{z \mid |1 + z| < 1\}$. 如果 $\lambda \in \mathbb{R}$, 则 $-2 < z < 0$, 故 $h < -2/\lambda$.

对于隐式 Euler, 有

$$y_{n+1} = y_n + hf(t_{n+1}, y_{n+1}) = y_n + \lambda h y_{n+1},$$

故 $R(z) = 1/(1 - z), A = \{z \mid |1 - z| > 1\}$, 从而 $\mathbb{C}^- \subset A$, 此时 A 稳定.

对于 Heun 方法,

$$\begin{cases} \bar{y}_{n+1} = y_n + hf_n, \\ y_{n+1} = y_n + \frac{1}{2}h(f_n + \bar{f}_{n+1}), \end{cases}$$

则

$$\bar{y}_{n+1} = y_n + h\lambda y_n = (1 + z)y_n, \quad y_{n+1} = y_n + \frac{1}{2}h(\lambda y_n + \lambda(1 + z)y_n) = \left(1 + z + \frac{z^2}{2}\right)y_n,$$

故 $R(z) = 1 + z + \frac{z^2}{2}, A = \left\{z \mid \left|1 + z + \frac{z^2}{2}\right| < 1\right\}$.

第二 Dahlquist barrier 指出线性显式 LMM 不可能 A 稳定, 不存在超过 2 阶的 A 稳定的 LMM.

第十九章 Runge-Kutta 方法

Taylor 展开法

对于 $y' = f(t, y)$, 有

$$\begin{aligned}y(t_{n+1}) &= y(t_n) + \int_{t_n}^{t_{n+1}} f(t, y) dt \\&= y(t_n) + \int_{t_n}^{t_{n+1}} [(f(t, y) - f(t_n, y(t_n))) + f(t_n, y(t_n))] dt \\&= y(t_n) + hf(t_n, y(t_n)) + \int_{t_n}^{t_{n+1}} \int_{t_n}^t \frac{d}{ds} f(s, y(s)) ds dt \\&= y(t_n) + hf(t_n, y(t_n)) + \int_{t_n}^{t_{n+1}} \int_{t_n}^t (\partial_s f + \partial_y f \cdot f) ds dt \\&= y_n + hf_n + \frac{h^2}{2}(\partial_s f_n + \partial_y f_n \cdot f_n) + \frac{h^3}{6}y'''|_{t=t_n} + \cdots,\end{aligned}$$

Runge-Kutta 方法

注意到 Heun 方法可以写成

$$\begin{cases} K_1 = f(t_n, y_n), \\ K_2 = f(t_{n+1}, y_n + hK_1), \\ y_{n+1} = y_n + h\left(\frac{1}{2}K_1 + \frac{1}{2}K_2\right), \end{cases}$$

故将其推广为

$$\begin{cases} K_1 = f(t_n, y_n), \\ K_2 = f(t_n + ch, y_n + ahK_1), \\ y_{n+1} = y_n + h(b_1K_1 + b_2K_2), \end{cases}$$

从而

$$y_{n+1} = y_n + h(b_1f_n + b_2(f_n + ch\partial_t f_n + ah\partial_y f \cdot K_1 + \mathcal{O}(h^2))),$$

因此

$$\begin{cases} b_1 + b_2 = 1, \\ b_2 c = 1/2, \\ b_2 a = 1/2, \end{cases}$$

此时 LTE 为 $\mathcal{O}(h^3)$. 比如取 $b_1 = 1/4, b_2 = 3/4, C = a = 2/3$.

由此得到一般的 Runge-Kutta 方法

$$\begin{cases} K_i = f\left(t_n + c_i h, y_n + h \sum_{j=1}^s a_{ij} K_j\right), & 1 \leq i \leq s, \\ y_{n+1} = y_n + h \sum_{i=1}^s b_i K_i, \end{cases}$$

定义 **Butcher 表** 为

$$\left(\begin{array}{c|cccc} c_1 & a_{11} & \cdots & a_{1s} \\ c_2 & a_{21} & \cdots & a_{2s} \\ \vdots & \vdots & \ddots & \vdots \\ c_s & a_{s1} & \cdots & a_{ss} \\ \hline & b_1 & \cdots & b_s \end{array} \right) = \left(\begin{array}{c|c} \mathbf{c} & \mathbf{A} \\ \hline & \mathbf{b}^T \end{array} \right).$$

对于 Heun 方法, $\mathbf{A} = \begin{pmatrix} 0 & 0 \\ 1 & 0 \end{pmatrix}$, 为**显式 RK**. 对于一般情形, 为**隐式 RK(IRK)**. 如果 $\mathbf{A}$ 为下三角形, 则为**对角隐式 RK(DIRK)**.

对于相容性, 需要 $\sum_{i=1}^s b_i = 1$, 即 LTE 为 $\mathcal{O}(h^2)$.

一般的阶条件非平凡, 由 Butcher 引入 rooted tree 给出 (B-series).

一般选取 $\sum_{j=1}^s a_{ij} = c_i$.

经典 RK 方法

记 s 为级数 (stage), p 为阶数 (order).

(1) $s = 3, p = 3$, 对应的 Butcher 表为

$$\left(\begin{array}{c|cccc} 0 & 0 & 0 & 0 \\ 1/3 & 1/3 & 0 & 0 \\ 2/3 & 0 & 2/3 & 0 \\ \hline & 1/4 & 3/4 & 0 \end{array} \right).$$

(2) $s = 4, p = 4$, 对应的 Butcher 表为

$$\begin{pmatrix} 0 & 0 & 0 & 0 & 0 \\ 1/2 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 0 & 1/6 & 2/6 & 2/6 & 1/6 \end{pmatrix}.$$

记 $S_{\min}$ 为达到 p 阶最少需要的级数 (显式), 则 如果允许隐格式, s 级 RK 最多可以达到 $2s$ 阶.

p 阶	1	2	3	4	5	6	7	8
$S_{\min}$	1	2	3	4	6	7	9	11

对于收敛性, 有 $y_{n+1} = y_n + h\Phi(t_n, y_n; h)$, 其中

$$\Phi(t_n, y_n; h) = \sum_{i=1}^s b_i K_i, \quad \mathbf{K} = \mathbf{F}(t_n, y_n \mathbf{1} + h\mathbf{A}\mathbf{K}),$$

其中

$$F_i(t_n, y_n \mathbf{1} + h\mathbf{A}\mathbf{K}) := f\left(t_n + c_i h, y_n + h \sum_{j=1}^s a_{ij} K_j\right).$$

如果 $\widetilde{\mathbf{K}} = \mathbf{F}(t_n, \widetilde{y}_n \mathbf{1} + h\mathbf{A}\widetilde{\mathbf{K}})$, 则

$$\|\mathbf{K} - \widetilde{\mathbf{K}}\| \leq \|y_n \mathbf{1} - \widetilde{y}_n \mathbf{1}\| + h\|\mathbf{A}\|\|\mathbf{K} - \widetilde{\mathbf{K}}\|,$$

故

$$\|\mathbf{K} - \widetilde{\mathbf{K}}\| \leq \frac{1}{1 - \|\mathbf{A}\|h} \|y_n \mathbf{1} - \widetilde{y}_n \mathbf{1}\|, \quad h \leq h_0 \ll 1.$$

绝对稳定域

4 级 4 阶 RK 对应的放大因子为

$$R(z) = 1 + z + \frac{z^2}{2} + \frac{z^3}{6} + \frac{z^4}{24},$$

(当 $s \leq 4$ 时, s 级 s 阶的显式 RK 方法对应的 $R(z)$ 都相同). $s = 3$ 和 $s = 4$ 对应的绝对稳定域都包含了虚轴的一部分.

对于一般情形, 代入 $y' = \lambda y$ 可得

$$K_i = \lambda \left(y_n + h \sum_{j=1}^s a_{ij} K_j \right) = \lambda y_n + z(\mathbf{A}\mathbf{K})_i,$$

故 $\mathbf{K} = \lambda y_n \cdot \mathbf{1} + z\mathbf{A}\mathbf{K}$, 即 $\mathbf{K} = \lambda y_n(\mathbf{I} - z\mathbf{A})^{-1}\mathbf{1}$, 故

$$R(z) = \mathbf{1} + z\mathbf{b}^T(\mathbf{I} - z\mathbf{A})^{-1}\mathbf{1} = \frac{\det(\mathbf{I} - z\mathbf{A} + z\mathbf{1} \cdot \mathbf{b}^T)}{\det(\mathbf{I} - z\mathbf{A})}.$$

从而显式 RK 对应的 $R(z)$ 为 z 的 s 次多项式.

另外, 有隐式 RK 方法 (Gauss 积分构造, Butcher, 1964)

$$\begin{cases} \sum_{j=1}^s c_j^{k-1} a_{ij} = \frac{1}{k} c_i^k, & 1 \leq i, k \leq s, \\ \sum_{j=1}^s b_j c_j^{k-1} = \frac{1}{k}, & 1 \leq k \leq s, \end{cases}$$

其中典型取 c_j 为 Legendre 多项式的根, b_j 为 Gauss-Legendre 求积系数. 事实上, 由于 $y' = f(t, y)$, 故

$$y_{n+1} = y_n + \int_{t_n}^{t_{n+1}} f(t, y) dt \approx y_n + h \sum_{i=1}^s b_i f(t_n + c_i h, y(t_n + c_i h)),$$

再取 $f(t, y) = t^k, 0 \leq k \leq s-1$, 以及 $t_n = 0, y(t_n) = 0$.