数值分析笔记

李铁军《数值分析》课程笔记

斑马数学　整理

2026 年 3 月

目录

第一章 Lagrange 插值 1

第二章 Newton 多项式插值 7

第三章 样条插值 (spline) 10

第四章 最小二乘拟合 (Least Squares Fitting) 16

第五章 其他论题 22

第六章 数值积分基础 (Numerical Integration/Quadrature) 24

第七章 Gauss 积分 30

第八章 自适应与谱精度 35

第九章 多维积分与数值微分 40

第十章 Monte Carlo 方法 44

第十一章 Metropolis 算法 49

第一章　Lagrange 插值

定义 1.1　Lagrange 插值

设 $n \in \mathbb{Z}_{\geqslant 0}$, 给定 $(x_i, y_i)_{0 \leqslant i \leqslant n}$, $x_i \neq x_j, \forall\, i \neq j$, 求

$$p(x) \in \mathcal{P}_n = \{q \mid \deg q \leqslant n\}, \quad p(x) = \sum_{k=0}^{n} a_k x^k,$$

使得 $p(x_i) = y_i, \forall\, 0 \leqslant i \leqslant n$, 记这样得到的 **Lagrange 插值多项式**为 $\Pi_n(x)$ 或 $L_n(x)$ 或 $\Pi_n f(x)$.

将 Π_n 理解为线性投影算子

$$\Pi_n : f \in C[a,b] \mapsto \Pi_n f \in C[a,b]$$

时, 显然有 $\Pi_n^2 = \Pi_n$.

由 $\Pi_n(x_i) = y_i, \forall\, 0 \leqslant i \leqslant n$ 得到

$$\sum_{k=0}^{n} a_k x_i^k = y_i, \quad \forall\, 0 \leqslant i \leqslant n,$$

从而得到线性方程组 $\boldsymbol{V}\boldsymbol{a} = \boldsymbol{y}$, 其中

$$\boldsymbol{a} = \begin{pmatrix} a_n \\ a_{n-1} \\ \vdots \\ a_0 \end{pmatrix}, \quad \boldsymbol{y} = \begin{pmatrix} y_0 \\ y_1 \\ \vdots \\ y_n \end{pmatrix}, \quad \boldsymbol{V} = \begin{pmatrix} x_0^n & x_0^{n-1} & \cdots & 1 \\ x_1^n & x_1^{n-1} & \cdots & 1 \\ \vdots & \vdots & \cdots & \vdots \\ x_n^n & x_n^{n-1} & \cdots & 1 \end{pmatrix}.$$

由 Vandermonde 行列式得到

$$\det \boldsymbol{V} = \prod_{n \geqslant i > j \geqslant 0} (x_i - x_j) \neq 0,$$

因此 $\Pi_n(x)$ 存在且唯一.

同时, 我们通过**基函数 (basis function)** 求 $\Pi_n(x)$: 取 $\{l_j(x)\}_{0 \leqslant j \leqslant n}, l_j(x) \in \mathcal{P}_n$, 使得

$$l_j(x_k) = \delta_{jk} = \begin{cases} 1, & j = k, \\ 0, & j \neq k. \end{cases}$$

δ 也称为 **Kronecker 记号**, 此时我们有

$$\Pi_n(x) = \sum_{j=0}^{n} y_j l_j(x),$$

这是因为 $\forall 0 \leqslant k \leqslant n$, 都有

$$\Pi_n(x_k) = \sum_{j=0}^{n} y_j l_j(x_k) = \sum_{j=0}^{n} y_j \delta_{jk} = y_k,$$

并且易得基函数

$$l_j(x) = \frac{\prod_{k\neq j}(x - x_k)}{\prod_{k\neq j}(x_j - x_k)} = \frac{\omega_{n+1}(x)/(x - x_j)}{\omega'_{n+1}(x_j)}, \quad \omega_{n+1}(x) := \prod_{j=0}^{n}(x - x_j) \in \mathcal{P}_{n+1}.$$

我们也可记 $l_j(x)$ 为 $l_{n,j}(x)$. 易得 $l_j(x)$ 有如下性质:

$$\sum_{j=0}^{n} x_j^k l_j(x) \equiv x^k, \quad \forall 0 \leqslant k \leqslant n.$$

误差估计 (Error estimate)

设

$$a = x_0 < x_1 < \cdots < x_n = b, \quad f \in C^\infty[a, b], \quad E_n(x) := f(x) - \Pi_n f(x)$$

定理 1.1

$\forall x \in [a, b]$, 都存在 $\xi \in [a, b]$, 使得

$$E_n(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi).$$

证明.

不妨设 $x \notin \{x_j\}_{0\leqslant j\leqslant n}$ (否则显然), 记

$$F(\xi) = (\Pi_n f(\xi) - f(\xi)) - \frac{\omega_{n+1}(\xi)}{\omega_{n+1}(x)}(\Pi_n f(x) - f(x)),$$

显然有 $F(x_j) = 0, \forall 0 \leqslant j \leqslant n$, 且 $F(x) = 0$. 由 Rolle 定理, 存在 $\xi \in [a, b]$, 使得 $F^{(n+1)}(\xi) = 0$, 因此

$$E_n(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi).$$

□

收敛性

考察 $E_n(x), n \to +\infty$ 的性质, 事实上, $f^{(n+1)}(x)$ 的性质可能极差. 取 $f(x) = (x - x_0)^{-1}$, 则

$$f^{(n+1)}(x) = (-1)^{n+1}(n+1)!(x - x_0)^{-(n+2)}.$$

数值稳定性 (Numerical stability)

设

$$\widetilde{\Pi}_n(x) = \sum_{j=0}^{n} \widetilde{y}_j l_j(x), \quad \widetilde{y}_j = y_j + \varepsilon_j,$$

则

$$\begin{aligned}\widetilde{\Pi}_n(x) - f(x) &= \widetilde{\Pi}_n(x) - \Pi_n(x) + \Pi_n(x) - f(x) \\ &= \sum_{j=0}^{n} \varepsilon_j l_j(x) + E_n(x),\end{aligned}$$

事实上, $|l_j(x)|$ 可能很大, 取等距节点高次 Lagrange 插值

$$a = x_{-n} < x_{-n+1} < \cdots < x_{-1} < x_0 < x_1 < \cdots < x_n = b, \quad x_{i+1} - x_i = h = \frac{b-a}{2n},$$

取 $x = x_n - h/2$, 则计算可得

$$|l_0(x)| = \frac{(4n)!}{2^{4n}(n!)^2(2n)!} \cdot \frac{1}{2n-1},$$

当 $n \to +\infty$ 时, 由 Stirling 公式得

$$|l_0(x)| \sim \frac{(4n)^{4n+\frac{1}{2}}\mathrm{e}^{-4n}}{2\pi \cdot 2^{4n} n^{2n+1}\mathrm{e}^{-4n}(2n)^{2n+\frac{1}{2}}} \cdot \frac{1}{2n-1} = \frac{4^n}{2\pi n(2n-1)} \to +\infty.$$

一致收敛性

定义点列 $X = \{x_j^{(n)}\}_{0 \leqslant j \leqslant n}$, 则 $\Pi_n f(x; X) \in \mathcal{P}_n$, 并记 $E_n f(x; X) = \Pi_n f(x; X) - f(x)$, 定义**无穷范数 (norm)**:

$$\|f\|_\infty = \max_{x \in [a,b]} \{|f(x)|\},$$

考察当 $n \to +\infty$ 时, $\|E_n f\|_\infty \to 0$ 的收敛性.

定理 1.2

如果 f 在 $C_{r_0} = B_{r_0}(\frac{a+b}{2}), r_0 > \frac{3}{2}(b-a)$ 内解析, 则 $\|E_n f\|_\infty \to 0, \forall X$.

证明.

由于

$$E_n f(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi), \quad \xi \in [a,b],$$

且由 Cauchy 积分公式得

$$f^{(n+1)}(x) = \frac{(n+1)!}{2\pi \mathrm{i}} \oint_{\partial C_{r_0}} \frac{f(\xi)}{(\xi - x)^{n+2}} \, \mathrm{d}\xi, \quad x \in C_{r_0},$$

从而

$$\|E_n f\|_\infty \leqslant \frac{(b-a)^{n+1}}{2\pi} \cdot \frac{\max_{z \in \partial B_{r_0}} |f(z)|}{(r_0 - \frac{b-a}{2})^{n+2}} \cdot 2\pi r_0 = \mathcal{O}\left(\left(\frac{b-a}{r_0 - \frac{b-a}{2}}\right)^n\right) \to 0.$$

□

一般的收敛性理论

定义 **Lebesgue 函数**

$$\lambda_n(x; X) = \max_{\|f\|_\infty \leqslant 1} |\Pi_n f(x; X)|,$$

再记 $\Pi_n f(x; X) = \Pi_n^x f(X)$, 则有线性泛函

$$\Pi_n^x : f \in C[a,b] \mapsto \Pi_n^x f \in \mathbb{R},$$

从而 $\lambda_n(x; X)$ 即为 Π_n^x 的算子范数, 并且易证

$$\lambda_n(x; X) = \sum_{j=0}^n |l_{n,j}(x; X)|.$$

再定义 **Lebesgue 常数**

$$\Lambda_n(X) = \max_{\|f\|_\infty \leqslant 1} \|\Pi_n f(\cdot; X)\|_\infty = \|\Pi_n\|_\infty = \max_{x \in [a,b]} \lambda_n(x; X) = \left\| \sum_{j=0}^n |l_{n,j}(x)| \right\|_\infty$$

和

$$E_n(f; X) = \|f - \Pi_n f\|_\infty,$$

以及 p_n^* 为 f 的最佳一致逼近多项式, 即

$$p_n^* = \arg\inf_{p_n \in \mathcal{P}_n} \|p_n - f\|_\infty, \quad E_n^*(f) = \inf_{p_n \in \mathcal{P}_n} \|f - p_n\|_\infty,$$

则

$$
\begin{aligned}
E_n(f;X) &= \|f - p_n^* + p_n^* - \Pi_n f\|_\infty \\
&\leqslant \|f - p_n^*\|_\infty + \|p_n^* - \Pi_n f\|_\infty \\
&= \|f - p_n^*\|_\infty + \|\Pi_n(p_n^* - f)\|_\infty \\
&\leqslant E_n^*(f) + \|\Pi_n\|_\infty E_n^*(f) \\
&= E_n^*(f)(1 + \Lambda_n(X)).
\end{aligned}
$$

定理 1.3

$\forall X$, 都存在 $C(X) > 0$, 使得

$$
\Lambda_n(X) > \frac{2}{\pi}\ln(n+1) - C(X), \quad \forall n \geqslant 1.
$$

证明.

见 W. Gautschi, *Numerical Analysis*. □

定理 1.4

对 Chebyshev 点组 $T = \{x_j^{(n)}\}_{0\leqslant j\leqslant n}$, 存在 $C_1 \in (0,1)$, 使得

$$
\frac{2}{\pi}\ln n + C_1 \leqslant \Lambda_n(T) \leqslant \frac{2}{\pi}\ln n + 1, \quad \forall n \geqslant 1.
$$

证明.

见 Theodore J. Rivlin, *Chebyshev Polynomials*. □

定理 1.5

当 f 为 Lipschitz 连续或者 C^1 时, 存在 $C > 0$, 使得

$$
E_n^*(f) \leqslant \frac{\pi}{n+1}C, \quad \forall n \geqslant 1.
$$

证明.

见 Elliott Ward Cheney, *Introduction to APproximation Theory*. □

定义 1.2 Runge 函数 (现象)

考虑函数

$$
f(x) = \frac{1}{1+25x^2} \in C^\infty[-1,1]
$$

以及等距节点 X , 则 Lagrange 插值不收敛.

如果考虑在 $[-0.726, 0.726]$ 上进行等距节点 Lagrange 插值, 则也收敛.

定理 1.6　Weierstrass 定理

$\forall f \in C[a,b]$ ，都存在 $p_n \in \mathcal{P}_n$ ，使得

$$\|p_n - f\|_\infty \to 0, \quad n \to +\infty.$$

定理 1.7　Chebyshev 定理

$\forall f \in C[a,b]$ ，都存在点组 X ，使得

$$\|f - \Pi_n f\|_\infty \to 0, \quad n \to +\infty.$$

定理 1.8　Farbor 定理

$\forall X$ ，都存在 $f \in C[a,b]$ ，使得 $\|f - \Pi_n f\|_\infty$ 不收敛于 0 .

第二章　Newton 多项式插值

定义 2.1　Newton 差商 (divided difference)

设 x_i 互不相同, 定义 **Newton 差商**

$$
\begin{aligned}
&f[x_0] = f(x_0), \\
&f[x_0, x_1, \cdots, x_k] = \frac{f[x_1, x_2, \cdots, x_k] - f[x_0, x_1, \cdots, x_{k-1}]}{x_k - x_0}, \quad \forall\, k \geqslant 1.
\end{aligned}
$$

可用 $\mathcal{O}(n^2)$ 的运算量计算得到 **Newton 差商表**. 易知 $f[x_0, x_1, \cdots, x_k]$ 是 $\{f_i = f(x_i)\}_{0 \leqslant i \leqslant n}$ 的线性组合, 且

$$
f[x_0, x_1, \cdots, x_k] = \sum_{j=0}^{k} \frac{f(x_j)}{\omega'_{k+1}(x_j)}, \quad \omega_{k+1}(x) := \prod_{i=0}^{k} (x - x_i),
$$

从而有 $f[x_{\tau(0)}, x_{\tau(1)}, \cdots, x_{\tau(k)}]$ 对任意置换 $\tau \in S_k$ 都不变.

如果 $f[x, x_0, x_1, \cdots, x_k]$ 是关于 x 的 m 次多项式, 则

$$
f[x, x_0, \cdots, x_k, x_{k+1}] = \frac{f[x_0, \cdots, x_{k+1}] - f[x, x_0, \cdots, x_k]}{x_{k+1} - x} \in \mathcal{P}_{m-1}.
$$

再注意到

$$
\begin{aligned}
f(x) &= f[x] \\
&= f[x_0] + (f[x] - f[x_0]) \\
&= f[x_0] + f[x, x_0](x - x_0) \\
&= f[x_0] + (f[x_0, x_1] + f[x, x_0] - f[x_0, x_1])(x - x_0) \\
&= f[x_0] + f[x_0, x_1](x - x_0) + f[x, x_0, x_1](x - x_1)(x - x_0) \\
&= \cdots \\
&= \sum_{k=0}^{n} f[x_0, x_1, \cdots, x_k]\omega_k(x) + f[x, x_0, \cdots, x_n]\omega_{n+1}(x),
\end{aligned}
$$

并令

$$
p_n(x) := \sum_{k=0}^{n} f[x_0, \cdots, x_k]\omega_k(x) \in \mathcal{P}_n,
$$

则 $p_n = \Pi_n f$. 事实上, 在上式中取 f 为 $\Pi_n f$, 则

$$(\Pi_n f)[x_0, \cdots, x_k] = f[x_0, \cdots, x_k],$$

并且分析多项式次数可得

$$(\Pi_n f)[x, x_0, \cdots, x_n] = 0,$$

因此 $p_n = \Pi_n f$, 同时

$$f(x) = \Pi_n f(x) + f[x, x_0, \cdots, x_n]\omega_{n+1}(x),$$

其中

$$\Pi_n f(x) = f[x_0] + f[x_0, x_1](x - x_0) + \cdots + f[x_0, \cdots, x_n](x - x_0)\cdots(x - x_{n-1})$$

因此每加一个点, 只需在最后多加一项, 运算量仅增加 $\mathcal{O}(n)$, 且基函数即为 $\omega_k(x)$. 我们实际上还得到

$$f[x, x_0, \cdots, x_n]\omega_{n+1}(x) = f(x) - \Pi_n f(x) = E_n f(x) = \frac{f^{n+1}(\xi)}{(n+1)!}\omega_{n+1}(x),$$

即

$$f[x, x_0, \cdots, x_n] = \frac{f^{(n+1)}(\xi)}{(n+1)!}, \quad \xi \in [a, b].$$

定义 2.2 质心形式 (Barycentric form)

由于

$$l_{n,j}(x) = \frac{\omega_{n+1}(x)}{x - x_j} \cdot W_j, \quad W_j := \frac{1}{\prod_{k \neq j}(x_j - x_k)},$$

故

$$\Pi_n(x) = \omega_{n+1}(x) \cdot \sum_{j=0}^{n} \frac{y_j W_j}{x - x_j},$$

再结合

$$1 = \sum_{j=0}^{n} l_{n,j}(x) = \omega_{n+1}(x) \sum_{j=0}^{n} \frac{W_j}{x - x_j},$$

从而有**质心形式**

$$\Pi_n(x) = \frac{\sum_{j=0}^{n} \frac{W_j}{x - x_j} y_j}{\sum_{j=0}^{n} \frac{W_j}{x - x_j}}.$$

此时增加一个点, 运算量也仅增加 $\mathcal{O}(n)$. 见 Trefethen .

定义 2.3 Lagrange 分片插值 (piecewise Lagrange Interpolation)

记

$$[a,b]=\bigcup_{j=0}^{k-1} I_j, \quad I_j:=[x_j,x_{j+1}], \quad h_j:=|I_j|, \quad h:=\max_j h_j.$$

并称 T_h 为**分划 (partition,triangulation)**,

$$X_h^k:=\{\Pi_h^k:\Pi_h^k|_{I_j}\in\mathcal{P}_k,\forall 0\leqslant j\leqslant k-1\}.$$

$k=0$ 得到分片常数, $k=1$ 得到分片线性. 显然有 $\Pi_h^k\in C^0\backslash C^1$.

对于分片线性的情形,

$$\Pi_h^1(x)=\sum_{j=0}^{n} y_j l_j(x), \quad l_j\in X_h^1, \quad l_j(x_k)=\delta_{jk},$$

$l_j(x)$ 被称为 **Tent function**, 显然有 $\sup(l_j)\subseteq I_{j-1}\cup I_j$.

再定义

$$S_{ij}=(l_i',l_j'), \quad m_{ij}=(l_i,l_j), \quad (f,g):=\int_a^b f(x)g(x)\,\mathrm{d}x,$$

则 $S=(S_{ij}),m=(m_{ij})$ 为三对角矩阵.

再考虑收敛性, 有

$$\|f(x)-\Pi_h^k(x)\|_\infty\leqslant\frac{M_{k+1}}{(k+1)!}h^{k+1}, \quad \Pi_h^k\in X_h^k.$$

第三章　样条插值 (spline)

定义 3.1　二点 Hermite 插值

给定 $\{(x_j, y_j^{(k)})\}_{k,j=0,1}$, 构造 $H(x) \in \mathcal{P}_3$, 有基函数表示

$$H(x) = \sum_{j,k=0}^{1} y_j^{(k)} h_j^{(k)}(x), \quad (h_j^{(k)})^{(l)}(x_m) = \delta_{kl}\delta_{jm}, \quad k, l, j, m = 0, 1,$$

其中 $h_j^{(k)}(x) \in \mathcal{P}_3$ 是基函数, 故

$$H^{(l)}(x_m) = \sum_{j,k=0}^{1} y_j^k \delta_{kl}\delta_{jm} = y_m^{(l)}.$$

若记 $y_j^{(k)} := f^{(k)}(x_j), f \in C^4[x_0, x_1]$, 则有误差估计:

$$H(x) - f(x) = \frac{f^{(4)}(\xi)}{4!}\Omega_4(x), \quad \Omega_4(x) := (x - x_0)^2(x - x_1)^2.$$

定义 3.2　多点 Hermite 插值

给定 $\{(x_j, y_j^{(k)})\}_{\substack{0\leqslant j\leqslant n \\ 0\leqslant k\leqslant n_j}}$, 并记 $N := \sum_{j=0}^{n}(n_j + 1)$, 构造 $H(x) \in \mathcal{P}_N$.

有误差估计

$$H(x) - f(x) = \frac{f^{(N)}(\xi)}{N!}\Omega_N(x), \quad \Omega_N(x) := \prod_{i=0}^{n}(x - x_i)^{n_i}.$$

定义 3.3　分片 Hermite 插值

给定 $\{(x_j, y_j^{(k)})\}_{\substack{0\leqslant j\leqslant n \\ 0\leqslant k\leqslant 1}}$, 构造 $\Pi_h(x) \in X_h^3$, 则 $\Pi_h \in C^1$ (分片两点 Hermite) .

有误差估计

$$\|\Pi_h - f\|_\infty \leqslant \frac{M_4}{4!} \max_{\substack{x\in[x_j,x_{j+1}] \\ 0\leqslant j\leqslant n-1}} (x - x_j)^2(x - x_{j+1})^2 \leqslant \frac{M_4}{4!}\left(\frac{h}{2}\right)^2, \quad M_4 := \max_{\xi\in[a,b]} |f^{(4)}(\xi)|.$$

定义 3.4　三次样条插值 (Cubic spline)

给定 $\{(x_j, y_j)\}_{0\leqslant j\leqslant n}$, 构造 $S(x) \in X_h^3$ 满足:

$$S(x_j) = y_j, \quad 0 \leqslant j \leqslant n, \quad S(x) \in C^2[a, b],$$

并记构成的线性空间为 $\mathcal{S}_3$.

考察自由度:

$$4n - 2(n-1) - 2 - 2(n-1) = 2,$$

其中约束分别为内点插值条件, 边界插值条件, 内点 C^2 . 因此还需补充条件:
(1) $S'(x_0) = d_0, S'(x_n) = d_n$ (**完全样条**).
(2) $S''(x_0) = S''(x_n) = 0$ (**自然样条**).
(3) 假定 $y_0 = y_n$, $S^{(k)}(x_0-) = S^{(k)}(x_n+), k = 1, 2$ (**周期样条**).

定理 3.1

$S(x) \in \mathcal{S}_3$ 存在且唯一.

证明.

由于 $S \in X_h^3 \cap C^2$, 故 S'' 为分片线性且 C^0 , 从而令

$$S''(x) = M_{j-1}\frac{x_j - x}{h_j} + M_j\frac{x - x_{j-1}}{h_j}, \quad x \in [x_{j-1}, x_j], \quad h_j := x_j - x_{j-1},$$

因此

$$S(x) = M_{j-1}\frac{(x_j - x)^3}{6h_j} + M_j\frac{(x - x_{j-1})^3}{6h_j} + C_{j-1}(x - x_{j-1}) + \widetilde{C}_{j-1},$$

取 $x = x_{j-1}$ 可得

$$y_{j-1} - M_{j-1}\frac{h_j^2}{6} = \widetilde{C}_{j-1},$$

再取 $x = x_j$ 可得

$$y_j - M_j\frac{h_j^2}{6} = C_{j-1}h_j + \widetilde{C}_{j-1},$$

故

$$C_{j-1}(x - x_{j-1}) + \widetilde{C}_{j-1} = (y_{j-1} - \frac{M_{j-1}}{6}h_j^2)\frac{x_j - x}{h_j} + (y_j - \frac{M_j}{6}h_j^2)\frac{x - x_{j-1}}{h_j}.$$

再结合 $S \in C^1$ 知 $S'(x_j-) = S'(x_j+)$, 从而

$$S'(x) = -M_{j-1}\frac{(x_j - x)^2}{2h_j} + M_j\frac{(x - x_{j-1})^2}{2h_j} + \frac{y_j - y_{j-1}}{h_j} - \frac{M_j - M_{j-1}}{6}h_j,$$

因此

$$\frac{h_j}{6}M_{j-1}+\frac{h_j+h_{j+1}}{3}M_j+\frac{h_{j+1}}{6}M_{j+1}=\frac{y_{j+1}-y_j}{h_{j+1}}-\frac{y_j-y_{j-1}}{h_j}.$$

两边除以 $\frac{h_j+h_{j+1}}{6}$ ，并记

$$\lambda_j:=\frac{h_{j+1}}{h_j+h_{j+1}},\quad \mu_j:=1-\lambda_j,$$

可得

$$\mu_jM_{j-1}+2M_j+\lambda_jM_{j+1}=b_j,\quad b_j\approx f''(x_j).$$

另外的 3 种补充条件:

(1)

$$\begin{cases}2M_0+M_1=\dfrac{6}{h_1}\left(\dfrac{y_1-y_0}{h_1}-d_0\right),\\ M_{n-1}+2M_n=\dfrac{6}{h_n}\left(d_n-\dfrac{y_n-y_{n-1}}{h_n}\right).\end{cases}$$

(2)

$$M_0=M_n=0.$$

(3)

$$\begin{cases}M_0=M_n,\\ -\dfrac{h_1}{3}M_0-\dfrac{h_1}{6}M_1+\dfrac{y_1-y_0}{h_1}=\dfrac{h_n}{6}M_{n-1}+\dfrac{h_n}{3}M_n+\dfrac{y_n-y_{n-1}}{h_n}.\end{cases}$$

综上得到线性方程组 $\boldsymbol{AM}=\boldsymbol{b}$:

(1)

$$\boldsymbol{M}=\begin{pmatrix}M_0\\M_1\\\vdots\\M_n\end{pmatrix},\quad \boldsymbol{A}=\begin{pmatrix}2&1&&&\\\mu_1&2&\lambda_1&&\\&\ddots&\ddots&\ddots&\\&&\mu_{n-1}&2&\lambda_{n-1}\\&&&1&2\end{pmatrix}.$$

(2)

$$\boldsymbol{M}=\begin{pmatrix}M_1\\M_2\\\vdots\\M_{n-1}\end{pmatrix},\quad \boldsymbol{A}=\begin{pmatrix}2&\lambda_1&&&\\\mu_2&2&\lambda_2&&\\&\ddots&\ddots&\ddots&\\&&\mu_{n-2}&2&\lambda_{n-2}\\&&&\mu_{n-1}&2\end{pmatrix}.$$

(3)

$$\boldsymbol{M}=\begin{pmatrix} M_0 \\ M_1 \\ \vdots \\ M_{n-1} \end{pmatrix}, \quad \boldsymbol{A}=\begin{pmatrix} 2 & \lambda_0 & & & \mu_0 \\ \mu_1 & 2 & \lambda_1 & & \\ & \ddots & \ddots & \ddots & \\ & & \mu_{n-2} & 2 & \lambda_{n-2} \\ \lambda_{n-1} & & & \mu_{n-1} & 2 \end{pmatrix}.$$

注意到上述三种情形都是严格对角占优矩阵, 故 $\det(\boldsymbol{A})>0$, 且利用求解三对角矩阵的追赶法可得求解计算复杂度为 $\mathcal{O}(n)$, 并且还可以得到 $\kappa(\boldsymbol{A})=\mathcal{O}(1)$, 因此求解也是稳定的. □

再考察样条基函数 $\{S_j\}_{0\leqslant j\leqslant n}$, 使得 $S_j(x_k)=\delta_{jk}$, 但由于 S_j 是全局函数, 故 $(S_j,S_k)_{0\leqslant j,k\leqslant n}$ 不为稀疏矩阵.

收敛性

设

$$f\in C^4[a,b], \quad h:=\max_j h_j, \quad \beta=\frac{h}{\min_j h_j},$$

则

$$\|f^{(r)}-S^{(r)}\|_\infty \leqslant C_r(\beta)h^{4-r}\|f^{(4)}\|_\infty, \quad 0\leqslant r\leqslant 3,$$

见 J. Appr. Theory 16(1976), 105.

最小能量性质

设 $S\in\mathcal{S}_3$, 则 $\forall\, g\in C^2[a,b]$ 满足插值条件, 都有

$$\int_a^b |S''(x)|^2\,\mathrm{d}x \leqslant \int_a^b |g''(x)|^2\,\mathrm{d}x, \quad a:=x_0, \quad b:=x_1.$$

事实上,

$$\begin{aligned} &\int_a^b |S''-g''|^2\,\mathrm{d}x \\ =&\int_a^b S''^2+g''^2-2S''g''\,\mathrm{d}x \\ =&\int_a^b -S''^2+g''^2+2S''^2-2S''g''\,\mathrm{d}x, \end{aligned}$$

而

$$\begin{aligned} &\int_a^b 2S''^2-2S''g''\,\mathrm{d}x \\ =&\,2\int_a^b S''(S''-g'')\,\mathrm{d}x \end{aligned}$$

$$
\begin{aligned}
&= 2\sum_{j=0}^{n-1}\int_{x_j}^{x_{j+1}} S''(S''-g'')\,\mathrm{d}x \\
&= 2\sum_{j=0}^{n-1}\int_{x_j}^{x_{j+1}} S''\,\mathrm{d}(S'-g') \\
&= 2\sum_{j=0}^{n-1}\left(S''(S'-g')\Big|_{I_j} - \int_{I_j} S'''(S'-g')\,\mathrm{d}x\right) \\
&= -2\sum_{j=0}^{n-1} S'''\Big|_{I_j}\int_{I_j}\mathrm{d}(S-g) = 0,
\end{aligned}
$$

故

$$
\int_a^b -S''^2 + g''^2\,\mathrm{d}x = \int_a^b |S''-g''|^2\,\mathrm{d}x \geqslant 0.
$$

定义杆的弯曲能为

$$
E_b := \int_0^L \frac{1}{2}\kappa^2\,\mathrm{d}s, \quad (\text{曲率})\ \kappa := \left|\frac{\mathrm{d}\hat{\tau}}{\mathrm{d}s}\right|, \quad \hat{\tau} := \frac{\tau}{|\tau|}, \quad \tau := (1, f'(x)), \quad \mathrm{d}s := \sqrt{1+f'^2}\,\mathrm{d}x,
$$

则计算可得

$$
E_b = \frac{1}{2}\int_a^b \frac{f''^2}{(1+f'^2)^3}\,\mathrm{d}x,
$$

如果 $|f'| \ll 1$, 则

$$
E_b \approx \frac{1}{2}\int_a^b |f''|^2\,\mathrm{d}x,
$$

因此三次样条为杆的弯曲能的最小值点.

定义 3.5　B 样条 (B-spline, B: basic, basis)

定义关于 y 的函数为

$$
\begin{aligned}
&M_k(y;x) := k((y-x)_+)^{k-1} \in C^{k-2}, \quad x_+ := \max\{x,0\} = x \vee 0, \quad k \geqslant 1, \\
&M_k(x) := M_k[x_0, x_1, \cdots, x_k; x],
\end{aligned}
$$

再定义**规范化 k 次 B 样条基函数**为

$$
B_{i,k}(x) = \frac{x_{i+k+1}-x_i}{k+1} M_{k+1}[x_i, \cdots, x_{i+k+1}; x], \quad k \geqslant 0.
$$

由于

$$
M_k(x) = \sum_{j=0}^{k} \frac{k(x_j-x)_+^{k-1}}{\omega'_{k+1}(x_j)}, \quad \omega_{k+1}(y) := \prod_{j=0}^{k}(y-x_j),
$$

且 $M_k(y;x)$ 的分片 $\in \mathcal{P}_{k-1}$, 故易证 $M_k(x)=0$ 当且仅当 $x \geqslant x_k$ (由截断) 或者 $x \leqslant x_0$ (由 Newton 差商与 $M_k \in \mathcal{P}_{k-1}$), 同时 $\operatorname{supp} M_k \subseteq [x_0, x_k]$.

同理有 $\operatorname{supp} B_{i,k} = [x_i, x_{i+k+1}]$, $B_{i,k} \in C^{k-1}$ 且分片 $\in \mathcal{P}_k$, 同时还线性无关.

定理 3.2

$M_k^{(m)}(x), m \leqslant k-2$ 在 (x_0, x_k) 内恰有 m 个不同零点 (单重), 特别地, $M_k(x) > 0, \forall x \in (x_0, x_k)$.

定理 3.3 Schoenbeng

当 $x_0, x_1, \cdots, x_k$ 等距, 步长为 1 时, 有

$$M_k(x) = \frac{1}{(k-1)!}\delta^k x_+^{k-1}, \quad k \geqslant 1, \quad \delta f(x) := f(x+\frac{1}{2}) - f(x-\frac{1}{2}), \quad \delta^k f(x) = \delta(\delta^{k-1} f(x)).$$

定理 3.4 Cox-de Boor 递推式

$B_{i,k}(x)$ 满足如下递推式:

$$B_{i,0}(x) = \begin{cases} 1, & x \in [x_i, x_{i+1}], \\ 0, & \text{其他}, \end{cases}$$

$$B_{i,k}(x) = \frac{x - x_i}{x_{i+k} - x_i} B_{i,k-1}(x) + \frac{x_{i+k+1} - x}{x_{i+k+1} - x_{i+1}} B_{i+1,k-1}(x), \quad k \geqslant 1.$$

定义 3.6 k 次样条

由于

$$\dim \mathcal{S}_k = n \cdot (k+1) - k(n-1) = n + k,$$

故给定 $n+1$ 个插值后自由度为

$$n + k - (n+1) = k - 1.$$

引入 $2k$ 个虚拟点:

$$x_{-k} \leqslant x_{-k+1} \leqslant \cdots \leqslant x_0 = a, \quad b = x_n \leqslant x_{n+1} \leqslant \cdots \leqslant x_{n+k},$$

则 $n+k$ 个 k 次样条基函数为 $B_{i,k}, i \in S_k := \{-k, \cdots, n-1\}$. 典型取法为

$$x_{-k} = \cdots = x_0, \quad x_n = \cdots = x_{n+k}.$$

而 $B_{i,k}$ 是紧支的基函数, 故求解基函数的系数所对应的系数矩阵为稀疏矩阵.

第四章　最小二乘拟合 (Least Squares Fitting)

定义 4.1　拟合 (Fitting)

给定 $\{(x_i, y_i)\}_{1\leqslant i\leqslant n}$, 求解

$$\min_{\theta} \sum_{i=1}^{n} d(f(x_i;\theta), y_i).$$

$d(\cdot,\cdot)$ 的取法:

$$\begin{aligned}
&d(y_1, y_2) = \|y_1 - y_2\|_2^2 \quad (\ell^2 \text{ 距离}) \quad \text{Least Squares Fitting},\\
&d(y_1, y_2) = \|y_1 - y_2\|_\infty \quad (\ell^\infty \text{ 距离}) \quad \text{Uniform},\\
&d(y_1, y_2) = \|y_1 - y_2\|_p^p \quad (\ell^p \text{ 距离}).
\end{aligned}$$

对于拟合

$$\min_{\theta} L(\theta) = \sum_{i=1}^{n} |f(x_i;\theta) - y_i|^2,$$

(1) 若 $x, y \in \mathbb{R}$, 取

$$f(x;\theta) = kx + b, \quad \theta = (k, b).$$

(2) 若 $\boldsymbol{x} \in \mathbb{R}^d, y \in \mathbb{R}$, 取

$$f(\boldsymbol{x};\theta) = \sum_{i=1}^{d} \beta_i x_i + \beta_0, \quad \theta = (\beta_0, \cdots, \beta_d).$$

(3) 若 $\boldsymbol{x} \in \mathbb{R}^d$, 取 $\theta = \{\boldsymbol{e}_\alpha\}_{1\leqslant\alpha\leqslant k}$, 求解

$$\min_{\{\boldsymbol{e}_\alpha\}_\alpha} \left\| \boldsymbol{x}_i - \sum_{\alpha=1}^{k} (\boldsymbol{x}_i \cdot \boldsymbol{e}_\alpha)\boldsymbol{e}_\alpha \right\|_2^2 \quad \textbf{(主成分分析 Principal Componet Analysis)}.$$

还有 x-$\ln y$ 和 $\ln x$-$\ln y$ 等拟合方式.

考虑统计模型

$$\boldsymbol{y} = \boldsymbol{f}(\boldsymbol{x};\theta) + \boldsymbol{\varepsilon}, \quad \boldsymbol{\varepsilon} \sim N(0, \sigma^2 \boldsymbol{I}) \quad (\text{Noise}),$$

及其**似然函数 (Likehood)**

$$\mathcal{L}(\mathcal{D} \mid \theta) = \prod_{i=1}^{n} \frac{1}{Z} \mathrm{e}^{-\frac{1}{2\sigma^2}\|\boldsymbol{y}_i - \boldsymbol{f}(\boldsymbol{x}_i;\theta)\|^2},$$

对应的**极大似然估计 (MLE)**

$$\max_{\theta} \log \mathcal{L}(\mathcal{D} \mid \theta) \iff \min_{\theta} \sum_{i=1}^{n} \frac{1}{2\sigma^2} \|\boldsymbol{y}_i - \boldsymbol{f}(\boldsymbol{x}_i;\theta)\|^2,$$

对于一般情形, 协方差矩阵不确定, 则为

$$\min_{\theta} \sum_{i=1}^{n} (\boldsymbol{y}_i - \boldsymbol{f}(\boldsymbol{x}_i;\theta))^{\mathrm{T}} \boldsymbol{\Sigma}^{-1} (\boldsymbol{y}_i - \boldsymbol{f}(\boldsymbol{x}_i;\theta)).$$

最小二乘法 (LSM)

考虑**法方程**, 定义内积

$$(f, g)_\omega := \int_a^b \omega(x) f(x) g(x) \,\mathrm{d}x,$$

其中权函数 $\omega(x)$ 须满足:

$$\omega(x) \geqslant 0, \quad (f, f)_\omega = 0 \Longrightarrow f \equiv 0.$$

再定义范数 $\|f\|_\omega = \sqrt{(f, f)_\omega}$. 我们要求解

$$\min_{\varphi \in S} \|f - \varphi\|_\omega^2, \quad \dim S = m.$$

先给出基底 $\{\varphi_i\}_{1 \leqslant i \leqslant n}$, 以及基底表示

$$\varphi(x) = \sum_{i=1}^{m} \alpha_i \varphi_i(x),$$

则

$$\begin{aligned}
\mathcal{L} &= \left\| f - \sum_{i=1}^{m} \alpha_i \varphi_i \right\|_\omega^2 \\
&= \left(f - \sum_i \alpha_i \varphi_i, f - \sum_j \alpha_j \varphi_j \right)_\omega \\
&= (f, f) - \left(\sum_i \alpha_i \varphi_i, f \right) - \left(f, \sum_j \alpha_j \varphi_j \right) + \left(\sum_i \alpha_i \varphi_i, \sum_j \alpha_j \varphi_j \right) \\
&= \|f\|_\omega^2 - 2 \sum_i \alpha_i (\varphi_i, f)_\omega + \sum_{i,j} \alpha_i \alpha_j (\varphi_i, \varphi_j)_\omega
\end{aligned}$$

若再记

$$\boldsymbol{\alpha} := \begin{pmatrix} \alpha_1 \\ \vdots \\ \alpha_m \end{pmatrix}, \quad \boldsymbol{F} := \begin{pmatrix} (\varphi_1, f)_\omega \\ \vdots \\ (\varphi_m, f)_\omega \end{pmatrix}, \quad \boldsymbol{G} := (\varphi_i, \varphi_j)_\omega$$

则上式即为

$$\|f\|_\omega^2 - 2\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{F} + \boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{G}\boldsymbol{\alpha},$$

求导得

$$\frac{\partial \mathcal{L}}{\partial \alpha_i} = -2F_i + 2\sum_i g_{i,j}\alpha_j = 0,$$

故 $\boldsymbol{G}\boldsymbol{\alpha} = \boldsymbol{F}$, 其中**度量矩阵 (Gram 矩阵)** $\boldsymbol{G}$ 对称正定, 事实上,

$$\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{G}\boldsymbol{\alpha} = \left\| \sum_i \alpha_i \varphi_i \right\|_\omega^2 \geqslant 0,$$

且

$$\boldsymbol{\alpha}^{\mathrm{T}}\boldsymbol{G}\boldsymbol{\alpha} = 0 \iff \sum_i \alpha_i \varphi_i = 0 \iff \alpha_i = 0, \forall\, i.$$

因此 $\boldsymbol{\alpha}^* = \boldsymbol{G}^{-1}\boldsymbol{F}$ 存在且唯一.

解的性质

(1) 解为投影: 令

$$\varphi^* = \sum_i \alpha_i^* \varphi_i,$$

则

$$(f - \varphi^*, \varphi)_\omega = 0, \quad \forall\, \varphi \in S.$$

事实上, 只需

$$(f - \varphi^*, \varphi_i)_\omega = 0, \quad \forall\, i,$$

而

$$(f - \varphi^*, \varphi_i)_\omega = (f, \varphi_i) - \sum_j \alpha_j^* (\varphi_j, \varphi_i) = 0.$$

(2) 最优性:

$$\|f-\varphi\|_\omega^2 \geqslant \|f-\varphi^*\|_\omega^2, \quad \forall \varphi \in S.$$

事实上, 有

$$\|f-\varphi\|_\omega^2 = \|f-\varphi^*\|_\omega^2 + \|\varphi^*-\varphi\|_\omega^2.$$

如果取

$$\omega(x)=1, \quad [a,b]=[0,1], \quad S=\mathcal{P}_{n-1}, \quad \varphi_i = x^i,$$

则 $\boldsymbol{G}$ 即为 **Hilbert 矩阵**: $g_{ij}=1/(i+j-1), \forall 1 \leqslant i,j \leqslant n$, 对应的 $\kappa_2(\boldsymbol{G}) \gg 1$.

定义 4.2　正交多项式 (orthogonal polynomial)

对于基底 $\{\varphi_k\}_{1\leqslant k\leqslant n}$ 和内积 $(\cdot,\cdot)$, 定义 $\|\varphi\|=\sqrt{(\varphi,\varphi)}$. 进行如下 **Gram-Schmidt 正交化**:
(1) $\psi_1=\varphi_1, k=1$.
(2) $u_k=\psi_k/\|\psi_k\|$.
(3) $\psi_{k+1}=\varphi_{k+1}-\sum_{j=1}^k(\varphi_{k+1},u_j)u_j$.
(4) 如果 $k+1<n$, 则返回 **(1)**.

对于 $\varphi_k(x)=x^k, 0\leqslant k\leqslant n$, 有 $\varphi_k,\psi_k\in\mathcal{P}_k$ 且 ψ_{k+1} 首一, 故

$$\psi_{k+1}=x\psi_k+\sum_{j=0}^k a_j\psi_j,$$

两边与 ψ_m 内积, 则 $\forall 0\leqslant m\leqslant k-2$, 都有 $(x\psi_k,\psi_m)=(\psi_k,x\psi_m)=0$, 故 $a_m=0$. 从而得到**三项递归式**

$$\psi_{k+1}=(x+\alpha_{k+1})\psi_k+\beta_{k+1}\psi_{k-1},$$

其中系数 α_{k+1},β_{k+1} 由如下计算可得. 两边与 ψ_{k-1} 内积得

$$(x\psi_k,\psi_{k-1})+\beta_{k+1}\|\psi_{k-1}\|^2=0,$$

即

$$\beta_{k+1}=-\frac{(x\psi_k,\psi_{k-1})}{(\psi_{k-1},\psi_{k-1})}=-\frac{(\psi_k,x\psi_{k-1})}{(\psi_{k-1},\psi_{k-1})}=-\frac{(\psi_k,\psi_k)}{(\psi_{k-1},\psi_{k-1})}.$$

两边再与 ψ_k 内积同理可得

$$\alpha_{k+1}=-\frac{(x\psi_k,\psi_k)}{(\psi_k,\psi_k)}.$$

Legendre 多项式: 取

$$\omega(x)=1, \quad [a,b]=[-1,1],$$

Rodergue(1814) 给出表达式

$$P_n(x) = \frac{1}{2^n n!}\frac{\mathrm{d}^n}{\mathrm{d}x^n}(x^2-1)^n.$$

Chebyshev 多项式: 取

$$\omega(x) = (1-x^2)^{-1/2}, \quad [a,b] = [-1,1],$$

有表达式

$$P_n(x) = \cos(n\arccos x), \quad |x| \leqslant 1.$$

Laguerre 多项式: 取

$$\omega(x) = \mathrm{e}^{-x}, \quad [a,b) = [0,+\infty),$$

有表达式

$$P_n(x) = \mathrm{e}^x \frac{\mathrm{d}^n}{\mathrm{d}x^n}(x^n \mathrm{e}^{-x}).$$

Hermite 多项式: 取

$$\omega(x) = \mathrm{e}^{-x^2}, \quad (a,b) = \mathbb{R},$$

有表达式

$$P_n(x) = (-1)^n \mathrm{e}^{x^2}\frac{\mathrm{d}^n}{\mathrm{d}x^n}(\mathrm{e}^{-x^2}).$$

定义 4.3　线性最小二乘

给定 $\{(x_j,y_j)\}_{1\leqslant j\leqslant m}$ ，进行拟合

$$f(x;\theta) = \sum_{k=1}^n a_k\varphi_k(x),$$

需要对于 $\{a_k\}$ 最小化

$$\sum_{j=1}^m \left|\sum_{k=1}^n a_k\varphi_k(x_j) - y_j\right|^2 := \|\boldsymbol{A}\boldsymbol{x}-\boldsymbol{b}\|^2,$$

其中

$$\boldsymbol{x} = \begin{pmatrix} a_1 \\ \vdots \\ a_n \end{pmatrix}, \quad \boldsymbol{b} = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}, \quad \boldsymbol{A} \in \mathbb{R}^{m\times n}.$$

从而只需求解

$$\min_{\boldsymbol{x}} \frac{1}{2}(\boldsymbol{x}^{\mathrm{T}}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} - 2\boldsymbol{b}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} + \boldsymbol{b}^{\mathrm{T}}\boldsymbol{b}) := \min_{\boldsymbol{x}} L(\boldsymbol{x}),$$

由 $\nabla_{\boldsymbol{x}} L = 0$ 可得 $\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}$.
(1) 若 $m \gg n$, $r(\boldsymbol{A}) = n$, 则 $r(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}) = n$ **(超定 Overdetermined)**, 则

$$\boldsymbol{x} = (\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b} := \boldsymbol{A}^{+}\boldsymbol{b}, \quad \boldsymbol{A}^{+} \text{ 广义逆}.$$

(2) 若 $m < n, m \sim \mathcal{O}(n)$ **(欠定 Underdetermined)**, 有解当且仅当 $r([\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}, \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}]) = r(\boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})$, 此时解存在但不唯一. 因此还需**正则化 (Regularization)**, 引入**罚函数**:

$$\min_{\boldsymbol{x}} \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|^2 + \lambda\|\boldsymbol{x}\|^2 := \min_{\boldsymbol{x}} L(\boldsymbol{x}), \quad \lambda > 0,$$

由 $\nabla_{\boldsymbol{x}} L = 0$ 可得

$$(\lambda\boldsymbol{I} + \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})\boldsymbol{x} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A}\boldsymbol{x} + \lambda\boldsymbol{x} = \boldsymbol{A}^{\mathrm{T}}\boldsymbol{b},$$

因此得到**正则化最小二乘解**

$$\boldsymbol{x} = (\lambda\boldsymbol{I} + \boldsymbol{A}^{\mathrm{T}}\boldsymbol{A})^{-1}\boldsymbol{A}^{\mathrm{T}}\boldsymbol{b}.$$

事实上, 从统计学来看罚函数是最大似然估计中的参数的**先验分布**, 此处即为**正态分布**.
对于 **Laplace 先验**: $\mathrm{e}^{-\lambda\|\boldsymbol{x}\|_1}$, 定义了**压缩感知问题 (Lasso)**:

$$\min_{\boldsymbol{x}} \frac{1}{2}\|\boldsymbol{A}\boldsymbol{x} - \boldsymbol{b}\|_2^2 + \lambda\|\boldsymbol{x}\|_1.$$

第五章　其他论题

考虑**最佳一致逼近 (BUAP), Uniform Approximation,** $L^\infty[a,b]$.

定理 5.1　Weierstrass 定理

$\forall f \in C[a,b]$, 存在 $\{p_n\}_{n\geqslant 0} \subseteq \mathcal{P}_n$, 使得 $\lim_{n\to+\infty}\|p_n - f_n\|_\infty = 0$.

证明.

不妨设 $f \in C[0,1]$, 定义 **Bernstein 多项式**:

$$B_n^f(x) := \sum_{k=0}^{n} f\left(\frac{k}{n}\right)\binom{n}{k} x^k (1-x)^{n-k} \in \mathcal{P}_n,$$

那么如果定义随机变量 $X_n \sim B(n,x)$, 则 $B_n^f(x) = \mathbb{E}f(X_n)$. 由**大数定律**知 $X_n \to x$.

(1) 若 $|X_n - x| \leqslant \delta$, 利用 f 的一致连续性.

(2) 若 $|X_n - x| > \delta$, 利用 **Chebyshev 不等式**. □

定义 5.1　偏差

定义**偏差**:

$$E_n = E_n(f) := \inf_{p\in\mathcal{P}_n} \Delta(p), \quad \Delta(p) := \|p - f\|_\infty.$$

显然有 E_n 单调减小且趋于 0 .

下面考虑是否存在唯一的 p_n^* , 使得 $\Delta(p_n^*) = E_n$.

定理 5.2　Borel 存在定理

p_n^* 存在.

证明.

由定义, 存在 $\{p_k\} \subseteq \mathcal{P}_n$, 使得 $\|p_k - f\|_\infty \to E_n$, 故 $\|p_k\|_\infty \leqslant C$. 设

$$p_k(x) = \sum_{j=0}^{n} a_j^{(k)} x^j, \quad \vec{a}^{(k)} := (a_0^{(k)}, \cdots, a_n^{(k)}),$$

再定义 $f(\vec{a}) = \|p - f\|_\infty$, 显然 f 关于 $\vec{a}$ 连续. 再注意到 $\|p_k\|_\infty$ 与 $\|a^{(k)}\|_\infty$ 等价 (范数等价即为相互可被

常数倍控制), 故 $\|a^{(k)}\|_\infty$ 也有界, 因此存在子列收敛于 a^* , 此时取

$$p_k^*(x) := \sum_{j=0}^{n} a_j^* x^j,$$

则

$$\|p_k^* - f\|_\infty = \lim_{k\to+\infty} \|p_k - f\|_\infty = E_n.$$

□

定理 5.3　Chebyshev 定理

$\mathcal{P}_n$ 中 BUAP 存在且唯一, 且 $p(x)$ 为 BUAP 当且仅当 $\varepsilon(x) = p(x) - f(x)$ 在 $[a,b]$ 上点数不少于 $n+2$ 的点列 $x_1 < \cdots < x_N (N \geqslant n+2)$ 上正负交错的, 取到 $\Delta(p)$.

定义 5.2　最小零偏差多项式

要求 $\min_{p\in\mathcal{P}_n} \|p\|_\infty$, 其中 p 的 n 次项系数为 1 . 事实上就是要求 $\min_{p\in\mathcal{P}_{n-1}} \|x^n - p(x)\|_\infty$. 再不妨设 $[a,b] = [-1,1]$, 则可以证明最小零偏差多项式恰为 $\cos(n\arccos x)/2^{n-1}$.

BUAP 还可以理解为

$$\min_{p\in\mathcal{P}_n} \max_{x\in[a,b]} |p(x) - f(x)|.$$

对应特征值问题 $\boldsymbol{Ax} = \lambda\boldsymbol{x}$, 特征值满足:

$$\lambda_1 > \lambda_2 \geqslant \cdots \geqslant \lambda_n \subseteq [\alpha, \beta],$$

用**幂法**求解时, 将 $\boldsymbol{A}$ 替代为 $p_k(\boldsymbol{A})$, 使得

$$\min_{p_k\in\mathcal{P}_k, p_k(\lambda_1)=1} \max_{\lambda\in[\alpha,\beta]} p_k(\lambda),$$

这即为最小零偏差多项式, 这称为 **Chebyshev 加速**, 见 Y. Saad. Numer. Methods for Large Ergenvalues Prob.

第六章　数值积分基础 (Numerical Integration/Quadrature)

我们在求解低/高维积分、PDE、IE 等场景中都需要进行数值积分.

定义 6.1　Lagrange 插值积分

记

$$I(f) := \int_a^b f(x)\,\mathrm{d}x.$$

我们有**中点公式 (Midpoint)**

$$f \approx l_0(x) \in \mathcal{P}_0, \quad I(f) \approx I(l_0) = I_0(f) = f\left(\frac{a+b}{2}\right)(b-a);$$

以及**梯形公式 (Trapezoidal rule)**

$$f \approx l_1(x) \in \mathcal{P}_1, \quad I(f) \approx I(l_1) = I_1(f) = \frac{f(a)+f(b)}{2}(b-a);$$

一般情形有

$$\begin{aligned}
&l_n(x) = \sum_{k=0}^{n} y_k l_{n,k}(x), \quad y_k = f(x_k), \quad x_k = a + kh, \quad h = \frac{b-a}{n}, \\
&l_{n,k}(x) = \frac{\prod\limits_{j\neq k}(x - x_j)}{\prod\limits_{j\neq k}(x_k - x_j)} = \frac{\omega_{n+1}(x)}{(x-x_k)\omega'_{n+1}(x_k)}, \\
&I(f) \approx I(l_n) = I_n(f),
\end{aligned}$$

如果作变量替换

$$x \in [a,b] \mapsto t = \frac{x-a}{h} \in [0,n], \quad x_j \mapsto j,$$

则

$$l_{n,k}(x) = \frac{\prod\limits_{j\neq k}(t-j)}{\prod\limits_{j\neq k}(k-j)} := \widetilde{l}_{n,k}(t),$$

从而

$$I_n(f)=\int_a^b l_n(x)\,\mathrm{d}x=\int_0^n\sum_{k=0}^n f(x_k)\widetilde{l}_{n,k}(t)h\,\mathrm{d}t=\sum_{k=0}^n f(x_k)C_k^{(n)}(b-a),$$

其中

$$C_k^{(n)}=\frac{1}{n}\int_0^n\widetilde{l}_{n,k}(t)\,\mathrm{d}t=\frac{(-1)^{n-k}}{nk!(n-k)!}\int_0^n\prod_{j\neq k}(t-j)\,\mathrm{d}t,$$

此时 $I_n(f)$ 又被称为 **Newton-Cotes 求积公式**, $C_k^{(n)}$ 也称为 **Newton-Cotes 求积系数**, 并且易知

$$\sum_{k=0}^n C_k^{(n)}=1,$$

当 $n=2$ 时又被称为 **Simpson 公式**; 当 $n=4$ 时又被称为 **Cotes 公式**.

注意到当 $n\geqslant 8$ 时, $C_k^{(n)}$ 有正有负, 且

$$\sum_{k=0}^n|C_k^{(n)}|\to+\infty\quad(n\to+\infty),$$

数值不稳定. 事实上, 如果 $\widetilde{f}(x_k)=f(x_k)+\varepsilon_k,\varepsilon_k\sim N(0,\varepsilon)$, 则

$$I_n(f)\sim\sum_k C_k^{(n)}f(x_k),\quad \widetilde{I}_n(f)\sim\sum_k C_k^{(n)}\widetilde{f}(x_k),$$

故

$$|I_n(f)-\widetilde{I}_n(f)|\leqslant\sum_k|C_k^{(n)}|\max_k|\varepsilon_k|,$$

其中 $\max_k|\varepsilon_k|\sim\mathcal{O}(\varepsilon)\ll 1$. 如果 $C_k^{(n)}\geqslant 0$, 则

$$\sum_k|C_k^{(n)}|=\sum_k C_k^{(n)}=1;$$

如果 $C_k^{(n)}<0$, 则 $\sum_k|C_k^{(n)}|$ 可能很大.

定义 6.2　复合数值积分 (Composite Integration)

利用分片多项式插值:

复合中点公式:

$$M_n=\sum_{k=1}^n f(x_{k-1/2})h,\quad x_{k-1/2}:=\left(k-\frac{1}{2}\right)h+a;$$

复合梯形公式:

$$T_n = \sum_{k=0}^{n-1} \frac{f(x_k) + f(x_{k+1})}{2} h;$$

复合 Simpson 公式:

$$S_n = \sum_{k=0}^{n-1} \frac{f(x_k) + 4f(x_{k+1/2}) + f(x_{k+1})}{6} h.$$

注意到

$$\begin{aligned} T_{2n} &= \sum_{k=0}^{n-1} \left(\frac{f(x_k) + f(x_{k+1/2})}{2} \cdot \frac{h}{2} + \frac{f(x_{k+1/2}) + f(x_{k+1})}{2} \cdot \frac{h}{2} \right) \\ &= \frac{h}{4} \sum_{k=0}^{n-1} (f(x_k) + 2f(x_{k+1/2}) + f(x_{k+1})) \\ &= \frac{1}{2} M_n + \frac{1}{2} T_n, \end{aligned}$$

故 $M_n = 2T_{2n} - T_n$. 类似地, 有

$$S_n = \frac{1}{3} T_n + \frac{2}{3} M_n = \frac{1}{3} T_n + \frac{2}{3}(2T_{2n} - T_n) = \frac{1}{3}(4T_{2n} - T_n),$$

以及

$$C_n = \frac{4^2 S_{2n} - S_n}{4^2 - 1}.$$

定义 6.3 Richardson 外推

设 $h \ll 1$,

$$f(h) = f(0) + c_1 h^{p_1} + c_2 h^{p_2} + \cdots, \quad \mathbb{N} \ni p_1 < p_2 < \cdots,$$

故

$$f(h/2) = f(0) + c_1 (h/2)^{p_1} + c_2 (h/2)^{p_2} + \cdots,$$

从而

$$\frac{1}{2^{p_1}} f(h) - f(h/2) = \left(\frac{1}{2^{p_1}} - 1 \right) f(0) + \widetilde{c}_2 h^{p_2} + \cdots,$$

因此

$$\widetilde{f}(h) := \frac{\frac{1}{2^{p_1}} f(h) - f(h/2)}{\frac{1}{2^{p_1}} - 1} = \frac{2^{p_1} f(h/2) - f(h)}{2^{p_1} - 1},$$

则

$$\widetilde{f}(h) = f(0) + \widetilde{c}_2 h^{p_2} + \cdots .$$

由 Richardson 外推可得 **Euler-Maclaurin 公式**

$$T(h) = I(f) + c_1 h^2 + c_2 h^4 + c_3 h^6 + \cdots .$$

定义 6.4 Romberg 积分

定义

$$\begin{cases} T_1^{(l)} = T_{2^l}, \quad l \geqslant 0, \\ T_{m+1}^{(k-1)} = \dfrac{4^m T_m^{(k)} - T_m^{(k-1)}}{4^m - 1}, \quad 1 \leqslant m \leqslant l, \quad 1 \leqslant k \leqslant l - m, \end{cases}$$

最终得到 $T_l^{(0)}$ 的精度极高.

误差分析

对于 Lagrange 插值积分, 注意到

$$f(x) - l_n(x) = \frac{\omega_{n+1}(x)}{(n+1)!} f^{(n+1)}(\xi),$$

从而有

(1) 中点公式:

$$\begin{aligned} e_m &= \int_a^b f(x)\,\mathrm{d}x - (b-a) f\left(\frac{a+b}{2}\right) \\ &= \int_a^b (f(x) - l_0(x))\,\mathrm{d}x \\ &= \int_a^b \omega_1(x) f'(\xi_x)\,\mathrm{d}x \sim \mathcal{O}(h^2), \quad (|b-a| \sim \mathcal{O}(h)), \end{aligned}$$

同时, 由于

$$f(x) = f\left(\frac{a+b}{2}\right) + f'\left(\frac{a+b}{2}\right)\left(x - \frac{a+b}{2}\right) + \frac{f''(\xi_x)}{2!}\left(x - \frac{a+b}{2}\right)^2,$$

从而

$$e_M = \int_a^b \frac{f''(\xi_x)}{2}\left(x - \frac{a+b}{2}\right)^2 \mathrm{d}x = \frac{f''(\xi)}{2} \cdot \frac{1}{12}(b-a)^3 = \frac{f''(\xi)}{24}(b-a)^3 \sim \mathcal{O}(h^3).$$

(2) 梯形公式:

$$e_T = \int_a^b f(x) - l_1(x)\,\mathrm{d}x = \int_a^b \frac{f''(\xi_x)}{2}(x-a)(x-b)\,\mathrm{d}x = -\frac{f''(\xi)}{12}(b-a)^3.$$

(3) Simpson 公式:

$$e_S = \int_a^b (f(x) - l_2(x))\,\mathrm{d}x.$$

取 $p_3(x) \in \mathcal{P}_3$ 为 Hermite 插值多项式, 则

$$p_3(a) = f(a), \quad p_3(b) = f(b), \quad p_3\left(\frac{a+b}{2}\right) = f\left(\frac{a+b}{2}\right), \quad p_3'\left(\frac{a+b}{2}\right) = f'\left(\frac{a+b}{2}\right),$$

故

$$\begin{aligned} e_S &= \int_a^b (f(x) - p_3(x))\,\mathrm{d}x = \int_a^b \frac{f^{(4)}(\xi_x)}{4!}\Omega_4(x)\,\mathrm{d}x, \quad \Omega_4(x) := (x-a)\left(x - \frac{a+b}{2}\right)^2 (x-b) \\ &= \frac{f^{(4)}(\xi)}{2880}(b-a)^5 \sim \mathcal{O}(h^5). \end{aligned}$$

定理 6.1　一般 Lagrange 插值积分误差

当 n 为奇数时,

$$E_n = \frac{K_n}{(n+1)!}(b-a)^{n+2} f^{(n+1)}(\xi);$$

当 n 为偶数时,

$$E_n = \frac{M_n}{(n+2)!}(b-a)^{n+3} f^{(n+2)}(\xi),$$

其中 n 为插值多项式的次数,

$$K_n := \int_0^n \Pi_{n+1}(t)\,\mathrm{d}t, \quad M_n := \int_0^n t\Pi_{n+1}(t)\,\mathrm{d}t, \quad \Pi_{n+1}(t) := \prod_{i=0}^n (t-i).$$

对于分片 Lagrange 插值积分: 设

$$a = x_0 < x_1 < x_2 < \cdots < x_n = b, \quad h_j = x_{j+1} - x_j, \quad h = \max_{0 \leqslant j \leqslant n-1} h_j,$$

则

$$I_h(f) = \sum_{j=0}^{n-1} \int_{x_j}^{x_{j+1}} f(x)\,\mathrm{d}x \approx \sum_{j=0}^{n-1} I(p_k^j), \quad p_k^{(j)} \in \mathcal{P}_k,$$

再记 $e_h := I(f) - I_h(f)$. 故

$$|e_h| \leqslant \begin{cases} \dfrac{K_n}{(n+1)!} h^{n+1} L_{n+1} \displaystyle\sum_{j=0}^{n-1} h_j = \dfrac{K_n}{(n+1)!} h^{n+1} L_{n+1}(b-a), & n \text{ 为奇数}; \\ \dfrac{M_n}{(n+2)!} h^{n+2} L_{n+2} \displaystyle\sum_{j=0}^{n-1} h_j = \dfrac{M_n}{(n+2)!} h^{n+2} L_{n+2}(b-a), & n \text{ 为偶数}. \end{cases}$$

其中

$$L_{n+1} := \max_{x\in[a,b]} \left|f^{(n+1)}(x)\right|.$$

定义 6.5　逼近阶 (Convergence order)

若 $|e_h| \leqslant c \cdot h^p$, 则称为 p **阶收敛**.

因此 **(1)** 复合 Midpoint 公式 $e_h \sim \mathcal{O}(h^2)$;**(2)** 复合 Trapezoidal 公式 $e_h \sim \mathcal{O}(h^2)$;**(3)** 复合 Simpson 公式 $e_h \sim \mathcal{O}(h^4)$.

如果 $e_h \sim c \cdot h^p$, 则

$$\ln\left(\frac{|e_h|}{|e_{h/2}|}\right) \sim p \ln 2,$$

故

$$p \approx \ln\left(\frac{|e_h|}{|e_{h/2}|}\right) / \ln 2.$$

第七章　Gauss 积分

定义 7.1　代数精度 (degree of exactness, DOE)

设

$$I(f) := \int_a^b f(x)\,\mathrm{d}x, \quad I_n(f) := \sum_{k=0}^{n} f(x_k)A_k^{(n)}, \quad E_n(f) := I(f) - I_n(f), \quad A_k^{(n)} := C_k^{(n)}(b-a).$$

称 x_k 为**节点**, $A_k^{(n)}, C_k^{(n)}$ 为**求积系数**. 称**代数精度**为 k , 如果 $E_n(f) = 0, \forall f \in \mathcal{P}_k$.

定义 7.2　插值型积分 (interpolatory)

取

$$I_n(f) = I(L_n(f)) = I\left(\sum_{k=0}^{n} f(x_k)l_{n,k}(x)\right) = \sum_{k=0}^{n} f(x_k)\int_a^b l_{n,k}(x)\,\mathrm{d}x := \sum_{k=0}^{n} f(x_k)A_k^{(n)}.$$

命题 7.1

数值积分为插值型的 $\iff$ 代数精度 $\geqslant n$ $\iff$ $A_k^{(n)} = \int_a^b l_{n,k}(x)\,\mathrm{d}x$.

证明.

后一个充分必要性显然, 下面证明前一个充分必要性.

若数值积分为插值型的, 只需证: $\forall f \in \mathcal{P}_n$, 都有 $I(f) = I_n(f)$. 事实上, 由于 $f \in \mathcal{P}_n$, 故 $f = L_n(f)$, 从而

$$I(f) = I(L_n(f)) = I_n(f).$$

若代数精度 $\geqslant n$, 只需证: $I_n(f) = I(L_n(f))$. 事实上, 由于 $L_n(f) \in \mathcal{P}_n$, 故

$$I(L_n(f)) = I_n(L_n(f)) = \sum_{k=0}^{n} L_n(f)(x_k)A_k^{(n)} = \sum_{k=0}^{n} f(x_k)A_k^{(n)} = I_n(f).$$

□

如果代数精度 $\geqslant n$, 则

$$A_j^{(n)} = \int_a^b l_{n,j}(x)\,\mathrm{d}x,$$

再取 $f = x^k$, 则

$$\int_a^b x^k \,\mathrm{d}x = \sum_{j=0}^{n} x_j^k A_j^{(n)}, \quad \forall\, k \geqslant 0.$$

定理 7.1

$\forall 0 \leqslant k \leqslant n+1$, 数值积分具有 $d = n+k$ 次代数精度 $\iff$ 数值积分为插值型的, 且 $\omega_{n+1}(x)$ 满足:

$$\int_a^b \omega_{n+1}(x) p(x) \,\mathrm{d}x = 0, \quad \forall\, p \in \mathcal{P}_{k-1}, \quad \omega_{n+1}(x) := \prod_{j=0}^{n}(x - x_j).$$

证明.

必要性: 前一条显然, 下证后一条. 事实上, $\forall\, f \in \mathcal{P}_{n+k}$, 设

$$f(x) = \omega_{n+1}(x) q(x) + r(x), \quad r \in \mathcal{P}_n, \quad q \in \mathcal{P}_{k-1},$$

则

$$I_n(f) = I(f) = I(\omega_{n+1} q) + I(r) = I(\omega_{n+1} q) + I_n(r),$$

故

$$I(\omega_{n+1} q) = I_n(f) - I_n(r) = 0,$$

这是因为 $f(x_j) = r(x_j), 0 \leqslant j \leqslant n$. 必要性得证.

充分性由必要性易证. □

推论 7.2

当 n 为偶数时, 等距节点 Lagrange 插值积分具有 $d = n+1$ 次代数精度.

证明.

由于

$$\omega_{n+1}(x) = \prod_{j=0}^{n}(x - x_j), \quad x_j = a + jh,$$

故只需证

$$\int_a^b \omega_{n+1}(x) \,\mathrm{d}x = 0.$$

事实上, 令 $x = a + th, n = 2m, \widetilde{t} = t - m$, 则

$$\int_a^b \omega_{n+1}(x) \,\mathrm{d}x = \int_0^n \prod_{j=0}^{n}(t - j) \,\mathrm{d}t \cdot h = h \int_{-m}^{m} \prod_{j=-m}^{m} (\widetilde{t} - j) \,\mathrm{d}\widetilde{t} = h \int_{-m}^{m} \widetilde{t} \prod_{j=1}^{m} (\widetilde{t}^2 - j^2) \,\mathrm{d}\widetilde{t} = 0.$$

□

由此可得

$$I(p_3) = I(L_2(f)),$$

事实上,

$$I(p_3) = I_2(p_3) = I_2(L_2(f)) = I(L_2(f)).$$

定义 7.3 Gauss 积分

如果 $E_n(f) = 0, \forall f \in \mathcal{P}_{2n+1}$, 即代数精度为 $2n+1$, 则称该数值积分为 **Gauss 积分**.

显然 Gauss 积分 $\Longleftrightarrow$

$$\int_a^b \omega_{n+1}(x)p(x)\,\mathrm{d}x = 0, \quad \forall p \in \mathcal{P}_n.$$

由正交多项式可得 $\{x_j\}_{0\leqslant j\leqslant n}$ 经过平移和缩放后为 $n+1$ 次 Legendre 多项式的零点.

定理 7.2

n 次正交多项式恰有 n 个不同的实零点.

证明.

先考虑无复根的情形, 假设有实的重根, 设

$$p_n(x) = (x - x_{i_1})^{m_1} \cdots (x - x_{i_k})^{m_k} \in \mathcal{P}_n, \quad x_{i_j} \text{ 互不相等},$$

不妨设 $m_1, m_2, \cdots, m_k$ 均为奇数, 取

$$q(x) = (x - x_{i_1}) \cdots (x - x_{i_k}), \quad \deg q = k < n,$$

则

$$\int_a^b p_n q\,\mathrm{d}x = \int_a^b (x - x_{i_1})^{m_1+1} \cdots (x - x_{i_k})^{m_k+1}\,\mathrm{d}x > 0,$$

其他情形类似可证. □

推论 7.3

Gauss 积分可通过正交多项式的零点来构造.

命题 7.4

Gauss 积分具有最高的代数精度.

证明.

反证: 如果数值积分

$$I_n(f) = \sum_{j=0}^{n} f(x_j) A_j^{(n)}$$

具有 $2n+2$ 次代数精度, 则取 $f(x) = \omega_{n+1}^2(x) \in \mathcal{P}_{2n+2}$, 故

$$I(f) = \int_a^b \omega_{n+1}^2(x)\,\mathrm{d}x > 0,$$

但 $I_n(f) = 0$, 矛盾. □

命题 7.5

Gauss 积分中 $A_k^{(n)}, C_k^{(n)} > 0$, 且 $\sum_{k=0}^{n} C_k^{(n)} = 1$.

证明.

取

$$f_k(x) = \left(\frac{\omega_{n+1}(x)}{x - x_k}\right)^2 \in \mathcal{P}_{2n},$$

则

$$0 < \int_a^b \left(\frac{\omega_{n+1}(x)}{x - x_k}\right)^2 \mathrm{d}x = I(f_k) = I_n(f_k) = \sum_{j=0}^{n} f_k(x_j) A_j^{(n)} = f_k(x_k) A_k^{(n)},$$

故 $A_k^{(n)} > 0$, 且取 $f(x) \equiv 1$ 可得 $\sum_{k=0}^{n} C_k^{(n)} = 1$. □

常见的 Gauss 节点: $[-1,1], \rho(x) \equiv 1$ **(Gauss-Legendre)**

$$\begin{aligned}
n = 0: &\quad x_0 = 0, \quad C_0^{(0)} = 1; \\
n = 1: &\quad x_{0,1} = \pm\frac{1}{\sqrt{3}}, \quad C_{0,1}^{(1)} = \frac{1}{2}; \\
n = 2: &\quad x_0 = 0, \quad x_\pm = \pm\sqrt{\frac{3}{5}}, \quad C_0^{(2)} = \frac{4}{9}, \quad C_\pm^{(2)} = \frac{5}{18}.
\end{aligned}$$

下面进行误差估计. 设 $f \in C^{2n+2}[a,b]$, 则 Gauss 积分对应的

$$E_n(f) = \frac{f^{(2n+2)}(\xi)}{(2n+2)!} \int_a^b \omega_{n+1}^2(x)\,\mathrm{d}x = \mathcal{O}(h^{2n+2}).$$

事实上,

$$E_n(f) = I(f) - I(L_n(f)) = I(f) - I(H_n(f)),$$

其中 Hermite 插值多项式 $H_n(f) \in \mathcal{P}_{2n+1}$ 满足:

$$H(x_k) = f(x_k), \quad H'(x_k) = f'(x_k), \quad \forall\, 0 \leqslant k \leqslant n.$$

从而再由 Hermite 插值多项式的误差估计可得

$$E_n(f) = I(f - H_n(f)) = \int_a^b \frac{f^{(2n+2)}(\xi_x)}{(2n+2)!}\omega_{n+1}^2(x)\,\mathrm{d}x.$$

第八章　自适应与谱精度

自适应 (adaptivity)

对积分 $I(f)=\int_a^b f(x)\,\mathrm{d}x$ 求数值积分

$$I_h(f),\quad a=x_0<x_1<\cdots<x_k<\cdots<x_n=b$$

时, 为提高精度, 网格是自由度.

我们采取**误差等分布原则 (Equi-distribution of error)**: 为使 $|I(f)-I_h(f)|\leqslant\varepsilon$, 只需

$$\left|\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x-I_h(f;[x_k,x_{k+1}])\right|\leqslant\frac{x_{k+1}-x_k}{b-a}\varepsilon.$$

以复合 Simpson 为例:

$$I(f)\approx\sum_k(S_k+e_k),$$

其中 S_k 为 Simpson 公式在 $[x_k,x_{k+1}]$ 上的积分, 则

$$S_k-\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x=C(x_{k+1}-x_k)^5f^{(4)}(\xi_1):=-e_k,\quad \xi_1\in(x_k,x_{k+1}),\quad h_k:=x_{k+1}-x_k,$$

步长折半后为

$$\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x=\left(\int_{x_k}^{x_{k+1/2}}+\int_{x_{k+1/2}}^{x_{k+1}}\right)f(x)\,\mathrm{d}x\approx S_k^{(1)}+S_k^{(2)}+C\left(\frac{h}{2}\right)^5\left(f^{(4)}(\widetilde{\xi}_1)+f^{(4)}(\widetilde{\xi}_2)\right),$$

这即为**折中 (trade-off)**. 假设 $f^{(4)}(\xi)\approx f^{(4)}(\widetilde{\xi}_1)=f^{(4)}(\widetilde{\xi}_2)$, 则

$$S_k+e_k=\int_{x_k}^{x_{k+1}} f(x)\,\mathrm{d}x=\left(\int_{x_k}^{x_{k+1/2}}+\int_{x_{k+1/2}}^{x_{k+1}}\right)f(x)\,\mathrm{d}x=S_k^{(1)}+S_k^{(2)}+\frac{e_k}{16},$$

故

$$e_k=\frac{16}{15}\left[(S_k^{(1)}+S_k^{(2)})-S_k\right]\approx\frac{h_k}{b-a}\varepsilon,$$

从而

$$\widetilde{e}_k=\frac{e_k}{16}=\frac{1}{15}\left[(S_k^{(1)}+S_k^{(2)})-S_k\right],$$

保守处理: 如果

$$\frac{1}{10}\left(S_k^{(1)}+S_k^{(2)}-S_k\right)\leqslant\varepsilon\cdot\frac{h_k}{b-a},$$

则通过检验.

算法描述: 记 A : 正在估计的区间 (Active interval); S : 已经通过检验的区间 (Safe), 积分值为 $I_S(f)$; N : 未处理的区间 (Not examined). 初始化: $S=\varnothing$, $A=N=[a,b]$; 循环: 设 $A=[\alpha,\beta]$. **(1)** 若 A 通过检验, 则 $S\leftarrow S\cup A, A=N$; **(2)** 若未通过检验, 则 $A=[\alpha,\frac{\alpha+\beta}{2}], N=[\frac{\alpha+\beta}{2},\beta]\cup N$.

Euler-Maclaurin 公式

定义 8.1 Bernoulli 多项式

令 $B_0(x)=1$, $\forall n\geqslant 1$, 取 $B_n\in\mathcal{P}_n$, 使得

$$B_n'=B_{n-1},\quad \int_0^1 B_n(x)\,\mathrm{d}x=0.$$

直接计算可得

$$B_1(x)=x-\frac{1}{2},\quad B_2(x)=\frac{1}{2}x^2-\frac{1}{2}x+\frac{1}{12},$$

并且显然有 $B_n(0)=B_n(1),\forall n\geqslant 2$.

定义 8.2 Bernoulli 数

定义 $b_n:=n!B_n(0),\forall n\geqslant 0$.

引理 8.1

$B_n(x)=(-1)^nB_n(1-x),\quad \forall x\in\mathbb{R},\forall n\geqslant 0$.

推论 8.2

对 $B_n(x)$ 在 $[0,1]$ 外作周期延拓, 则当 n 为偶数时, $\widetilde{B}_n$ 为偶函数; 当 n 为奇数时, $\widetilde{B}_n$ 为奇函数.

引理 8.3

$B_{2m+1}(x),m\geqslant 1$ 在 $[0,1]$ 上有且仅有 3 个根 $x=0,1/2,1$; $B_{2m}(x),m\geqslant 0$ 满足: $B_{2m}(0)\neq 0$.

证明.

由 $B_{2m+1}(0)=B_{2m+1}(1),m\geqslant 1$ 以及 $B_{2m+1}(0)=-B_{2m+1}(1)$ 可得 $B_{2m+1}(0)=B_{2m+1}(1)=0$. 再由 $B_{2m+1}(1/2)=-B_{2m+1}(1/2)$ 可得 $B_{2m+1}(1/2)=0$.

下证仅有 3 个根. 对 B_3 显然, 假设存在 $x_0\in(0,1/2)$, 使得 $B_{2m+1}(x_0)=0$. 由 Rolle 定理, $B_{2m-1}(x)$ 在 $(0,1/2)$ 中有根, 由归纳法知矛盾.

对 $B_{2m}(x)$: 由于 $B_{2m+1}(x)$ 在 $x=0,1/2,1$ 上为 0 , 故 $B_{2m}(x)$ 在 $(0,1/2)$ 上有一点为 0 . 如果还有

$B_{2m}(0)=B_{2m}(1)=0$, 则 $B_{2m-1}(x)$ 在 $(0,1/2)$ 上有根, 矛盾. □

命题 8.4

$$\widetilde{B}_{2m}(x)=2(-1)^{m-1}\sum_{k=1}^{+\infty}\frac{\cos 2\pi kx}{(2\pi k)^{2m}},$$
$$\widetilde{B}_{2m+1}(x)=2(-1)^{m+1}\sum_{k=1}^{+\infty}\frac{\sin 2\pi kx}{(2\pi k)^{2m+1}}.$$

由 $B_{2m}(0)\neq 0$ 可得 $b_{2m}\neq 0,\forall m\geqslant 0$.

定理 8.1 Euler-Maclaurin 公式

取数值积分为等距节点的复合梯形公式, 则

$$I(f)-I_T(f)=-\sum_{j=1}^{[m/2]}\frac{b_{2j}h^{2j}}{(2j)!}\left(f^{(2j-1)}(b)-f^{(2j-1)}(a)\right)+(-1)^m h^m\int_a^b\widetilde{B}_m\left(\frac{x-a}{h}\right)f^{(m)}(x)\,\mathrm{d}x.$$

证明.

注意到

$$\int_0^1 B_1(z)g'(z)\,\mathrm{d}z=\int_0^1\left(z-\frac{1}{2}\right)g'(z)\,\mathrm{d}z=\int_0^1 z\,\mathrm{d}g-\frac{1}{2}\left(g(1)-g(0)\right)=\frac{1}{2}(g(0)+g(1))-\int_0^1 g\,\mathrm{d}z,$$

并且

$$\int_0^1 B_1(z)g'(z)\,\mathrm{d}z=\int_0^1 g'(z)\,\mathrm{d}B_2=g'B_2\Big|_0^1-\int_0^1 B_2g''\,\mathrm{d}z=b_2(g'(1)-g'(0))-\int_0^1 B_2g''\,\mathrm{d}z,$$

不断重复上述步骤可得上式等于

$$\sum_{j=2}^{m}(-1)^jB_j(0)\left(g^{(j-1)}(1)-g^{(j-1)}(0)\right)-(-1)^m\int_0^1 B_m(z)g^{(m)}(z)\,\mathrm{d}z,$$

因此

$$\int_0^1 g(z)\,\mathrm{d}z=\frac{1}{2}(g(0)+g(1))-\sum_{j=1}^{[m/2]}\frac{b_{2j}}{(2j)!}\left(g^{(2j-1)}(1)-g^{(2j-1)}(0)\right)+(-1)^m\int_0^1 B_m(z)g^{(m)}(z)\,\mathrm{d}z,$$

设 $x=x_k+hz,g(z)=f(x_k+hz)$, 代入可得 $\int_{x_k}^{x_{k+1}}f(x)\,\mathrm{d}x$ 的估计, 再对 k 求和即可得证. □

推论 8.5

设 $f\in C^{2m+1}$ 且以 2π 为周期, 则

$$|E_T(f)|\leqslant Ch^{2m+1}\int_0^{2\pi}\left|f^{(2m+1)}(z)\right|\mathrm{d}z.$$

谱收敛 (Spectual Convergence)

设 $f:\mathbb{R}\to\mathbb{R}$ 实解析 (任意一点 x 处 Taylor 展开式, 都存在邻域 $B_{r(x)}(x)$ 在复域上收敛), 且以 2π 为周期.

引理 8.6

$$\left(\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi}-\int_{-\mathrm{i}\alpha}^{-\mathrm{i}\alpha+2\pi}\right)\cot\left(\frac{nz}{2}\right)f(z)\,\mathrm{d}z=-\frac{4\pi\mathrm{i}}{n}\sum_{k=1}^{n}f\left(\frac{2k\pi}{n}\right).$$

证明.

由于

$$\cot\left(\frac{nz}{2}\right)=\frac{\cos(\frac{nz}{2})}{\sin(\frac{nz}{2})},$$

故 $z=2k\pi/n$ 为其一阶极点, 再结合留数定理即证. □

推论 8.7

$$\mathrm{Re}\left(\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi}\mathrm{i}\cot\left(\frac{nz}{2}\right)f(z)\,\mathrm{d}z\right)=\frac{2\pi}{n}\sum_{k=1}^{n}f\left(\frac{2k\pi}{n}\right).$$

引理 8.8

$$\mathrm{Re}\left(\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi}f(z)\,\mathrm{d}z\right)=\int_{0}^{2\pi}f(x)\,\mathrm{d}x.$$

证明.

由留数定理,

$$\left(\int_{0}^{\mathrm{i}\alpha}+\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi}-\int_{2\pi}^{\mathrm{i}\alpha+2\pi}-\int_{0}^{2\pi}\right)f(z)\,\mathrm{d}z=0,$$

再由周期性可得

$$\int_{0}^{\mathrm{i}\alpha}f(x)\,\mathrm{d}z=\int_{2\pi}^{\mathrm{i}\alpha+2\pi}f(z)\,\mathrm{d}z,$$

故

$$\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi}f(z)\,\mathrm{d}z=\int_{0}^{2\pi}f(z)\,\mathrm{d}z.$$

同理可得

$$\int_{-\mathrm{i}\alpha}^{-\mathrm{i}\alpha+2\pi} f(z)\,\mathrm{d}z = \int_0^{2\pi} f(z)\,\mathrm{d}z,$$

再由解析延拓的唯一性可得 $f(\overline{z}) = \overline{f(z)}$, 从而

$$\int_{-\mathrm{i}\alpha}^{-\mathrm{i}\alpha+2\pi} f(z)\,\mathrm{d}z = \overline{\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi} f(z)\,\mathrm{d}z},$$

因此

$$\int_0^{2\pi} f(x)\,\mathrm{d}x = \frac{1}{2}\left(\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi} f(z)\,\mathrm{d}z + \int_{-\mathrm{i}\alpha}^{-\mathrm{i}\alpha+2\pi} f(z)\,\mathrm{d}z\right) = \mathrm{Re}\left(\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi} f(z)\,\mathrm{d}z\right).$$

□

定理 8.2

如果存在 $D_\alpha = \mathbb{R}\times(-\alpha,\alpha)\subseteq\mathbb{C}, \alpha>0$, 使得 f 在 D_α 上解析, 则

$$|E_T(f)| \leqslant \frac{4\pi M}{\mathrm{e}^{n\alpha}-1}, \quad M := \max_{z\in D_\alpha}|f(z)|, \quad h = \frac{2\pi}{n}.$$

证明.

由上述引理可得

$$E_n(f) = \mathrm{Re}\left(\int_{\mathrm{i}\alpha}^{\mathrm{i}\alpha+2\pi}\left(1-\mathrm{i}\cot\frac{nz}{2}\right)f(z)\,\mathrm{d}z\right),$$

而

$$\cot z = \mathrm{i}\cdot\frac{\mathrm{e}^{\mathrm{i}z}+\mathrm{e}^{-\mathrm{i}z}}{\mathrm{e}^{\mathrm{i}z}-\mathrm{e}^{-\mathrm{i}z}} = \mathrm{i}\cdot\frac{\mathrm{e}^{2\mathrm{i}z}+1}{\mathrm{e}^{2\mathrm{i}z}-1},$$

故

$$\begin{aligned}E_n(f) &= \mathrm{Re}\left(\int_0^{2\pi}\left(1+\frac{\mathrm{e}^{2\mathrm{i}(\mathrm{i}\alpha+\theta)\frac{n}{2}}+1}{\mathrm{e}^{2\mathrm{i}(\mathrm{i}\alpha+\theta)\frac{n}{2}}-1}\right)f(\mathrm{i}\alpha+\theta)\,\mathrm{d}\theta\right)\\ &= \mathrm{Re}\left(\int_0^{2\pi}\frac{2\mathrm{e}^{-n\alpha}\mathrm{e}^{\mathrm{i}n\theta}}{\mathrm{e}^{-n\alpha}\mathrm{e}^{\mathrm{i}n\theta}-1}f(\mathrm{i}\alpha+\theta)\,\mathrm{d}\theta\right),\end{aligned}$$

从而

$$|E_n(f)| \leqslant \int_0^{2\pi}\frac{2\mathrm{e}^{-n\alpha}}{1-\mathrm{e}^{-n\alpha}}M\,\mathrm{d}\theta = \frac{4\pi M}{\mathrm{e}^{n\alpha}-1}.$$

□

第九章　多维积分与数值微分

多维数值积分 (multi-dimensional)

积分约化

考察积分

$$I(f)=\iint_{\Omega} f(x,y)\,\mathrm{d}x\,\mathrm{d}y,$$

其中

$$\Omega=\{(x,y)\mid a\leqslant x\leqslant b,\phi_1(x)\leqslant y\leqslant \phi_2(x)\},$$

则

$$I(f)=\int_a^b \mathrm{d}x\int_{\phi_1(x)}^{\phi_2(x)} f(x,y)\,\mathrm{d}y:=\int_a^b F(x)\,\mathrm{d}x\approx\sum_{i=1}^{N^x}\alpha_i F(x_i)=\sum_{i=1}^{N^x}\alpha_i\sum_{j=1}^{n_i^y}\beta_j^i f(x_i,y_j^i).$$

复合求积

做单纯形剖分

$$\Omega=\bigcup_{T\in\mathcal{T}_h} T,$$

则

$$\iint_{\Omega} f(x,y)\,\mathrm{d}x\,\mathrm{d}y=\sum_{T\in\mathcal{T}_h}\iint_T f(x,y)\,\mathrm{d}x\,\mathrm{d}y\approx\sum_{T\in\mathcal{T}_h}\sum_{j=0}^{d_T-1}\alpha_j^T f(\vec{x}_j^T),$$

其中

$$\iint_T f(x,y)\,\mathrm{d}x\,\mathrm{d}y\approx\iint_T\sum_{j=0}^{d_T-1} f(\vec{x}_j^T)l_j(x,y)\,\mathrm{d}x\,\mathrm{d}y=\sum_{j=0}^{d_T-1} f(\vec{x}_j^T)\iint_T l_j(x,y)\,\mathrm{d}x\,\mathrm{d}y.$$

再作仿射变换 A_T , 使得 $A_T(T)=\hat{T}$, 其中 $\hat{T}$ 是以 $(0,0),(0,1),(1,0)$ 为顶点的三角形, 故上式等于

$$\sum_{j=0}^{d_T-1} f(\vec{x}_j^T)\iint_{\hat{T}}\hat{l}_j(\hat{x},\hat{y})\frac{\partial(x,y)}{\partial(\hat{x},\hat{y})}\,\mathrm{d}\hat{x}\,\mathrm{d}\hat{y}=2|T|\sum_{j=0}^{d_T-1} f(\vec{x}_j^T)\iint_{\hat{T}}\hat{l}_j(\hat{x},\hat{y})\,\mathrm{d}\hat{x}\,\mathrm{d}\hat{y},$$

可类似推广到多维.

对于 2 维情形中的特例:

(1) 若 $d_T = 1, k = 0$, 则

$$I_h^0(f) = \sum_{T\in\mathcal{T}_h} f(\vec{x}_0^T)|T|,$$

其中 $\vec{x}_0^T$ 的典型取法为 T 的重心.

(2) 若 $d_k = 3, k = 1$, 则

$$I_h^1(f) = \sum_{T\in\mathcal{T}_h}\sum_{j=0}^{2} f(\vec{x}_j^{\mathrm{T}})\frac{|T|}{3},$$

其中 $\vec{x}_j^{\mathrm{T}}, 0 \leqslant j \leqslant 2$ 为 T 的 3 个顶点.

数值微分

基本做法

设 $f(x)$ 的 Lagrange 插值多项式为 $L_n(x)$, 则 $f'(x) \approx L_n'(x)$. 在 $x = x_0$ 处

$$\begin{aligned}
&f(x) = L_n(x) + R_n(x),\\
&L_n(x) = f[x_0] + f[x_0, x_1](x - x_0) + \cdots + f[x_0, \cdots, x_n]\omega_n(x),\\
&R_n(x) = f[x_0, \cdots, x_n, x]\omega_{n+1}(x),
\end{aligned}$$

从而

$$\begin{aligned}
&f'(x_0) = L_n'(x_0) + R_n'(x_0),\\
&L_n'(x_0) = f[x_0, x_1] + \cdots + f[x_0, \cdots, x_n](x_0 - x_1)\cdots(x_0 - x_{n-1}),\\
&R_n'(x_0) = f[x_0, \cdots, x_n, x_0](x_0 - x_1)\cdots(x_0 - x_n) = \frac{f^{(n+1)}(\xi)}{(n+1)!}(x_0 - x_1)\cdots(x_0 - x_n).
\end{aligned}$$

当 $n = 1$ 时, 取 $x_1 = x_0 + h$, 则

$$f'(x_0) \approx \frac{f(x_1) - f(x_0)}{x_1 - x_0}, \quad e_h = \frac{f''(\xi)}{2}h.$$

当 $n = 2$ 时, 取 $x_k = x_0 + kh, k = 1, 2$, 则

$$f'(x_0) \approx \frac{f(x_1) - f(x_0)}{h} - \frac{f(x_2) - 2f(x_1) + f(x_0)}{2h} = \frac{-f(x_2) + 4f(x_1) - 3f(x_0)}{2h}, \quad e_h = \mathcal{O}(h^2).$$

如果改成取 $x_k = x_0 + kh, k = -1, 1$, 则得到**中心差商 (Central difference)**

$$f'(x_0) \approx \frac{f(x_1) - f(x_{-1})}{2h}, \quad e_h = \mathcal{O}(h^2).$$

我们还可定义**谱导数 (pseudo-spectual derivative)**: 取 $L_n(x)$ 为 Gauss 点上的 Lagrange 插值.

以上的本质为 Taylor 展开, 注意到

$$
\begin{aligned}
f(x_1) &= f(x_0) + f'(x_0)h + \frac{1}{2}f''(x_0)h^2 + \cdots, \\
f(x_{-1}) &= f(x_0) - f'(x_0)h + \frac{1}{2}f''(x_0)h^2 + \cdots,
\end{aligned}
$$

适当选取 $\alpha_{-1}, \alpha_0, \alpha_1$, 使得

$$
\sum_{i=-1}^{1} \alpha_i f(x_i) = f'(x_0)\beta_1 h + f''(x_0)\beta_2 h^2 + \cdots.
$$

数值稳定性

以中心差商为例, 记

$$
f' \approx \frac{f(x_1) - f(x_{-1})}{2h} := f'_h,
$$

则

$$
|f'_h - f'| \leqslant Ch^2,
$$

但数值上

$$
\widetilde{f}'_h = \frac{\widetilde{f}(x_1) - \widetilde{f}(x_{-1})}{2h}, \quad \widetilde{f}(x_k) = f(x_k) + \varepsilon_k, \quad |\varepsilon_k| \leqslant \varepsilon, \quad k = \pm 1,
$$

从而

$$
\begin{aligned}
|\widetilde{f}'_h - f'| &= |\widetilde{f}'_h - f'_h + f'_h - f_h| \\
&\leqslant |\widetilde{f}'_h - f'_h| + |f'_h - f'| \\
&= \left|\frac{\varepsilon_1 - \varepsilon_{-1}}{2h}\right| + Ch^2 \\
&\leqslant \frac{\varepsilon}{h} + Ch^2,
\end{aligned}
$$

两项分别对应**噪声 (noise)** 和**偏差 (bias)** . 当 $h = \sqrt[3]{\varepsilon/2C}$ 时, $\varepsilon/h + Ch^2$ 最小, 二者达到**折中 (Trade-off)** , 此时

$$
|\widetilde{f}'_h - f'| \leqslant \frac{3}{2\sqrt[3]{2C}}\varepsilon^{2/3}.
$$

紧致格式 (Compact scheme)

采用**基架 (stencile)** , 求解如下线性方程组

$$
h\sum_{k=-m}^{m} \alpha_k f'_{i-k} = \sum_{k=-m'}^{m'} \beta_k f(x_{i-k}).
$$

以 $m = m' = 1$ 为例, 此时得到

$$f_i' + e_h = \alpha f_{i-1}' + \alpha f_{i+1}' + \frac{\beta}{2h}(f_{i+1} - f_{i-1}),$$

设置 α, β 使得 e_h 尽可能高阶.

第十章　Monte Carlo 方法

我们希望计算高维积分

$$I(f)=\int_{\mathbb{R}^d} f(\vec{x})\,\mathrm{d}\vec{x},\quad d\gg 1.$$

基本思想

以 1 维为例. 设

$$I(f)=\int_0^1 f(x)\,\mathrm{d}x,$$

记中点公式

$$I_N^{(1)}:=h\sum_{j=1}^N f(x_{j-1/2}),\quad x_{j-1/2}=(j-1/2)h,\quad h=1/N,$$

则

$$e_N^{(1)}\sim\mathcal{O}(h^2)=\mathcal{O}(N^{-2}).$$

由于

$$I(f)=\mathbb{E}f(X),\quad X\sim\mathcal{U}(0,1),$$

故

$$I_N^{(2)}:=\frac{1}{N}\sum_{j=1}^N f(X_j),\quad X_j\overset{\text{i.i.d.}}{\sim}\mathcal{U}(0,1),$$

由**强大数定律 (SLLN)** 可得 $I_N^{(2)}\xrightarrow{\text{a.s.}}\mathbb{E}f(X), N\to+\infty$, 此时

$$\begin{aligned}\mathbb{E}\left|e_N^{(2)}\right|^2&=\mathbb{E}\left|I(f)-\frac{1}{N}\sum_{j=1}^N f(X_j)\right|^2\\&=\mathbb{E}\left(\frac{1}{N}\sum_{j=1}^N(f(X_j)-I(f))\right)^2\end{aligned}$$

$$
\begin{aligned}
&= \frac{1}{N^2}\sum_{i,j=1}^{N}\mathbb{E}(f(X_i)-I(f))(f(X_j)-I(f)) \\
&= \frac{1}{N^2}\sum_{i=1}^{n}\mathbb{E}(f(X_i)-I(f))^2 \\
&= \frac{1}{N}\mathbb{E}(f(X)-I(f))^2 \\
&= \frac{\mathrm{Var}_X(f)}{N},
\end{aligned}
$$

再由 Hölder 不等式可得

$$
\mathbb{E}|fg| \leqslant (\mathbb{E}|f|^p)^{1/p}\,(\mathbb{E}|g|^q)^{1/q}, \quad p,q \geqslant 1, \quad \frac{1}{p}+\frac{1}{q}=1,
$$

从而

$$
\mathbb{E}\left|e_N^{(2)}\right| \leqslant \left(\mathbb{E}\left|e_N^{(2)}\right|^2\right)^{1/2} = N^{-1/2}\sigma_f, \quad \sigma_f := \sqrt{\mathrm{Var}_X(f)}.
$$

对于高维 (d 维) 情形

$$
I(f) = \int_{[0,1]^d} f(x)\,\mathrm{d}x,
$$

有中点公式

$$
I_N^{(1)} := h^d \sum_{j=1}^{M^d} f(\vec{x}_j), \quad h = 1/M,
$$

且

$$
e_N^{(1)} \sim \mathcal{O}(h^2) = \mathcal{O}(M^{-2}).
$$

同时

$$
I_N^{(2)} := \frac{1}{N}\sum_{j=1}^{N} f(X_j), \quad X_j \overset{\text{i.i.d.}}{\sim} \mathcal{U}((0,1)^d),
$$

同理有

$$
\mathbb{E}\left|e_N^{(2)}\right| \leqslant N^{-1/2}\sigma_f.
$$

在相同的计算代价下 $N = M^d$, 即 $M = N^{1/d}$, 故 $e_N^{(1)} \sim \mathcal{O}(N^{-2/d})$, 当 $d = 4$ 时二者收敛阶相同.

因此, 当 $d \gg 1$ 时, Monte Carlo 比确定性数值积分更有效, 并且 Monte Carlo 的精度为 $\mathcal{O}(N^{-1/2})$, 不依赖于维数 d , 但依赖于 σ_f , 以及 Monte Carlo 天然可并行, 结果是随机的 (**大偏差理论, LDT**).

一般来说,

$$
I(f) = \int_{\mathbb{R}^d} f(x)p(x)\,\mathrm{d}x = \mathbb{E}f(X), \quad X \sim p(x),
$$

取 **Gibbs 分布**

$$p(x)=\frac{1}{Z}\mathrm{e}^{-H(x)},\quad Z=\int_{\mathbb{R}^d}\mathrm{e}^{-H(x)}\,\mathrm{d}x,$$

即 $H(x)=-\ln p(x)+C$.

方差减小技术 (Variance Reduction)

重要性抽样 (Importance Sampling)

由于

$$\begin{aligned}I(f)&=\int_0^1 f(x)\,\mathrm{d}x=\mathbb{E}f(X),\quad X\sim\mathcal{U}(0,1),\\&=\int_0^1\frac{f}{p}(x)p(x)\,\mathrm{d}x=\mathbb{E}\frac{f}{p}(Y),\quad Y\sim p(y),\end{aligned}$$

故定义

$$\widetilde{I}_N:=\frac{1}{N}\sum_{j=1}^N\frac{f}{p}(Y_j),\quad Y_j\overset{\text{i.i.d.}}{\sim}p(y),$$

从而

$$\mathbb{E}|\widetilde{e}_N|\leqslant N^{-1/2}\sigma_{f/p},$$

其中

$$\begin{aligned}\sigma_{f/p}^2&=\mathbb{E}\left(\frac{f}{p}(Y)-I\right)^2\\&=\int_0^1\left(\frac{f}{p}(y)-I\right)^2p(y)\,\mathrm{d}y\\&=\int_0^1\frac{f^2}{p}(y)\,\mathrm{d}y-I^2,\end{aligned}$$

且

$$\sigma_f^2=\int_0^1 f^2(x)\,\mathrm{d}x-I^2.$$

因此需要求

$$\min_{p\geqslant 0,\int_0^1 p(y)\,\mathrm{d}y=1}\int_0^1\frac{f^2}{p}(y)\,\mathrm{d}y,$$

不妨设 $f>0$, 由于

$$I=\int_0^1\frac{f}{\sqrt{p}}(y)\sqrt{p(y)}\,\mathrm{d}y\leqslant\left(\int_0^1\frac{f^2}{p}\,\mathrm{d}y\right)^{1/2}\left(\int_0^1 p(y)\,\mathrm{d}y\right)^{1/2}=\left(\int_0^1\frac{f^2}{p}\,\mathrm{d}y\right)^{1/2},$$

即

$$I^2 \leqslant \int_0^1 \frac{f^2}{p}(y)\,\mathrm{d}y.$$

取等条件:

$$\frac{f}{\sqrt{p}}(y) = C\sqrt{p(y)} \iff f(y) = Cp(y) \iff p(y) = f(y)/C, \quad C = I(f).$$

控制变量法 (Control Variables)

考虑

$$\begin{aligned} I(f) &= \int_0^1 f(x)\,\mathrm{d}x + \alpha\left(\int_0^1 g(x)\,\mathrm{d}x - I(g)\right) \\ &= \int_0^1 (f(x) - \alpha g(x))\,\mathrm{d}x + \alpha I(g), \end{aligned}$$

其中 $g(x)$ 为**控制变量**, 故定义

$$\hat{I}_N := \frac{1}{N}\sum_{j=1}^{N}((f-\alpha g)(X_j)) + \alpha I(g), \quad X_j \overset{\text{i.i.d.}}{\sim} \mathcal{U}(0,1),$$

此时

$$\mathbb{E}|\hat{e}_N| \leqslant N^{-1/2}\sigma_{f-\alpha g},$$

其中

$$\begin{aligned} \sigma_{f-\alpha g}^2 &= \int_0^1 \left[(f - I(f)) + \alpha(g - I(g))\right]^2 \mathrm{d}x \\ &= \sigma_f^2 + \alpha^2\sigma_g^2 + 2\alpha\int_0^1 (f - I(f))(g - I(g))\,\mathrm{d}x, \end{aligned}$$

取

$$\alpha^* = -\frac{\int_0^1 (f - I(f))(g - I(g))\,\mathrm{d}x}{\sigma_g^2},$$

则

$$\begin{aligned} \sigma_{f-\alpha^* g}^2 &= \sigma_f^2 - \frac{\left(\int_0^1 (f - I(f))(g - I(g))\,\mathrm{d}x\right)^2}{\sigma_g^2} \\ &= \sigma_f^2 - \frac{\mathrm{Cov}^2(f,g)}{\sigma_g^2} \\ &= (1 - \rho_{f,g}^2)\sigma_f^2 \leqslant \sigma_f^2, \end{aligned}$$

其中

$$\rho_{f,g} = \frac{\mathrm{Cov}(f,g)}{\sigma_f \sigma_g}, \quad |\rho_{f,g}| \leqslant 1.$$

如果 $\rho_{f,g} = \pm 1 \iff f = cg$, 则 $\sigma_{f-\alpha^* g} = 0$.

相对误差

对于数值积分 $I_N \approx I$, 我们希望相对误差尽可能小:

$$\frac{|I - I_N|}{|I|} \ll 1 \iff \frac{N^{-1/2}\sigma_f}{|I|} \leqslant \varepsilon_0,$$

其中 $I \sim \mathcal{O}(1)$. 如果取 $X \sim \mathcal{U}[0,1]$,

$$f(x) = \begin{cases} 1/\varepsilon, & x \in [a, a+\varepsilon], \\ 0, & \text{其他}, \end{cases}$$

则 $\sigma_f = \mathbb{E} f^2(X) - I^2 = \mathcal{O}(\varepsilon^{-1})$, 故此时 $N \geqslant \mathcal{O}(\varepsilon_0^{-2}\varepsilon^{-2})$.

第十一章　Metropolis 算法

Metropolis 算法首次发表于 The Journal of Chemical Physics (JCP), 论文作者为 Metropolis, Rosenbluth, Rosenbluth, Teller, Teller ($\mathrm{MR^2T^2}$).

我们希望计算高维积分

$$I(f) = \int_{\mathbb{R}^d} f(\vec{x})p(\vec{x})\,\mathrm{d}\vec{x},$$

其中 $p(\vec{x}) = \frac{1}{Z}\mathrm{e}^{-\beta U(\vec{x})}$ 是 **Gibbs 分布 (正则分布, Canonical distribution)**, $Z = \int_{\mathbb{R}^d} \mathrm{e}^{-\beta U(\vec{x})}\,\mathrm{d}\vec{x}$, $\beta > 0$ 是**逆温度**.

记 $U(x) = -\beta^{-1}\ln p(x) - \beta^{-1}\ln Z$ 为**势函数**. 考虑 Monte Carlo 方法:

$$I_N = \frac{1}{N}\sum_{j=1}^{N} f(X_j), \quad X_j \overset{\text{i.i.d.}}{\sim} p(\vec{x}).$$

Metropolis 算法实际为 **Markov Chain Monte Carlo 算法 (MCMC)**. 设置 $\vec{x} \in \mathcal{S} = \{1, 2, \cdots, M\}$, 令

$$p(\vec{x}) \mapsto \vec{\pi} = (\pi_1, \cdots, \pi_M), \quad \pi_i := p(i) = \frac{1}{Z}\mathrm{e}^{-\beta U_i} \geqslant 0, \quad \sum_{i=1}^{M}\pi_i = 1,$$

则

$$I(f) = \sum_{i=1}^{M} f(i)\pi_i \approx \frac{1}{N}\sum_{j=1}^{N} f(X_j), \quad X_j \sim \vec{\pi}.$$

考虑 **Markov 过程 (Markov 链)** 的**离散时间转移概率矩阵** $P = (p_{ij})_{i,j\in\mathcal{S}}$, 其中

$$p_{ij} = \mathbb{P}(X_{n+1} = j \mid X_n = i), \quad \sum_{j\in\mathcal{S}} p_{ij} = 1, \quad \forall\, i \in \mathcal{S}.$$

再定义

$$\mu_n(i) := \mathbb{P}(X_n = i), \quad \sum_{i\in\mathcal{S}} \mu_n(i) = 1,$$

则

$$\mu_{n+1}(j) = \sum_{i\in\mathcal{S}} \mathbb{P}(X_n = i)\mathbb{P}(X_{n+1} = j \mid X_n = i) = \sum_{i\in\mathcal{S}} \mu_n(i)p_{ij},$$

即 $\vec{\mu}_{n+1} = \vec{\mu}_n P$, 其中 $\vec{\mu}_n \in \mathbb{R}^{1\times M}, P \in \mathbb{R}^{M\times M}$, 我们希望 $\vec{\mu}_n \to \vec{\pi}, n \to +\infty$, 从而得到必要条件 $\vec{\pi} = \vec{\pi}P$ (**GBC**) , 其中 $\vec{\pi}$ 称为**不变分布**, 并且 P 还满足 $P\vec{1} = \vec{1}, p_{ij} \geqslant 0$.

我们可以取 **DBC(细致平衡条件)**:

$$\pi_i p_{ij} = \pi_j p_{ji} \iff \frac{p_{ij}}{p_{ji}} = \frac{\pi_j}{\pi_i} = \frac{\mathrm{e}^{-\beta U_j}}{\mathrm{e}^{-\beta U_i}} = \mathrm{e}^{-\beta \Delta U_{ij}}, \quad \Delta U_{ij} := U_j - U_i, \quad \forall\, i, j.$$

选择 1 **(Metropolis 策略)**: 取

$$p_{ij} = 1 \wedge \mathrm{e}^{-\beta \Delta U_{ij}} = \min\left(1, \mathrm{e}^{-\beta \Delta U_{ij}}\right),$$

则

$$\frac{p_{ij}}{p_{ji}} = \frac{\min\left(1, \mathrm{e}^{-\beta \Delta U_{ij}}\right)}{\min\left(1, \mathrm{e}^{-\beta \Delta U_{ji}}\right)} = \mathrm{e}^{-\beta \Delta U_{ij}}.$$

选择 2 **(Glauber 策略)**: 取

$$p_{ij} = \frac{1}{1 + \mathrm{e}^{\beta \Delta U_{ij}}},$$

则

$$\frac{p_{ij}}{p_{ji}} = \frac{1 + \mathrm{e}^{\beta \Delta U_{ji}}}{1 + \mathrm{e}^{\beta \Delta U_{ij}}} = \mathrm{e}^{-\beta \Delta U_{ij}}.$$

从而 P 的最终设置为

$$p_{ij} = \begin{cases} Q_{ij} A_{ij}, & i \neq j, \\ 1 - \sum\limits_{k \neq i} Q_{ik} A_{ik}, & i = j, \end{cases}$$

其中 $A_{ij} := 1 \wedge \mathrm{e}^{-\beta \Delta U_{ij}}$, 称为**决策矩阵 (Decision Matrix)**, $Q_{ij} = Q_{ji}, Q\vec{1} = \vec{1}, Q_{ij} \geqslant 0$, 称为**预选矩阵 (Proposal Matrix)**, 此时显然有

$$\frac{p_{ij}}{p_{ji}} = \frac{Q_{ij} A_{ij}}{Q_{ji} A_{ji}} = \mathrm{e}^{-\beta \Delta U_{ij}}, \quad \forall\, i \neq j.$$

接受: $X_{n+1} = j$; 拒绝: $X_{n+1} = i$. Q 还可以取成非对称的 **(Metropolis-Hastings 算法)**, 此时

$$A_{ij} = 1 \wedge \left(\frac{Q_{ij}}{Q_{ji}} \mathrm{e}^{-\beta \Delta U_{ij}}\right).$$

Q 可选取为

$$Q = \begin{pmatrix} 0 & \frac{1}{M-1} & \cdots & \frac{1}{M-1} \\ \frac{1}{M-1} & 0 & \cdots & \frac{1}{M-1} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{M-1} & \frac{1}{M-1} & \cdots & 0 \end{pmatrix}.$$

Ising 模型 (1 维)

定义 11.1 Ising 模型 (1 维)

考虑 $\vec{\sigma} \in \mathcal{S} = \{\pm 1\}^M$, $|\mathcal{S}| = 2^M$, 给出如下定义

(1) **能量:**

$$H(\vec{\sigma}) = -\sum_{\langle i,j \rangle} \sigma_i \sigma_j, \quad \langle i,j \rangle \iff |i-j| = 1.$$

(2) **Gibbs 分布:**

$$\pi(\vec{\sigma}) = \frac{1}{Z_\beta} \mathrm{e}^{-\beta H(\vec{\sigma})}.$$

(3) **内能:**

$$\langle H \rangle = \mathbb{E} H(\vec{\sigma}) = \sum_{\vec{\sigma} \in \mathcal{S}} H(\vec{\sigma}) \cdot \frac{1}{Z_\beta} \mathrm{e}^{-\beta H(\vec{\sigma})} := U(\beta).$$

(4) **比热:**

$$\mathrm{Var}(H) = \langle H^2 \rangle - \langle H \rangle^2 := C(\beta).$$

令 $u = U/M, c = C/M$, 则可得到 u 和 c 与 β 的关系. 此时 Q 有如下 2 种选取方法:

取法 1: $Q \in \mathbb{R}^{2^M \times 2^M}$ 满足: 对任意两个状态 σ 和 σ' , 如果它们不同, 则 $Q_{\sigma,\sigma'} = 1/(2^M - 1)$, 否则 $Q_{\sigma,\sigma'} = 0$.

取法 2: **(Gibbs 抽样)** $Q \in \mathbb{R}^{2^M \times 2^M}$ 满足: 对任意两个状态 σ 和 σ' , 如果它们之间恰有一个自旋不同, 则 $Q_{\sigma,\sigma'} = 1/M$, 否则 $Q_{\sigma,\sigma'} = 0$.