最优化方法第七次作业

崔正平 2400010714

推论 6.2. 在假设 6.1 的条件下, 次梯度算法的收敛性满足 ($\widehat{f}^k$ 的定义和定理 6.5 中的定义相同):

(1) 取 $\alpha_i = t$ 为固定步长, 则

$$\widehat{f}^k - f^* \leqslant \frac{\|x^0 - x^*\|^2}{2kt} + \frac{1}{2}G^2 t;$$

(2) 取 α_i 使得 $\|x^{i+1} - x^i\|$ 固定, 即 $\alpha_i \|g^i\| = s$ 为常数, 则

$$\widehat{f}^k - f^* \leqslant \frac{G\|x^0 - x^*\|^2}{2ks} + \frac{1}{2}Gs;$$

(3) 取 α_i 为消失步长, 即 $\alpha_i \to 0$ 且 $\sum\limits_{i=0}^{\infty} \alpha_i = +\infty$, 则

$$\widehat{f}^k - f^* \leqslant \frac{\|x^0 - x^*\|^2 + G^2 \sum\limits_{i=0}^{k} \alpha_i^2}{2\sum\limits_{i=0}^{k} \alpha_i},$$

进一步可得 $\widehat{f}^k$ 收敛到 f^*.

解答: 注意到由定理 6.5 的证明过程, 我们实际得到了更强的结论

$$2(\widehat{f}^k - f^*)\sum_{i=0}^{k} \alpha_i \leqslant \left\|x^0 - x^*\right\|^2 + \sum_{i=0}^{k} \alpha_i^2 \left\|g^i\right\|^2 \leqslant \left\|x^0 - x^*\right\|^2 + G^2 \sum_{i=0}^{k} \alpha_i^2.$$

(1) 取 $\alpha_i = t$ 为固定步长, 则

$$2(k+1)t(\widehat{f}^k - f^*) \leqslant \left\|x^0 - x^*\right\|^2 + G^2(k+1)t^2 \implies \widehat{f}^k - f^* \leqslant \frac{\|x^0 - x^*\|^2}{2(k+1)t} + \frac{1}{2}G^2 t.$$

(2) 取 α_i 使得 $\|x^{i+1} - x^i\|$ 固定, 即 $\alpha_i \|g^i\| = s$ 为常数, 则

$$\frac{2(k+1)s}{G}(\widehat{f}^k - f^*) \leqslant 2(\widehat{f}^k - f^*)\sum_{i=0}^{k} \frac{s}{\|g^i\|} \leqslant \left\|x^0 - x^*\right\|^2 + (k+1)s^2,$$

故

$$\widehat{f}^k - f^* \leqslant \frac{G\left\|x^0 - x^*\right\|^2}{2(k+1)s} + \frac{1}{2}Gs.$$

(3) 取 α_i 为消失步长, 即 $\alpha_i \to 0$ 且 $\sum\limits_{i=0}^{\infty} \alpha_i = +\infty$, 则

$$\widehat{f}^k - f^* \leqslant \frac{\left\|x^0 - x^*\right\|^2 + G^2 \sum\limits_{i=0}^{k} \alpha_i^2}{2\sum\limits_{i=0}^{k} \alpha_i}.$$

注意到 $\alpha_i \to 0$ 且 $\sum\limits_{i=0}^{\infty} \alpha_i = +\infty$, 故 $\frac{1}{\sum\limits_{i=0}^{k} \alpha_i} \to 0$, 并且由 Stolz 定理可得

$$\lim_{k\to\infty} \frac{\sum\limits_{i=0}^{k} \alpha_i^2}{\sum\limits_{i=0}^{k} \alpha_i} = \lim_{k\to\infty} \frac{\alpha_k^2}{\alpha_k} = 0,$$

从而

$$0 \leqslant \widehat{f}^k - f^* \leqslant \frac{\left\|x^0 - x^*\right\|^2}{2\sum\limits_{i=0}^{k} \alpha_i} + \frac{G^2 \sum\limits_{i=0}^{k} \alpha_i^2}{2\sum\limits_{i=0}^{k} \alpha_i} \to 0, \quad k \to \infty,$$

即 $\widehat{f}^k$ 收敛到 f^*.

□

习题 6.4. 考虑非光滑函数

$$f(x) = \max_{1\leqslant i\leqslant K} x_i + \frac{1}{2}\left\|x\right\|^2,$$

其中 $x \in \mathbb{R}^n$, 且 $K \in [1, n]$ 为一个给定的正整数.

(a) 求出 $f(x)$ 的最小值点 x^* 和对应的函数值 f^*;

(b) 证明 $f(x)$ 在区域 $\{x \in \mathbb{R}^n : \|x\| \leqslant R := 1/\sqrt{K}\}$ 上是 G-Lipschitz 连续的, 其中 $G = 1 + \frac{1}{\sqrt{K}}$;

(c) 设初值 $x^0 = 0$, 考虑使用次梯度算法 (6.3.1) 对 $\min f(x)$ 进行求解, 步长 α_k 可任意选取, 求证: 存在一种次梯度的取法, 在 $k < K$ 次迭代后,

$$\widehat{f}^k - f^* \geqslant \frac{GR}{2(1+\sqrt{K})},$$

> 其中 $\widehat{f}^k$ 的定义和定理 6.5 相同. 并根据此例子推出次梯度算法的收敛速度 $\mathcal{O}(\frac{GR}{\sqrt{K}})$ 是不能改进的.

解答:

(a) $\forall x \in \mathbb{R}^n$, 设 $x_j = \max\limits_{1\leqslant i\leqslant K} x_i, 1 \leqslant j \leqslant K$. 若 $x_j \geqslant 0$, 则

$$f(x) = x_j + \frac{1}{2}\sum_{i=1}^{n} x_i^2 \geqslant x_j + \frac{1}{2}x_j^2 \geqslant 0,$$

当且仅当 $x = 0$ 时取到; 若 $x_j < 0$, 则

$$f(x) = x_j + \frac{1}{2}\sum_{i=1}^{n} x_i^2 \geqslant x_j + \frac{1}{2}Kx_j^2 \geqslant -\frac{1}{2K},$$

当且仅当 $x_1 = \cdots = x_K = -\frac{1}{K}$, 其余 x_i 等于 0 时取到. 故最小值点 x^* 为前 K 个分量均为 $-\frac{1}{K}$, 其余分量均为 0, 对应的函数值 $f^* = -\frac{1}{2K}$.

(b) $\forall x, y \in \mathbb{R}^n$ 满足 $\|x\|, \|y\| \leqslant R$, 设 $x_j = \max\limits_{1\leqslant i\leqslant K} x_i, y_\ell = \max\limits_{1\leqslant i\leqslant K} y_i$, 则

$$x_j - y_\ell \leqslant x_j - y_j \leqslant |x_j - y_j| \leqslant \|x - y\|, \quad y_\ell - x_j \leqslant y_\ell - x_\ell \leqslant |y_\ell - x_\ell| \leqslant \|x - y\|,$$

故 $|x_j - y_\ell| \leqslant \|x - y\|$. 从而

$$\begin{aligned} |f(x) - f(y)| &\leqslant |x_j - y_\ell| + \frac{1}{2}|\,\|x\|^2 - \|y\|^2\,| \\ &\leqslant \|x - y\| + \frac{1}{2}(\|x\| + \|y\|)|\,\|x\| - \|y\|\,| \\ &\leqslant \|x - y\| + \frac{1}{\sqrt{K}}\|x - y\| = \left(1 + \frac{1}{\sqrt{K}}\right)\|x - y\|, \end{aligned}$$

因此 $f(x)$ 在区域 $\{x \in \mathbb{R}^n : \|x\| \leqslant R := 1/\sqrt{K}\}$ 上是 G-Lipschitz 连续的.

(c) 注意到

$$\partial f(x) = x + \operatorname{conv}\left\{e_j : x_j = \max_{1\leqslant i\leqslant K} x_i, 1 \leqslant j \leqslant K\right\},$$

故对于任意第 $k < K$ 次迭代, 取 $j_k \in \arg\max\limits_{1\leqslant i\leqslant K} x_i^k$, 以及 $g_k = x^k + e_{j_k}$, 则 $x^{k+1} = (1 - \alpha_k)x^k - \alpha_k e_{j_k}$. 从而每次迭代最多新增一个非零分量, 而 $x^0 = 0$, 因此在 $k < K$ 次迭代后前 K 个分量中至少有一个为 0. 故 $f(x^k) \geqslant 0, \forall\, 1 \leqslant k < K$, 从而

$$\widehat{f}^k - f^* \geqslant \frac{1}{2K} = \frac{GR}{2(1 + \sqrt{K})} \geqslant \frac{GR}{4\sqrt{K}}.$$

进而次梯度算法的收敛速度 $\mathcal{O}(\frac{GR}{\sqrt{K}})$ 是不能改进的.

□