应用随机分析笔记

李铁军《应用随机分析》课程笔记

斑马数学

整理

2026 年 10 月

目录

第一章 引言 **1**

1.1 随机性的来源与应用 1
1.2 蒙特卡罗的基本思想 1
1.3 进一步的应用 2
1.4 课程安排 4
1.5 主要参考资料 4

第二章 随机变量 **5**

2.1 基本概念 5
2.1.1 离散分布的例子 5
2.1.2 连续分布的例子 6
2.1.3 概率空间 7
2.1.4 各种收敛概念 8
2.1.5 条件期望 8
2.2 特征函数 11
2.3 概率生成函数 12
2.4 矩生成函数与累积量 13
2.5 Borel–Cantelli 引理 14

第三章 随机变量的生成 **16**

3.1 基本蒙特卡罗方法 16
3.2 随机变量的生成 16
3.2.1 均匀分布 16
3.2.2 统计检验 17
3.2.3 逆变换法 17
3.2.4 生成 Gaussian 随机变量的 Box–Muller 方法 18
3.2.5 随机变量的组合 19
3.2.6 接受–拒绝法 19

第四章 方差缩减 **21**

4.1 为什么需要方差缩减 21
4.2 方差缩减方法 21
4.2.1 重要性抽样 21
4.2.2 控制变量 23
4.2.3 Rao–Blackwell 化 24
4.2.4 对偶变量 24
4.2.5 分层抽样 24

第五章 极限定理 **27**
5.1 大数定律 . . . 27
5.2 中心极限定理 . . . 29
5.3 Laplace 渐近法 . . . 30
5.4 Cramér 大偏差定理 . . . 31

第六章 Markov 链 **35**
6.1 离散时间 Markov 链 . . . 35
6.1.1 时间反演 . . . 38
6.1.2 击中时间分布 . . . 39
6.2 连续时间 Markov 链 . . . 40
6.2.1 Poisson 过程 . . . 40
6.2.2 Q-过程 . . . 41

第七章 Metropolis 算法 **43**
7.1 引入 . . . 43
7.2 Ising 模型 . . . 43
7.3 Metropolis 算法 . . . 44

第八章 多层次采样与动力学蒙特卡罗 **47**
8.1 Swendsen–Wang 算法 . . . 47
8.2 Wolff 的改进 . . . 47
8.3 模拟调温 . . . 48
8.4 并行调温 . . . 48
8.5 动力学蒙特卡罗 . . . 49

第九章 模拟退火与拟蒙特卡罗 **50**
9.1 模拟退火 . . . 50
9.1.1 基本框架 . . . 50
9.1.2 理论结果 . . . 51
9.2 拟蒙特卡罗方法 . . . 52
9.2.1 差异度 . . . 52
9.2.2 全变差 . . . 53
9.2.3 拟蒙特卡罗积分 . . . 54
9.2.4 QMC 的局限 . . . 54

第十章 随机游走与布朗运动 **55**
10.1 一维随机游走 . . . 55
10.1.1 终点分布 . . . 55
10.1.2 反射边界与吸收边界 . . . 56
10.2 反正弦定律与重对数律 . . . 58
10.3 Gaussian 位移的随机飞行 . . . 60
10.4 Einstein 的布朗运动理论 . . . 60

第十一章 随机过程与布朗运动 **62**
11.1 随机过程的公理化构造 . . . 62
11.2 滤过 . . . 63
11.3 Gaussian 过程 . . . 66
11.4 Wiener 过程 . . . 67

第十二章 布朗运动的构造及路径性质 **71**
12.1 Wiener 过程的构造 . . . 71
12.2 Wiener 路径的性质 . . . 76

第十三章 随机微分方程与 Itô 公式 **80**
13.1 白噪声 . . . 80
13.2 Itô 积分 . . . 80
13.3 Itô 公式 . . . 83
13.4 随机微分方程 . . . 87
13.4.1 适定性 . . . 87
13.4.2 扩散过程 . . . 88
13.4.3 简单的 SDE . . . 89
13.4.4 物理布朗运动 . . . 90
13.5 Stratonovich 积分 . . . 91

第十四章 与偏微分方程的联系 **93**
14.1 Liouville 方程 . . . 93
14.2 Fokker–Planck 方程 . . . 93
14.3 边界条件 . . . 96
14.4 后向方程 . . . 96
14.5 不变分布与详细平衡 . . . 97
14.6 扩散过程的进一步主题 . . . 98
14.6.1 半群与后向方程 . . . 98
14.6.2 Feynman–Kac 公式 . . . 98
14.6.3 首次出界时间 . . . 100

第十五章 SDE 数值方法: 基础 **102**
15.1 数值格式 . . . 102
15.2 强收敛 . . . 105
15.3 弱收敛 . . . 108

第十六章 SDE 数值方法: 进阶 **113**
16.1 隐式格式 . . . 113
16.2 外推方法 . . . 114
16.3 多层蒙特卡罗方法 . . . 114

第十七章 路径积分 **119**

17.1 Wiener 测度 119

17.2 Wiener 泛函的期望 120

17.3 Girsanov 变换 123

17.4 再看 Feynman–Kac 公式 128

参考文献 **130**

第一章　引言

1.1　随机性的来源与应用

随机模型至少有三种来源. 第一种是对象本身的统计规律, 例如分子碰撞, 放射性衰变和反应事件的发生. 第二种是描述尺度的选择: 一个系统即使有确定的微观运动规律, 通常只观测宏观变量, 此时把未解析的自由度当作随机影响. 第三种是主动引入随机性来计算确定的量, 例如高维积分, 矩阵乘积和优化问题.

随机分析研究随机变量和随机过程的分布, 平均, 涨落及其演化. 一个随机变量描述单次观测, 一个随机过程描述一串相关观测; 蒙特卡罗方法利用前者计算期望, 随机微分方程利用后者描述动力学.

1.2　蒙特卡罗的基本思想

例题 1.2.1　Buffon 投针

平行直线间距为 a, 针长为 $l < a$. 针中心到最近直线的距离 x 在 $[0, a/2]$ 均匀分布, 针与直线夹角 φ 可取为 $[0, \pi/2]$ 上均匀分布, 且两者独立. 相交的条件是 $x \leqslant (l/2)\sin\varphi$, 所以

$$p = \frac{4}{a\pi}\int_0^{\pi/2}\int_0^{(l/2)\sin\varphi} \mathrm{d}x\,\mathrm{d}\varphi = \frac{2l}{a\pi}.$$

投 N 次, 命中 K 次, 则 K/N 估计 p, $2lN/(aK)$ 估计圆周率. 后一个估计量经过非线性变换, 一般不无偏, 且 $K = 0$ 时没有定义; 随样本增加的一致性由大数定律给出.

例题 1.2.2　蒙特卡罗积分

考虑 $I(f) = \int_0^1 f(x)\,\mathrm{d}x$. 取 $h = 1/N$, 复合中点公式为

$$I_N^{\mathrm{mid}} = h\sum_{i=1}^{N} f((i-\tfrac{1}{2})h), \qquad |I_N^{\mathrm{mid}} - I(f)| \leqslant \frac{\|f''\|_\infty}{24}h^2.$$

若 $X_i \overset{\text{i.i.d.}}{\sim} U(0,1)$, 另一种近似是

$$I_N = \frac{1}{N}\sum_{i=1}^{N} f(X_i), \qquad \mathbb{E}I_N = I(f), \qquad \mathbb{E}|I_N - I(f)|^2 = \frac{\sigma_f^2}{N}, \quad \sigma_f^2 = \int_0^1 f^2 - I(f)^2.$$

下面展开均方误差的计算. 记 $Y_i = f(X_i) - I(f)$, 则 $\mathbb{E}Y_i = 0$; 当 $i \neq j$ 时, 由独立性有 $\mathbb{E}(Y_iY_j) =$

$\mathbb{E}Y_i\mathbb{E}Y_j = 0$, 而 $\mathbb{E}Y_i^2 = \sigma_f^2$. 因此

$$\mathbb{E}|I_N - I(f)|^2 = \mathbb{E}\left(\frac{1}{N}\sum_{i=1}^{N} Y_i\right)^2 = \frac{1}{N^2}\sum_{i,j=1}^{N}\mathbb{E}(Y_iY_j)$$
$$= \frac{1}{N^2}\sum_{i=1}^{N}\mathbb{E}Y_i^2 = \frac{\sigma_f^2}{N}.$$

这里无偏性也直接来自 $\mathbb{E}I_N = N^{-1}\sum_i \mathbb{E}f(X_i) = I(f)$. 因此均方根误差是 $\sigma_f/\sqrt{N}$, 它描述重复实验的典型误差尺度, 不是每次运行必然满足的确定误差上界.

在 d 维中, 若每个方向取 n 个格点, 总成本 $N = n^d$, 二阶网格公式的误差尺度为 $n^{-2} = N^{-2/d}$. 蒙特卡罗仍为 $N^{-1/2}$, 但方差常数可能随维数, 被积函数变化. 高维时它常有优势, 不能由这一比较断言所有高维积分只能用蒙特卡罗.

例题 1.2.3 系综平均

统计物理中的典型对象是系综平均

$$\langle A\rangle = \frac{1}{Z}\int_{\mathbb{R}^{6N}} A(q,p)\mathrm{e}^{-\beta H(q,p)}\,\mathrm{d}q\,\mathrm{d}p, \qquad Z = \int_{\mathbb{R}^{6N}} \mathrm{e}^{-\beta H(q,p)}\,\mathrm{d}q\,\mathrm{d}p.$$

位置, 动量各占 $3N$ 维, H 为能量, $\beta = (k_BT)^{-1}$ 为逆温度, 其中 k_B 是 Boltzmann 常数, T 是绝对温度. 即使积分区域已知, 归一化常数 Z 也通常算不出; 这正是后续 Metropolis 方法的动机. 若每个方向只放 10 个节点, 也需 10^{6N} 个节点. 只比较渐近幂次且忽略常数时, $d > 4$ 有 $N^{-1/2}$ 优于 $N^{-2/d}$; 但真实效率还受函数光滑性和结构影响. 独立样本便于并行, 概率表示适用面广, 是 MC 的优点; 收敛慢且输出有噪声, 是需要方差缩减的原因.

1.3 进一步的应用

例题 1.3.1 随机矩阵乘法

设 $A \in \mathbb{R}^{m\times n}$, $B \in \mathbb{R}^{n\times p}$. 把乘积写成秩一矩阵之和: $AB = \sum_{i=1}^{n} A_{:i}B_{i:}$. 独立抽取 K 个指标 i_r, 使 $\mathbb{P}(i_r = i) = p_i$, 其中非零项对应 $p_i > 0$. 令

$$L^{(r)} = \frac{A_{:i_r}}{\sqrt{Kp_{i_r}}}, \qquad R^{(r)} = \frac{B_{i_r:}}{\sqrt{Kp_{i_r}}}, \qquad \widehat{C} = \sum_{r=1}^{K} L^{(r)}R^{(r)}.$$

逐项取期望可得 $\mathbb{E}\widehat{C} = AB$. 把矩阵看作 Frobenius 内积空间中的向量, 独立性进一步给出

$$\mathbb{E}\|\widehat{C} - AB\|_F^2 = \frac{1}{K}\left(\sum_i \frac{\|A_{:i}\|_2^2\|B_{i:}\|_2^2}{p_i} - \|AB\|_F^2\right).$$

由 Cauchy–Schwarz, $\sum_i c_i^2/p_i \geqslant (\sum_i c_i)^2$, 等号条件是 $p_i \propto c_i = \|A_{:i}\|_2\|B_{i:}\|_2$. 因此 “按贡献大小抽样” 可以精确化为最小方差原则.

例题 1.3.2 Bayes 推断

数据 x, 参数 θ, 先验 $\pi(\theta)$ 和似然 $L(\theta \mid x)$ 确定后验

$$\pi(\theta \mid x) = \frac{L(\theta \mid x)\pi(\theta)}{\int L(\vartheta \mid x)\pi(\vartheta)\,\mathrm{d}\vartheta}.$$

分母是另一个高维积分. 后验均值, 可信区间等可以由后验样本估计; 归一化常数未知不妨碍构造满足详细平衡的采样链.

例题 1.3.3 优化与模拟退火

梯度流 $\dot{x} = -\nabla H(x)$ 通常只能沿能量下降, 可能困在局部极小值. 加入噪声得到形式方程 $\dot{x} = -\nabla H(x) + \varepsilon \dot{W}_t$, 其严格写法为

$$\mathrm{d}X_t = -\nabla H(X_t)\,\mathrm{d}t + \varepsilon\,\mathrm{d}W_t.$$

沿确定性轨道有 $\mathrm{d}H(x(t))/\,\mathrm{d}t = -|\nabla H(x(t))|^2 \leqslant 0$; 随机项则使系统有机会跨越能垒; 再逐步降温, 使概率质量向全局极小值集中. 必须同时考虑平衡分布随温度的变化和动力学达到平衡所需的时间.

例题 1.3.4 受热浴驱动的振子

一维 Langevin 模型为

$$\mathrm{d}x = v\,\mathrm{d}t, \qquad m\,\mathrm{d}v = (-\gamma v - kx)\,\mathrm{d}t + \sqrt{2k_B T\gamma}\,\mathrm{d}W_t.$$

阻尼消耗能量, 噪声注入能量, 二者系数的关系保证正确的热平衡. $\mathrm{d}W_t$ 不是通常可微函数的微分, 须等到 Itô 积分建立后才有严格意义. 去掉随机力得到 $m\ddot{x} + \gamma\dot{x} + kx = 0$; 再去掉阻尼得到保守振子 $m\ddot{x} + kx = 0$. 三个层次分别描述孤立振动, 耗散运动及与热浴交换能量的运动.

例题 1.3.5 调和函数的随机表示

若 $\Delta u = 0$ 于有界区域 D, 边界值为 f, 则适当正则条件下

$$u(x) = \mathbb{E}_x f(W_{\tau_D}), \qquad \tau_D = \inf\{t \geqslant 0 : W_t \notin D\}.$$

从 x 出发模拟布朗路径, 记录出界点的边界值, 再求平均, 就把边值问题变为期望计算. 第 14 章用停止的 Itô 公式证明此式.

例题 1.3.6 粒子, 密度和平均场

确定性粒子 $\dot{X} = b(X)$ 的密度满足 Liouville 方程 $\partial_t \psi + \nabla \cdot (b\psi) = 0$. 加入标准独立布朗噪声后,

$\mathrm{d}X = b(X)\,\mathrm{d}t + \mathrm{d}W$ 的密度满足

$$\partial_t \psi + \nabla \cdot (b\psi) = \frac{1}{2}\Delta\psi.$$

若粒子相互作用漂移为 $N^{-1}\sum_j b(X_i - X_j)$, 在合适的大粒子数极限中得到

$$U(x,t) = \int b(x-y)\psi(y,t)\,\mathrm{d}y, \qquad \partial_t \psi = -\nabla \cdot (U\psi) + \frac{1}{2}\Delta\psi.$$

这里 U 又依赖未知密度, 方程因而非线性; 独立噪声并不意味着相互作用粒子相互独立.

例题 1.3.7 化学反应

高浓度下常用反应速率方程 $\dot{x} = a(x)$, 其中 x 是反应物浓度, a 是净反应速率; 分子数较少时, 反应一次会使分子数发生整数跳变. 若当前状态下第 j 类反应的强度为 a_j, 下一次反应等待时间服从参数 $\sum_j a_j$ 的指数分布, 类型按 $a_j / \sum_k a_k$ 选择. 这就是连续时间 Markov 链及 Gillespie 型直接模拟的基本结构.

例题 1.3.8 扩散限制凝聚与高分子

扩散限制凝聚 (DLA) 使粒子从远处随机游走, 首次接触已有团簇即黏附, 从而生成分枝结构. 高分子构象也可用随机链表示: 自由连接链只规定键长, 半柔性链通过相邻键的夹角势惩罚弯曲, 刚性杆则近似只保留整体方向. 后续随机游走的极限定理解释长链端到端向量为何常近似 Gaussian. 悬浮液, 胶体, 液晶等复杂流体还涉及颗粒的位置, 取向和相互作用; 选择柔性链, 半柔性链或刚性杆模型, 是在分辨率与计算成本之间作物理建模选择.

1.4 课程安排

先学习随机变量, 随机数生成, 方差缩减和极限定理; 再用 Markov 链建立 MCMC, 集群算法, 温度交换和动力学蒙特卡罗; 随后讨论模拟退火与拟蒙特卡罗. 连续时间部分从随机游走过渡到布朗运动, 建立随机过程, Itô 积分与 SDE, 连接 Liouville, Fokker–Planck, 后向方程及 Feynman–Kac 表示. 最后研究 SDE 数值方法, 多层蒙特卡罗, Wiener 测度, Girsanov 变换和路径积分. 原大纲还列有多尺度, 稀有事件以及生物, 复杂流体和网络应用, 属于进一步学习方向.

1.5 主要参考资料

概率基础可读 Billingsley 或 Chung; 随机过程与随机分析可读 Gardiner, Øksendal, Karatzas–Shreve; 计算方面可读 Press 等人的 *Numerical Recipes*, Robert–Casella 的 *Monte Carlo Statistical Methods*, Glasserman 的蒙特卡罗专著, Kloeden–Platen 的 SDE 数值专著, 以及 Caflisch 的蒙特卡罗综述. 完整书目置于文末, 课程中的主要论证在正文自足展开.

第二章　随机变量

2.1　基本概念

2.1.1　离散分布的例子

定义 2.1.1　Bernoulli 分布与二项分布

Bernoulli 随机变量 X 以概率 p 取 1, 以概率 $q=1-p$ 取 0. 于是 $\mathbb{E}X=p$, $\mathrm{Var}(X)=pq$. 若 $X_1,\cdots,X_n$ 独立同分布, 则 $S_n=\sum_i X_i\sim B(n,p)$,

$$\mathbb{P}(S_n=k)=\binom{n}{k}p^kq^{n-k},\quad \mathbb{E}S_n=np,\quad \mathrm{Var}(S_n)=npq.$$

定义 2.1.2　多项分布

把每次试验推广为 r 种互斥类别, 概率 $p_1+\cdots+p_r=1$, 则计数向量服从多项分布:

$$\mathbb{P}(X_1=k_1,\cdots,X_r=k_r)=\frac{n!}{\prod_i k_i!}\prod_i p_i^{k_i},\quad \sum_i k_i=n.$$

令 I_{ai} 表示第 a 次试验是否落在类别 i, 则 $X_i=\sum_{a=1}^n I_{ai}$. 不同试验相互独立, 同一次试验的不同类别互斥, 故

$$\mathbb{E}I_{ai}=p_i,\quad \mathrm{Var}(I_{ai})=p_i(1-p_i),\quad \mathbb{E}(I_{ai}I_{aj})=0\quad (i\neq j).$$

于是

$$\mathbb{E}X_i=np_i,\quad \mathrm{Var}(X_i)=np_i(1-p_i),\quad \mathrm{Cov}(X_i,X_j)=\sum_{a=1}^n(0-p_ip_j)=-np_ip_j.$$

负相关来自总数固定, 而不是不同试验之间存在依赖.

定义 2.1.3 Poisson 分布与几何分布

Poisson 分布记为 $P(\lambda)$, $\mathbb{P}(X=k)=\mathrm{e}^{-\lambda}\lambda^k/k!$, 均值与方差都为 λ. 若 $np_n\to\lambda$, 则固定 k 时

$$\binom{n}{k}p_n^k(1-p_n)^{n-k}\longrightarrow \mathrm{e}^{-\lambda}\frac{\lambda^k}{k!}.$$

例如取 $p_n=\lambda/n$, 把二项概率写为

$$\frac{n(n-1)\cdots(n-k+1)}{n^k}\frac{\lambda^k}{k!}\left(1-\frac{\lambda}{n}\right)^n\left(1-\frac{\lambda}{n}\right)^{-k},$$

四个因子分别趋于 $1,\lambda^k/k!,\mathrm{e}^{-\lambda},1$, 即得极限. Poisson 矩可直接由级数计算:

$$\mathbb{E}X=\mathrm{e}^{-\lambda}\sum_{k=1}^{\infty}\frac{k\lambda^k}{k!}=\lambda\mathrm{e}^{-\lambda}\sum_{j=0}^{\infty}\frac{\lambda^j}{j!}=\lambda,$$

$$\mathbb{E}[X(X-1)]=\lambda^2,\qquad \mathrm{Var}(X)=\mathbb{E}[X(X-1)]+\mathbb{E}X-(\mathbb{E}X)^2=\lambda.$$

它刻画许多次独立机会中发生的稀少事件. 空间均匀 Poisson 点过程在区域 D 中的点数服从 $P(\lambda|D|)$, 互不相交区域的计数独立. 几何分布则描述首次成功所需试验数: $\mathbb{P}(T=k)=q^{k-1}p$, $k\geqslant 1$, $\mathbb{E}T=1/p$.

例题 2.1.1 占位问题

把 n 个球放入 N 个盒子, 是否区分球, 是否允许同盒多球, 会改变样本空间:

球是否可区分	每盒容量	状态数
可区分	不限制	N^n
不可区分	不限制	$\binom{N+n-1}{n}$
可区分	至多一个	$N!/(N-n)!$
不可区分	至多一个	$\binom{N}{n}$

第一, 二, 四行分别对应 Maxwell–Boltzmann, Bose–Einstein, Fermi–Dirac 计数思想. 经典 MB 计数本身不施加排他限制. 若不同配置等概率, MB 模型中每球落在不同盒的概率是 $(N)_n/N^n$, BE 模型是 $\binom{N}{n}/\binom{N+n-1}{n}$, FD 模型则为 1. 对一个指定的含 n 个盒子的集合, 恰好每盒一个的概率, MB 为 $n!/N^n$, BE 为 $1/\binom{N+n-1}{n}$. 因此, 计数概率取决于所选样本空间及其等概率假设.

2.1.2 连续分布的例子

定义 2.1.4 均匀分布, 指数分布与正态分布

$U(a,b)$ 的密度为 $(b-a)^{-1}\mathbf{1}_{(a,b)}$, 均值为 $(a+b)/2$, 方差为 $(b-a)^2/12$. 指数分布 $\mathrm{Exp}(\lambda)$ 的密度, 尾概率为

$$p(x)=\lambda\mathrm{e}^{-\lambda x}\mathbf{1}_{x\geqslant 0},\qquad \mathbb{P}(X>t)=\mathrm{e}^{-\lambda t},\quad \mathbb{E}X=\lambda^{-1},\quad \mathrm{Var}(X)=\lambda^{-2}.$$

正态分布 $N(\mu,\sigma^2)$ 的密度为

$$p(x)=\frac{1}{\sqrt{2\pi}\sigma}\exp\left[-\frac{(x-\mu)^2}{2\sigma^2}\right].$$

若 Σ 是正定的 $d\times d$ 矩阵, 多元正态密度为

$$p(x)=\frac{\exp[-\frac{1}{2}(x-\mu)^{\mathrm{T}}\Sigma^{-1}(x-\mu)]}{(2\pi)^{d/2}\sqrt{\det\Sigma}}.$$

若 $Z\sim N(0,I)$ 且 $BB^{\mathrm{T}}=\Sigma$, 则 $\mu+BZ\sim N(\mu,\Sigma)$. 半正定而奇异的 Σ 仍定义 Gaussian 向量, 只是其分布集中在较低维仿射空间, 没有全维 Lebesgue 密度.

当 np 与 nq 均较大时, $B(n,p)$ 可近似为 $N(np,npq)$; 大参数的 Poisson 分布可近似为 $N(\lambda,\lambda)$. 计算离散区间概率时, 连续性修正如 $\mathbb{P}(X\leqslant k)\approx\Phi((k+1/2-\mu)/\sigma)$ 常能改善近似.

2.1.3 概率空间

定义 2.1.5 概率空间

σ-代数 $\mathcal{F}$ 是 Ω 的子集族, 含 Ω, 对补集及可数并封闭. 概率测度满足 $\mathbb{P}(\Omega)=1$, 以及对两两不交的 A_n 有 $\mathbb{P}(\bigcup_n A_n)=\sum_n\mathbb{P}(A_n)$. 三元组 $(\Omega,\mathcal{F},\mathbb{P})$ 称为**概率空间**.

集合 $A\in\mathcal{F}$ 称为事件, $\mathbb{P}(A)$ 为其概率; σ-代数的封闭性保证事件列的上下极限仍为事件.

定义 2.1.6 随机变量与分布

实数上的 Borel σ-代数 $\mathcal{B}(\mathbb{R})$ 由开集生成. 随机变量是可测映射 $X:\Omega\to\mathbb{R}$, 即 $\{X\leqslant x\}\in\mathcal{F}$ 对每个 x 成立. 其分布是推前测度

$$\mu_X(B)=\mathbb{P}(X\in B),\qquad F_X(x)=\mathbb{P}(X\leqslant x).$$

若 $\mu_X(B)=\int_B p(x)\,\mathrm{d}x$, 称 p 为**概率密度**; 分布既可以有原子, 也可以没有密度, 所以分布比密度更一般.

定义 2.1.7 期望, 方差与独立性

期望是对概率测度的积分: $\mathbb{E}X=\int_\Omega X\,\mathrm{d}\mathbb{P}$. 若 X 非负, 期望允许为 $+\infty$; 若 X 有正有负, 有限期望要求 $\mathbb{E}|X|<\infty$. 对可积函数 g,

$$\mathbb{E}g(X)=\int g(x)\mu_X(\mathrm{d}x),\quad \mathrm{Var}(X)=\mathbb{E}(X-\mathbb{E}X)^2,\quad \mathrm{Cov}(X,Y)=\mathbb{E}[(X-\mathbb{E}X)(Y-\mathbb{E}Y)].$$

独立性要求所有 Borel 集 B_i 都满足 $\mathbb{P}(X_1\in B_1,\cdots,X_r\in B_r)=\prod_i\mathbb{P}(X_i\in B_i)$. 独立且可积时 $\mathbb{E}(XY)=\mathbb{E}X\mathbb{E}Y$; 仅有协方差零通常不能推出独立.

命题 2.1.1 积分与期望的基本性质

(1) 单调收敛: $0 \leqslant X_n \uparrow X$ 则 $\mathbb{E}X_n \uparrow \mathbb{E}X$.
(2) 控制收敛: $X_n \to X$ 几乎必然, 且 $|X_n| \leqslant Y$, $\mathbb{E}Y < \infty$, 则 $\mathbb{E}X_n \to \mathbb{E}X$.
(3) Tonelli: 非负函数可交换积分次序, 即使积分无限; Fubini: 绝对可积函数可交换积分次序.
(4) Jensen: 凸函数 ϕ 满足 $\phi(\mathbb{E}X) \leqslant \mathbb{E}\phi(X)$; Cauchy–Schwarz 给出 $|\mathbb{E}XY| \leqslant (\mathbb{E}X^2\mathbb{E}Y^2)^{1/2}$.

推论 2.1.2 尾积分公式

例如非负 Y 可写成 $Y = \int_0^\infty \mathbf{1}_{Y>t}\,\mathrm{d}t$, Tonelli 因而给出尾积分公式 $\mathbb{E}Y = \int_0^\infty \mathbb{P}(Y > t)\,\mathrm{d}t$. 交换期望与积分时, 分别由非负性或绝对可积性保证上述等式成立.

2.1.4 各种收敛概念

定义 2.1.8 随机变量的收敛

对同一概率空间上的 X_n, X, 依次定义:

$$\begin{aligned} X_n \to X \text{ a.s.}: &\quad \mathbb{P}\{\omega : X_n(\omega) \to X(\omega)\} = 1; \\ X_n \to X \text{ 依概率}: &\quad \mathbb{P}(|X_n - X| > \varepsilon) \to 0 \quad (\varepsilon > 0); \\ X_n \to X \text{ 在} L^p: &\quad \mathbb{E}|X_n - X|^p \to 0 \quad (p > 0). \end{aligned}$$

依分布收敛 $X_n \Rightarrow X$ 是分布测度弱收敛: $\mathbb{E}f(X_n) \to \mathbb{E}f(X)$ 对所有有界连续 f 成立; 实值情形等价于在 F_X 的连续点处 $F_{X_n}(x) \to F_X(x)$.

命题 2.1.3 收敛方式之间的关系

几乎必然收敛或 L^p 收敛都推出依概率收敛, 后者推出依分布收敛. L^p 的结论来自 Markov 不等式 $\mathbb{P}(|X_n - X| > \varepsilon) \leqslant \varepsilon^{-p}\mathbb{E}|X_n - X|^p$. 几乎必然情形则对指标函数用控制收敛.

评注 逆命题与子列 反方向通常不成立. $X_n = n\mathbf{1}_{[0,1/n]}$ 在 $\Omega = [0,1]$ 上几乎必然趋于零, 但 $\mathbb{E}X_n = 1$. 依分布收敛甚至无需把变量放在同一个概率空间上, 因此本身不比较样本路径. 若极限为常数, 依分布收敛等价于依概率收敛. 依概率收敛的序列总能抽出几乎必然收敛的子列: 选 n_k 使 $\mathbb{P}(|X_{n_k} - X| > 2^{-k}) \leqslant 2^{-k}$, 再用 Borel–Cantelli 引理.

2.1.5 条件期望

条件期望是在给定信息下对随机变量取平均. $\mathbb{E}(X \mid Y)$ 随 Y 的观测值而变化; 当 $\mathbb{P}(Y = y) = 0$ 时, 应通过子 σ-代数定义.

定义 2.1.9 条件期望

设 $X \in L^1$, $\mathcal{G} \subset \mathcal{F}$ 为子 σ-代数. $Z = \mathbb{E}(X \mid \mathcal{G})$ 满足: Z 是 $\mathcal{G}$-可测且可积; 对所有 $A \in \mathcal{G}$,

$$\int_A Z \,\mathrm{d}\mathbb{P} = \int_A X \,\mathrm{d}\mathbb{P}.$$

它存在且除零测集外唯一. 记 $\mathbb{E}(X \mid Y) = \mathbb{E}(X \mid \sigma(Y))$.

存在性可由 Radon–Nikodym 定理得到: 在 $\mathcal{G}$ 上定义有限符号测度 $\nu(A) = \int_A X \,\mathrm{d}\mathbb{P}$, 它绝对连续于 $\mathbb{P}|_{\mathcal{G}}$, 其密度 $Z = \mathrm{d}\nu / \mathrm{d}(\mathbb{P}|_{\mathcal{G}})$ 恰满足定义. 若 Z_1, Z_2 都满足定义, 则对 $A_n = \{Z_1 - Z_2 > 1/n\} \in \mathcal{G}$ 有

$$0 = \int_{A_n} (Z_1 - Z_2) \,\mathrm{d}\mathbb{P} \geqslant \frac{1}{n}\mathbb{P}(A_n).$$

因此 $\mathbb{P}(Z_1 > Z_2) = 0$; 交换二者得几乎必然唯一. 定义的实际含义是: Z 只使用 $\mathcal{G}$ 中的信息, 并在每个由这些信息可区分的事件上保留正确平均.

命题 2.1.4 条件期望的基本性质

条件期望具有线性, 保序性, $\mathbb{E}\mathbb{E}(X \mid \mathcal{G}) = \mathbb{E}X$. 若 Y 是 $\mathcal{G}$-可测且相关乘积可积, 则

$$\mathbb{E}(YX \mid \mathcal{G}) = Y\mathbb{E}(X \mid \mathcal{G}).$$

若 X 与 $\mathcal{G}$ 独立, 则条件期望为常数 $\mathbb{E}X$. 若 $\mathcal{G} \subset \mathcal{H}$, 塔式性质是

$$\mathbb{E}[\mathbb{E}(X \mid \mathcal{H}) \mid \mathcal{G}] = \mathbb{E}(X \mid \mathcal{G}), \qquad \mathbb{E}[\mathbb{E}(X \mid \mathcal{G}) \mid \mathcal{H}] = \mathbb{E}(X \mid \mathcal{G}).$$

第一式可直接验证定义中的积分等式; 第二式因为内层已对 $\mathcal{H}$ 可测.

证明: 线性只需将定义中的积分等式线性组合, 再用唯一性. 取 $A = \Omega$ 得到全期望公式. 若 X 已对 $\mathcal{G}$ 可测, 则 X 本身满足条件期望的定义, 因此 $\mathbb{E}(X \mid \mathcal{G}) = X$.
抽出已知因子时, 先取 $Y = \mathbf{1}_B$, $B \in \mathcal{G}$. 对任意 $A \in \mathcal{G}$,

$$\int_A Y\mathbb{E}(X \mid \mathcal{G}) \,\mathrm{d}\mathbb{P} = \int_{A\cap B} \mathbb{E}(X \mid \mathcal{G}) \,\mathrm{d}\mathbb{P} = \int_A YX \,\mathrm{d}\mathbb{P}.$$

再由简单函数逼近和截断推广到相关乘积可积的 Y. 保序性可由 $X \geqslant 0$ 时在 $\{\mathbb{E}(X \mid \mathcal{G}) < 0\}$ 上积分得到. 若 X 与 $\mathcal{G}$ 独立, 则

$$\int_A X \,\mathrm{d}\mathbb{P} = \mathbb{E}(X\mathbf{1}_A) = \mathbb{E}X\mathbb{P}(A) = \int_A \mathbb{E}X \,\mathrm{d}\mathbb{P},$$

常数 $\mathbb{E}X$ 因而满足定义.

最后, 若 $\mathcal{G}\subset\mathcal{H}$, 则对 $A\in\mathcal{G}$ 有

$$\int_A \mathbb{E}[\mathbb{E}(X\mid\mathcal{H})\mid\mathcal{G}]\,\mathrm{d}\mathbb{P}=\int_A \mathbb{E}(X\mid\mathcal{H})\,\mathrm{d}\mathbb{P}=\int_A X\,\mathrm{d}\mathbb{P}.$$

这证明第一条塔式公式. 第二条则是已经可测的情形. □

命题 2.1.5 条件 Jensen 不等式

条件 Jensen 不等式为 $\phi(\mathbb{E}(X\mid\mathcal{G}))\leqslant\mathbb{E}(\phi(X)\mid\mathcal{G})$, 假设 ϕ 凸且相关量可积.

证明: 将凸函数写为可数个仿射支撑函数的上确界: 每个 $ax+b\leqslant\phi(x)$ 都给 $a\mathbb{E}(X\mid\mathcal{G})+b\leqslant\mathbb{E}(\phi(X)\mid\mathcal{G})$, 再对支撑函数取上确界. 特别地 $|\mathbb{E}(X\mid\mathcal{G})|^p\leqslant\mathbb{E}(|X|^p\mid\mathcal{G})(p\geqslant 1)$, 所以条件期望不会增加 L^p 范数. □

例题 2.1.2 离散条件概率与条件期望

设 $p(i,j)=\mathbb{P}(X=i,Y=j)$, 且 $\mathbb{P}(Y=j)>0$. 则

$$p(i\mid j)=\frac{p(i,j)}{\sum_k p(k,j)},\qquad \mathbb{E}(f(X)\mid Y=j)=\sum_i f(i)p(i\mid j).$$

这与抽象定义相同. 事实上, $\Omega_j=\{Y=j\}$ 是 $\sigma(Y)$ 的原子, $\sigma(Y)$-可测函数在该集合上为常数; 记 $\mathbb{E}(f(X)\mid Y)=z_j$, 则

$$z_j\mathbb{P}(\Omega_j)=\int_{\Omega_j} f(X)\,\mathrm{d}\mathbb{P}=\sum_i f(i)p(i,j).$$

除以 $\mathbb{P}(\Omega_j)$ 即得离散公式. 在零概率的 Ω_j 上取何值不影响条件期望的几乎必然等价类.

命题 2.1.6 条件期望的正交投影性质

若 $X\in L^2$, 令 $Z=\mathbb{E}(X\mid\mathcal{G})$. 对所有 $\mathcal{G}$-可测的 $Y\in L^2$,

$$\mathbb{E}[(X-Z)Y]=0,\qquad \mathbb{E}(X-Y)^2=\mathbb{E}(X-Z)^2+\mathbb{E}(Z-Y)^2.$$

因此条件期望是基于已知信息的最佳均方预测. 取 $Y=\mathbb{E}X$, 得到全方差公式

$$\operatorname{Var}(X)=\mathbb{E}\big[\operatorname{Var}(X\mid\mathcal{G})\big]+\operatorname{Var}\big(\mathbb{E}(X\mid\mathcal{G})\big).\tag{2.1}$$

证明: 对 $\mathcal{G}$-可测的有界 Y, 条件期望的定义给出 $\mathbb{E}[(X-Z)Y]=0$. 一般 $Y\in L^2$ 时, 先将 Y 截断,

再由 Cauchy–Schwarz 不等式取极限, 仍得正交关系. 由于 $Z-Y$ 也对 $\mathcal{G}$ 可测,

$$\begin{aligned}\mathbb{E}(X-Y)^2 &= \mathbb{E}\left[(X-Z)+(Z-Y)\right]^2\\ &= \mathbb{E}(X-Z)^2+\mathbb{E}(Z-Y)^2.\end{aligned}$$

最后取 $Y=\mathbb{E}X$, 并用塔式性质 $\mathbb{E}Z=\mathbb{E}X$, 即得全方差公式. □

2.2 特征函数

定义 2.2.1 特征函数

定义 $f_X(\xi)=\mathbb{E}\mathrm{e}^{\mathrm{i}\xi X}$. 因为复指数模长为 1, 它对所有实数 ξ 存在. 基本性质为

$$f_X(0)=1,\quad |f_X(\xi)|\leqslant 1,\quad f_X(-\xi)=\overline{f_X(\xi)}.$$

命题 2.2.1 特征函数的基本性质

它一致连续: $|f_X(\xi+h)-f_X(\xi)|\leqslant \mathbb{E}|\mathrm{e}^{ihX}-1|\to 0$, 右侧与 ξ 无关. 若 $\mathbb{E}|X|^k<\infty$, 可在期望内求导, 得到 $f_X^{(k)}(0)=\mathrm{i}^k\mathbb{E}X^k$. 独立和满足 $f_{X+Y}=f_Xf_Y$.

分布	特征函数
Bernoulli(p)	$q+pe^{\mathrm{i}\xi}$
$B(n,p)$	$(q+pe^{\mathrm{i}\xi})^n$
$P(\lambda)$	$\exp[\lambda(\mathrm{e}^{\mathrm{i}\xi}-1)]$
$\mathrm{Exp}(\lambda)$	$\lambda/(\lambda-\mathrm{i}\xi)$
$N(\mu,\sigma^2)$	$\exp(\mathrm{i}\mu\xi-\sigma^2\xi^2/2)$

定理 2.2.1 Lévy 连续性定理

若 $X_n\Rightarrow X$, 则 $f_{X_n}(\xi)\to f_X(\xi)$, 并且在每个有限闭区间上一致收敛. 反之, 若 f_{X_n} 逐点收敛到 f, 且 f 在 0 连续, 则 f 是某概率分布的特征函数, 并且 X_n 依分布收敛到该分布.

第一方向来自弱收敛定义, 对正弦, 余弦分别应用即可. 反方向是后面 CLT 的理论工具, 此处作为基础定理使用. 特别地, 特征函数唯一决定分布. 若 $f_X\in L^1(\mathbb{R})$, Fourier 反演给出密度

$$p_X(x)=\frac{1}{2\pi}\int_{\mathbb{R}}\mathrm{e}^{-\mathrm{i}\xi x}f_X(\xi)\,\mathrm{d}\xi.$$

定理 2.2.2 Bochner 判别

连续函数 f 是某个概率分布的特征函数, 当且仅当 $f(0)=1$ 且正定, 即对任意 $c_j\in\mathbb{C}$, $\xi_j\in\mathbb{R}$,

$$\sum_{j,k} c_j\overline{c_k}f(\xi_j-\xi_k)\geqslant 0.$$

必要性的证明: 若 $f(\xi)=\int \mathrm{e}^{\mathrm{i}\xi x}\mu(\mathrm{d}x)$, 由有限求和与积分交换,

$$\begin{aligned}\sum_{j,k} c_j\overline{c_k}f(\xi_j-\xi_k) &= \int \sum_{j,k}(c_j e^{\mathrm{i}\xi_j x})\overline{(c_k e^{\mathrm{i}\xi_k x})}\mu(\mathrm{d}x)\\ &= \int \left|\sum_j c_j e^{\mathrm{i}\xi_j x}\right|^2 \mu(\mathrm{d}x)\geqslant 0.\end{aligned}$$

其余两个条件已由特征函数的性质得到. 充分性是 Bochner 定理的另一方向, 此处作为基础结果使用. □

2.3 概率生成函数

定义 2.3.1 概率生成函数

若 X 为非负整数值, $G_X(z)=\mathbb{E}z^X=\sum_{k\geqslant 0}\mathbb{P}(X=k)z^k$, 至少在 $|z|\leqslant 1$ 有意义.

命题 2.3.1 生成函数与独立和

概率由 $G_X^{(k)}(0)/k!$ 恢复; 当矩存在时, $G_X'(1)=\mathbb{E}X$, $G_X''(1)=\mathbb{E}[X(X-1)]$. 独立和对应生成函数乘积, 系数相乘正是概率卷积.

$$G_{\mathrm{Bern}}(z)=q+pz,\qquad G_{B(n,p)}(z)=(q+pz)^n,\qquad G_{P(\lambda)}(z)=\mathrm{e}^{\lambda(z-1)}.$$

例如独立 Poisson 变量之和仍是 Poisson, 参数相加, 直接由最后一个公式得到. 具体地, 若 $a_j=\mathbb{P}(X=j)$, $b_j=\mathbb{P}(Y=j)$, 则独立和的概率为 $c_k=\sum_{j=0}^{k}a_jb_{k-j}$, 记作序列卷积 $c=a*b$; 生成函数满足 $C(z)=A(z)B(z)$, 由非负项交换求和即可验证.

证明: 对 $|z|<1$, 幂级数可以逐项求导, 故 $G_X^{(k)}(0)=k!\mathbb{P}(X=k)$. 在 $z\uparrow 1$ 时, 对非负系数应用单调收敛, 即得阶乘矩公式. 若 X,Y 独立, 则

$$\begin{aligned}\mathbb{P}(X+Y=k)&=\sum_{j=0}^{k}\mathbb{P}(X=j,Y=k-j)=\sum_{j=0}^{k}a_jb_{k-j},\\ G_{X+Y}(z)&=\sum_{j,l\geqslant 0}a_jb_lz^{j+l}=\left(\sum_{j\geqslant 0}a_jz^j\right)\left(\sum_{l\geqslant 0}b_lz^l\right).\end{aligned}$$

交换求和在 $|z|\leqslant 1$ 由绝对收敛保证. 特别地, $\mathrm{e}^{\lambda(z-1)}\mathrm{e}^{\mu(z-1)}=\mathrm{e}^{(\lambda+\mu)(z-1)}$, 证明独立 Poisson 变量参数相加的性质. □

2.4 矩生成函数与累积量

定义 2.4.1 矩生成函数与累积量

矩生成函数 $M(t)=\mathbb{E}\mathrm{e}^{tX}$ 可能在任何 $t\neq 0$ 都发散; 只有在 0 的某个邻域有限时, 才能用其 Taylor 展开编码全部矩. 定义 $K(t)=\log M(t)$, $\kappa_r=K^{(r)}(0)$, 有

$$\kappa_1=\mathbb{E}X,\qquad \kappa_2=\operatorname{Var}(X),\qquad \kappa_3=\mathbb{E}(X-\mathbb{E}X)^3,$$

$$\kappa_4=\mathbb{E}(X-\mathbb{E}X)^4-3\operatorname{Var}(X)^2.$$

特征函数附近也可定义 $H(\xi)=\log f_X(\xi)$, 其系数相应带 i^r. 独立和的 K 相加, 故累积量逐阶相加.

常用矩生成函数为

$$M_{B(n,p)}(t)=(pe^t+1-p)^n,\quad M_{P(\lambda)}(t)=\mathrm{e}^{\lambda(\mathrm{e}^t-1)},$$

$$M_{\mathrm{Exp}(\lambda)}(t)=\frac{\lambda}{\lambda-t}\ (t<\lambda),\qquad M_{N(\mu,\sigma^2)}(t)=\mathrm{e}^{\mu t+\sigma^2t^2/2}.$$

在零点邻域有限时, $M^{(r)}(0)=\mathbb{E}X^r$, $M(t)=\sum_{r\geqslant 0}\mathbb{E}X^rt^r/r!$. 绝对 p 阶矩则是 $\mathbb{E}|X|^p$, 奇数阶矩与相应绝对矩一般不同.

命题 2.4.1 矩与累积量的关系

对向量 X, $K(t)=\log\mathbb{E}\mathrm{e}^{t^{\mathrm{T}}X}$, 混合偏导定义联合累积量. 一般的矩–累积量关系是

$$\mathbb{E}\prod_{j=1}^{n}X_j=\sum_{\mathcal{P}}\prod_{B\in\mathcal{P}}\kappa(X_j:j\in B),$$

其中 $\mathcal{P}$ 遍历 $\{1,\cdots,n\}$ 的所有集合分拆. 这由 $M=\mathrm{e}^K$ 反复求导得到: 每个导数指标分配到一个 K 因子, 恰对应一个分块. 记多重指标 $k=(k_1,\cdots,k_d)$, $|k|=\sum_j k_j$, $k!=\prod_j k_j!$, 则 $\mu_k=\mathbb{E}\prod_j X_j^{k_j}=\partial^kM(0)$, $\kappa_k=\partial^kK(0)$, $M(t)=\sum_k\mu_kt^k/k!$, $K(t)=\sum_k\kappa_kt^k/k!$. 低阶关系例如 $\mu_{XY}=\kappa_{XY}+\mu_X\mu_Y$, $\mu_{XYZ}=\kappa_{XYZ}+\mu_X\kappa_{YZ}+\mu_Y\kappa_{XZ}+\mu_Z\kappa_{XY}+\mu_X\mu_Y\mu_Z$.

证明: 在矩生成函数有限的开区间内, 可以在期望下逐次求导. 例如, 若 $[t-\delta,t+\delta]$ 在该区间内, 则

存在 $C_{r,\delta}$ 使

$$|X|^r e^{tX} \leqslant C_{r,\delta}\big(\mathrm{e}^{(t+\delta)X} + \mathrm{e}^{(t-\delta)X}\big),$$

右端可积, 因而 $M^{(r)}(t) = \mathbb{E}(X^r e^{tX})$. 由 $M = \mathrm{e}^K$,

$$\begin{aligned} M' &= MK', \qquad M'' = M\big((K')^2 + K''\big), \\ M''' &= M\big((K')^3 + 3K'K'' + K'''\big), \\ M^{(4)} &= M\big((K')^4 + 6(K')^2K'' + 3(K'')^2 + 4K'K''' + K^{(4)}\big). \end{aligned}$$

在 $t = 0$ 代入 $M(0) = 1$, 逐次解出 $K^{(r)}(0)$, 便得到前述四阶累积量. 向量情形同理,

$$\partial_i\partial_j M = M(K_iK_j + K_{ij}),$$

再对第三个指标求导得到三阶联合矩公式. 一般阶的归纳中, 新导数或者作用于前面的 M, 生成一个单元素分块, 或者作用于已有的 K 因子, 把新指标加入该分块; 这两类恰好不重不漏地列出全部集合分拆. □

命题 2.4.2 Wick 公式

Gaussian 向量的 $K(t) = \mu^{\mathrm{T}}t + \frac{1}{2}t^{\mathrm{T}}\Sigma t$, 三阶及以上累积量为零. 于是中心 Gaussian 向量的奇数阶矩为零, 偶数阶矩为所有两两配对的协方差乘积之和, 这就是 Wick 公式. 例如

$$\mathbb{E}X_1X_2X_3X_4 = \Sigma_{12}\Sigma_{34} + \Sigma_{13}\Sigma_{24} + \Sigma_{14}\Sigma_{23}.$$

例题 2.4.1 配分函数的导数

统计物理中 $Z(\beta) = \int \mathrm{e}^{-\beta H}\,\mathrm{d}x$, 因此在可以微分的条件下,

$$Z' = -\int He^{-\beta H}\,\mathrm{d}x, \qquad Z'' = \int H^2\mathrm{e}^{-\beta H}\,\mathrm{d}x,$$

从而 $-\partial_\beta \log Z = -Z'/Z = \langle H\rangle$, 且

$$\partial_\beta^2 \log Z = \frac{Z''}{Z} - \left(\frac{Z'}{Z}\right)^2 = \langle H^2\rangle - \langle H\rangle^2 = \mathrm{Var}(H).$$

若参考测度本身归一化, 令随机变量 $X = H$, 则 $Z(\beta) = M_X(-\beta)$, $F(\beta) = -\beta^{-1}K_X(-\beta)$. 自由能 $F = -\beta^{-1}\log Z$ 把配分函数的导数变成宏观响应量.

2.5 Borel–Cantelli 引理

事件 A_n “发生无穷多次” 记为 $\overline{\lim}_n A_n = \bigcap_m \bigcup_{n\geqslant m} A_n$.

定理 2.5.1 Borel–Cantelli 引理

若 $\sum_n \mathbb{P}(A_n) < \infty$, 则 $\mathbb{P}(A_n \text{ 无穷多次}) = 0$. 若 A_n 相互独立且该级数发散, 则此概率为 1.

证明: 第一部分由 $\mathbb{P}(\bigcup_{n\geqslant m} A_n) \leqslant \sum_{n\geqslant m} \mathbb{P}(A_n) \to 0$ 得到. 第二部分利用

$$\mathbb{P}\Big(\bigcap_{n=m}^{N} A_n^c\Big) = \prod_{n=m}^{N} (1-\mathbb{P}(A_n)) \leqslant \exp\Big(-\sum_{n=m}^{N} \mathbb{P}(A_n)\Big) \to 0.$$

因此从任意 m 开始都几乎必然还会发生某个 A_n, 对可数个 m 取交即得结论. □

引理 2.5.1 Markov–Chebyshev 不等式

若 $p>0$ 且 $\mathbb{E}|X|^p < \infty$, 则对任意 $a>0$,

$$\mathbb{P}(|X| \geqslant a) \leqslant \frac{\mathbb{E}|X|^p}{a^p}.$$

特别地, $\mathbb{P}(|X-\mathbb{E}X| \geqslant a) \leqslant \operatorname{Var}(X)/a^2$.

证明: 在事件 $\{|X| \geqslant a\}$ 上有 $|X|^p \geqslant a^p$, 所以

$$\mathbb{E}|X|^p \geqslant \mathbb{E}\big[|X|^p \mathbf{1}_{|X|\geqslant a}\big] \geqslant a^p \mathbb{P}(|X| \geqslant a).$$

除以 a^p 即得第一式, 取 $p=2$ 并将 X 换为 $X-\mathbb{E}X$ 得第二式. □

推论 2.5.2 可积同分布序列的增长

若 X_n 同分布且 $\mathbb{E}|X_1| < \infty$, 不要求独立, 就有 $X_n/n \to 0$ 几乎必然.

证明: 对每个 $\varepsilon = 1/k$, 由尾积分公式有

$$\sum_{n\geqslant 1} \mathbb{P}(|X_n| > \varepsilon n) = \sum_{n\geqslant 1} \mathbb{P}(|X_1| > \varepsilon n) \leqslant \frac{\mathbb{E}|X_1|}{\varepsilon} < \infty.$$

应用 Borel–Cantelli 引理, 再对 k 取可数交即得结论. □

第三章　随机变量的生成

3.1　基本蒙特卡罗方法

定义 3.1.1　基本蒙特卡罗估计

对目标 $I=\mathbb{E}f(X)$, 基本过程是独立生成 $X_1,\cdots,X_N$, 计算 $I_N=N^{-1}\sum_{i=1}^{N}f(X_i)$, 并用

$$s_N^2=\frac{1}{N-1}\sum_{i=1}^{N}(f(X_i)-I_N)^2,\qquad \widehat{\mathrm{SE}}=s_N/\sqrt{N}$$

估计标准误差. 这里假设二阶矩有限; 若样本相关, 这个标准误公式需要修正. 计算上常先得到 $U(0,1)$ 伪随机数, 再变换成所需分布.

3.2　随机变量的生成

3.2.1　均匀分布

计算机产生的通常是确定性算法给出的伪随机序列.

定义 3.2.1　线性同余发生器

线性同余发生器为

$$X_{n+1}=(aX_n+b)\bmod m,\qquad U_n=X_n/m.$$

状态只有 m 个, 因此必然最终周期化.

定理 3.2.1　Hull–Dobell 定理

对混合型线性同余发生器, 满周期 m 当且仅当 $\gcd(b,m)=1$, m 的每个素因子都整除 $a-1$, 且当 $4\mid m$ 时还需 $4\mid a-1$.

例如 $m=2^k$, $a=4c+1$, b 为奇数便满足满周期条件.

乘法型 $b=0$ 的 0 是吸收状态, 非零种子最多取得周期 $m-1$. 经典参数 $a=16807$, $m=2^{31}-1$ 属于后一类.

更高阶递推为

$$X_{n+1} = (a_0 X_n + a_1 X_{n-1} + \cdots + a_j X_{n-j} + b) \bmod m.$$

它使用若干过去状态, 能扩大状态空间, 却仍是有限状态的确定性动力系统. 若状态由 r 个模 m 的分量组成, 总状态数至多 m^r; 减去一个状态的周期上界仅适用于零状态被排除的相应构造.

长周期不是全部要求. 线性同余点组 $(U_n, \cdots, U_{n+s-1})$ 会落在有限多个平行超平面上; Marsaglia 的谱结构分析给出可用约 $(s!m)^{1/s}$ 个超平面覆盖的界. 这揭示了高维相关结构. `ran0` 的周期约为 2.1×10^9, 组合及洗牌发生器 `ran2` 的周期约为 2.3×10^{18}; 周期 $2^{19937} - 1$ 的 Mersenne Twister 是经典实例; 使用时仍应记录算法和种子, 避免随意把多个流拼接成所谓独立样本.

3.2.2 统计检验

评注　均匀性与独立性检验　把 $[0,1]$ 分成 k 个等长区间, 计数 O_j, 则 Pearson 统计量

$$\chi^2 = \sum_{j=1}^{k} \frac{(O_j - N/k)^2}{N/k}$$

在独立均匀假设和每格期望计数足够大时近似服从 χ^2_{k-1}. 它检验边缘均匀性, 不能排除序列依赖. 串行检验检查相邻若干项形成的点在多维小格中的分布; 游程检验检查升降或高低符号的连续段长度. 必须把检验水平, 多个检验及样本量一起考虑: 一次未拒绝不能证明随机数独立, 偶尔拒绝也可能是设定显著性水平允许的事件.

3.2.3 逆变换法

命题 3.2.1　逆变换法

对分布函数 F, 定义广义逆

$$F^{-1}(u) = \inf\{x : F(x) \geqslant u\}, \qquad 0 < u < 1.$$

若 $U \sim U(0,1)$, 则 $X = F^{-1}(U)$ 的分布函数为 F.

证明:　先证明事件等价关系. 若 $u \leqslant F(x)$, 则 x 属于 $\{y : F(y) \geqslant u\}$, 故 $F^{-1}(u) \leqslant x$. 反之, 令 $a = F^{-1}(u)$. 可以选 $y_n \downarrow a$ 且 $F(y_n) \geqslant u$; 右连续性给出 $F(a) \geqslant u$. 当 $a \leqslant x$ 时, 单调性给出 $F(x) \geqslant u$. 因此对 $0 < u < 1$ 有

$$F^{-1}(u) \leqslant x \quad \Longleftrightarrow \quad u \leqslant F(x).$$

在 $u = 0, 1$ 处的定义不影响连续均匀变量的分布. 于是

$$\mathbb{P}(X \leqslant x) = \mathbb{P}(F^{-1}(U) \leqslant x) = \mathbb{P}(U \leqslant F(x)) = F(x).$$

□

> **评注** 广义逆的定义允许 F 有跳跃或常值区间.

于是均匀变量为 $a+(b-a)U$, 指数变量为 $-\lambda^{-1}\log U$.
标准正态分布函数为

$$\Phi(x)=\frac{1}{2}\left[1+\operatorname{erf}\left(\frac{x}{\sqrt{2}}\right)\right].$$

其中 $\operatorname{erf}(x)=\frac{2}{\sqrt{\pi}}\int_0^x e^{-t^2}\,\mathrm{d}t$, 故

$$\Phi^{-1}(u)=\sqrt{2}\,\operatorname{erf}^{-1}(2u-1).$$

它的逆通常数值计算. 离散分布则累积概率直到首次超过 U; 类别很多且重复抽样时可以预处理累积数组或别名表. 程序中应避免把精确的 $U=0$ 送入对数.

3.2.4 生成 Gaussian 随机变量的 Box–Muller 方法

命题 3.2.2 Box–Muller 方法

令 U_1,U_2 独立均匀, 取 $R=\sqrt{-2\log U_1}$, $\Theta=2\pi U_2$, 再令

$$X=R\cos\Theta,\qquad Y=R\sin\Theta.$$

则 X,Y 相互独立且均服从 $N(0,1)$.

证明: 二维标准 Gaussian 密度在极坐标下分解为

$$\frac{1}{2\pi}\mathrm{e}^{-(x^2+y^2)/2}\,\mathrm{d}x\,\mathrm{d}y=\frac{1}{2\pi}\,\mathrm{d}\theta\,re^{-r^2/2}\,\mathrm{d}r.$$

径向分布函数为 $F_R(r)=\int_0^r se^{-s^2/2}\,\mathrm{d}s=1-\mathrm{e}^{-r^2/2}$, 所以逆变换给出 $R=\sqrt{-2\log U_1}$; 角度 $\Theta=2\pi U_2$ 与之独立. 反过来, (R,Θ) 的联合密度是 $(2\pi)^{-1}re^{-r^2/2}$. 除以极坐标 Jacobian r, 得到

$$p_{X,Y}(x,y)=\frac{1}{2\pi}\mathrm{e}^{-(x^2+y^2)/2}=\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-x^2/2}\frac{1}{\sqrt{2\pi}}\mathrm{e}^{-y^2/2}.$$

联合密度分解为两个标准正态密度, 故两者独立. □

另一个近似方法是 $Z_N=\sqrt{12/N}\,(\sum_{j=1}^{N}U_j-N/2)$. CLT 保证 $N\to\infty$ 时近似正态; 经典 $N=12$ 时变成 $\sum_j U_j-6$, 但其支撑有界, 不可能产生真正的 Gaussian 远尾. 估计稀有事件时这种近似尤其需要谨慎.

3.2.5 随机变量的组合

例题 3.2.1 卷积, 最大值与混合分布

若 U,V 独立均匀, 则 $U+V$ 在 $[0,2]$ 上有三角形密度: $x(0<x<1)$ 及 $2-x(1<x<2)$. 该密度来自卷积

$$p_{U+V}(z)=\int_{\mathbb{R}}\mathbf{1}_{(0,1)}(u)\mathbf{1}_{(0,1)}(z-u)\,\mathrm{d}u=\big|(0,1)\cap(z-1,z)\big|.$$

一般独立和用卷积计算; 独立最大值满足

$$\mathbb{P}(\max_i X_i\leqslant x)=\prod_i F_{\mathrm{i}}(x),$$

因为 $\{\max_i X_i\leqslant x\}=\bigcap_i\{X_i\leqslant x\}$, 独立性使概率变为乘积. 这里各 X_i 无须同分布. 特别地, n 个独立 $U(0,1)$ 的最大值在 $[0,1]$ 上有分布函数 x^n, 密度 nx^{n-1}. 若目标密度为混合 $p=\sum_i\beta_i p_i$, 先以概率 β_i 选类别, 再从 p_i 生成一个样本, 就得到 p. 若给定的是非归一化函数 $p(x)=\sum_i\alpha_i g_{\mathrm{i}}(x)$, 应取

$$\beta_i=\alpha_i\int g_{\mathrm{i}}(x)\,\mathrm{d}x,\qquad p_i=g_i/\int g_i,$$

并检查 $\sum_i\beta_i=1$. 不能把函数前的系数未经积分就当成混合概率.

3.2.6 接受–拒绝法

命题 3.2.3 接受–拒绝法

设目标密度为 p, 找到容易抽样的密度 q 和常数 M, 使 $p(x)\leqslant Mq(x)$. 独立生成 $X\sim q, U\sim U(0,1)$, 当 $U\leqslant p(X)/(Mq(X))$ 时接受, 则被接受的样本服从密度 p, 接受概率为 $1/M$.

证明: 由独立性可得

$$\mathbb{P}(X\in B,\text{接受})=\int_B q(x)\frac{p(x)}{Mq(x)}\,\mathrm{d}x=\frac{1}{M}\int_B p(x)\,\mathrm{d}x,$$

接受概率为 $1/M$, 条件于接受后样本密度正是 p. 平均需要 M 次尝试. □

等价地, 取包络 $f\geqslant p$, $A=\int f$, 先从 f/A 抽横坐标, 再在 $[0,f(X)]$ 均匀抽纵坐标. 两步的联合密度为

$$\frac{f(x)}{A}\frac{1}{f(x)}\mathbf{1}_{0<y<f(x)}=\frac{1}{A}\mathbf{1}_{0<y<f(x)}.$$

因此在包络下方均匀分布. 条件于 $0<Y<p(X)$ 后, 联合密度变为 $\mathbf{1}_{0<y<p(x)}$, 对 y 积分得到边缘密度 $p(x)$. 接受概率是两区域面积比 $1/A$.

若记非归一化累积分布 $F(x)=\int_{-\infty}^{x}f(s)\,\mathrm{d}s$, 则具体步骤为: 独立生成 $Z,U\sim U(0,1)$, 令 $X=F^{-1}(AZ)$, $Y=Uf(X)$, 当 $Y<p(X)$ 时接受, 否则重新生成. 若 p 支撑在 $[a,b]$ 且 $p\leqslant d$, 则取 $f=d\mathbf{1}_{[a,b]}$,

即先生成 $X \sim U(a,b)$, $Y \sim U(0,d)$; 此时接受率为 $1/[d(b-a)]$. 对于非归一化目标 $\widetilde{p}$, 只要知道 $\widetilde{p} \leqslant Cq$, 也可用 $\widetilde{p}/(Cq)$, 接受后归一化常数自动消去.

包络的尾部必须覆盖目标尾部. 例如 Cauchy 密度尾部较厚, 常可包住 Gaussian; 它不能自动支配任意重尾目标. 具体地,

$$f(x) = \frac{c_0}{1 + ((x - x_0)/a_0)^2}, \quad A = \int f = c_0 a_0 \pi, \quad X = x_0 + a_0 \tan[\pi(U - 1/2)]$$

给出常用 Cauchy 包络及其归一化采样, $a_0, c_0 > 0$; 选参数后需核验 $f \geqslant p$. 为衔接离散情形, Poisson 概率可嵌入阶梯密度

$$p(x) = \mathrm{e}^{-\lambda} \frac{\lambda^{\lfloor x \rfloor}}{\lfloor x \rfloor !} \mathbf{1}_{x \geqslant 0};$$

其积分为 1, 连续接受–拒绝抽到 X 后取 $\lfloor X \rfloor$ 即得所需计数.

第四章　方差缩减

4.1　为什么需要方差缩减

对无偏平均估计量, 均方误差等于 σ^2/N. 若想把标准误减半, 直接抽样需四倍样本. 方差缩减的目标是在同样的计算预算下, 通过利用函数形状, 相关量或条件结构, 构造期望不变而方差更小的随机变量. 比较方法时应比较 “方差乘以单个样本成本”, 不能只比较样本数.

4.2　方差缩减方法

4.2.1　重要性抽样

命题 4.2.1　重要性抽样及最优密度

计算 $I=\int f(x)\,\mathrm{d}x$ 时, 用 $X\sim p$ 可写成

$$I=\mathbb{E}_p\frac{f(X)}{p(X)},\qquad \operatorname{Var}(\widehat{I}_N)=\frac{1}{N}\left(\int\frac{f(x)^2}{p(x)}\,\mathrm{d}x-I^2\right).$$

要求 $f\neq 0$ 的区域上 $p>0$, 且二阶积分有限.

证明:　由 $X\sim p$ 有

$$\mathbb{E}_p\frac{f(X)}{p(X)}=\int\frac{f(x)}{p(x)}p(x)\,\mathrm{d}x=I,\qquad \mathbb{E}_p\left(\frac{f(X)}{p(X)}\right)^2=\int\frac{f(x)^2}{p(x)}\,\mathrm{d}x.$$

独立样本均值的方差等于单样本方差除以 N, 即得所述误差公式. 又由 Cauchy–Schwarz 不等式,

$$\left(\int|f|\right)^2=\left(\int\frac{|f|}{\sqrt{p}}\sqrt{p}\right)^2\leqslant\left(\int\frac{f^2}{p}\right)\left(\int p\right)=\int\frac{f^2}{p}.$$

等号要求 $|f|/\sqrt{p}=c\sqrt{p}$, 所以最优密度为 $p^*=|f|/\int|f|$. 当 $f\geqslant 0$ 时, 理想估计量恒等于 I, 方差为零; 但该密度的归一化恰恰需要未知的 I, 所以实际应寻找接近它而又易抽样, 易计算密度的分布. □

例题 4.2.1 Gaussian 建议分布

例如 $\int_{-10}^{10} \mathrm{e}^{-x^2/2}\,\mathrm{d}x$ 用区间均匀抽样会浪费大量尾部样本. 以标准正态为建议分布, 权重为 $\sqrt{2\pi}\mathbf{1}_{|X|\leqslant 10}$, 几乎没有涨落.
再考虑二维区域 $D=[-1,1]^2$ 上

$$f(x,y)=\tfrac{1}{2}\mathrm{e}^{-90(x-1/2)^2-45(y+1/10)^4}+\mathrm{e}^{-45(x+2/5)^2-60(y-1/2)^2}.$$

可把第一项的四次幂近似为 $10(y+1/10)^2$ 来设计 Gaussian 混合建议分布. 两个 Gaussian 的均值为 $(1/2,-1/10)$, $(-2/5,1/2)$, 协方差为 $\mathrm{diag}(1/180,1/20)$, $\mathrm{diag}(1/90,1/120)$; 按这两项在整个平面上的积分归一化, 权重约为 $0.46, 0.54$. 若从整个平面的混合密度 g 抽样, 应估计 $f(X)\mathbf{1}_D(X)/g(X)$; 若拒绝 D 外样本, 则密度变成截断后的条件密度, 必须相应调整归一化. 该近似用于设计抽样, 不能把原积分里的四次项直接替换掉.

定义 4.2.1 自归一化重要性抽样

更一般地, 目标是 $\mathbb{E}_\pi f$, 建议分布为 g 时, 权重为 $w=\pi/g$. 若只知道 $\widetilde{\pi}=Z\pi$, 可用自归一化估计

$$\widehat{I}_N^{\mathrm{SN}}=\frac{\sum_i f(X_i)\widetilde{\pi}(X_i)/g(X_i)}{\sum_i \widetilde{\pi}(X_i)/g(X_i)}.$$

记 $w_i=\widetilde{\pi}(X_i)/g(X_i)$, 若 $\int |f|\widetilde{\pi}<\infty$ 且 $0<Z=\int\widetilde{\pi}<\infty$, 强大数定律给出

$$\frac{1}{N}\sum_i w_i f(X_i)\longrightarrow Z\mathbb{E}_\pi f,\qquad \frac{1}{N}\sum_i w_i\longrightarrow Z\quad \text{a.s.}.$$

因极限分母非零, 两式相除得到一致性; 有限样本时, 两个随机量之比的期望一般不等于期望之比, 故通常有偏. 权重集中程度可粗略用 $(\sum_i w_i)^2/\sum_i w_i^2$ 描述; 这不是对所有 f 都准确的有效样本数.

评注 交叉熵方法 对非负 f, 理想密度 $\mu=f\pi/\mathbb{E}_\pi f$. 在参数族 μ_u 中最小化

$$\mathrm{KL}(\mu\|\mu_u)=\int \mu\log\frac{\mu}{\mu_u}$$

的计算可以展开为

$$\mathrm{KL}(\mu\|\mu_u)=\int \mu\log\mu-\frac{1}{I(f)}\int f(x)\pi(x)\log\mu_u(x)\,\mathrm{d}x.$$

第一项与 u 无关, 且 $I(f)>0$, 所以等价于最大化 $F(u)=\int f\pi\log\mu_u$. 若可交换参数微分与积分, 内点最优解满足

$$\nabla_u F(u)=\int f(x)\pi(x)\frac{\nabla_u\mu_u(x)}{\mu_u(x)}\,\mathrm{d}x=0.$$

可用已有建议分布加权估计该目标, 迭代改进抽样.

若 $f=\mathbf{1}_A$ 且 $p=\mathbb{P}(A)\ll 1$, 直接平均的相对标准误为 $\sqrt{(1-p)/(Np)}$; 需要 Np 足够大才可能稳定. 条件密度 $\pi(\cdot\mid A)$ 是零方差理想目标, 但通常难以直接获得. 逐步逼近稀有集合或用指数倾斜把稀有事件变成常见事件, 是实际可行的思路.

4.2.2 控制变量

命题 4.2.2 最优控制变量

设要估计 $\mathbb{E}U$, 另有均值 $\mu=\mathbb{E}V$ 已知且与 U 相关的变量. 对 $U_c=U+c(V-\mu)$,

$$\operatorname{Var}(U_c)=\operatorname{Var}(U)+2c\operatorname{Cov}(U,V)+c^2\operatorname{Var}(V).$$

若 $\operatorname{Var}(V)>0$, 配方得到

$$c^*=-\frac{\operatorname{Cov}(U,V)}{\operatorname{Var}(V)},\qquad \operatorname{Var}(U_{c^*})=\operatorname{Var}(U)(1-\rho^2).$$

证明: 首先 $\mathbb{E}U_c=\mathbb{E}U+c(\mathbb{E}V-\mu)=\mathbb{E}U$. 将 $U_c-\mathbb{E}U_c=(U-\mathbb{E}U)+c(V-\mu)$ 平方取期望, 有

$$\begin{aligned}\operatorname{Var}(U_c)&=\operatorname{Var}(V)\left(c+\frac{\operatorname{Cov}(U,V)}{\operatorname{Var}(V)}\right)^2+\operatorname{Var}(U)-\frac{\operatorname{Cov}(U,V)^2}{\operatorname{Var}(V)}\\&=\operatorname{Var}(V)(c-c^*)^2+\operatorname{Var}(U)(1-\rho^2).\end{aligned}$$

第一项非负, 且在 $c=c^*$ 时为零, 故得到最优系数与最小方差. 若 $\operatorname{Var}(V)=0$, 则 $V=\mu$ 几乎必然, 控制项恒为零. □

为了保持直接的无偏性论证, 可以用独立预试验估计 c^* 后固定使用; 用同一批样本估系数会引入额外的有限样本分析. 多个控制量时, 对协方差矩阵求解线性系统即可. 样本系数为 $\widehat{c}=-\sum_{\mathrm{i}}(U_i-\bar U)(V_i-\bar V)/\sum_{\mathrm{i}}(V_i-\bar V)^2$, 分母需非零. 积分形式中最简单的控制是 $I(f)=I(f-g)+I(g)$, 把已知的 $I(g)$ 精确加回, 仅对小波动的剩余量抽样.

例题 4.2.2 控制变量与对称性

设 $X\sim N(0,1)$, $U=(1+\mathrm{e}^{\sigma X})^{-1}$ 可用 $V=\mathbf{1}_{X\leqslant 0}$, $\mu=1/2$ 控制. 这个特例其实有更强的对称性: $U(x)+U(-x)=1$, 所以原期望恰为 $1/2$. 比值型和指数型修正也可能有效, 但不再自动无偏, 必须重新分析其期望. 非线性修正还包括 $\bar X\,\mathbb{E}Y/\bar Y$ 和 $\bar X\exp(\bar Y-\mathbb{E}Y)$; 前者还须保证分母不为零, 相应比值可积. 它们与线性零均值控制项的严格无偏性不可混淆.

4.2.3 Rao–Blackwell 化

命题 4.2.3 Rao–Blackwell 方差缩减

若可计算 $\widetilde{U}=\mathbb{E}(U\mid V)$, 则其期望不变, 而由式 (2.1)

$$\operatorname{Var}(\widetilde{U})=\operatorname{Var}(U)-\mathbb{E}\operatorname{Var}(U\mid V)\leqslant\operatorname{Var}(U).$$

因此, 若条件期望可显式计算, 便可用它代替原随机变量. 例如 $U=\mathbf{1}_{Y\leqslant g(X)}$, $Y\sim U(0,1)$ 独立于 X 且 $0\leqslant g\leqslant 1$, 则条件期望是 $g(X)$. 用 $g(X)$ 平均总不比再抛一次 Bernoulli 的方法差.

4.2.4 对偶变量

命题 4.2.4 对偶变量

若 $X\sim U(0,1)$, 则 $1-X$ 同分布. 用一对样本的平均 $Z=[f(X)+f(1-X)]/2$, 其方差为

$$\operatorname{Var}(Z)=\frac{1}{2}\operatorname{Var}(f(X))+\frac{1}{2}\operatorname{Cov}(f(X),f(1-X)).$$

证明: 方差恒等式由平方展开得到. 若 f 单调, 则 $f(X)$ 与 $f(1-X)$ 的协方差非正. 事实上, 对独立副本 X',

$$2\operatorname{Cov}(g(X),h(X))=\mathbb{E}[(g(X)-g(X'))(h(X)-h(X'))],$$

其中一个函数递增, 另一个递减时, 被积项非正. □

比较时应与两个独立样本的平均相比较; 两者都需两次函数评价. 非单调函数不能自动保证收益.

4.2.5 分层抽样

定义 4.2.2 分层抽样

把区域分为互不相交的 D_k, 记 $\bar{p}_k=\mathbb{P}(X\in D_k)$, $\bar{f}_k=\mathbb{E}(f(X)\mid D_k)$, $v_k=\operatorname{Var}(f(X)\mid D_k)$. 每层独立抽 N_k 个条件样本, 估计量与方差为

$$\widehat{I}=\sum_k \bar{p}_k\frac{1}{N_k}\sum_{i=1}^{N_k} f(X_{ki}),\qquad \operatorname{Var}(\widehat{I})=\sum_k\frac{\bar{p}_k^2 v_k}{N_k}.$$

也可记 $\sigma_k^2=\int_{D_k}(f-\bar{f}_k)^2p(x)\,\mathrm{d}x=\bar{p}_k v_k$, 在该记号下方差是 $\sum_k \bar{p}_k\sigma_k^2/N_k$, 两种写法不可混用.

证明: 记第 k 层的样本均值为 $\widehat{f}_k$. 条件密度为 $p^{(k)}(x)=p(x)\mathbf{1}_{D_k}(x)/\bar{p}_k$, 故

$$\mathbb{E}\widehat{f}_k=\bar{f}_k,\qquad \operatorname{Var}(\widehat{f}_k)=\frac{v_k}{N_k}.$$

因此 $\mathbb{E}\widehat{I} = \sum_k \bar{p}_k \bar{f}_k = \int f(x)p(x)\,\mathrm{d}x$. 不同层独立, 使交叉协方差消失, 故

$$\mathrm{Var}(\widehat{I}) = \sum_k \bar{p}_k^2 \,\mathrm{Var}(\widehat{f}_k) = \sum_k \frac{\bar{p}_k^2 v_k}{N_k}.$$

特别地, 在均匀分布, 等长分层和 $N_k = N/M$ 时, $\bar{p}_k = 1/M$, 所以

$$\mathrm{Var}(\widehat{I}) = \frac{1}{N}\sum_k \int_{D_k} (f - \bar{f}_k)^2 \,\mathrm{d}x = \frac{\sigma_s^2}{N}.$$

每一层的均值使平方误差最小. 具体地, 对任意常数 c,

$$\int_{D_k} (f-c)^2 p \,\mathrm{d}x = \int_{D_k} (f - \bar{f}_k)^2 p \,\mathrm{d}x + \bar{p}_k(\bar{f}_k - c)^2,$$

因为交叉项含 $\int_{D_k}(f - \bar{f}_k)p\,\mathrm{d}x = 0$. 取 $c = I$ 并对 k 求和, 得到

$$\mathrm{Var}_p(f) = \sum_k \bar{p}_k v_k + \sum_k \bar{p}_k (\bar{f}_k - I)^2 \geqslant \sum_k \bar{p}_k v_k.$$

这既证明 $\sigma_s \leqslant \sigma$, 也证明一般比例分配 $\bar{p}_k/N_k = 1/N$ 的方差缩减性质. □

命题 4.2.5 Neyman 最优分配

比例分配 $N_k \approx N\bar{p}_k$ 的方差为 $N^{-1}\sum_k \bar{p}_k v_k$. 全方差公式显示, 它比直接抽样少了层间均值的方差. 固定 $\sum_k N_k = N$ 时, 最优连续分配为

$$N_k = N\frac{\bar{p}_k\sqrt{v_k}}{\sum_j \bar{p}_j\sqrt{v_j}}, \qquad \min \mathrm{Var}(\widehat{I}) = \frac{(\sum_k \bar{p}_k\sqrt{v_k})^2}{N}.$$

证明: 记 $a_k = \bar{p}_k^2 v_k$, 先设各 $a_k > 0$. 对

$$\sum_k \frac{a_k}{N_k} + \lambda\left(\sum_k N_k - N\right)$$

求驻点, 得到 $-a_k/N_k^2 + \lambda = 0$, 即 $N_k = \sqrt{a_k/\lambda}$. 代入样本数约束, 有

$$\sqrt{\lambda} = \frac{\sum_j \sqrt{a_j}}{N}, \qquad N_k = \frac{N\sqrt{a_k}}{\sum_j \sqrt{a_j}}.$$

再代回方差得到 $(\sum_k \sqrt{a_k})^2/N$. 全局最优性由

$$\left(\sum_k \sqrt{a_k}\right)^2 \leqslant \left(\sum_k \frac{a_k}{N_k}\right)\sum_k N_k$$

及其等号条件保证. 零方差层的条件均值为常数, 可以单独处理. □

实际需取整并保证相关层被抽到; 未知 v_k 可用预试验估计. 对 $[0,1]$ 等分为 M 层, 每层取 N/M 个均匀样本的原始版本, 令 $\bar{f}(x)$ 为各层平均构成的阶梯函数, 则 $\mathrm{Var}(\widehat{I}) = N^{-1}\int_0^1 (f-\bar{f})^2\,\mathrm{d}x$. 它把均匀覆盖与随机抽样结合起来; 确定性移动网格, 重要性抽样与分层分别体现网格适应, 抽样密度适应和分区控制, 不能脱离光滑性就把三者精度作绝对排序.

第五章　极限定理

5.1　大数定律

设 X_j 独立同分布, $S_n=\sum_{j=1}^n X_j$, $\eta=\mathbb{E}X_1$.

定理 5.1.1　弱大数定律

若 $\mathbb{E}|X_1|<\infty$, 则 $S_n/n\to\eta$ 依概率成立.

证明:　若二阶矩有限, 中心化后 $\mathbb{E}S_n^2=n\operatorname{Var}(X_1)$, 故 Chebyshev 不等式给出

$$\mathbb{P}(|S_n/n-\eta|>\varepsilon)\leqslant\frac{\operatorname{Var}(X_1)}{n\varepsilon^2}\to 0.$$

只有一阶矩时, 固定 K, 令 $X_j^{(K)}=X_j\mathbf{1}_{|X_j|\leqslant K}$, $R_j^{(K)}=X_j-X_j^{(K)}$, 并记 $r_K=\mathbb{E}|R_1^{(K)}|\to 0$. 则

$$\frac{S_n}{n}-\eta=\frac{1}{n}\sum_{j=1}^n(X_j^{(K)}-\mathbb{E}X_j^{(K)})+\frac{1}{n}\sum_{j=1}^n(R_j^{(K)}-\mathbb{E}R_j^{(K)}).$$

第一项的方差为 $\operatorname{Var}(X_1^{(K)})/n$, 第二项的绝对期望不超过 $2r_K$. 因此

$$\mathbb{P}\left(\left|\frac{S_n}{n}-\eta\right|>\varepsilon\right)\leqslant\frac{4\operatorname{Var}(X_1^{(K)})}{n\varepsilon^2}+\frac{4r_K}{\varepsilon}.$$

先令 $n\to\infty$, 再令 $K\to\infty$, 右端趋于零. □

定理 5.1.2　强大数定律

对独立同分布实值变量, S_n/n 几乎必然收敛到一个有限常数, 当且仅当 $\mathbb{E}|X_1|<\infty$; 此时极限为 η.

证明:　先设 $\eta=0$, $\mathbb{E}X_1^4<\infty$. 展开四次幂时, 含只出现一次的下标的项都因独立和中心化而消失. 剩余项只有四个下标相同, 或两个下标各出现两次. 第一类有 n 项; 第二类选两个不同下标有 $\binom{n}{2}$ 种, 每组有 $4!/(2!2!)=6$ 种排列, 故

$$\mathbb{E}S_n^4=n\mathbb{E}X_1^4+3n(n-1)(\mathbb{E}X_1^2)^2\leqslant Cn^2.$$

于是 $\sum_n \mathbb{P}(|S_n/n|>\varepsilon) \leqslant C\varepsilon^{-4}\sum_n n^{-2}<\infty$, Borel–Cantelli 得到几乎必然收敛.
一般可积情形可用逐项截断补足. 令 $Y_n = X_n \mathbf{1}_{|X_n|\leqslant n}$. 尾积分公式保证 $\sum_n \mathbb{P}(X_n \neq Y_n)<\infty$, 故两序列最终相同. 并且

$$\sum_n \frac{\operatorname{Var}(Y_n)}{n^2} \leqslant \mathbb{E}\left[X_1^2 \sum_{n \geqslant \max(1,\lceil |X_1| \rceil)} n^{-2} \right] \leqslant C\mathbb{E}|X_1| < \infty.$$

对独立中心变量, 方差之和有限保证级数几乎必然收敛. 其证明工具是 Kolmogorov 最大不等式

$$\mathbb{P}\left(\max_{1\leqslant k\leqslant n} \left| \sum_{j=1}^{k} Z_j \right| \geqslant a \right) \leqslant a^{-2} \sum_{j=1}^{n} \mathbb{E} Z_j^2 :$$

下面给出所需的两步论证. 令 $T_k = \sum_{j=1}^{k} Z_j$, $A_k = \{|T_j| < a \ (j<k),\ |T_k| \geqslant a\}$. A_k 两两不交, 且 $T_n - T_k$ 独立于 A_k, T_k, 均值为零, 因而

$$\mathbb{E}[T_n^2 \mathbf{1}_{A_k}] = \mathbb{E}[T_k^2 \mathbf{1}_{A_k}] + \mathbb{E}[(T_n - T_k)^2]\mathbb{P}(A_k) \geqslant a^2 \mathbb{P}(A_k).$$

求和并使用 $\mathbb{E}T_n^2 = \sum_j \mathbb{E}Z_j^2$, 即得最大不等式. 若 $\sum \mathbb{E}Z_j^2 < \infty$, 选 N_r 使尾方差 $\sum_{j>N_r} \mathbb{E}Z_j^2 \leqslant 2^{-4r}$, 对尾部最大值应用不等式并令上界指标趋于无穷, 得到

$$\mathbb{P}\left(\sup_{m>N_r} \left| \sum_{j=N_r+1}^{m} Z_j \right| > 2^{-r} \right) \leqslant 2^{-2r}.$$

Borel–Cantelli 表明上述尾部上确界最终不超过 2^{-r}, 部分和因而几乎必然是 Cauchy 列.
现在取 $Z_n = (Y_n - \mathbb{E}Y_n)/n$. 记收敛的部分和 $T_n = \sum_{j=1}^{n} Z_j \to T$, 分部求和给出 Kronecker 引理在此处的具体形式:

$$\frac{1}{n}\sum_{j=1}^{n}(Y_j - \mathbb{E}Y_j) = \frac{1}{n}\sum_{j=1}^{n} j(T_j - T_{j-1}) = T_n - \frac{1}{n}\sum_{j=1}^{n-1} T_j \longrightarrow T - T = 0.$$

由于 $\mathbb{E}Y_j \to \eta$, 其 Cesàro 平均也趋于 η, 充分性成立.
必要性方面, 若 S_n/n 有有限极限, 则 $X_n/n = S_n/n - [(n-1)/n]S_{n-1}/(n-1) \to 0$. 若 $\mathbb{E}|X_1| = \infty$, 尾积分比较给出 $\sum_n \mathbb{P}(|X_n|>n) = \infty$; 独立性与 Borel–Cantelli 第二部分产生矛盾. □

例题 5.1.1 Cauchy 分布

密度 $p(x) = 1/[\pi(1+x^2)]$ 的特征函数是 $\mathrm{e}^{-|\xi|}$, 所以

$$f_{S_n/n}(\xi) = f_X(\xi/n)^n = \mathrm{e}^{-|\xi|}.$$

每个样本均值仍有相同 Cauchy 分布, 不依分布收敛到常数.

评注 Cauchy 分布的期望 Cauchy 分布的期望不存在. 对称性只能使对称截断积分为零, 不能把两个无穷的正负部分相减后写成 $\mathbb{E}X = 0$.

5.2 中心极限定理

定理 5.2.1 Lindeberg–Lévy CLT

若 X_j 独立同分布, $\mathbb{E}X_j = \eta$, $0 < \mathrm{Var}(X_j) = \sigma^2 < \infty$, 则

$$\frac{S_n - n\eta}{\sigma\sqrt{n}} \Rightarrow N(0,1).$$

证明: 先取 $Y_j = (X_j - \eta)/\sigma$, 使均值为零, 方差为一. 为简化记号, 以下仍记为 X_j. 由二阶矩有限, 特征函数满足

$$f(0) = 1, \qquad f'(0) = i\mathbb{E}X_1 = 0, \qquad f''(0) = -\mathbb{E}X_1^2 = -1.$$

Taylor 公式给出 $f(u) = 1 - u^2/2 + o(u^2)$. 这里无需三阶矩: 二阶导数 $f''(u) = -\mathbb{E}[X_1^2 \mathrm{e}^{iuX_1}]$ 在零点由控制收敛连续, 已经足以保证 $o(u^2)$ 余项. 独立性给出

$$f_{S_n/\sqrt{n}}(\xi) = \left[1 - \frac{\xi^2}{2n} + o(n^{-1})\right]^n \to \mathrm{e}^{-\xi^2/2}.$$

极限在零处连续, Lévy 连续性定理完成证明. □

大数定律给出样本均值的极限, 中心极限定理进一步给出其涨落的尺度与极限分布. 它使蒙特卡罗置信区间近似为

$$I_N \pm z_{1-\alpha/2}\frac{s_N}{\sqrt{N}}.$$

这里的覆盖率指重复抽样时区间覆盖固定真值的比例; 没有二阶矩, 样本强相关或尾部极难探索时, 不能机械套用.

例题 5.2.1 自由连接高分子链

自由连接高分子有 K 根长度 b_0, 方向独立均匀的键 r_i. 旋转对称性给出 $\mathbb{E}r_i = 0$, 各坐标方差相等且总和为 b_0^2, 故协方差为 $b_0^2 I_3/3$. 端到端向量 $R = \sum_i r_i$ 因而近似

$$R \sim N\left(0, \frac{Kb_0^2}{3} I_3\right), \qquad \mathbb{E}|R|^2 = Kb_0^2.$$

评注 稳定分布 重尾变量可能不满足经典 CLT. 若存在常数 $a_n>0, b_n$ 使 $a_n(S_n-b_n)$ 依分布收敛到一个非退化分布 G, 则 G 必为稳定分布. 所谓稳定, 是指两个独立同分布副本的任意正系数线性组合, 仍与原变量的某个缩放平移同分布. 标准正态与 Cauchy 分别对应稳定指数 2 与 1; 并不是任意无限方差分布都自动具有这种极限.

对于自由连接链, 单键分布也可形式地写为 $p(r)=(4\pi b_0^2)^{-1}\delta(|r|-b_0)$, 表示球面上的均匀概率测度. 用球坐标积分可验证其总质量为 1. 具有有限二阶矩的其他独立键分布也可产生 Gaussian 长链近似, 但其均值与协方差须由相应单键分布计算.

5.3 Laplace 渐近法

命题 5.3.1 Laplace 渐近公式

考虑 $I(t)=\int_a^b \mathrm{e}^{th(x)}g(x)\,\mathrm{d}x$, $t\to\infty$. 假设 h 在内点 x_0 唯一取最大值, $h''(x_0)<0$, g 在该点连续且 $g(x_0)\neq 0$, 并假设远处积分可控, 则

$$I(t)\sim \mathrm{e}^{th(x_0)}g(x_0)\sqrt{\frac{2\pi}{t|h''(x_0)|}}. \tag{5.1}$$

证明: 先证明原始的标准形式 $F(t)=\int_{\mathbb{R}}\mathrm{e}^{th(x)}\,\mathrm{d}x$. 设 $h(0)=0$ 是唯一最大值, $h''(0)=-a<0$, $\int \mathrm{e}^{h(x)}\,\mathrm{d}x<\infty$; 并假设对每个充分小的 $\delta>0$, 在 $|x|\geqslant\delta$ 上有 $h(x)\leqslant -\eta_\delta<0$. 这是控制无界积分域尾部所需的假设.

给定 $0<\varepsilon<a/2$, 由二阶 Taylor 展开, 可取 $\delta>0$ 使

$$-\frac{a+2\varepsilon}{2}x^2\leqslant h(x)\leqslant -\frac{a-2\varepsilon}{2}x^2 \qquad (|x|\leqslant\delta).$$

于是局部积分被两个 Gaussian 积分夹住:

$$\int_{-\delta}^{\delta}\mathrm{e}^{-t(a+2\varepsilon)x^2/2}\,\mathrm{d}x\leqslant\int_{-\delta}^{\delta}\mathrm{e}^{th(x)}\,\mathrm{d}x\leqslant\int_{-\delta}^{\delta}\mathrm{e}^{-t(a-2\varepsilon)x^2/2}\,\mathrm{d}x.$$

另一方面, 对 $t\geqslant 1$,

$$0\leqslant\int_{|x|>\delta}\mathrm{e}^{th(x)}\,\mathrm{d}x=\int_{|x|>\delta}\mathrm{e}^{(t-1)h(x)}\mathrm{e}^{h(x)}\,\mathrm{d}x\leqslant\mathrm{e}^{-(t-1)\eta_\delta}\int_{\mathbb{R}}\mathrm{e}^{h(x)}\,\mathrm{d}x.$$

此项乘以 $\sqrt{t}$ 后仍趋于零. 对局部上下界作代换 $y=\sqrt{t}\,x$, 有

$$\sqrt{t}\int_{-\delta}^{\delta}\mathrm{e}^{-tcx^2/2}\,\mathrm{d}x=\int_{-\delta\sqrt{t}}^{\delta\sqrt{t}}\mathrm{e}^{-cy^2/2}\,\mathrm{d}y\longrightarrow\sqrt{\frac{2\pi}{c}}.$$

因此

$$\sqrt{\frac{2\pi}{a+2\varepsilon}} \leqslant \varliminf_{t\to\infty} \sqrt{t}F(t) \leqslant \varlimsup_{t\to\infty} \sqrt{t}F(t) \leqslant \sqrt{\frac{2\pi}{a-2\varepsilon}}.$$

令 $\varepsilon \downarrow 0$, 便得 $F(t) \sim \sqrt{2\pi/(ta)}$.
一般的 x_0 和 $h(x_0)$ 通过平移自变量并提出 $\mathrm{e}^{th(x_0)}$ 处理. 若另有连续因子 g, 在局部作同样代换后, $g(x_0+y/\sqrt{t}) \to g(x_0)$; 二次上界给出 Gaussian 支配函数. 若远处的 $\int \mathrm{e}^{h(x)-h(x_0)}|g(x)|\,\mathrm{d}x$ 有限且有同样的指数间隙, 尾部仍可忽略, 得到所述公式. □

对正的积分取对数并除以 t, 前因子只贡献 $O(\log t/t)$, 故又得到常用的鞍点形式

$$\lim_{t\to\infty} \frac{1}{t}\log F(t) = \sup_x h(x).$$

评注　高维与端点情形　多维非退化极大值的对应式为

$$\int \mathrm{e}^{th(x)} g(x)\,\mathrm{d}x \sim \mathrm{e}^{th(x_0)} g(x_0)(2\pi/t)^{d/2}[\det(-\nabla^2 h(x_0))]^{-1/2}.$$

若最大值在左端点 a 且 $h'(a)<0$, 主导宽度变为 t^{-1}, 结果为 $\mathrm{e}^{th(a)}g(a)/(t|h'(a)|)$. 因此内点与端点不能使用同一个幂次.

5.4 Cramér 大偏差定理

令 μ_n 为 S_n/n 的分布,

$$M(\lambda) = \mathbb{E}\mathrm{e}^{\lambda X_1}, \quad \Lambda(\lambda) = \log M(\lambda), \quad I(x) = \sup_{\lambda\in\mathbb{R}}\{\lambda x - \Lambda(\lambda)\}.$$

以下先设 $M(\lambda)<\infty$ 对全部实数 λ 成立. 标准 Cramér 定理只要求零点邻域内有限.

定理 5.4.1　Cramér 大偏差定理

对闭集 F 与开集 G,

$$\varlimsup_{n\to\infty} \frac{1}{n}\log \mu_n(F) \leqslant -\inf_{x\in F} I(x), \qquad \varliminf_{n\to\infty} \frac{1}{n}\log \mu_n(G) \geqslant -\inf_{x\in G} I(x).$$

这描述固定距离的异常平均值, 其概率以 $\mathrm{e}^{-nI(x)}$ 的指数尺度衰减. 若某集合内部和闭包上的 I 下确界相同, 可把上下界合为一个极限; 一般集合不能直接把上下界改成等号.

引理 5.4.1　Legendre–Fenchel 变换

设 $f:\mathbb{R}^d \to \mathbb{R}\cup\{+\infty\}$ 为真, 下半连续凸函数, 定义 $f^*(y) = \sup_x\{x\cdot y - f(x)\}$. 则 f^* 凸且下半连

续, 满足 Fenchel 不等式

$$x \cdot y \leqslant f(x) + f^*(y),$$

并且 $f^{**} = f$. 这里真函数指不恒为 $+\infty$ 且不取 $-\infty$. 约定 $\inf \varnothing = +\infty$, $\sup \varnothing = -\infty$.

证明: f^* 是连续仿射函数 $y \mapsto x \cdot y - f(x)$ 的上确界, 所以凸且下半连续. 固定 x, y, 定义直接给出 $f^*(y) \geqslant x \cdot y - f(x)$, 这就是 Fenchel 不等式. 它又给出 $f^{**} \leqslant f$; 反向不等式由闭凸上图的分离定理得到: 对 $a < f(x_0)$, 存在仿射支撑函数 $\ell(x) = y \cdot x - c \leqslant f(x)$ 且 $\ell(x_0) > a$, 于是 $f^*(y) \leqslant c$, 从而 $f^{**}(x_0) > a$. 令 $a \uparrow f(x_0)$ 即得等号. 此处使用的是闭凸函数为其仿射下界之上确界的标准分离定理. □

引理 5.4.2 速率函数的基本性质

I 凸且下半连续, $I^* = \Lambda$; 并且 $I \geqslant 0$, $I(\eta) = 0$. I 在 $(-\infty, \eta]$ 上不增, 在 $[\eta, \infty)$ 上不减. 若 $x > \eta$, 可将定义中的上确界限于 $\lambda \geqslant 0$; 若 $x < \eta$, 可限于 $\lambda \leqslant 0$.

证明: 对 $0 < \theta < 1$, Hölder 不等式给出

$$\mathbb{E}\mathrm{e}^{[\theta\lambda_1 + (1-\theta)\lambda_2]X_1} \leqslant (\mathbb{E}\mathrm{e}^{\lambda_1 X_1})^{\theta} (\mathbb{E}\mathrm{e}^{\lambda_2 X_1})^{1-\theta},$$
$$\Lambda(\theta\lambda_1 + (1-\theta)\lambda_2) \leqslant \theta\Lambda(\lambda_1) + (1-\theta)\Lambda(\lambda_2).$$

故 Λ 凸; 它在整个实轴上有限, 因而连续. 前一引理给出 I 的凸性, 下半连续性及 $I^* = \Lambda$. 取 $\lambda = 0$ 得 $I(x) \geqslant 0$; Jensen 不等式给出

$$\Lambda(\lambda) = \log \mathbb{E}\mathrm{e}^{\lambda X_1} \geqslant \log \mathrm{e}^{\lambda\eta} = \lambda\eta,$$

故 $I(\eta) \leqslant 0$, 所以等于零. 若 $\eta \leqslant x \leqslant y$, 写 $x = (1-\theta)\eta + \theta y$, 得到 $I(x) \leqslant \theta I(y) \leqslant I(y)$; 左侧同理. 最后, 若 $x > \eta$, $\lambda \leqslant 0$, 则

$$\lambda x - \Lambda(\lambda) \leqslant \lambda\eta - \Lambda(\lambda) \leqslant 0.$$

这些参数不能提高已经非负的上确界, 故只需 $\lambda \geqslant 0$; 另一侧同理. □

以下证明 Cramér 定理.

证明: 对 $x > \eta$ 和 $\lambda > 0$, 指数 Markov 不等式给出

$$\mathbb{P}(S_n/n \geqslant x) \leqslant \mathrm{e}^{-n\lambda x} (\mathbb{E}\mathrm{e}^{\lambda X_1})^n = \mathrm{e}^{-n[\lambda x - \Lambda(\lambda)]}.$$

对 λ 优化得到 $\mathrm{e}^{-nI(x)}$. 左尾同理. 若闭集 F 包含 η, 则 $\inf_F I = 0$, 所需上界由概率不超过 1 得到.

否则令 $x_- = \sup(F \cap (-\infty, \eta))$, $x_+ = \inf(F \cap (\eta, \infty))$, 空的一侧直接略去. 闭性保证非空一侧的有限端点属于 F, 且

$$F \subset (-\infty, x_-] \cup [x_+, \infty), \qquad \inf_{x \in F} I(x) = \min\{I(x_-), I(x_+)\}.$$

由两尾上界和 $a + b \leqslant 2\max(a, b)$,

$$\frac{1}{n} \log \mu_n(F) \leqslant \frac{\log 2}{n} - \min\{I(x_-), I(x_+)\}.$$

令 $n \to \infty$ 即得闭集上界.

下界需要构造使偏差变成典型值的新分布. 若 $x = \Lambda'(\lambda_0)$, 定义指数倾斜

$$\frac{\mathrm{d}\mathbb{P}_{\lambda_0}}{\mathrm{d}\mathbb{P}}(X) = \mathrm{e}^{\lambda_0 X - \Lambda(\lambda_0)}.$$

归一化来自 M 的定义; 新均值为 x, 新方差为 $\Lambda''(\lambda_0)$. 设 $(x - \delta, x + \delta) \subset G$, 在 n 个样本的乘积空间上

$$\begin{aligned} \mu_n(G) &\geqslant \mathbb{E}_{\lambda_0}\left[\mathrm{e}^{-\lambda_0 S_n + n\Lambda(\lambda_0)} \mathbf{1}_{|S_n/n - x| < \delta}\right] \\ &\geqslant \mathrm{e}^{-n[I(x) + |\lambda_0|\delta]} \mathbb{P}_{\lambda_0}(|S_n/n - x| < \delta). \end{aligned}$$

最后一个概率由大数定律趋于 1, 所以取对数, 除 n, 再令 $\delta \downarrow 0$, 得到 $-I(x)$. 对开集内的 x 优化完成内部点的证明. 还需处理上确界不在有限参数处达到的情形. $I(x) = \infty$ 时下界平凡; 若 $I(x) < \infty$, 取极大化序列 λ_k. 有界子列会给出有限极大点, 故只需考虑 $\lambda_k \to +\infty$ 或 $-\infty$. 以前者为例,

$$\mathrm{e}^{\Lambda(\lambda_k) - \lambda_k x} = \mathbb{E}\mathrm{e}^{\lambda_k(X_1 - x)} \longrightarrow \mathrm{e}^{-I(x)} < \infty.$$

若 $\mathbb{P}(X_1 > x) > 0$, 存在 $\varepsilon > 0$ 使 $\mathbb{P}(X_1 \geqslant x + \varepsilon) > 0$, 左端至少为 $\mathrm{e}^{\lambda_k \varepsilon}\mathbb{P}(X_1 \geqslant x + \varepsilon) \to \infty$, 矛盾. 因此 $X_1 \leqslant x$ 几乎必然. 控制收敛随即给出

$$\mathrm{e}^{-I(x)} = \lim_k \mathbb{E}\mathrm{e}^{\lambda_k(X_1 - x)} = \mathbb{P}(X_1 = x).$$

当 $x \in G$, 所有样本都取 x 的事件包含于 $\{S_n/n \in G\}$, 所以

$$\mu_n(G) \geqslant \mathbb{P}(X_1 = \cdots = X_n = x) = \mathrm{e}^{-nI(x)}.$$

$\lambda_k \to -\infty$ 时对左端点同理. 两类情形合并, 再对 $x \in G$ 取下确界, 即完成下界证明. □

例题 5.4.1 可显式计算的速率函数

Bernoulli(p) 的 $\Lambda(\lambda) = \log(q + pe^{\lambda})$, 驻点条件是 $x = pe^{\lambda}/(q + pe^{\lambda})$, 从而

$$I(x) = x \log \frac{x}{p} + (1 - x) \log \frac{1 - x}{q}, \quad 0 \leqslant x \leqslant 1,$$

具体地, 对 $0<x<1$, 驻点给出 $\mathrm{e}^{\lambda}=xq/[p(1-x)]$, 代回 $\lambda x-\log(q+pe^{\lambda})$ 即得上式; $x=0,1$ 分别取 $\lambda\to-\infty,+\infty$, 得到 $-\log q,-\log p$. 区间外为 $+\infty$, 约定 $0\log 0=0$. 它也是两个 Bernoulli 分布的相对熵; 对一般有限概率向量, $D(\mu\|\nu)=\sum_{\mathrm{i}}\mu_i\log(\mu_i/\nu_i)$. Gaussian $N(\eta,\sigma^2)$ 的速率为 $(x-\eta)^2/(2\sigma^2)$. $\mathrm{Exp}(\lambda)$ 的速率为 $\lambda x-1-\log(\lambda x)(x>0)$, $x\leqslant 0$ 时为 $+\infty$; 该例只需零点邻域的矩生成函数假设.

Laplace 方法说明了二者的联系: 若平均值的概率在指数尺度上形如 $\mathrm{e}^{-nI(x)}$, 则 $\mathbb{E}\mathrm{e}^{n\lambda S_n/n}$ 的指数主项是 $\sup_x(\lambda x-I(x))$. 这说明了矩生成函数与速率函数的共轭关系; 严格结论由前述大偏差上下界保证.

例题 5.4.2 熵与自由能

令 $\Omega=\{0,1\}^n$, 参考测度使 2^n 个配置等概率. 记

$$H_n(\omega)=\sum_{i=1}^{n}s_i,\qquad h_n(\omega)=\frac{H_n(\omega)}{n}.$$

当 $p=1/2$, 速率函数为 $I(E)=E\log E+(1-E)\log(1-E)+\log 2$. 令 $W_n(E,\delta)$ 为 $|h_n-E|<\delta$ 内的微观状态数, Boltzmann 熵为 $S_n(E,\delta)=k_B\log W_n(E,\delta)$. 因为

$$\mathbb{P}(|h_n-E|<\delta)=\frac{W_n(E,\delta)}{2^n},$$

先令 $n\to\infty$, 再令 $\delta\downarrow 0$, 大偏差原理给出单位自旋熵

$$S(E)=\lim_{\delta\downarrow 0}\lim_{n\to\infty}\frac{S_n(E,\delta)}{n}=k_B[\log 2-I(E)].$$

此处能量窗口的极限次序使离散能量格点不造成歧义.
再考虑固定温度的正则系综. 定义

$$Z_n(\beta)=\sum_{\omega\in\Omega}\mathrm{e}^{-\beta H_n(\omega)},\qquad F_n(\beta)=-\beta^{-1}\log Z_n(\beta),\qquad F(\beta)=\lim_{n\to\infty}\frac{F_n(\beta)}{n}.$$

由独立性, $\mathbb{E}\mathrm{e}^{\lambda H_n}=M(\lambda)^n$; 由等概率参考测度, $\mathbb{E}\mathrm{e}^{-\beta H_n}=2^{-n}Z_n(\beta)$. 所以

$$\Lambda(-\beta)=\lim_{n\to\infty}\frac{1}{n}\log(2^{-n}Z_n)=-\beta F(\beta)-\log 2.$$

将 $I(E)=\log 2-S(E)/k_B$ 代入共轭关系, 得到

$$-\beta F(\beta)-\log 2=\sup_E\left\{-\beta E-\log 2+\frac{S(E)}{k_B}\right\},$$
$$F(\beta)=\inf_E\{E-TS(E)\}.$$

若极小点 E^* 在内部且 S 可微, 则 $1-TS'(E^*)=0$, 即 $S'(E^*)=1/T$. 这把宏观自由能的极小化与微观状态数的指数增长联系起来.

第六章　Markov 链

6.1　离散时间 Markov 链

定义 6.1.1　Markov 链

过程 X_n 满足 Markov 性, 如果条件于当前状态后, 过去不再提供预测下一状态的额外信息:

$$\mathbb{P}(X_{n+1}=j \mid X_0,\cdots,X_n)=\mathbb{P}(X_{n+1}=j \mid X_n).$$

若右侧等于与 n 无关的 p_{ij}(当 $X_n=i$), 称为**时间齐次**, $P=(p_{ij})$ 为转移概率矩阵.

$p_{ij}\geqslant 0$, $\sum_j p_{ij}=1$. 若初始分布为行向量 μ_0, 则 $\mu_n=\mu_0 P^n$, 路径概率为 $\mu_0(i_0)\prod_{r=0}^{n-1}p_{i_r i_{r+1}}$. 插入中间状态求和得到 Chapman–Kolmogorov 关系 $P^{n+m}=P^nP^m$.

例题 6.1.1　随机游走与 Ehrenfest 模型

整数上的随机游走是最简单例子: 每步加独立的 ±1. Ehrenfest 模型把 N 个球放在两个盒子中, 每步随机选一个球换盒; 若 $X_n=k$ 表示第一盒球数, 则 $p_{k,k-1}=k/N$, $p_{k,k+1}=(N-k)/N$. 它描述从微观可逆移动产生的宏观向平衡弛豫.

定义 6.1.2　不变分布与平稳性

不变分布满足 $\pi P=\pi$, $\pi_i\geqslant 0$, $\sum_i\pi_i=1$. 若初始分布为 π, 所有时刻的边缘分布相同, 且时间齐次链的所有有限维分布平移不变, 称为平稳过程. 时间齐次性是转移规律的性质, 平稳性则是过程联合分布的性质.

定义 6.1.3　通信类与周期

若存在 $n\geqslant 0$ 使 $(P^n)_{ij}>0$, 称 j 从 i 可达; 互相可达形成通信类. 离开不了的类称闭类. 有限状态链不可约是指只有一个通信类, 等价于无法经置换写成非平凡块上三角形式. 不可约非负矩阵的 Perron–Frobenius 定理保证谱半径为正单特征值且左右特征向量可取严格正. 对随机矩阵, $P\mathbf{1}=\mathbf{1}$ 且谱半径为 1, 故有限不可约链有唯一严格正不变分布.

状态的周期是 $\gcd\{n\geqslant 1:(P^n)_{ii}>0\}$; 不可约时所有状态周期相同. 周期为 1 称非周期. 有限不可约非周期矩阵是本原的, 即某个 P^{n_0} 所有元素严格正.

例题 6.1.2 不变分布与周期性

$$P_1=\begin{pmatrix}1&0&0\\1/2&0&1/2\\0&0&1\end{pmatrix},\qquad P_2=\begin{pmatrix}0&1&0\\1/2&0&1/2\\0&1&0\end{pmatrix}.$$

P_1 有两个吸收态, 不变分布是 $(1,0,0)$ 与 $(0,0,1)$ 的任意凸组合; P_2 不可约, 不变分布唯一为 $(1/4,1/2,1/4)$, 但周期为 2, 所以一般 $\mu_0P_2^n$ 不收敛.

例题 6.1.3 闭通信类与不变分布

再考虑以下两个转移矩阵

$$P_3=\begin{pmatrix}0&1&0&0&0\\.5&.5&0&0&0\\.3&0&.4&.3&0\\0&0&0&.5&.5\\0&0&0&.5&.5\end{pmatrix},\quad P_4=\begin{pmatrix}0&1&0&0&0\\.3&.4&.3&0&0\\.3&0&.4&.3&0\\0&0&0&.5&.5\\0&0&0&.5&.5\end{pmatrix}.$$

P_3 的闭类为 $\{1,2\}$, $\{4,5\}$, 不变分布不唯一; P_4 只有后一个闭类, 唯一不变分布为 $(0,0,0,1/2,1/2)$. 因此可约不等于不变分布不唯一; 关键是闭通信类的数目.

定理 6.1.1 有限链的收敛与遍历

设状态空间有限. 不可约链的 Cesàro 平均 $n^{-1}\sum_{k=0}^{n-1}\mu_0P^k$ 趋于 π; 若还非周期, 则 μ_0P^n 以几何速度趋于 π. 对任意函数 f, 不可约链满足

$$\frac{1}{n}\sum_{k=0}^{n-1}f(X_k)\longrightarrow\sum_i\pi_if(i)\quad\text{a.s.}.$$

证明: 先证明本原链的分布收敛. 对两个概率向量, 令 $v=\mu-\widetilde{\mu}$, 则 $\sum_i v_i=0$, 故

$$d(\mu,\widetilde{\mu})=\frac{1}{2}\sum_i|v_i|=\sum_i v_i^+=\sum_i v_i^-\leqslant 1.$$

取 s 使 P^s 所有元素为正, 再取 $0<\alpha<1$ 使 $(P^s)_{ji}\geqslant\alpha$. 设 $B_+=\{i:(vP^s)_i>0\}$; 若两分布不同, B_+ 不能是整个状态空间, 否则 $\sum_i(vP^s)_i>0$ 与行和为一矛盾. 因此对每个 j 都有 $\sum_{i\in B_+}(P^s)_{ji}\leqslant 1-\alpha$. 于是

$$d(\mu P^s,\widetilde{\mu}P^s)=\sum_{i\in B_+}\sum_j v_j(P^s)_{ji}$$

$$\leqslant \sum_j v_j^+ \sum_{i\in B_+} (P^s)_{ji} \leqslant (1-\alpha) d(\mu, \widetilde{\mu}).$$

任意随机矩阵 R 都满足

$$\sum_i |(vR)_i| \leqslant \sum_{i,j} |v_j| R_{ji} = \sum_j |v_j|,$$

所以其余不足 s 步的转移不会增加总变差距离. 令 $\mu_n = \mu_0 P^n$, $k = \lfloor n/s \rfloor$, 对任意 $m \geqslant 0$,

$$d(\mu_n, \mu_{n+m}) \leqslant (1-\alpha)^k d(\mu_{n-ks}, \mu_{n+m-ks}) \leqslant (1-\alpha)^k.$$

有限维概率单纯形完备, 故 μ_n 收敛到某个 π. 取极限得 $\pi P = \pi$. 若 $\widetilde{\pi}$ 也不变, 则

$$d(\pi, \widetilde{\pi}) \leqslant (1-\alpha) d(\pi, \widetilde{\pi}),$$

所以二者相等. 取 $\widetilde{\mu} = \pi$ 便得几何误差界.
对于可能有周期的不可约链, 令 $\bar{\mu}_n = n^{-1} \sum_{k=0}^{n-1} \mu_0 P^k$. 则

$$\bar{\mu}_n P - \bar{\mu}_n = \frac{\mu_0 P^n - \mu_0}{n} \longrightarrow 0.$$

概率单纯形紧致, 所以每个子列都有收敛子列; 其极限由上式必为不变分布. Perron–Frobenius 定理保证不变分布唯一, 故所有聚点均为 π, 于是整个 $\bar{\mu}_n \to \pi$.
最后证明路径时间平均. 记 $\bar{f} = f - \sum_i \pi_i f(i)$. 有限不可约链中 $\ker(I-P)$ 由常数向量张成, 左零空间由 π 张成, 故 $\pi \bar{f} = 0$ 保证 Poisson 方程 $(I-P)g = \bar{f}$ 有解. 令

$$D_{k+1} = g(X_{k+1}) - (Pg)(X_k), \qquad M_n = \sum_{k=0}^{n-1} D_{k+1}.$$

条件期望 $\mathbb{E}(D_{k+1} \mid X_0, \cdots, X_k) = 0$, 即 M_n 是鞅; 由于状态有限, 增量有界且彼此正交, $\mathbb{E} M_n^2 \leqslant Cn$. 由平方可积鞅最大不等式,

$$\mathbb{P}\left(\max_{k \leqslant 2^r} |M_k| > \varepsilon 2^r \right) \leqslant \frac{C}{\varepsilon^2 2^r}.$$

右端对 r 可求和, Borel–Cantelli 及相邻二进区间比较给出 $M_n/n \to 0$ 几乎必然. 这里最大不等式与独立和的证明相同: 在首次越界事件上, 未来鞅增量的条件期望为零. 由

$$\sum_{k=0}^{n-1} \bar{f}(X_k) = g(X_0) - g(X_n) + M_n$$

并除以 n, 有界端点项趋于零, 即得遍历结论. □

评注　分布收敛与时间平均　几何速度适用于非周期链的 P^n 收敛, 不能一般宣称 Cesàro 平均也按指数速度收敛; 即使 $P^n - \mathbf{1}\pi$ 几何衰减, 其从 0 开始的平均通常仍只有 $O(1/n)$. 无限状态链还需正

再生等条件, 本节有限状态结论不能无条件照搬.

6.1.1 时间反演

定义 6.1.4 时间反演与详细平衡

平稳链中, 在 $\pi_i>0$ 的支撑上, 由 Bayes 公式

$$\widehat{p}_{ij}=\mathbb{P}(X_{n-1}=j\mid X_n=i)=\frac{\pi_j p_{ji}}{\pi_i}.$$

若 $\widehat{P}=P$, 称链关于 π 可逆, 等价于详细平衡 $\pi_i p_{ij}=\pi_j p_{ji}$. 对 i 求和立即得到不变性; 反过来不变性只要求总流入等于总流出, 不要求每对边的流量分别抵消.

命题 6.1.1 反向 Markov 性

反向过程仍为 Markov 链不仅是两时刻概率的猜测: 对完整反向路径, 有 $\pi_{i_N}p_{i_N i_{N-1}}\cdots p_{i_1 i_0}=\pi_{i_0}\widehat{p}_{i_0 i_1}\cdots\widehat{p}_{i_{N-1}i_N}$, 中间的 π 因子逐一抵消, 给出全部联合分布的 Markov 分解.

命题 6.1.2 Dirichlet 型恒等式

令 $L=P-I$, 加权内积 $(f,g)_\pi=\sum_i \pi_i f_i g_i$. 详细平衡使 L 自伴随, 并且

$$-(f,Lf)_\pi=\frac{1}{2}\sum_{i,j}\pi_i p_{ij}(f_j-f_i)^2\geqslant 0.$$

若沿用 $D(f)=\sum\pi_i p_{ij}(f_j-f_i)^2$ 的记号, 则 $D(f)=2(f,-Lf)_\pi$.

证明: 由详细平衡,

$$(f,Pg)_\pi=\sum_{i,j}\pi_i p_{ij}f_i g_j=\sum_{i,j}\pi_j p_{ji}f_i g_j=(Pf,g)_\pi,$$

故 P 及 $L=P-I$ 自伴随. 展开平方后,

$$\begin{aligned}\frac{1}{2}\sum_{i,j}\pi_i p_{ij}(f_j-f_i)^2&=\frac{1}{2}\sum_j f_j^2\underbrace{\sum_i\pi_i p_{ij}}_{\pi_j}+\frac{1}{2}\sum_i\pi_i f_i^2\underbrace{\sum_j p_{ij}}_{1}-\sum_{i,j}\pi_i p_{ij}f_i f_j\\&=\sum_i\pi_i f_i^2-(f,Pf)_\pi=(f,-Lf)_\pi.\end{aligned}$$

□

6.1.2 击中时间分布

命题 6.1.3 吸收链的击中时间

令 $\tau_A=\inf\{n\geqslant 0: X_n\in A\}$. 在计算首次击中之前, 可把 A 压成一个吸收态; 过程击中之后的运动已不影响 τ_A. 若 S 为补集上的次随机转移块, 初始分布 α 支撑在补集, 则

$$\mathbb{P}(\tau_A>n)=\alpha S^n\mathbf{1},\qquad \mathbb{P}(\tau_A=n)=\alpha S^{n-1}(I-S)\mathbf{1}\quad (n\geqslant 1).$$

求和得到 $\mathbb{E}\tau_A=\alpha(I-S)^{-1}\mathbf{1}$, 前提是吸收几乎必然且级数收敛. 在有限状态且所有补集状态均能到达 A 时该条件成立.

证明: 在补集 A^c 中连续停留 n 步的路径概率相加, 恰为 $\alpha S^n\mathbf{1}$. 首次在第 n 步进入 A 的概率等于两个尾概率之差, 故

$$\mathbb{P}(\tau_A=n)=\alpha S^{n-1}\mathbf{1}-\alpha S^n\mathbf{1}.$$

又由非负整数变量的尾和公式,

$$\mathbb{E}\tau_A=\sum_{n=0}^{\infty}\mathbb{P}(\tau_A>n)=\alpha\sum_{n=0}^{\infty}S^n\mathbf{1}.$$

有限状态下, 若每个状态均可达 A, 可取统一步数 s 和 $\varepsilon>0$, 使从任何补集状态出发在 s 步内击中 A 的概率至少为 ε. 于是尾概率按 $1-\varepsilon$ 几何衰减, 矩阵级数收敛; 由 $(I-S)\sum_{k=0}^{n}S^k=I-S^{n+1}$ 得其和为 $(I-S)^{-1}$. □

例题 6.1.4 击中时间的矩阵计算

例如

$$P=\begin{pmatrix}1/4 & 1/2 & 1/4 & 0\\ 1/3 & 0 & 1/3 & 1/3\\ 1/4 & 1/4 & 1/4 & 1/4\\ 0 & 1/3 & 1/3 & 1/3\end{pmatrix},\quad A=\{3,4\}$$

压缩后为 $\widetilde{P}=\left(\begin{smallmatrix}1/4 & 1/2 & 1/4\\ 1/3 & 0 & 2/3\\ 0 & 0 & 1\end{smallmatrix}\right)$, $q(n)=\mu_0(\widetilde{P}^{n}-\widetilde{P}^{n-1})e_3$. 逐状态平均击中时间也可由 $u_i=1+\sum_{j\notin A}p_{ij}u_j$, $u|_A=0$ 求得.

6.2 连续时间 Markov 链

6.2.1 Poisson 过程

定义 6.2.1 Poisson 过程

参数 $\lambda > 0$ 的 Poisson 过程 N_t 是从 0 出发, 路径右连续非减的整数值计数过程, 有独立平稳增量, 并满足短时间内一次事件的概率为 $\lambda h + o(h)$, 两次及以上为 $o(h)$.

命题 6.2.1 Poisson 计数分布

记 $p_m(t) = \mathbb{P}(N_t = m)$, 按最后一小段分类得到

$$p_0' = -\lambda p_0, \qquad p_m' = \lambda p_{m-1} - \lambda p_m,$$

初值 $p_0(0) = 1$, 于是 $p_m(t) = \mathrm{e}^{-\lambda t}(\lambda t)^m / m!$. 也可对生成函数求解 $\partial_t G = \lambda(z-1)G$.

证明: 增量独立且平稳, 故 $p_0(t+h) = p_0(t)p_0(h) = p_0(t)(1-\lambda h) + o(h)$. 移项除以 h 并令 $h \downarrow 0$ 得 $p_0' = -\lambda p_0$, 初值给出 $p_0(t) = \mathrm{e}^{-\lambda t}$. 当 $m \geqslant 1$ 时, 按最后 h 时间内增加的计数分解:

$$\begin{aligned} p_m(t+h) &= \sum_{j=0}^{m} p_{m-j}(t) p_j(h) \\ &= p_m(t)(1-\lambda h) + p_{m-1}(t)\lambda h + o(h). \end{aligned}$$

因此 $p_m' + \lambda p_m = \lambda p_{m-1}$. 乘以积分因子 $\mathrm{e}^{\lambda t}$, 归纳地有

$$\frac{\mathrm{d}}{\mathrm{d}t}(\mathrm{e}^{\lambda t} p_m(t)) = \lambda \mathrm{e}^{\lambda t} p_{m-1}(t) = \frac{\lambda^m t^{m-1}}{(m-1)!}.$$

从 0 积分到 t 并使用 $p_m(0) = 0$, 得到 $p_m(t) = \mathrm{e}^{-\lambda t}(\lambda t)^m / m!$. □

命题 6.2.2 指数等待时间

首次等待时间 H_1 满足 $\mathbb{P}(H_1 > t) = \mathbb{P}(N_t = 0) = \mathrm{e}^{-\lambda t}$. 独立增量及无记忆性保证后续等待时间独立同分布为 $\mathrm{Exp}(\lambda)$; 到达时刻 $T_n = \sum_{j=1}^{n} H_j$, $N_t = \max\{n : T_n \leqslant t\}$. 计数与等待时间是同一过程的两种描述.

6.2.2 Q-过程

定义 6.2.2 生成矩阵与 Q-过程

设从状态 i 跳到 $j\neq i$ 的速率为 $q_{ij}\geqslant 0$, 定义 $q_i=\sum_{j\neq i}q_{ij}$, $q_{ii}=-q_i$. 生成矩阵 Q 行和为零, 短时转移为 $P(h)=I+hQ+o(h)$. 半群关系导出

$$P'(t)=QP(t)=P(t)Q,\qquad P(0)=I,\qquad P(t)=\mathrm{e}^{tQ}$$

(有限状态). 分布行向量满足前向方程 $\nu'(t)=\nu(t)Q$; 对观测量 f, $u_{\mathrm{i}}(t)=\mathbb{E}_i f(X_t)$ 满足后向方程 $u'=Qu$.

证明: 原来的短时速率记号为 $p_{ii}(h)=1-\lambda_i h+o(h)$, $p_{ij}(h)=\lambda_{ij}h+o(h)$. 因此 $q_{ii}=-\lambda_i$, $q_{ij}=\lambda_{ij}$, 归一化给出 $\lambda_i=\sum_{j\neq i}\lambda_{ij}$.
插入中间时刻的状态, 由全概率公式与 Markov 性,

$$p_{ij}(t+s)=\sum_k p_{ik}(t)p_{kj}(s),\qquad P(t+s)=P(t)P(s).$$

所以

$$\frac{P(t+h)-P(t)}{h}=P(t)\frac{P(h)-I}{h}=\frac{P(h)-I}{h}P(t).$$

令 $h\downarrow 0$ 得前向和后向矩阵方程, 初值 $P(0)=I$ 给出 e^{tQ}. 分布的第 j 个分量满足

$$\nu_j(t+h)=\sum_{i\neq j}\nu_{\mathrm{i}}(t)q_{ij}h+\nu_j(t)(1+q_{jj}h)+o(h),$$

故 $\nu_j'(t)=\sum_i \nu_{\mathrm{i}}(t)q_{ij}$, 解为 $\nu(t)=\nu(0)\mathrm{e}^{tQ}$. 而 $u(t)=P(t)f$ 是列向量, 微分得到 $u'=Qu$. 两式作用对象不同, 因此一个将生成矩阵写在右侧, 一个写在左侧. □

命题 6.2.3 嵌入跳链与等待时间

在状态 i 的等待时间服从 $\mathrm{Exp}(q_i)$, 离开后去 j 的概率为 q_{ij}/q_i. 因此模拟步骤是先抽等待时间 $H=-\log U/q_i$, 再按这些概率抽新状态; $q_i=0$ 时为吸收态. 令 Y_n 为第 n 次跳后的状态, J_n 为跳时刻, 则 $X_t=Y_n$ 于 $J_n\leqslant t<J_{n+1}$. 嵌入链的转移矩阵是 $\widetilde{q}_{ij}=q_{ij}/q_i(j\neq i)$, 等待时间是在给定嵌入状态序列后按对应参数独立生成的, 一般并非无条件独立同分布.

证明: 令 $\mu_{\mathrm{i}}(t)=\mathbb{P}_{\mathrm{i}}(H_1>t)$. 尚未离开 i 时, 下个 h 内不跳的概率为 $1-q_ih+o(h)$, 故 $\mu_{\mathrm{i}}(t+h)=\mu_{\mathrm{i}}(t)(1-q_ih)+o(h)$. 于是 $\mu_i'=-q_{\mathrm{i}}\mu_i$, $\mu_{\mathrm{i}}(0)=1$, 解为 $\mathrm{e}^{-q_{\mathrm{i}}t}$. 首次在 θ 附近跳往 j 的联合密度为

$$p(\theta,j\mid 0,i)=\mathrm{e}^{-q_{\mathrm{i}}\theta}q_{ij}.$$

对 θ 积分得到 $\mathbb{P}_{\mathrm{i}}(Y_1=j)=q_{ij}/q_i$; 更进一步,

$$\mathrm{e}^{-q_{\mathrm{i}}\theta}q_{ij}=\left(q_i e^{-q_{\mathrm{i}}\theta}\right)\frac{q_{ij}}{q_i},$$

表明给定当前状态后, 等待时间与下一状态独立. 对每个跳时刻使用强 Markov 性, 便得到嵌入链与各段指数等待时间的递归构造. □

有限状态, 有限速率保证有限时间内不会发生无穷次跳跃. 可数状态则可能爆炸, 必须另外验证非爆炸性. 有限情形还可用均匀化: 取 $\Lambda\geqslant\max_i q_i$, 令 $R=I+Q/\Lambda$, 则

$$\mathrm{e}^{tQ}=\mathrm{e}^{-\Lambda t}\sum_{n\geqslant 0}\frac{(\Lambda t)^n}{n!}R^n.$$

这表示以 Poisson 时钟尝试跳转, 允许自环. 有限不可约 CTMC 有唯一 $\pi Q=0$, 其分布收敛不需另加离散链的非周期条件; 随机等待时间已消除了固定节拍.

定理 6.2.1 连续时间的收敛与遍历

有限不可约的生成矩阵 Q 有唯一不变分布 π, 满足 $\pi Q=0$, 且

$$p_{ij}(t)\longrightarrow\pi_j,\qquad \frac{1}{T}\int_0^T f(X_t)\,\mathrm{d}t\longrightarrow\sum_i\pi_i f(i)\quad\text{a.s.}.$$

证明: 在均匀化中取严格大于 $\max_i q_i$ 的 Λ, 则 $R=I+Q/\Lambda$ 不可约且对角元为正, 故为本原矩阵. 它有唯一不变分布 π, 而 $\pi R=\pi$ 等价于 $\pi Q=0$. 固定 $t>0$, 对任意 i,j, 不可约性给出某个 n 使 $(R^n)_{ij}>0$; 均匀化级数对应项严格正, 所以 $P(t)$ 所有元素均为正. 应用离散链收缩证明于任意固定时间间隔, 再用剩余时间的非扩张性, 得到 $P(t)$ 的收敛.
对遍历结论, 解 $-Qg=f-\pi f$; 可解性与离散情形相同. 跳过程的补偿恒等式给出平方可积鞅

$$M_t=g(X_t)-g(X_0)-\int_0^t Qg(X_s)\,\mathrm{d}s,$$

其二阶矩不超过 Ct, 因为有限状态下 $\sum_j q_{ij}(g(j)-g(i))^2$ 有统一上界. 用二进时刻的鞅最大不等式与 Borel–Cantelli, 得到 $M_t/t\to 0$ 几乎必然. 再由

$$\int_0^t(f(X_s)-\pi f)\,\mathrm{d}s=M_t-g(X_t)+g(X_0)$$

除以 t 即得结论. 补偿恒等式可直接从短时条件均值 $\mathbb{E}[g(X_{t+h})-g(X_t)\mid X_t]=hQg(X_t)+o(h)$ 积分得到, 后续章节将系统定义鞅. □

连续时间平均是 $T^{-1}\int_0^T f(X_t)\,\mathrm{d}t$. 只平均跳链访问状态会按离开速率偏置: 其平稳权重正比于 $\pi_i q_i$. 要恢复 CTMC 的 π, 必须计入各状态实际停留时长.

第七章　Metropolis 算法

7.1　引入

对 $\pi(x)=Z^{-1}\mathrm{e}^{-\beta H(x)}$, 配分函数 Z 通常不可计算. MCMC 构造以 π 为不变分布的 Markov 链, 用时间平均近似系综平均. 详细平衡保证不变性; 不可约性, 非周期性与混合速度决定收敛及采样效率.

7.2　Ising 模型

定义 7.2.1　Ising 模型

在格点上令自旋 $\sigma_i\in\{-1,1\}$, 能量为

$$H(\sigma)=-J\sum_{\langle i,j\rangle}\sigma_i\sigma_j-h\sum_i\sigma_i.$$

每条无向邻边只数一次, $J>0$ 为铁磁相互作用, h 是外场. 先以 M 表示格点总数, 定义

$$Z_M=\sum_\sigma \mathrm{e}^{-\beta H(\sigma)},\qquad F_M=-\beta^{-1}\log Z_M,\qquad f_M=F_M/M.$$

内部能量及单位格点能量为 $U_M=\langle H\rangle$, $u_M=U_M/M$. 对配分函数求导,

$$\partial_\beta Z_M=-\sum_\sigma H(\sigma)\mathrm{e}^{-\beta H(\sigma)},\qquad U_M=-\frac{\partial_\beta Z_M}{Z_M}=-\partial_\beta\log Z_M.$$

再次求导,

$$\partial_\beta U_M=-\frac{\sum_\sigma H(\sigma)^2\mathrm{e}^{-\beta H(\sigma)}}{Z_M}+\left(\frac{\sum_\sigma H(\sigma)\mathrm{e}^{-\beta H(\sigma)}}{Z_M}\right)^2=-\operatorname{Var}(H).$$

由 $\beta=(k_BT)^{-1}$ 有 $\mathrm{d}\beta/\mathrm{d}T=-k_B\beta^2$, 所以比热为

$$C_M=\frac{\partial U_M}{\partial T}=k_B\beta^2\operatorname{Var}(H)=k_B\beta^2\partial_\beta^2\log Z_M,\qquad c_M=C_M/M.$$

总磁化的系综平均及单位格点磁化为

$$G_M=\left\langle\sum_i\sigma_i\right\rangle,\qquad g_M=G_M/M.$$

由于 $\partial_h H = -\sum_i \sigma_i$, 对 Gibbs 平均的分子, 分母同时求导, 得到

$$\Phi_M = \frac{\partial G_M}{\partial h} = \beta \left[\left\langle \left(\sum_i \sigma_i \right)^2 \right\rangle - \left\langle \sum_i \sigma_i \right\rangle^2 \right], \qquad \phi_M = \Phi_M / M.$$

这里方差作用于随机配置的总磁化 $\sum_i \sigma_i$, 而非确定的均值 G_M.

二维无限方格, 零外场的临界温度满足 $k_B T_c = 2J/\log(1+\sqrt{2})$. 记先取热力学极限后的单位格点磁化为 $g(\beta, h)$, 则

$$\begin{cases} \lim\limits_{h\to 0^+} g(\beta,h) = \lim\limits_{h\to 0^-} g(\beta,h) = 0, & 0 < \beta < \beta_c, \\ \lim\limits_{h\to 0^+} g(\beta,h) = g(\beta,+) > 0, & \beta > \beta_c, \\ \lim\limits_{h\to 0^-} g(\beta,h) = g(\beta,-) = -g(\beta,+) < 0, & \beta > \beta_c. \end{cases}$$

后二式合称低温下的自发磁化. 有限系统在 $h = 0$ 时, 由配置 σ 与 $-\sigma$ 等权, 必有 $G_M = 0$; 所以取热力学极限与令 $h \to 0$ 的次序不可交换. 这些临界温度及磁化结论是二维 Ising 模型的精确结果, 此处用于说明采样对象, 不在本课程中证明.

7.3 Metropolis 算法

定义 7.3.1 Metropolis–Hastings 转移核

从当前状态 x 依建议核 $Q(x,y)$ 提议 y, 以概率

$$A(x,y) = \min\left\{1, \frac{\pi(y)Q(y,x)}{\pi(x)Q(x,y)}\right\} \tag{7.1}$$

接受, 否则留在 x. 目标密度为零的点按支撑处理; 若正向建议有概率而反向为零, 则该提议的接受率为零. 非对角转移是 $P(x,y) = Q(x,y)A(x,y)$, 对角项补足行和.

命题 7.3.1

Metropolis–Hastings 转移核保持目标分布 π.

证明: 该转移核满足关于 π 的详细平衡. 事实上,

$$\pi(x)P(x,y) = \min\{\pi(x)Q(x,y), \pi(y)Q(y,x)\} = \pi(y)P(y,x).$$

对 x 求和, 利用 $\sum_x P(y,x) = 1$, 得 $\sum_x \pi(x)P(x,y) = \pi(y)$, 即目标分布不变. □

拒绝步骤产生的自环是转移核的一部分, 不能把拒绝样本从时间序列中删去再当作原目标的等权样本. 对称建议下, Gibbs 分布的 Metropolis 接受率为 $\min(1, \mathrm{e}^{-\beta\Delta H})$. 降能量的提议总接受, 升能量的以

Boltzmann 因子接受. Glauber 接受率 $A(x,y)=1/(1+\mathrm{e}^{\beta\Delta H})$ 也满足详细平衡, 因为

$$\frac{A(x,y)}{A(y,x)}=\frac{1+\mathrm{e}^{-\beta\Delta H}}{1+\mathrm{e}^{\beta\Delta H}}=\mathrm{e}^{-\beta\Delta H}=\frac{\pi(y)}{\pi(x)}.$$

它与 Metropolis 核具有相同的不变分布, 但动力学和效率不同. 一次更新的完整步骤是: 依 Q 产生提议 y, 计算 $A(x,y)$, 独立生成 $r\sim U(0,1)$; 若 $r\leqslant A(x,y)$ 则取下一状态为 y, 否则仍为 x. 对角概率是 $P(x,x)=1-\sum_{y\neq x}Q(x,y)A(x,y)$.

在 $M\times M$ 自旋系统中共有 $N_t=2^{M^2}$ 个配置. 全局均匀建议在其他配置间以 $1/(N_t-1)$ 选取, 通常效率低. 单自旋建议只以 $1/M^2$ 选一个格点翻转, 能量差只涉及该点的邻居:

$$\Delta H=2\sigma_i\left(J\sum_{j\sim i}\sigma_j+h\right).$$

因为不含格点 i 的各项前后相消, 而每个含 σ_i 的项符号改变,

$$[-J(-\sigma_i)\sigma_j]-[-J\sigma_i\sigma_j]=2J\sigma_i\sigma_j,\qquad [-h(-\sigma_i)]-[-h\sigma_i]=2h\sigma_i.$$

因此一次更新无需重新计算全部能量. 有限温度下连接整个状态空间的翻转建议配合正接受率可保证不可约; 非周期性还需自环或其他奇数回路. 特别地 $\beta=0$ 时若每次必翻一颗自旋, 配置奇偶性每步改变, 链周期为 2. 可使用懒惰核 $(I+P)/2$ 消除这一问题.

命题 7.3.2 平稳样本均值的方差

设链已平稳, $Y_k=f(X_k)$, $\gamma_r=\mathrm{Cov}(Y_0,Y_r)$. 直接展开双重和得

$$\mathrm{Var}\left(\frac{1}{n}\sum_{k=0}^{n-1}Y_k\right)=\frac{1}{n}\left[\gamma_0+2\sum_{r=1}^{n-1}(1-r/n)\gamma_r\right].$$

若协方差绝对可和, 渐近方差为 $\sigma_{\mathrm{as}}^2=\gamma_0+2\sum_{r\geqslant 1}\gamma_r$, 积分自相关时间为 $\tau_{\mathrm{int}}=\sigma_{\mathrm{as}}^2/\gamma_0$, 对应有效样本数约 n/τ_{int}. 有限非周期不可约链的几何混合使这些级数良好, 并由 Chebyshev 得到 $C/(n\varepsilon^2)$ 型误差概率界. 实际可以用批均值或适当的自协方差截断估计标准误.

证明: 平稳性使 $\mathrm{Cov}(Y_i,Y_j)=\gamma_{|j-i|}$. 展开样本均值的方差, 主对角线上有 n 个 γ_0, 距离主对角线 r 的两条斜线上各有 $n-r$ 个 γ_r, 故

$$\mathrm{Var}\left(\frac{1}{n}\sum_{k=0}^{n-1}Y_k\right)=\frac{1}{n^2}\left[n\gamma_0+2\sum_{r=1}^{n-1}(n-r)\gamma_r\right].$$

若 $\sum_r|\gamma_r|<\infty$, 对级数用控制收敛, 得到 $n\,\mathrm{Var}(\bar{Y}_n)\to\sigma_{\mathrm{as}}^2$. 有限本原链有 $\|P^r f-\pi f\|_\infty\leqslant C\rho^r$, 所以 $|\gamma_r|\leqslant C'\rho^r$, Chebyshev 不等式给出 $C/(n\varepsilon^2)$ 界.

任意初始分布下也有相同数量级的弱大数界: 由上一章的 Poisson 方程分解,

$$\sum_{k=0}^{n-1}(f(X_k)-\pi f)=g(X_0)-g(X_n)+M_n,\qquad \mathbb{E}M_n^2\leqslant Cn.$$

因此 $\mathbb{E}|n^{-1}\sum f(X_k)-\pi f|^2\leqslant C_1/n+C_2/n^2$, 再次应用 Chebyshev 即得

$$\mathbb{P}\left(\left|\frac{1}{n}\sum_{k=0}^{n-1}f(X_k)-\pi f\right|>\varepsilon\right)\leqslant\frac{C}{n\varepsilon^2}.$$

□

评注　初始化与混合　非平稳初值会引入初始化偏差, 可通过多个起点和预热样本检查其影响. 接受率本身不能反映跨模态混合速度.

第八章　多层次采样与动力学蒙特卡罗

8.1　Swendsen–Wang 算法

对零外场, 铁磁 $J \geqslant 0$ 的 Ising 模型, 单点翻转在临界附近会很慢. 集群算法引入辅助边变量, 把许多同向自旋作为一个整体更新. 引入辅助变量 u_{ij}, 构造联合密度

$$\Pi(x,u) \propto \prod_{\langle i,j\rangle} \mathbf{1}_{0\leqslant u_{ij}\leqslant \mathrm{e}^{\beta J(1+x_i x_j)}}.$$

对 u 积分得到 $\prod \mathrm{e}^{\beta J(1+x_i x_j)}$, 与 Ising 权重只差配置无关的常数, 因此 x 的边缘正是目标分布. 给定 x, 各 u_{ij} 在相应区间独立均匀; 若 $u_{ij} > 1$, 则必须有 $x_i = x_j$. 同向自旋间形成这种约束边的概率是

$$p_b = 1 - \mathrm{e}^{-2\beta J},$$

异向自旋间没有约束边. 给定边后, 每个连通簇内部自旋必须相同, 不同簇的符号可以独立等概率选取. 算法因此为: 对同向邻边以 p_b 连边; 找连通簇; 对各簇独立以 $1/2$ 选正负号.

正确性可直接从条件密度验证. 若当前 x 的边缘为 $\pi(x)$, 先抽 $u \mid x$ 后, 联合密度为 $\pi(x)\Pi(u \mid x) = \Pi(x,u)$; 再抽 $x' \mid u$ 后,

$$\int \Pi(x,u)\Pi(x' \mid u)\,\mathrm{d}x = \Pi(u)\Pi(x' \mid u) = \Pi(x',u).$$

因此两个条件更新保持联合分布, 投影后保持 Ising 分布. 连边概率的计算是

$$\mathbb{P}(u_{ij} > 1 \mid x_i = x_j) = \frac{\mathrm{e}^{2\beta J} - 1}{\mathrm{e}^{2\beta J}} = 1 - \mathrm{e}^{-2\beta J}.$$

若 $x_i \neq x_j$, 则 $u_{ij} \leqslant 1$, 不能连边. 给定 u 后, 联合密度在所有满足连边约束的配置上为同一常数, 因此每个簇独立等概率选正负号. 外场非零, 反铁磁或其他相互作用需要修改构造, 不能直接照搬此公式.

8.2　Wolff 的改进

Wolff 每次只生长并翻转一个簇: 随机选种子, 沿同向邻边以 p_b 加入邻居, 递归扩展, 最后把整个簇翻转. 实现时应检查每条可能的连接边; 某个点通过一条边未被加入, 不代表通过另一条边也不能加入.

命题 8.2.1

Wolff 簇翻转满足详细平衡, 且接受概率为 1.

证明: 设簇边界上有 m 条与外部同向的邻边, n 条异向邻边. 翻转前后目标概率比为 $\mathrm{e}^{2\beta J(n-m)}$. 要使该簇停止生长, 边界上同向边都必须未连接, 概率带有 $(1-p_b)^m = \mathrm{e}^{-2\beta Jm}$. 反向构造对应 $(1-p_b)^n$, 所以反向与正向建议之比为 $\mathrm{e}^{2\beta J(m-n)}$. 两者相乘为 1, 式 (7.1) 的接受率即为 1. □

8.3 模拟调温

定义 8.3.1 模拟调温的扩展分布

给定温度 $T_1 < \cdots < T_L$, 扩展状态为 (x, i), 目标为

$$\pi_{\mathrm{st}}(x, i) \propto \pi_i \mathrm{e}^{-U(x)/T_i}.$$

固定 i 时的条件分布是相应温度 Gibbs 分布; 温度层边缘概率正比于 $\pi_i Z_i$. 理想伪先验 $\pi_i \propto 1/Z_i$ 使各层访问均匀, 但 Z_i 往往未知, 需要预估或有理论控制的适应阶段.

一种保持目标的混合核是: 以概率 α_0 固定层 i, 使用保持该层条件分布的 MCMC 核更新 x; 否则固定 x, 按 $\alpha(i, j)$ 提议温度层 j, 接受率为

$$\min\left\{1, \frac{\pi_j \mathrm{e}^{-U(x)/T_j}\alpha(j, i)}{\pi_i \mathrm{e}^{-U(x)/T_i}\alpha(i, j)}\right\}.$$

常用建议为 $\alpha(i, i \pm 1) = 1/2 (2 \leqslant i \leqslant L-1)$, $\alpha(1, 2) = \alpha(L, L-1) = 1$. 它在端点 "强制向内" 时, 正反建议概率可能不同, 必须保留 $\alpha(j, i)/\alpha(i, j)$. 高温让系统跨越低温能垒, 再回到目标低温; 估计 T_1 下期望时, 应使用该层样本或正确重加权.

模拟烧结 (simulated sintering) 等扩展策略, 其共同思想是引入有助于跨越障碍的附加层或模型参数; 若层间状态维数改变, 则还须补充可逆跳跃所需的维数匹配与 Jacobian, 不能直接用同维交换公式.

8.4 并行调温

命题 8.4.1 并行调温的交换概率

同时保留各温度的配置 $x_1, \cdots, x_L$, 联合目标为 $\prod_i Z_i^{-1}\mathrm{e}^{-\beta_i U(x_i)}$. 各层独立进行自己的 MCMC 更新后, 可提议交换相邻层配置 x_i, x_j, 以

$$A_{ij} = \min\{1, \exp[(\beta_i - \beta_j)(U(x_i) - U(x_j))]\}$$

接受. 只交换配置而非温度标签时, 此式直接由交换前后的联合密度比得到, 所有 Z_i 抵消.

证明: 交换只改变两个因子, 故对称交换建议的目标比为

$$\frac{\pi_{\mathrm{i}}(x_j)\pi_j(x_i)}{\pi_{\mathrm{i}}(x_i)\pi_j(x_j)} = \frac{\mathrm{e}^{-\beta_i U(x_j) - \beta_j U(x_i)}}{\mathrm{e}^{-\beta_i U(x_i) - \beta_j U(x_j)}}$$

$$= \exp\{(\beta_i - \beta_j)(U(x_i) - U(x_j))\}.$$

使用 Metropolis 接受率即满足详细平衡. 实际可取混合更新: 以概率 α_0 同时执行各层自己的 MCMC 核, 否则随机选一对邻层并尝试交换. 前一核保持乘积分布, 后一核也保持它, 所以混合核同样保持它. □

温度间隔太大使交换几乎总拒绝, 太小则层数和成本增加. 粗略原则是让典型的 $|\Delta\beta\Delta U|$ 不过大; 若希望某类不利交换接受率约为 p_a, 可参考 $|\Delta\beta\Delta U| \approx -\log p_a$. 这只是设计尺度, 不能代替能量分布重叠和往返时间的实际检查.

8.5 动力学蒙特卡罗

低温单自旋 Metropolis 常发生大量拒绝. Bortz–Kalos–Lebowitz(BKL, 亦称 n-fold way) 把可发生的事件直接按速率抽取, 并同时推进随机时间. 二维方格可按自旋 ±1 和四个邻居中向上个数 $k = 0, \cdots, 4$ 分成十类; 类 j 的格点数为 n_j, 翻转接受因子为 P_j, 基本尝试时间为 τ.

若每个格点以速率 $1/\tau$ 尝试更新, 则当前总实际翻转率为 Q_{10}/τ, 其中 $Q_j = \sum_{r\leqslant j} n_r P_r$. 生成 $R \sim U(0, Q_{10})$, 找到 $Q_{j-1} < R \leqslant Q_j$, 在该类等概率选一个格点翻转; 独立生成

$$\Delta t = -\frac{\tau \log U}{Q_{10}}.$$

其时间公式可由无事件概率推导. 令 $S(t)$ 表示从当前配置起 t 时间内没有翻转的概率; 在尚未翻转条件下总速率保持 Q_{10}/τ, 所以

$$S(t+h) = S(t)\left(1 - \frac{Q_{10}}{\tau}h\right) + o(h), \qquad S'(t) = -\frac{Q_{10}}{\tau}S(t), \quad S(0) = 1.$$

解得 $S(t) = \exp(-Q_{10}t/\tau)$, 逆变换即得到 Δt. 每个指定的第 j 类格点被选中的概率为

$$\frac{n_j P_j}{Q_{10}}\frac{1}{n_j} = \frac{P_j}{Q_{10}},$$

乘以总事件速率 Q_{10}/τ, 恰为所需的单点速率 P_j/τ. 这同时验证事件类型和时间间隔均正确.

随后只需更新该点及邻居所属类别. 若 $Q_{10} = 0$, 系统已经吸收. 这个算法精确模拟速率 $q(\sigma, \sigma^{(i)}) = P_{j(i)}/\tau$ 的 CTMC; 若基本时钟定义为 “整个系统一次尝试”, 时间尺度需相应换算.

它与被 Poisson 时钟驱动的拒绝式动力学相对应, 不能把删掉拒绝后的离散步号直接叫物理时间. 平衡观测应按 $\sum_n f(X_n)\Delta t_n / \sum_n \Delta t_n$ 加权. 至于这段时间是否代表真实材料动力学, 还取决于事件速率模型是否有物理依据; 满足详细平衡只固定平衡分布, 并不唯一固定动力学.

第九章　模拟退火与拟蒙特卡罗

9.1　模拟退火

例题 9.1.1　旅行商问题

旅行商问题把路线写作排列 x, 代价为 $H(x)=\sum_i l_{x_i,x_{i+1}}$, 末点接回起点. 固定出发点, 把反向路线视为同一路线的无向问题有 $(N-1)!/2$ 条不同路线; 若不固定起点或把不同表示也计数, 会多出相应因子. 交换城市或反转一段路径可构造局部建议.

例题 9.1.2　图像恢复

在图像恢复中, 设像素 $x_s\in\{0,\cdots,255\}$, 观测 y_s, 能量

$$H(x)=\alpha\sum_{\langle s,t\rangle}(x_s-x_t)^2+\frac{1}{2\sigma^2}\sum_s(x_s-y_s)^2.$$

第一项促使相邻像素平滑, 第二项贴合观测. 离散约束使组合搜索复杂; 若去掉整数约束, 这个特定二次模型是凸二次优化, 可用线性代数求解, 因此不能泛称所有此类图像模型都必须退火.

9.1.1　基本框架

命题 9.1.1　Gibbs 分布的零温极限

有限状态集 $\mathcal{X}$ 上令 $\Pi_\beta(x)=\mathrm{e}^{-\beta H(x)}/Z_\beta$, 极小值集合为 $\mathcal{M}$. 把分子分母同时除以 $\mathrm{e}^{-\beta H_{\min}}$, 得到 $\beta\to\infty$ 时

$$\Pi_\beta(x)\to\frac{\mathbf{1}_{x\in\mathcal{M}}}{|\mathcal{M}|}.$$

证明:　记 $m=\min_x H(x)$, $\delta_x=H(x)-m\geqslant 0$. 则

$$\Pi_\beta(x)=\frac{\mathrm{e}^{-\beta\delta_x}}{|\mathcal{M}|+\sum_{z\notin\mathcal{M}}\mathrm{e}^{-\beta\delta_z}}.$$

当 $\beta\to\infty$, 分母趋于 $|\mathcal{M}|$, 分子在极小点为 1, 其余趋于零, 因而得到极限. 若 $x\in\mathcal{M}$, 分子固定, 分母随 β 不增, 所以权重不减; 能量非恒定时严格增加.

一般点的导数为

$$\begin{aligned}\partial_\beta \Pi_\beta(x) &= \frac{-H(x)\mathrm{e}^{-\beta H(x)} Z_\beta - \mathrm{e}^{-\beta H(x)} Z'_\beta}{Z_\beta^2} \\ &= \Pi_\beta(x)\left(\sum_z H(z)\Pi_\beta(z) - H(x)\right).\end{aligned}$$

有限状态下可对上述极限求和, 得 $\mathbb{E}_{\Pi_\beta} H \to m$. 若 $x \notin \mathcal{M}$, 最终 $\mathbb{E}_{\Pi_\beta} H < H(x)$, 所以该点权重最终严格减少. 这证明了原结论中的最终单调性. □

算法在第 n 步使用逆温度 $\beta(n)$ 的 Metropolis 核. 这里既要 $\beta(n) \to \infty$ 以集中于最优解, 又不能升得太快, 以免提前冻结在局部极小值. 固定逆温度的平衡极限与改变逆温度的链的极限, 是下面需要连接的两个问题.

9.1.2 理论结果

定理 9.1.1 对数降温的充分条件

设 G 为有限连通建议图, τ 为其最大最短路径长度, Δ 为最大相邻能量增量. 对称, 连通且具有自环的固定建议核满足以下充分条件: 当 $\Delta > 0$ 时, 取

$$\beta(n) = \frac{\log(n + n_0)}{c}, \qquad c > \tau\Delta, \quad n_0 \geqslant 1,$$

则有限状态退火链可收敛到极小值集合上的极限平衡分布. 该界可能远慢于问题所需的实际最优降温; 更精确的理论使用能垒深度. 具体记号为 $N(x) = \{y \neq x : G(x,y) > 0\}$, $\sigma(x,y)$ 是从 x 到 y 的最短邻接路径长度, $\tau = \max_{x,y} \sigma(x,y)$, $\Delta = \max_{x \in \mathcal{X},\, y \in N(x)} [H(y) - H(x)]$; 最后一个最大值中的 x 遍历全部状态, y 遍历它的邻居.

证明: 写 $P_n = P^{\beta(n)}$, $\pi_n = \Pi_{\beta(n)}$. 其非对角元为

$$P_n(x,y) = G(x,y)\min\{1, \mathrm{e}^{-\beta(n)[H(y)-H(x)]}\},$$

对角元补足行和. 详细平衡给出 $\pi_n P_n = \pi_n$.
由于建议图有限, 连通且各点具有自环, 可取 $g_* > 0$, 使所有正的建议概率及自环概率至少为 g_*. 任意两点之间的路径长至多 τ, 较短的路径用自环补足为 τ 步. 每一步上升能量不超过 Δ, 且 β 不减, 故任何从第 $n+1$ 步开始的块核 $B_n = P_{n+1} \cdots P_{n+\tau}$ 都满足

$$B_n(x,y) \geqslant g_*^\tau \mathrm{e}^{-\tau\Delta\beta(n+\tau)}.$$

固定一个目标状态 y_0, 将每一行共同的 $\varepsilon_n \delta_{y_0}$ 部分提出, 其中可取 $\varepsilon_n = C(n+\tau+n_0)^{-a}$, $a = \tau\Delta/c < 1$, $0 < C < 1$. 于是对任意两个分布

$$\|\mu B_n - \nu B_n\|_1 \leqslant (1 - \varepsilon_n)\|\mu - \nu\|_1.$$

沿互不重叠的块, $\sum_k \varepsilon_{k\tau}=\infty$, 所以

$$\prod_{k=k_0}^{K}(1-\varepsilon_{k\tau}) \leqslant \exp\left(-\sum_{k=k_0}^{K}\varepsilon_{k\tau}\right) \longrightarrow 0.$$

因此从任意固定时刻出发, 不同初始分布经同一后续核序列演化后, 其距离趋于零. 这就是此处所需的弱遍历性.

还要证明演化跟随移动的不变分布. 上一命题说明每个坐标 $\pi_n(x)$ 最终单调, 因此有限状态下

$$\sum_{n=1}^{\infty}\|\pi_n-\pi_{n-1}\|_1<\infty.$$

令 $\mu_n=\mu_0P_1\cdots P_n$, 由 $\pi_nP_n=\pi_n$, 逐步展开得

$$\mu_n-\pi_n=(\mu_0-\pi_0)P_1\cdots P_n+\sum_{j=1}^{n}(\pi_{j-1}-\pi_j)P_j\cdots P_n.$$

第一项由弱遍历性趋于零. 对和式, 先固定 J: 前 J 项都是总质量为零的固定向量, 可写为等质量的两个概率向量之差, 故逐项趋于零; 其余项的范数至多 $\sum_{j>J}\|\pi_{j-1}-\pi_j\|_1$, 可随 $J\to\infty$ 任意小. 因此 $\|\mu_n-\pi_n\|_1\to 0$. 结合 $\pi_n\to\Pi_\infty=|\mathcal{M}|^{-1}\mathbf{1}_{\mathcal{M}}$, 即得所述收敛. □

评注　降温条件　仅有上界 $\beta(n)\leqslant \log n/(\tau\Delta)$ 不足以推出最优解收敛: 常数逆温度也满足大 n 的上界, 却不向零温极限集中. 还需要求逆温度趋于无穷, 并说明日程单调性和链的遍历条件. 若 $\Delta=0$, 连通图上能量恒定, 不需要退火. 对数日程 $\beta(n)=\log(n+n_0)/c$ 意味着达到逆温度 B 约需 $n\approx \mathrm{e}^{cB}$ 步, 理论保证的代价可能极高. 实际也常采用几何降温 $T_n=T_0r^n(0<r<1)$, 即逆温度几何增长; 其速度更快, 但不满足这里的充分条件.

9.2　拟蒙特卡罗方法

拟蒙特卡罗 (QMC) 使用确定性, 空间覆盖较均匀的点来近似积分. 这里误差控制来自点集的几何均匀性, 而非独立抽样的方差公式.

9.2.1　差异度

定义 9.2.1　差异度

对 $[0,1)^d$ 中的点 $x_1,\cdots,x_N$ 和矩形 B, 定义

$$R_N(B)=\frac{1}{N}\sum_{i=1}^{N}\mathbf{1}_{x_i\in B}-|B|.$$

令 $\mathcal{E}$ 为全部轴平行半开矩形, $\mathcal{E}^*$ 为从原点出发的矩形 $[0,t)$. 极大差异度及星差异度为

$$D_N=\sup_{B\in\mathcal{E}}|R_N(B)|,\qquad D_N^*=\sup_{B\in\mathcal{E}^*}|R_N(B)|.$$

对矩形参数积分还可定义 L^2 型量 T_N,T_N^*, 它们衡量平均偏离而非最坏偏离. 通过将一般矩形写为至多 2^d 个原点矩形指标的带符号组合, 得到 $D_N^*\leqslant D_N\leqslant 2^dD_N^*$. 精确定义为

$$T_N=\left[\int_{0\leqslant x\leqslant y\leqslant\mathbf{1}}R_N([x,y))^2\,\mathrm{d}x\,\mathrm{d}y\right]^{1/2},\qquad T_N^*=\left[\int_{[0,1]^d}R_N([0,y))^2\,\mathrm{d}y\right]^{1/2}.$$

坐标间的不等式逐分量理解; 把平方换成 p 次幂并取 p 次根即定义相应 L^p 差异度.

9.2.2 全变差

定义 9.2.2 Hardy–Krause 变差

一维 Jordan 变差为 $V[f]=\sup_{\mathcal{P}}\sum_j|f(t_j)-f(t_{j-1})|$; 若 f 绝对连续, 则等于 $\int_0^1|f'(x)|\,\mathrm{d}x$. 高维 Koksma–Hlawka 不等式需要 Hardy–Krause 变差. 对充分光滑 f, 以 1 为锚点可写为

$$V_{\mathrm{HK}}(f)=\sum_{\varnothing\neq u\subseteq\{1,\cdots,d\}}\int_{[0,1]^{|u|}}\left|\frac{\partial^{|u|}f}{\prod_{j\in u}\partial x_j}(x_u,\mathbf{1}_{-u})\right|\mathrm{d}x_u.$$

它同时包含内部混合导数和所有相应边界面的贡献. 非光滑函数可用分割上的矩形交错增量定义多维变差. 逐个非空坐标子集相加能避免递归写法重复计数低维面.

定理 9.2.1 Koksma–Hlawka

若 $V_{\mathrm{HK}}(f)<\infty$, 则

$$\left|\frac{1}{N}\sum_{i=1}^{N}f(x_i)-\int_{[0,1]^d}f(x)\,\mathrm{d}x\right|\leqslant V_{\mathrm{HK}}(f)D_N^*.$$

证明: 先对光滑函数给出完整计算. 令带符号测度

$$\nu_N=\frac{1}{N}\sum_{i=1}^{N}\delta_{x_i}-\mathrm{d}x,\qquad R(t)=\nu_N([0,t)),\qquad \nu_N([0,1]^d)=0.$$

一维时由 $f(x)=f(1)-\int_x^1 f'(t)\,\mathrm{d}t$ 和 Fubini 定理,

$$\int f(x)\nu_N(\mathrm{d}x)=-\int_0^1 R(t)f'(t)\,\mathrm{d}t.$$

故绝对值不超过 $D_N^*\int|f'|$.

二维时, 将微积分基本定理分别用于两个坐标, 有

$$f(x_1,x_2)=f(1,1)-\int_{x_1}^{1}f_1(t,1)\,\mathrm{d}t-\int_{x_2}^{1}f_2(1,s)\,\mathrm{d}s+\int_{x_1}^{1}\int_{x_2}^{1}f_{12}(t,s)\,\mathrm{d}s\,\mathrm{d}t.$$

常数项对 ν_N 积分为零, 其他项分别产生 $R(t,1)$, $R(1,s)$, $R(t,s)$. 因此误差不超过

$$D_N^*\left(\int_0^1|f_1(t,1)|\,\mathrm{d}t+\int_0^1|f_2(1,s)|\,\mathrm{d}s+\int_{[0,1]^2}|f_{12}|\right).$$

一般维数重复同一操作, 得到

$$\int f\,\mathrm{d}\nu_N=\sum_{\varnothing\neq u\subseteq\{1,\cdots,d\}}(-1)^{|u|}\int R(t_u,\mathbf{1}_{-u})\,\partial^u f(t_u,\mathbf{1}_{-u})\,\mathrm{d}t_u.$$

每个 R 的绝对值均不超过 D_N^*, 逐项取绝对值得到 $D_N^*V_{\mathrm{HK}}(f)$. 这也解释了为何必须计入边界面上的变差, 而不能只保留最高阶混合导数. 若 f 在相应边界面为零, 则这些面上的项消失, 退化为原讲义中的内部积分证明. 有限 Hardy–Krause 变差情形用对应的 Stieltjes 变差测度代替混合导数, 积分估计仍成立; 矩形端点按同一单侧约定处理. □

9.2.3 拟蒙特卡罗积分

若点列满足 $D_N\leqslant C(\log N)^k/N$, 其中 C,k 可依赖维数而不依赖 N, 则称为低差异点列. 对有限变差函数, 前述不等式随即给出同样数量级的确定性积分误差.

例题 9.2.1 van der Corput 与 Halton 序列

对整数 $n=\sum_{j\geqslant0}a_jb^j$, 定义根反演函数 $\phi_b(n)=\sum_{j\geqslant0}a_jb^{-j-1}$. 二进制 van der Corput 序列从 $n=1$ 开始为 $1/2,1/4,3/4,1/8,5/8,3/8,7/8,\cdots$; 它把低位数字移到小数点后, 逐层填充空隙. Halton 序列在第 j 个坐标使用不同素数底 p_j: $x_n=(\phi_{p_1}(n),\cdots,\phi_{p_d}(n))$. 适当低差异序列具有 $D_N^*=O((\log N)^d/N)$ 的固定维数界. Sobol 序列和 Faure 序列也是常用的数字构造.

9.2.4 QMC 的局限

维数相关常数和 $(\log N)^d$ 可能很大; 函数不光滑或变换到单位立方体后出现奇异性时, V_{HK} 也可能无穷. 有效维数小, 重要坐标排在前面和适当变量变换可以改善表现. 低差异点不等于独立随机数, 不能未经论证直接替代动力学中独立噪声. 随机化 QMC 可以保留均匀边缘并用独立随机化重复估计误差, 但其收益仍依赖结构.

第十章　随机游走与布朗运动

10.1　一维随机游走

定义 10.1.1　对称简单随机游走

令 ξ_j 独立, 以相同概率取 ± 1, $X_N = \sum_{j=1}^{N} \xi_j$. 每条长度 N 的路径概率为 2^{-N}, $\mathbb{E}X_N = 0$, $\operatorname{Var}(X_N) = N$. 位置的标准差按 $\sqrt{N}$ 而非 N 增长, 这是扩散尺度.

10.1.1　终点分布

命题 10.1.1　终点分布与扩散极限

到达 m 需要 $(N+m)/2$ 次向右步, 因此

$$W(m,N) = \mathbb{P}(X_N = m) = 2^{-N}\binom{N}{(N+m)/2},$$

仅在 $|m| \leqslant N$ 且 $N+m$ 偶数时非零. Stirling 公式 $n! \sim \sqrt{2\pi n}(n/e)^n$ 代入并在 $m = O(\sqrt{N})$ 的中心尺度展开, 得到局部 Gaussian 近似

$$W(m,N) \sim \sqrt{\frac{2}{\pi N}}\,\mathrm{e}^{-m^2/(2N)}.$$

令物理步长 l, 时间间隔 τ, 取 $x = ml$, $t = N\tau$, 并保持 $l^2/(2\tau) = D$. 固定时刻只能到达一种奇偶格点, 相邻可达位置间距为 $2l$, 所以概率密度应由 $W/(2l)$ 得到:

$$W(x,t) = \frac{1}{\sqrt{4\pi D t}}\,\mathrm{e}^{-x^2/(4Dt)}, \qquad \partial_t W = D\,\partial_{xx} W. \tag{10.1}$$

此处格点间距为 $2l$, 相应归一化因子不可省略. 标准布朗运动对应 $D = 1/2$.

证明: 记 $r = m/N$, $a = (N+m)/2$, $b = (N-m)/2$. 由 $W = 2^{-N} N!/(a!b!)$ 及带余项的 Stirling 公式,

$$\begin{aligned}\log W(m,N) = {}& \frac{1}{2}\log\frac{2}{\pi N} - \frac{1}{2}\log(1-r^2) \\ & - \frac{N}{2}\big[(1+r)\log(1+r) + (1-r)\log(1-r)\big] + O(N^{-1}).\end{aligned}$$

这里余项在 $|r| \leqslant 1/2$ 时一致. 括号内的奇数次项抵消, 且

$$(1+r)\log(1+r)+(1-r)\log(1-r) = r^2 + \frac{r^4}{6} + O(r^6).$$

因此在 $m = O(\sqrt{N})$ 的尺度下, $r = O(N^{-1/2})$, $Nr^4 = O(N^{-1})$, 从而

$$\log W(m,N) = \frac{1}{2}\log\frac{2}{\pi N} - \frac{m^2}{2N} + o(1).$$

指数化即得局部 Gaussian 近似. 仅有 $m/N \to 0$ 并不足以在所有范围内忽略 m^4/N^3; 这里的扩散尺度正好保证了该余项趋零.

若 $\Delta x \gg l$, 区间 $[x-\Delta x/2, x+\Delta x/2]$ 中约有 $\Delta x/(2l)$ 个可达格点, 故

$$W(x,t)\Delta x \approx W(m,N)\frac{\Delta x}{2l}.$$

使用 $Nl^2 = 2Dt$, 得

$$\frac{1}{2l}\sqrt{\frac{2}{\pi N}} = \frac{1}{\sqrt{4\pi Dt}}, \qquad \frac{m^2}{2N} = \frac{x^2}{4Dt}.$$

这证明密度的归一化和指数都与连续公式一致. 最后直接微分,

$$\partial_t W = \left(-\frac{1}{2t} + \frac{x^2}{4Dt^2}\right)W, \qquad D\partial_{xx}W = \left(-\frac{1}{2t} + \frac{x^2}{4Dt^2}\right)W,$$

故满足热方程. 其初始条件在分布意义下为 $W(x,0) = \delta(x)$. □

一般 d 维无漂移过程的扩散系数定义为 $D = \lim_{t\to\infty} \mathbb{E}|X_t - X_0|^2/(2dt)$, 若该极限存在; 有恒定漂移时应先减去平均位移. 离散单位步长, 单位时间的对称一维游走有 $\mathbb{E}X_N^2 = N$, 故 $D = 1/2$.

10.1.2 反射边界与吸收边界

命题 10.1.2 镜像法

在右侧 $m_1 > 0$ 设边界. 把首次到达边界后的路径镜像反射, 可在 “曾越过边界且最终到达 m” 与 “最终到达镜像点 $2m_1 - m$” 之间建立保概率对应. 因此内部点的镜像表达为

$$W_r(m,N;m_1) = W(m,N) + W(2m_1-m,N), \quad W_a(m,N;m_1) = W(m,N) - W(2m_1-m,N).$$

反射模型在边界处的离散跳转规则需明确; 边界格点不能把同一个镜像点重复计数. 连续极限在 $x < x_1$ 为

$$W_{r/a}(x,t;x_1) = \frac{\mathrm{e}^{-x^2/(4Dt)} \;\pm\; \mathrm{e}^{-(2x_1-x)^2/(4Dt)}}{\sqrt{4\pi Dt}}.$$

加号满足 $\partial_x W_r(x_1,t) = 0$, 表示无净流出; 减号满足 $W_a(x_1,t) = 0$, 存活总质量随时间减少.

证明: 固定内部终点 $m<m_1$. 对曾到达 m_1 的自由路径, 令 τ 为首次到达时刻, 把 τ 后的所有增量取反, 得到终点 $2m_1-m$ 的路径. 镜像操作两次回到原路径, 且每条自由路径概率同为 2^{-N}, 所以这是双射并保持概率. 吸收情况下, 存活路径等于全部终点为 m 的路径减去已触边路径, 得到 W_a.
反射模型规定从边界 m_1 下一步必到 m_1-1. 把自由路径用映射 $z\mapsto m_1-|z-m_1|$ 折叠, 正好得到这一反射链. 在内部点 m 有两个原像 $m, 2m_1-m$, 故对应概率相加; 在边界只有一个原像, 不能加倍. 连续极限中的边界单点没有概率质量, 内部的加号公式即确定反射密度.
设 $G(x,t)=(4\pi Dt)^{-1/2}\mathrm{e}^{-x^2/(4Dt)}$, 则 $W_r=G(x,t)+G(2x_1-x,t)$, 在 $x=x_1$ 处两个空间导数符号相反并抵消; $W_a=G(x,t)-G(2x_1-x,t)$ 在边界的两项相等而抵消. 故分别得到 Neumann 与 Dirichlet 条件. □

命题 10.1.3 首次击中时间的密度

首次击中边界的概率, 按最后一步之前位于 m_1-1 分解, 得

$$a(m_1,N)=\tfrac{1}{2}W_a(m_1-1,N-1;m_1)=\frac{m_1}{N}W(m_1,N).$$

仍须满足奇偶条件. 连续极限的击中时间密度为

$$a(x_1,t)=\frac{x_1}{\sqrt{4\pi D}\,t^{3/2}}\mathrm{e}^{-x_1^2/(4Dt)}=-D\partial_x W_a(x_1,t;x_1).$$

最后一式也可从存活概率 $S(t)=\int_{-\infty}^{x_1}W_a(x,t)\,\mathrm{d}x$ 积分热方程得到: $-S'(t)$ 等于边界流出通量. 此密度积分为 1, 但尾部按 $t^{-3/2}$ 衰减, 所以平均击中时间无穷. 几乎必然到达与平均等待有限并不是一回事.

证明: 首次在第 N 步触边, 要求前 $N-1$ 步尚未触边且位于 m_1-1, 最后向右一步的概率为 $1/2$. 镜像公式给出

$$a(m_1,N)=\frac{1}{2}\{W(m_1-1,N-1)-W(m_1+1,N-1)\}.$$

记 $r=(N+m_1)/2$. 两个二项系数分别是 $\binom{N-1}{r-1}$ 与 $\binom{N-1}{r}$, 故

$$\begin{aligned}a(m_1,N)&=2^{-N}\left[\frac{r}{N}-\frac{N-r}{N}\right]\binom{N}{r}\\&=\frac{2r-N}{N}\,2^{-N}\binom{N}{r}=\frac{m_1}{N}W(m_1,N).\end{aligned}$$

击中时刻也只有一种奇偶性, 时间格距为 2τ, 所以连续密度是 $a(m_1,N)/(2\tau)$. 代入 $W(m_1,N)\sim 2lW(x_1,t)$ 及 $m_1/N=x_1\tau/(lt)$, 得到

$$a(x_1,t)=\frac{x_1}{t}W(x_1,t).$$

又由 $\partial_x W_a(x_1,t;x_1)=-(x_1/(Dt))W(x_1,t)$, 得到通量形式. 对 $S(t)$ 积分热方程, 远端导数消失, 故

$S'(t) = D\partial_x W_a(x_1, t; x_1) = -a(x_1, t).$ □

10.2 反正弦定律与重对数律

仍以 S_n 表示对称随机游走. 令 $u_{2k} = \mathbb{P}(S_{2k} = 0) = \binom{2k}{k}/4^k$, $u_0 = 1$; f_{2k} 为首次回到零发生于 $2k$ 的概率. 反射计数给出

$$f_{2k} = \frac{u_{2k-2}}{2k} = u_{2k-2} - u_{2k}, \qquad u_{2k} = \sum_{r=1}^{k} f_{2r} u_{2k-2r}.$$

第二式按第一次返回的时刻分解: 返回后的增量与过去独立, 重新从零开始. 在限定观察窗内, 将首次返回记为 $\sigma_{2n} = \min\{1 \leqslant j \leqslant 2n : S_j = 0\}$; 若没有返回则定义为 $+\infty$, 因此 $f_{2k} = \mathbb{P}(\sigma_{2n} = 2k)(k \leqslant n)$.

首次返回公式也可由上一节的击中公式得到. 若第一步向右, 其概率为 $1/2$, 从 1 首次到达 0 还需 $2k-1$ 步; 第一步向左同理, 故

$$f_{2k} = 2 \cdot \frac{1}{2} \cdot \frac{1}{2k-1} W(1, 2k-1) = \frac{1}{2k} \frac{\binom{2k-2}{k-1}}{4^{k-1}} = \frac{u_{2k-2}}{2k}.$$

又 $u_{2k}/u_{2k-2} = (2k-1)/(2k)$, 所以 $f_{2k} = u_{2k-2} - u_{2k}$. 对于返回分解, 事件 $\{S_{2k} = 0\}$ 按首次返回时间 $2r$ 不交分解; 在该时刻后的增量与前 $2r$ 步独立, 故条件返回概率为 $u_{2(k-r)}$, 于是得到上述卷积恒等式.

定理 10.2.1 离散反正弦定律

在每个时间段 $[j-1, j]$ 中, 只要 S_{j-1}, S_j 至少一个为正, 就把该段记为 "正侧"; 这个约定排除了在零点的计数歧义. 记前 $2n$ 步中正侧时间为 $\gamma(2n)$, $P_{2k,2n} = \mathbb{P}(\gamma(2n) = 2k)$. 则

$$P_{2k,2n} = u_{2k} u_{2n-2k}, \qquad 0 \leqslant k \leqslant n. \tag{10.2}$$

证明: 先证明边界情形, 而不把路径计数留作引用. 始终不为负, 终点为 $2j$ 的路径数等于全部终点为 $2j$ 的路径数减去曾到达 -1 的路径数. 反射原理将后一类双射到终点 $2j+2$ 的路径, 故数目为

$$\binom{2n}{n+j} - \binom{2n}{n+j+1}, \qquad 0 \leqslant j \leqslant n.$$

对 j 求和, 差分相消得到 $\binom{2n}{n}$; 除以 2^{2n}, 始终在非负侧的概率为 u_{2n}. 此事件对应 $\gamma(2n) = 2n$, 反射对称性给出 $\gamma(2n) = 0$ 的概率也为 u_{2n}. 因此 $k = 0, n$ 的公式成立. 对 $0 < k < n$, 按首次完整正游程或负游程的长度 $2r$ 分解, 有

$$P_{2k,2n} = \frac{1}{2} \sum_{r=1}^{k} f_{2r} P_{2(k-r),2(n-r)} + \frac{1}{2} \sum_{r=1}^{n-k} f_{2r} P_{2k,2(n-r)}.$$

对总步数 $2n$ 作归纳. 两个和中的总步数 $2(n-r)$ 都小于 $2n$, 所以均可使用归纳假设, 而不必固定同

一个 k. 具体地,

$$P_{2(k-r),2(n-r)} = u_{2(k-r)}u_{2(n-k)},$$
$$P_{2k,2(n-r)} = u_{2k}u_{2(n-k-r)}.$$

代回并使用首次返回分解, 得到

$$\begin{aligned} P_{2k,2n} &= \frac{1}{2}u_{2(n-k)}\sum_{r=1}^{k} f_{2r}u_{2(k-r)} + \frac{1}{2}u_{2k}\sum_{r=1}^{n-k} f_{2r}u_{2(n-k-r)} \\ &= \frac{1}{2}u_{2(n-k)}u_{2k} + \frac{1}{2}u_{2k}u_{2(n-k)} = u_{2k}u_{2(n-k)}. \end{aligned}$$

这证明式 (10.2). 第二个求和上限必须为 $n-k$, 因为负游程不能超过总负侧时间. □

推论 10.2.1 正侧占时的极限分布

由 $u_{2k} \sim 1/\sqrt{\pi k}$, 中间区域的求和转成 Riemann 积分, 端点附近的质量由 $k^{-1/2}$ 可积控制, 得到

$$\mathbb{P}\left(\frac{\gamma(2n)}{2n} \leqslant x\right) \longrightarrow \frac{2}{\pi}\arcsin\sqrt{x}, \qquad 0 \leqslant x \leqslant 1.$$

极限密度 $1/[\pi\sqrt{x(1-x)}]$ 在两端很大. 这说明即使左右完全对称, 一条长路径也常在一侧逗留很久; 对称性并不强迫单条路径的正负占时各一半.

证明: 固定 $0 < a < b < 1$, Stirling 公式在 $an \leqslant k \leqslant bn$ 上一致给出

$$u_{2k}u_{2(n-k)} = \frac{1+o(1)}{\pi\sqrt{k(n-k)}} = \frac{1+o(1)}{\pi n\sqrt{(k/n)(1-k/n)}}.$$

求和即成为 Riemann 和, 极限为 $\pi^{-1}\int_a^b [t(1-t)]^{-1/2}\,\mathrm{d}t$. 端点附近由 $u_{2k} \leqslant C/\sqrt{k+1}$ 得

$$\sum_{0\leqslant k\leqslant \delta n} u_{2k}u_{2(n-k)} \leqslant \frac{C}{\sqrt{n}}\sum_{k\leqslant\delta n}\frac{1}{\sqrt{k+1}} \leqslant C'\sqrt{\delta} + O(n^{-1/2}).$$

另一端由对称性同样控制. 先对固定 δ 取 $n\to\infty$, 再令 $\delta\downarrow 0$, 便可将积分延至端点. 最后用 $t = \sin^2\theta$,

$$\frac{1}{\pi}\int_0^x \frac{\mathrm{d}t}{\sqrt{t(1-t)}} = \frac{2}{\pi}\int_0^{\arcsin\sqrt{x}} \mathrm{d}\theta = \frac{2}{\pi}\arcsin\sqrt{x}.$$

□

定理 10.2.2 重对数律

对均值零, 方差 $\sigma^2 \in (0,\infty)$ 的独立同分布增量,

$$\overline{\lim_{n\to\infty}} \frac{S_n}{\sqrt{2\sigma^2 n \log\log n}} = 1, \qquad \underline{\lim_{n\to\infty}} \frac{S_n}{\sqrt{2\sigma^2 n \log\log n}} = -1 \quad \text{a.s..}$$

这是比大数定律和 CLT 更细的路径定理, 完整证明需要精细尾估计与 Borel–Cantelli, 在此陈述使用. 它刻画一条无限路径最终仍会反复触及的涨落包络, 不能用固定时刻的 CLT 直接代替证明.

10.3 Gaussian 位移的随机飞行

一般独立步向量 $r_i \in \mathbb{R}^3$ 的密度记为 $\tau_1(r_i)$, 总位移 $R = \sum_{i=1}^N r_i$ 的密度记为 W_N. 利用独立性,

$$\begin{aligned}\widehat{W}_N(\rho) &= \int_{\mathbb{R}^3} W_N(R) \mathrm{e}^{i\rho\cdot R}\,\mathrm{d}R = \mathbb{E}\exp\left(i\rho\cdot\sum_{i=1}^N r_i\right)\\ &= \prod_{i=1}^N \mathbb{E}\mathrm{e}^{i\rho\cdot r_i} = \prod_{i=1}^N \int_{\mathbb{R}^3} \tau_1(r)\mathrm{e}^{i\rho\cdot r}\,\mathrm{d}r.\end{aligned}$$

对 $r_i \overset{\text{i.i.d.}}{\sim} N(0, l^2 I_3)$, 每个因子是 $\mathrm{e}^{-l^2|\rho|^2/2}$, 所以乘积为 $\mathrm{e}^{-Nl^2|\rho|^2/2}$. Fourier 反演得到

$$W_N(R) = \frac{1}{(2\pi N l^2)^{3/2}} \mathrm{e}^{-|R|^2/(2Nl^2)}, \qquad \mathbb{E}|R|^2 = 3Nl^2.$$

取 $l^2/(2\tau) = D$, 得到

$$W(x,t) = \frac{1}{(4\pi D t)^{3/2}} \mathrm{e}^{-|x|^2/(4Dt)}, \qquad \partial_t W = D\Delta W.$$

一般维数把 $3/2$ 换成 $d/2$. 半空间的平面反射和吸收仍可用镜像; 一般几何区域则由相应 Neumann 或 Dirichlet 热方程刻画, 未必存在简单镜像公式.

10.4 Einstein 的布朗运动理论

若一个短时间 τ 内的位移密度为 $\phi_\tau(\Delta)$, 独立增量使

$$\psi(x, t+\tau) = \int \psi(x-\Delta, t)\phi_\tau(\Delta)\,\mathrm{d}\Delta.$$

对时间, 空间分别展开,

$$\begin{aligned}\psi(x,t+\tau) &= \psi(x,t) + \tau\partial_t\psi(x,t) + o(\tau),\\ \psi(x-\Delta,t) &= \psi(x,t) - \Delta\partial_x\psi(x,t) + \frac{\Delta^2}{2}\partial_{xx}\psi(x,t) + r(x,t,\Delta).\end{aligned}$$

代入积分式, 使用 $\int \phi_\tau = 1$, 对称性给出的 $\int \Delta \phi_\tau = 0$, 消去两侧的 $\psi(x,t)$, 得

$$\tau \partial_t \psi = \frac{1}{2} \partial_{xx} \psi \int \Delta^2 \phi_\tau(\Delta)\,\mathrm{d}\Delta + \int r(x,t,\Delta)\phi_\tau(\Delta)\,\mathrm{d}\Delta + o(\tau).$$

若 $\mathbb{E}\Delta^2 = 2D\tau + o(\tau)$, 且余项期望为 $o(\tau)$, 除以 τ 并取极限便得到 $\partial_t \psi = D \partial_{xx} \psi$. 例如三阶空间导数有界且 $\mathbb{E}|\Delta|^3 = o(\tau)$ 时, Taylor 余项满足此要求. 非零平均 $\mathbb{E}\Delta = b\tau + o(\tau)$ 产生漂移项, 非均匀系数进一步导向 Fokker–Planck 方程. 推导的实质是短时间条件矩的尺度, 而不是形式上把所有高阶项删除.

第十一章　随机过程与布朗运动

11.1　随机过程的公理化构造

无限抛硬币的样本空间为 $\Omega=\{H,T\}^{\mathbb{N}}$. 单个 ω 指定全部未来结果, 每个固定无限序列的概率为零, 但整个空间的概率为一. 不能把不可数个零概率直接用 “可数可加性” 相加.

只限制有限个坐标的集合称柱集. 例如前 m 次结果落在某个集合 $C_m\subset\{H,T\}^m$ 的概率为 $2^{-m}|C_m|$. 这些规则在不同长度间相容, 因为忽略一个新坐标时, 其两个可能值的概率相加为一. 柱集生成的代数上可定义有限可加概率; 若递减的一串非空柱集永远相容, 可通过逐坐标选子列或紧致性得到共同的无限序列. 因此该构造满足延拓所需的连续性, 继而延拓到生成的 σ-代数.

引理 11.1.1　递减非空柱集的交

在 $\Omega=\{H,T\}^{\mathbb{N}}$ 中, 若 A_n 是非空柱集且 $A_{n+1}\subset A_n$, 则 $\bigcap_n A_n\neq\varnothing$.

证明: 写 $A_n=\{\omega:(\omega_1,\cdots,\omega_{m_n})\in C_n\}$, 从每个 A_n 中选一条序列 $\omega^{(n)}$. 因为第一坐标只有两个可能值, 可以选无限子列使第一坐标固定; 再从该子列中选无限子列使第二坐标固定, 依此进行. 取对角子列 $\omega^{(n_k)}$, 使 $n_k\geqslant k$ 且对每个固定 r, 其前 r 个坐标从 $k\geqslant r$ 起均不变. 记稳定的坐标为 u_r, 得到 $u=(u_1,u_2,\cdots)$.

固定 n, 取 $k\geqslant\max(n,m_n)$. 由递减性, $\omega^{(n_k)}\in A_{n_k}\subset A_n$; 它的前 m_n 个坐标与 u 相同, 而 A_n 只由这些坐标决定, 因此 $u\in A_n$. 对所有 n 均成立, 故交集非空. □

因此, 若柱集列 $A_n\downarrow\varnothing$, 必有某个 A_n 已为空, 故 $\mathbb{P}(A_n)\downarrow 0$. 有限可加概率在空集处的这种连续性等价于代数上的可数可加性: 对不交集合 B_k 且 $B=\bigcup_k B_k$ 仍在代数中, 余集 $B\setminus\bigcup_{k=1}^{n}B_k\downarrow\varnothing$, 有限可加性取极限即得可数可加性. 测度延拓定理因而可应用.

定义 11.1.1　随机过程, 样本路径与柱集

随机过程是同一概率空间上的一族随机变量 $\{X_t:t\in T\}$. 固定 t 得到随机变量 $\omega\mapsto X_t(\omega)$, 固定 ω 得到样本路径 $t\mapsto X_t(\omega)$. 若另有联合可测性, 则可将它作为 $\Omega\times T$ 上的可测函数. 在典范空间 $\mathbb{R}^T$ 上, 坐标过程为 $X_t(\omega)=\omega(t)$, 柱集形如

$$C=\{\omega:(\omega(t_1),\cdots,\omega(t_k))\in A\},\qquad A\in\mathcal{B}(\mathbb{R}^k).$$

其概率由有限维分布 $\mu_{t_1,\cdots,t_k}$ 决定.

定理 11.1.1 Kolmogorov 延拓定理, 实值过程版本

给每组有限时刻 $t_1,\cdots,t_n$ 指定概率分布, 若这些分布在置换坐标时相应置换, 删除坐标时得到相应边缘分布, 具体地, 对任意置换 σ,

$$\mu_{t_{\sigma(1)},\cdots,t_{\sigma(k)}}(F_1\times\cdots\times F_k)=\mu_{t_1,\cdots,t_k}(F_{\sigma^{-1}(1)}\times\cdots\times F_{\sigma^{-1}(k)}),$$

且增加任意时刻后有边缘相容性

$$\mu_{t_1,\cdots,t_k}(F_1\times\cdots\times F_k)=\mu_{t_1,\cdots,t_{k+m}}(F_1\times\cdots\times F_k\times\mathbb{R}^m).$$

则在乘积空间 $\mathbb{R}^T$ 的柱 σ-代数上存在概率测度, 使坐标过程 $X_t(\omega)=\omega(t)$ 具有这些有限维分布.

因此, 可以通过相容的有限维分布构造随机过程. 但它本身不保证样本路径连续, 也不自动保证 $(t,\omega)\mapsto X_t(\omega)$ 联合可测. 逐个 t 的随机变量可测, 与整条路径的正则性是不同层次的问题.

11.2 滤过

定义 11.2.1 滤过与适应过程

滤过 $(\mathcal{F}_t)$ 是递增的 σ-代数族: $s\leqslant t$ 时 $\mathcal{F}_s\subseteq\mathcal{F}_t$. 若每个 X_t 对 $\mathcal{F}_t$ 可测, 称过程**适应**于此滤过. 自然滤过为 $\mathcal{F}_t^X=\sigma(X_s:s\leqslant t)$.

在抛硬币例子中, $\mathcal{F}_n$ 的原子是长度 n 的 2^n 种前缀, 每个可测事件是若干原子的并, 所以 $\mathcal{F}_n$ 含 2^{2^n} 个事件. 因此, 该 σ-代数只记录前 n 次试验的信息.

若每个 $\mathcal{F}_t$ 都包含 $\mathcal{F}$ 中所有零概率事件的子集, 且 $\mathcal{F}_t=\bigcap_{s>t}\mathcal{F}_s$, 则称滤过满足**通常条件**. 下文随机微积分中的滤过均满足通常条件. 相对于 $(\mathcal{F}_t)$ 的布朗运动不仅要求增量相互独立, 还要求 W_t-W_s 与整个 $\mathcal{F}_s$ 独立; 若把未来信息提前放进滤过, 这一点会失败.

定义 11.2.2 鞅与次鞅

过程 M_t 若适应, $\mathbb{E}|M_t|<\infty$ 且 $\mathbb{E}(M_t\mid\mathcal{F}_s)=M_s(s\leqslant t)$, 称为**鞅**. 若将等式改为 $\mathbb{E}(M_t\mid\mathcal{F}_s)\geqslant M_s$, 则称为**次鞅**; 反向不等式定义**上鞅** (亦称超鞅).

例题 11.2.1 基本鞅

独立中心增量的部分和为鞅; 标准布朗运动 W_t 和 W_t^2-t 也是鞅, 因为

$$\mathbb{E}(W_t^2\mid\mathcal{F}_s)=W_s^2+\mathbb{E}(W_t-W_s)^2=W_s^2+t-s.$$

若 ϕ 凸且 $\phi(M_t)$ 可积, 则条件 Jensen 不等式给出 $\mathbb{E}(\phi(M_t)\mid\mathcal{F}_s)\geqslant\phi(M_s)$, 故 $\phi(M_t)$ 是次鞅. 例如 $|M_t|$ 是次鞅; 平方可积时 $|M_t|^2$ 也是次鞅.

定理 11.2.1 Doob 最大不等式

设 M 为连续平方可积鞅, 则

$$\mathbb{E}\sup_{s\leqslant T}|M_s|^2 \leqslant 4\mathbb{E}|M_T|^2. \tag{11.1}$$

证明: 先考虑有限离散时间, 记 $M^* = \max_{s\leqslant T}|M_s|$. 按首次越过阈值 λ 的时刻分解事件, 并利用 $|M|$ 的次鞅性质, 得到

$$\lambda\mathbb{P}(M^* \geqslant \lambda) \leqslant \mathbb{E}\left[|M_T|\mathbf{1}_{M^*\geqslant\lambda}\right].$$

对 $\lambda \in [0, L]$ 积分, 由 Tonelli 定理及 Cauchy–Schwarz 不等式,

$$\begin{aligned}\mathbb{E}(M^*\wedge L)^2 &\leqslant 2\mathbb{E}\left[|M_T|(M^*\wedge L)\right]\\ &\leqslant 2(\mathbb{E}|M_T|^2)^{1/2}\left(\mathbb{E}(M^*\wedge L)^2\right)^{1/2}.\end{aligned}$$

故 $\mathbb{E}(M^*\wedge L)^2 \leqslant 4\mathbb{E}|M_T|^2$, 令 $L\to\infty$ 即得离散情形. 连续时间对逐渐加密的有限网格应用此式, 再由路径连续性和单调收敛定理取极限. □

定义 11.2.3 停止时

随机时间 $\tau:\Omega\to[0,\infty]$ 若满足 $\{\tau\leqslant t\}\in\mathcal{F}_t$, 称为**停止时**. 记

$$\mathcal{F}_\tau = \{A\in\mathcal{F} : A\cap\{\tau\leqslant t\}\in\mathcal{F}_t,\ \forall t\geqslant 0\}.$$

$\mathcal{F}_\tau$ 描述停止时 τ 之前可获得的信息. 条件 $\{\tau\leqslant t\}\in\mathcal{F}_t$ 表示到时刻 t 就能判断是否已经停止. 连续适应过程首次离开开集的时刻是典型例子; “到最终时刻为止的最后一次峰值时刻” 一般需要未来信息, 不是停止时.

定义 11.2.4 一致可积性与局部鞅

随机变量族 $\{Y_\alpha\}$ 称为**一致可积**, 如果

$$\lim_{K\to\infty}\sup_{\alpha}\mathbb{E}\left[|Y_\alpha|\mathbf{1}_{|Y_\alpha|>K}\right] = 0.$$

例如 $\sup_\alpha\mathbb{E}|Y_\alpha|^2<\infty$ 蕴含一致可积, 因为上式期望不超过 $K^{-1}\mathbb{E}|Y_\alpha|^2$. 若连续适应过程 M 存在停止时列 $\tau_n\uparrow\infty$ 几乎必然, 使每个停止过程 $M_{t\wedge\tau_n}$ 都是鞅, 则称 M 为**局部鞅**. 局部鞅不一定是真鞅; 一致可积性可用于将停止过程的条件期望关系传递到极限.

定理 11.2.2 可选停止定理

设 M 为右连续鞅, $\sigma \leqslant \tau$ 为有界停止时, 则 $\mathbb{E}(M_\tau \mid \mathcal{F}_\sigma) = M_\sigma$, 从而 $\mathbb{E}M_\tau = \mathbb{E}M_0$. 若 M 一致可积, 结论可推广到几乎必然有限的停止时.

证明: 先设停止时只取有限个确定时刻. 鞅增量可写成在尚未停止时才保留的增量:

$$M_\tau - M_\sigma = \sum_k \mathbf{1}_{\sigma \leqslant t_k < \tau}(M_{t_{k+1}} - M_{t_k}).$$

对任意 $A \in \mathcal{F}_\sigma$, $A \cap \{\sigma \leqslant t_k < \tau\} \in \mathcal{F}_{t_k}$, 因此每项乘 $\mathbf{1}_A$ 后期望为零. 这正是条件期望等式.
一般有界停止时以向上取整的二进停止时 σ_n, τ_n 逼近, 右连续性给出 $M_{\sigma_n} \to M_\sigma$, $M_{\tau_n} \to M_\tau$. 取一个统一上界 T, 这些离散停止值均可表示为 $\mathbb{E}(M_T \mid \mathcal{F}_{\tau_n})$; 一个可积变量的全部条件期望构成一致可积族, 故上述收敛在 L^1 中成立. 对 $A \in \mathcal{F}_\sigma \subset \mathcal{F}_{\sigma_n}$ 取极限, 即得结论. 若停止时无界而鞅一致可积, 则先对 $\sigma \wedge n, \tau \wedge n$ 应用有界情形, 再以一致可积性取极限. □

评注 布朗运动首次到达 1 的时刻几乎必然有限, 但 $W_\tau = 1$, 不能由 $\mathbb{E}W_t = 0$ 错推 $\mathbb{E}W_\tau = 0$. 停止近似 $\tau \wedge n$ 的极限未必允许交换期望.

定理 11.2.3 强 Markov 性

设 W 为标准布朗运动. 在几乎必然有限的停止时 τ 后, $W_{\tau+t} - W_\tau$ 是独立于 $\mathcal{F}_\tau$ 的新布朗运动.

证明: 设停止时 τ 只取有限个值 t_j. 对 $A \in \mathcal{F}_\tau$, 有界连续函数 $F : \mathbb{R}^m \to \mathbb{R}$ 及 $0 < s_1 < \cdots < s_m$, 独立平稳增量给出

$$\begin{aligned}
&\mathbb{E}\left[\mathbf{1}_A F(W_{\tau+s_1} - W_\tau, \cdots, W_{\tau+s_m} - W_\tau)\right] \\
&= \sum_j \mathbb{E}\left[\mathbf{1}_{A \cap \{\tau = t_j\}} F(W_{t_j+s_1} - W_{t_j}, \cdots, W_{t_j+s_m} - W_{t_j})\right] \\
&= \sum_j \mathbb{P}(A \cap \{\tau = t_j\}) \mathbb{E}F(W_{s_1}, \cdots, W_{s_m}) \\
&= \mathbb{P}(A)\mathbb{E}F(W_{s_1}, \cdots, W_{s_m}).
\end{aligned}$$

因 $A \cap \{\tau = t_j\} \in \mathcal{F}_{t_j}$, 第二个等号合法. 可数取值时由绝对可和继续成立. 对一般几乎必然有限的停止时, 取 $\tau_n = 2^{-n}\lceil 2^n \tau \rceil \downarrow \tau$, 则 $A \in \mathcal{F}_\tau \subset \mathcal{F}_{\tau_n}$, 可对 τ_n 使用上式. 由路径连续性和 F 有界, 控制收敛给出同一恒等式的极限. 它同时证明了所有有限维分布与原布朗运动相同, 并与 $\mathcal{F}_\tau$ 独立; 路径连续性由原路径继承. □

11.3 Gaussian 过程

定义 11.3.1 Gaussian 过程

若任意有限组 $(X_{t_1},\cdots,X_{t_n})$ 都联合服从 Gaussian 分布, 称 X_t 为 **Gaussian 过程**. 它由均值 $m(t)=\mathbb{E}X_t$ 和协方差核 $K(s,t)=\mathbb{E}[(X_s-m(s))(X_t-m(t))]$ 完全确定.

K 对称且非负定, 因为 $\sum_{i,j}c_ic_jK(t_i,t_j)=\operatorname{Var}(\sum_i c_iX_{t_i})\geqslant 0$. 反过来, 任何这样的核配合均值函数都定义相容的有限维 Gaussian 分布, 从而由延拓定理构造过程. 对联合 Gaussian 向量, 不相关的两组分量独立, 这由其特征函数分解证明; 不能把这一性质推广到任意分布.

命题 11.3.1 Gaussian 过程的协方差算子

假设 X 联合可测且 $\mathbb{E}\int_0^T X_t^2\,\mathrm{d}t<\infty$, 则它可视为 $L^2[0,T]$ 值随机元素. 其均值 $m\in L^2[0,T]$, 协方差算子

$$(Kf)(s)=\int_0^T K(s,t)f(t)\,\mathrm{d}t$$

是紧, 自伴, 非负算子, 并且对 $\xi\in L^2[0,T]$,

$$\mathbb{E}\mathrm{e}^{\mathrm{i}(\xi,X)}=\exp\{\mathrm{i}(\xi,m)-\tfrac12(\xi,K\xi)\}.$$

证明: 先由 Jensen 和 Tonelli 得

$$\int_0^T m(t)^2\,\mathrm{d}t\leqslant\int_0^T\mathbb{E}X_t^2\,\mathrm{d}t<\infty.$$

令 $Y_t=X_t-m(t)$. 对期望应用 Cauchy–Schwarz,

$$\begin{aligned}\int_0^T\int_0^T|K(s,t)|^2\,\mathrm{d}s\,\mathrm{d}t&=\int_0^T\int_0^T|\mathbb{E}(Y_sY_t)|^2\,\mathrm{d}s\,\mathrm{d}t\\&\leqslant\int_0^T\int_0^T\mathbb{E}Y_s^2\mathbb{E}Y_t^2\,\mathrm{d}s\,\mathrm{d}t=\left(\int_0^T\operatorname{Var}(X_t)\,\mathrm{d}t\right)^2<\infty.\end{aligned}$$

因此 K 是平方可积核. 用有限和核 $K_n(s,t)=\sum_{j=1}^{r_n}a_j(s)b_j(t)$ 在 $L^2([0,T]^2)$ 中逼近 K, 对应算子 K_n 有限秩, 而

$$\|(K-K_n)f\|_2^2\leqslant\|K-K_n\|_{L^2([0,T]^2)}^2\|f\|_2^2.$$

所以 K 是有限秩算子的算子范数极限, 因而紧. 对称性和 Fubini 给出 $(Kf,g)=(f,Kg)$; 并且

$$(Kf,f)=\int_0^T\int_0^T\mathbb{E}(Y_sY_t)f(s)f(t)\,\mathrm{d}s\,\mathrm{d}t$$

$$= \mathbb{E}\left(\int_0^T Y_t f(t)\,\mathrm{d}t\right)^2 \geqslant 0.$$

上述交换均由二阶可积性和 Cauchy–Schwarz 保证.
积分 $\int \xi(t)X_t\,\mathrm{d}t$ 属于有限线性组合 $\sum_j a_j X_{t_j}$ 在 $L^2(\Omega)$ 中的闭包. 可把 $t \mapsto \xi(t)X_t$ 作为 $L^2(\Omega)$ 值可积函数, 用简单函数积分逼近; 必要时先截断 ξ 和 $\|X_t\|_{L^2(\Omega)}$. 有限线性组合为 Gaussian, 而其 L^2 极限仍为 Gaussian. 其均值为 (ξ, m), 方差为 $(\xi, K\xi)$, 故得到特征泛函公式. 所用闭包性质由下一个命题证明. □

命题 11.3.2 Gaussian 分布的闭包性质

若 Gaussian 随机变量 X_n 依概率收敛于有限随机变量 X, 则 X 也服从 Gaussian 分布, 允许方差为零. 相同结论适用于有限维 Gaussian 向量.

证明: 写 $X_n \sim N(m_n, \sigma_n^2)$. 依概率收敛推出分布族紧, 所以可取 R 使 $\mathbb{P}(|X_n| \leqslant R) \geqslant 3/4$ 对所有 n 成立. 若 $\sigma_n \to \infty$ 沿某子列成立, 由正态密度上界得

$$\mathbb{P}(|X_n| \leqslant R) \leqslant \frac{2R}{\sqrt{2\pi}\sigma_n} \longrightarrow 0,$$

矛盾. 因此 σ_n 有界. 若 $|m_n| \to \infty$, 则当 $|m_n| > R$ 时 Chebyshev 不等式给出

$$\mathbb{P}(|X_n| \leqslant R) \leqslant \mathbb{P}(|X_n - m_n| \geqslant |m_n| - R) \leqslant \frac{\sigma_n^2}{(|m_n| - R)^2} \longrightarrow 0,$$

再次矛盾. 因此两组参数都相对紧. 取任意收敛参数子列 $m_{n_k} \to m$, $\sigma_{n_k}^2 \to \sigma^2$, 其特征函数满足

$$\mathbb{E}\mathrm{e}^{\mathrm{i}\xi X_{n_k}} = \mathrm{e}^{\mathrm{i}\xi m_{n_k} - \sigma_{n_k}^2 \xi^2/2} \longrightarrow \mathrm{e}^{\mathrm{i}\xi m - \sigma^2\xi^2/2}.$$

另一方面, 依概率收敛及复指数有界给出 $\mathbb{E}\mathrm{e}^{\mathrm{i}\xi X_{n_k}} \to \mathbb{E}\mathrm{e}^{\mathrm{i}\xi X}$, 故 $X \sim N(m, \sigma^2)$. 正态分布唯一确定均值与方差, 因此所有参数聚点一致, 整个参数序列也收敛. 向量情形对每个线性组合应用一维结论, 即得联合 Gaussian 性. □

11.4 Wiener 过程

定义 11.4.1 Wiener 过程

标准 Wiener 过程, 亦称标准布朗运动, 是满足 $W_0 = 0$, 路径连续, 独立增量和 $W_t - W_s \sim N(0, t-s)$ 的过程. 等价地, 它是均值零, 协方差 $K(s,t) = \min(s,t)$ 的连续 Gaussian 过程. 后一描述中,

$$\operatorname{Cov}(W_t - W_s, W_v - W_u) = 0 \qquad (s \leqslant t \leqslant u \leqslant v)$$

保证不相交增量独立. 它有平稳增量, 却不是平稳过程, 因为 $\operatorname{Var}(W_t) = t$.

两个定义的等价性: 若增量独立且服从所给 Gaussian 分布, 则任意有限组 W_{t_j} 是独立 Gaussian 增量的线性变换, 所以联合 Gaussian. 对 $s \leqslant t$,

$$\mathbb{E}W_sW_t = \mathbb{E}[W_s(W_s + W_t - W_s)] = \mathbb{E}W_s^2 + \mathbb{E}W_s\mathbb{E}(W_t - W_s) = s.$$

反过来, 假设过程是中心 Gaussian, 协方差为 $s \wedge t$. 则

$$\mathrm{Var}(W_t - W_s) = t + s - 2s = t - s,$$

而对 $s \leqslant t \leqslant u \leqslant v$,

$$\mathrm{Cov}(W_t - W_s, W_v - W_u) = t - t - s + s = 0.$$

任意有限组不相交增量仍联合 Gaussian, 协方差矩阵为对角形, 所以特征函数分解为各分量特征函数之积, 即相互独立. $\mathrm{Var}(W_0) = 0$ 给出 $W_0 = 0$ 几乎必然, 两种描述因而等价. □

命题 11.4.1 Wiener 过程的有限维密度

其转移密度为 $(2\pi(t-s))^{-1/2}\exp[-(x-y)^2/(2(t-s))]$. 对 $0 = t_0 < t_1 < \cdots < t_n$, 联合密度是

$$Z_n^{-1}\mathrm{e}^{-I_n(w)}, \qquad I_n(w) = \frac{1}{2}\sum_{j=1}^{n}\frac{(w_j - w_{j-1})^2}{t_j - t_{j-1}}, \quad Z_n = (2\pi)^{n/2}\prod_j\sqrt{t_j - t_{j-1}}, \quad w_0 = 0.$$

多维标准布朗运动由独立的一维分量组成, 协方差为 $(s \wedge t)I_d$.

证明: 令 $z_j = w_j - w_{j-1}$. 从增量向量 $(z_1, \cdots, z_n)$ 到位置向量 $(w_1, \cdots, w_n)$ 的变换矩阵是下三角且对角为 1, Jacobian 为 1. 因此独立增量的密度相乘直接得到

$$p_n(w_1, \cdots, w_n) = \prod_{j=1}^{n}\frac{1}{\sqrt{2\pi(t_j - t_{j-1})}}\exp\left[-\frac{(w_j - w_{j-1})^2}{2(t_j - t_{j-1})}\right].$$

将常数和指数分别合并, 便得到 Z_n 与 I_n. 条件于 $W_s = y$, 未来增量独立于过去, 故

$$\mathbb{P}(W_t \in B \mid \mathcal{F}_s) = \int_B p(x, t \mid W_s, s)\,\mathrm{d}x, \qquad p(x, t \mid y, s) = \frac{\mathrm{e}^{-(x-y)^2/[2(t-s)]}}{\sqrt{2\pi(t-s)}}.$$

这同时验证 Markov 性, 时间齐次性及 $\partial_t p = \frac{1}{2}\partial_{xx}p$. 这里时间齐次指核只依赖时间差, 不能据此把 W 称为平稳过程. □

评注 修正与不可区分 Kolmogorov 延拓先在所有函数构成的乘积空间上给出坐标过程. 柱 σ-代数中的事件只依赖至多可数个坐标, 连续性却限制不可数时刻; "所有连续路径" 在这个大空间里并不由有限维构造直接保证可测. 需要连续修正定理, 或直接在连续函数空间构造概率测度.

两个过程是修正, 指每个固定 t 有 $\mathbb{P}(X_t = Y_t) = 1$; 不可区分则要求 $\mathbb{P}(X_t = Y_t \text{ 对全部} t) = 1$. 不可数个概率一事件的交不自动仍概率一; 若二者都有连续路径, 则先在可数有理时刻同时相等, 再用连续性, 可提升为不可区分.

命题 11.4.2 柱 σ-代数不能直接识别全部连续路径

在 $\Omega = \mathbb{R}^{[0,\infty)}$ 的坐标柱 σ-代数中, 每个事件只依赖某个可数时刻集; 所有连续函数构成的集合 C 不属于这个 σ-代数.

证明: 令 $\mathcal{D}$ 为能由某个可数坐标集决定的事件族. 补集仍由同一坐标集决定; 可数个事件的并由其坐标集的可数并决定, 所以 $\mathcal{D}$ 是 σ-代数, 且包含全部柱集. 因此每个柱可测事件均属于 $\mathcal{D}$.
还需说明 "决定" 的含义: 若 $A \in \sigma(X_t : t \in S)$, 而两条路径在 S 上完全相同, 则它们或者都属于 A, 或者都不属于 A. 具有这一性质的集合族本身是包含生成柱集的 σ-代数, 故结论成立.
若 C 可测, 则存在可数 S 决定它. 取零函数 $\omega \in C$, 再选 $t_0 \notin S$, 把 $\omega(t_0)$ 改成 1, 其余时刻仍为零, 得到不连续的 ω'. 两条路径在 S 上相同, 却只有一条连续, 矛盾. □

定理 11.4.1 Kolmogorov 连续性准则

在有限时间区间, 若 $\mathbb{E}|X_t - X_s|^\alpha \leqslant C|t-s|^{1+\beta}$, 其中 $\alpha, \beta > 0$, 则存在连续修正, 其路径局部 Hölder 指数可取任意 $\gamma < \beta/\alpha$.

证明: 只需证明 $[0,1]$ 的情形. 取 $0 < \gamma < \beta/\alpha$, 令 $D_n = \{k2^{-n} : 0 \leqslant k \leqslant 2^n\}$. 由 Markov 不等式,

$$\begin{aligned}\mathbb{P}\left(\max_{0\leqslant k<2^n} |X_{(k+1)2^{-n}} - X_{k2^{-n}}| > 2^{-n\gamma}\right) \\ \leqslant \sum_{k=0}^{2^n-1} \frac{C2^{-n(1+\beta)}}{2^{-n\alpha\gamma}} = C2^{-n(\beta-\alpha\gamma)}.\end{aligned}$$

该级数可求和, 故几乎必然存在有限随机常数 K, 使所有层, 所有相邻二进点的增量不超过 $K2^{-n\gamma}$; 有限个早期层可吸收进 K.
对任意二进点 $s < t$, 选 n 使 $2^{-n-1} < t - s \leqslant 2^{-n}$, 令 s_n, t_n 为在第 n 层向下取整的网格点. 它们至多相隔两个网格步, 故 $|X_{t_n} - X_{s_n}| \leqslant 2K2^{-n\gamma}$. 沿逐层二进逼近, 每层只需增加至多一个相邻增量, 于是

$$|X_t - X_{t_n}| + |X_s - X_{s_n}| \leqslant 2K \sum_{r=n+1}^{\infty} 2^{-r\gamma} \leqslant C_\gamma K 2^{-n\gamma}.$$

因此二进稠密集上 $|X_t - X_s| \leqslant C'_\gamma K|t-s|^\gamma$, 可唯一连续延拓为 $\widetilde{X}$. 对固定非二进时刻 t, 取 $t_n \to t$, 原矩估计给出 $X_{t_n} \to X_t$ 依概率, 而构造给出 $X_{t_n} \to \widetilde{X}_t$ 几乎必然. 依概率极限唯一, 故 $\widetilde{X}_t = X_t$ 几乎必然, 即它确为修正.

对递增的指数列 $\gamma_j \uparrow \beta/\alpha$, 在可数个概率一事件上同时构造; 所得连续修正不可区分, 因此同一修正具有所有较小的 Hölder 指数. 布朗增量满足 $\mathbb{E}|W_t - W_s|^{2p} = C_p|t-s|^p$, 取任意大的整数 p, 可得到任意小于 $1/2$ 的指数. □

第十二章　布朗运动的构造及路径性质

12.1　Wiener 过程的构造

A. 从不变性原理构造

定理 12.1.1　Donsker 不变性原理

设 ξ_j 独立同分布, 均值零, 方差一, $S_k=\sum_{j=1}^{k}\xi_j$. 令 $k=\lfloor nt\rfloor$, 用线性插值定义

$$X_t^n=\frac{1}{\sqrt{n}}\left[S_k+(nt-k)\xi_{k+1}\right].$$

Donsker 不变性原理说: 对每个 $T<\infty$, X^n 的分布在赋予一致范数的 $C[0,T]$ 上弱收敛于 Wiener 测度. 它不仅说每个固定 t 的分布趋于正态, 还说整条随机函数的分布收敛. 不同的增量分布只要满足这些矩条件, 都给出同一个极限, 因此叫不变性原理.

命题 12.1.1　连续路径空间的可分完备性

在 $C[0,\infty)$ 上使用局部一致度量

$$\rho(x,y)=\sum_{k=1}^{\infty}2^{-k}\big(\|x-y\|_{L^\infty[0,k]}\wedge 1\big).$$

若 x_n 关于 ρ 是 Cauchy, 则在每个 $[0,k]$ 上一致 Cauchy, 连续极限在重叠区间相容, 拼成连续函数, 故该空间完备. 以有理节点, 有理函数值构造分段线性函数, 可在任意紧区间一致逼近连续函数, 给出可数稠密集, 故空间可分. 由于连续函数在有理时刻的值决定全路径, 且一致范数上确界可在有理点取, Borel σ-代数与坐标柱集生成的 σ-代数相同.

评注　路径分布的弱收敛　路径空间上的弱收敛仍定义为对所有有界连续泛函 F, $\mathbb{E}F(X^n)\to\mathbb{E}F(W)$. 证明通常分两步: 有限维分布收敛和紧性. 有限维部分对不相交时间段使用 CLT 与独立性, 得到协方差 $s\wedge t$. 紧性意味着对任意 $\varepsilon>0$, 存在紧集 K 使所有路径分布对 K 的概率至少为 $1-\varepsilon$. Arzelà–Ascoli 将路径紧性归结为有界性和一致连续模控制; Prokhorov 定理再保证弱收敛子列. 有限维分布的唯一性识别所有子列极限.

Gaussian 或有限四阶矩增量时可利用四阶矩估计完成紧性论证; 仅有限二阶矩的一般 Donsker 定理还要截断与最大不等式, 不能从单点 CLT 直接略去这一步. 所得极限测度称 Wiener 测度, 典范过

程为 $W_t(\omega)=\omega(t)$.

Gaussian 增量情形的不变性原理: 上一章已构造出连续布朗运动 W. 令 $\widetilde{X}^n$ 是它在网格 k/n 上的分段线性插值. 由于 $\sqrt{n}(W_{(k+1)/n}-W_{k/n})$ 独立且服从 $N(0,1)$, $\widetilde{X}^n$ 与原定义中的 X^n 具有相同的路径分布. 对任意固定 T, 路径一致连续性给出

$$\sup_{t\leqslant T}|\widetilde{X}^n_t-W_t|\leqslant 2\sup_{\substack{s,t\leqslant T+1\\ |s-t|\leqslant 1/n}}|W_t-W_s|\longrightarrow 0\quad \text{a.s.}.$$

所以对任何有界连续路径泛函 F, 控制收敛给出 $\mathbb{E}F(X^n)=\mathbb{E}F(\widetilde{X}^n)\to\mathbb{E}F(W)$, 证明 Gaussian 增量情形.

若增量不是 Gaussian, 单点计算为

$$\frac{S_k}{\sqrt{n}}=\sqrt{\frac{k}{n}}\,\frac{S_k}{\sqrt{k}}\Rightarrow N(0,t)\qquad (k/n\to t).$$

网格时刻的协方差为 $\mathbb{E}(S_kS_l)/n=(k\wedge l)/n\to s\wedge t$; 对多个不相交区间应用 CLT 得到联合极限. 完整的一般情形还需要前述紧性定理, 不能只凭这两个矩计算断言路径弱收敛. □

B. Karhunen–Loève 展开

定理 12.1.2 Karhunen–Loève 展开

在 $[0,1]$ 上设中心 Gaussian 过程有连续协方差核 K, 解特征值问题

$$\int_0^1 K(s,t)\phi_k(t)\,\mathrm{d}t=\lambda_k\phi_k(s),\qquad \int_0^1\phi_k\phi_j=\delta_{kj}.$$

协方差算子紧, 自伴, 非负, 故有非负特征值及正交特征函数. 取独立 $\alpha_k\sim N(0,1)$, 构造

$$X_t^N=\sum_{k=1}^{N}\alpha_k\sqrt{\lambda_k}\phi_k(t).$$

Mercer 定理对连续非负核给出一致的核展开 $K(s,t)=\sum_k\lambda_k\phi_k(s)\phi_k(t)$, 因此

$$\sup_{t\in[0,1]}\mathbb{E}|X_t^N-X_t^M|^2=\sup_t\sum_{k=M+1}^{N}\lambda_k\phi_k(t)^2\to 0.$$

极限的有限维分布仍为 Gaussian, 均值零, 协方差为 K. 这里是 $\sup_t\mathbb{E}|\cdot|^2$ 收敛, 不能擅自改成 $\mathbb{E}\sup_t|\cdot|^2$; 后者需要路径控制.

证明: 非负紧自伴算子的谱定理给出正特征值 $\lambda_k\downarrow 0$ 及相应正交归一特征函数; 零特征空间不贡献

随机部分. 连续核的 Mercer 定理给出绝对一致收敛

$$K(s,t)=\sum_{k=1}^{\infty}\lambda_k\phi_k(s)\phi_k(t).$$

因此对 $N>M$, 由 $\mathbb{E}\alpha_k\alpha_l=\delta_{kl}$,

$$\mathbb{E}|X_t^N-X_t^M|^2=\sum_{k=M+1}^{N}\lambda_k\phi_k(t)^2,$$

且右端关于 t 一致趋零. 于是 X^N 在范数 $\sup_t(\mathbb{E}|X_t^N|^2)^{1/2}$ 下为 Cauchy 列, 得到极限 X. 每个有限向量 $(X_{t_1}^N,\cdots,X_{t_m}^N)$ 在 L^2 中收敛; Gaussian 闭包性质保证极限仍联合 Gaussian. 均方收敛和 Cauchy–Schwarz 给出

$$\mathbb{E}X_t=\lim_N\mathbb{E}X_t^N=0,\qquad \mathbb{E}X_sX_t=\lim_N\mathbb{E}X_s^NX_t^N=\sum_k\lambda_k\phi_k(s)\phi_k(t)=K(s,t).$$

所以构造的过程具有指定的均值与协方差.
若已有过程 X, 要在同一概率空间表示它, 可对 $\lambda_k>0$ 定义

$$\alpha_k=\lambda_k^{-1/2}\int_0^1 X_t\phi_k(t)\,\mathrm{d}t.$$

它们联合 Gaussian, 且

$$\mathbb{E}\alpha_k\alpha_l=\frac{(K\phi_k,\phi_l)}{\sqrt{\lambda_k\lambda_l}}=\delta_{kl},$$

因而是独立标准正态. 又 $\mathbb{E}[X_t\alpha_k]=\sqrt{\lambda_k}\phi_k(t)$, 所以

$$\mathbb{E}\left|X_t-\sum_{k=1}^{N}\sqrt{\lambda_k}\alpha_k\phi_k(t)\right|^2=K(t,t)-\sum_{k=1}^{N}\lambda_k\phi_k(t)^2\longrightarrow 0$$

一致于 t, 从而得到对原过程本身的展开. □

例题 12.1.1 布朗运动的 Karhunen–Loève 展开

对布朗核 $K(s,t)=s\wedge t$, 特征方程为

$$\int_0^s t\phi(t)\,\mathrm{d}t+s\int_s^1\phi(t)\,\mathrm{d}t=\lambda\phi(s).$$

第一次求导时两项端点贡献抵消:

$$\lambda\phi'(s)=s\phi(s)+\int_s^1\phi(t)\,\mathrm{d}t-s\phi(s)=\int_s^1\phi(t)\,\mathrm{d}t.$$

再求导得 $\lambda\phi''(s)=-\phi(s)$. 在积分方程中取 $s=0$ 得 $\phi(0)=0$, 在一阶导数方程中取 $s=1$ 得

$\phi'(1)=0$. 若 $\lambda=0$, 同样两次微分给出 $\phi=0$, 故非零特征函数对应 $\lambda>0$. 常微分方程的解为

$$\phi(s)=A\sin(s/\sqrt{\lambda})+B\cos(s/\sqrt{\lambda}).$$

$\phi(0)=0$ 给出 $B=0$, $\phi'(1)=0$ 给出 $\cos(1/\sqrt{\lambda})=0$, 即 $1/\sqrt{\lambda}=(k-1/2)\pi$. 再由 $\int_0^1\sin^2((k-1/2)\pi t)\,\mathrm{d}t=1/2$ 归一化, 得到

$$\lambda_k=[(k-\tfrac12)\pi]^{-2},\qquad \phi_k(t)=\sqrt{2}\sin((k-\tfrac12)\pi t),$$

$$W_t=\sum_{k\geqslant 1}\frac{\sqrt{2}\alpha_k\sin((k-1/2)\pi t)}{(k-1/2)\pi}. \tag{12.1}$$

评注　Gaussian 过程的连续性　Gaussian 过程的自然距离为 $d(s,t)=[\mathbb{E}|X_s-X_t|^2]^{1/2}$. 若覆盖数 $N(\varepsilon)$ 满足熵积分 $\int_0^{\varepsilon_0}\sqrt{\log N(\varepsilon)}\,\mathrm{d}\varepsilon<\infty$, 则标准 Gaussian 链式估计可保证连续版本. 这一深层充分条件此处只陈述. 若 $d(s,t)\leqslant p(|t-s|)$, p 递增且 $p(u)\to 0(u\downarrow 0)$, 则对应的一个充分条件可写成 $\int_0^1\sqrt{\log(1/u)}\,\mathrm{d}p(u)<\infty$. 布朗运动取 $p(u)=\sqrt{u}$, 此时

$$\int_0^1\sqrt{\log(1/u)}\,\mathrm{d}p(u)=\frac12\int_0^1 u^{-1/2}\sqrt{\log(1/u)}\,\mathrm{d}u=\frac12\int_0^\infty v^{1/2}\mathrm{e}^{-v/2}\,\mathrm{d}v<\infty;$$

自然距离是方差的平方根, 不能漏掉根号. 在这个充分条件下, 对 KL 级数还可得到几乎必然的一致收敛; 可通过 Gaussian 链式估计与独立对称级数的收敛理论建立, 不能仅由均方核展开推出. 后面的 Haar 构造将直接证明布朗级数具有一致连续极限.

例题 12.1.2　布朗桥与 Brownian sheet

Brownian bridge $B_t=W_t-tW_1$ 的协方差为 $s\wedge t-st$, 特征函数为 $\sqrt{2}\sin(k\pi t)$, 特征值 $(k\pi)^{-2}$. 多参数 Brownian sheet 的协方差可取 $\prod_j(s_j\wedge t_j)$, 对应张量积特征展开; 它是 Gaussian 随机场, 不应直接当作一参数 Markov 过程.

C. Haar 基与 Lévy–Ciesielski 构造

定理 12.1.3　Lévy–Ciesielski 构造

令 $H_0^0=1$, ψ 在 $[0,1/2)$ 为 1, $[1/2,1)$ 为 -1, 其余为零, 定义

$$H_k^n(t)=2^{(n-1)/2}\psi(2^{n-1}t-k),\quad n\geqslant 1,\quad 0\leqslant k<2^{n-1}.$$

它们构成 $L^2[0,1]$ 的正交归一 Haar 基. 积分 $S_k^n(t)=\int_0^t H_k^n(s)\,\mathrm{d}s$ 为局部三角帐篷, 最大高度

$2^{-(n+1)/2}$; 同层帐篷支撑内部不相交. 取全部独立标准正态系数, 令

$$W_t = \alpha_0^0 t + \sum_{n\geqslant 1}\sum_{k=0}^{2^{n-1}-1} \alpha_k^n S_k^n(t).$$

上述级数几乎必然一致收敛, 其和为标准布朗运动.

证明: 先推导所需尾界. 对 $Z\sim N(0,1)$, $x>0$,

$$\mathbb{P}(|Z|>x) = \sqrt{\frac{2}{\pi}}\int_x^\infty \mathrm{e}^{-y^2/2}\,\mathrm{d}y \leqslant \sqrt{\frac{2}{\pi}}\int_x^\infty \frac{y}{x}\mathrm{e}^{-y^2/2}\,\mathrm{d}y = \sqrt{\frac{2}{\pi}}\frac{\mathrm{e}^{-x^2/2}}{x}.$$

再用并集界,

$$\mathbb{P}\left(\max_k |\alpha_k^n| > n\right) \leqslant 2^{n-1}\mathbb{P}(|Z|>n) \leqslant C 2^n n^{-1}\mathrm{e}^{-n^2/2},$$

可求和. 故几乎必然从某层起 $\max_k|\alpha_k^n|\leqslant n$, 而该层函数和的上确界至多 $n2^{-(n+1)/2}$. 因此对概率一的每条样本路径,

$$\sum_{n\geqslant N(\omega)} \sup_{t\in[0,1]}\left|\sum_k \alpha_k^n(\omega) S_k^n(t)\right| \leqslant \sum_{n\geqslant N(\omega)} n2^{-(n+1)/2} < \infty.$$

Weierstrass 判别法给出一致收敛, 每个部分和连续, 故极限连续. 有限维向量是 Gaussian 向量的几乎必然极限, 因此仍为 Gaussian. 为识别其协方差, 先在 $L^2(\Omega)$ 中计算: 固定 s,t, 由系数正交性, 截断协方差是

$$\mathbb{E}W_s^N W_t^N = \sum_{n\leqslant N}\sum_k \left(\int_0^s H_k^n(u)\,\mathrm{d}u\right)\left(\int_0^t H_k^n(u)\,\mathrm{d}u\right).$$

Parseval 保证这一级数收敛; 特别地, 固定时刻的部分和在 $L^2(\Omega)$ 中 Cauchy, 其均方极限与已经得到的几乎必然极限相同. 故可传递期望并得到

$$\mathbb{E}W_sW_t = \sum_H \langle \mathbf{1}_{[0,s]}, H\rangle\langle \mathbf{1}_{[0,t]}, H\rangle = \langle \mathbf{1}_{[0,s]}, \mathbf{1}_{[0,t]}\rangle = s\wedge t.$$

于是它确实构造出布朗运动. 尾估计必须控制系数的绝对值, 只控制最大正值不能控制负向尖峰. □

推论 12.1.2 布朗桥的中点分布

相应的二分模拟法是先取 $W_1\sim N(0,1)$, 再递归插入中点. 给定 $W_s=x, W_t=y$,

$$W_{(s+t)/2}\mid W_s=x, W_t=y \sim N\left(\frac{x+y}{2}, \frac{t-s}{4}\right).$$

由两个独立, 同方差的半段增量条件于它们的和, 可直接求得这个条件正态分布.

命题 12.1.3 二次 Wiener 泛函

由 Karhunen–Loève 展开可得

$$\mathbb{E}\exp\left(-\frac{1}{2}\int_0^1 W_t^2\,\mathrm{d}t\right)=\prod_{k\geqslant 1}(1+\lambda_k)^{-1/2}=(\cosh 1)^{-1/2}.$$

证明: 由路径在 $L^2[0,1]$ 中的正交展开和 Parseval 等式,

$$\int_0^1 W_t^2\,\mathrm{d}t=\sum_{k=1}^{\infty}\lambda_k\alpha_k^2\quad\text{a.s..}$$

由于 $\sum_k\lambda_k=\int_0^1 K(t,t)\,\mathrm{d}t=1/2$, 右端非负随机级数的期望有限, 因此几乎必然有限. 先截取前 N 项, 独立性给出

$$\begin{aligned}\mathbb{E}\exp\left(-\frac{1}{2}\sum_{k=1}^{N}\lambda_k\alpha_k^2\right)&=\prod_{k=1}^{N}\mathbb{E}\mathrm{e}^{-\lambda_k\alpha_k^2/2}\\&=\prod_{k=1}^{N}\frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}}\mathrm{e}^{-(1+\lambda_k)x^2/2}\,\mathrm{d}x=\prod_{k=1}^{N}(1+\lambda_k)^{-1/2}.\end{aligned}$$

左端的被积函数在 $[0,1]$ 内, 由控制收敛可令 $N\to\infty$; 右端乘积因 $\sum_k\log(1+\lambda_k)\leqslant\sum_k\lambda_k<\infty$ 而收敛到正数. 经典的双曲余弦乘积公式为

$$\cosh z=\prod_{k=1}^{\infty}\left(1+\frac{4z^2}{(2k-1)^2\pi^2}\right).$$

代入 $z=1$ 和特征值, 得到所求期望 $(\cosh 1)^{-1/2}=\sqrt{2\mathrm{e}/(1+\mathrm{e}^2)}$. 第 17 章还会用 PDE 独立核对. □

12.2 Wiener 路径的性质

命题 12.2.1 布朗运动的变换

由均值与协方差检查可知: $-W_t$, $W_{t+s}-W_s$, $cW_{t/c^2}(c>0)$ 都为标准布朗运动; 对固定 T, W_T-W_{T-t} 也是 $[0,T]$ 上的布朗运动. 时间反演过程

$$\widetilde{W}_t=tW_{1/t}\ (t>0),\qquad \widetilde{W}_0=0$$

同样如此: 其协方差为 $st\min(1/s,1/t)=s\wedge t$, 零点连续性由 $W_u/u\to 0(u\to\infty)$ 保证. 这些是分布相等, 不是同一路径逐点相等.

命题 12.2.2 布朗运动的二次变差

对确定分割 $\Pi: 0=t_0<\cdots<t_n=t$, 令 $Q_\Pi=\sum_j (W_{t_{j+1}}-W_{t_j})^2$. 独立 Gaussian 增量给出

$$\mathbb{E}Q_\Pi = t, \qquad \mathbb{E}|Q_\Pi - t|^2 = 2\sum_j (t_{j+1}-t_j)^2 \leqslant 2t|\Pi|.$$

故网格趋零时 $Q_\Pi \to t$ 在 L^2 成立; 对二进分割, 误差概率可求和, 进一步几乎必然收敛. 记 $[W]_t = t$.

证明: 记 $\Delta_j = t_{j+1}-t_j$, $Z_j = W_{t_{j+1}}-W_{t_j}$. 由 $Z_j \sim N(0,\Delta_j)$, 有 $\mathbb{E}Z_j^2=\Delta_j$, $\mathbb{E}Z_j^4 = 3\Delta_j^2$, 所以

$$\operatorname{Var}(Z_j^2) = 3\Delta_j^2 - \Delta_j^2 = 2\Delta_j^2.$$

不同 j 的增量独立, 其平方也独立, 因此

$$\mathbb{E}(Q_\Pi - t)^2 = \sum_j \operatorname{Var}(Z_j^2) = 2\sum_j \Delta_j^2 \leqslant 2|\Pi| \sum_j \Delta_j = 2t|\Pi|.$$

二进分割上 $|\Pi_n| = t2^{-n}$, 由 Chebyshev 不等式, 任意 $\varepsilon>0$ 的误差概率之和有限. 对 $\varepsilon = 1/k$ 使用 Borel–Cantelli, 便得到几乎必然收敛. 在任意有理端点区间上重复此论证, 再取可数交, 可使这些区间的二次变差在同一概率一事件上同时成立. □

推论 12.2.3 总变差与幂次变差

连续有界变差函数 x 则满足 $\sum(\Delta x)^2 \leqslant \max|\Delta x| \sum|\Delta x| \to 0$. 布朗路径连续而二次变差不为零, 因此在任何非平凡区间上总变差无穷. 对 $p>2$, 同样的估计给 $\sum|\Delta W|^p \to 0$; 对 $p<2$, 二进分割上的该和趋于无穷. 这说明 “一个布朗增量大小约为 $\sqrt{\Delta t}$” 的精确累积意义.

证明: 在上述共同的概率一事件上, 固定有理区间 $[p,q]$. 若其总变差 V 有限, 则对二进分割

$$q-p = \lim_n \sum_j (\Delta W_j)^2 \leqslant \lim_n \left(\max_j |\Delta W_j|\right) V = 0,$$

最后一步来自连续路径在紧区间上的一致连续性, 矛盾. 任意非平凡区间包含有理端点子区间, 所以全部区间上的总变差均无穷.

对 $r>2$, $\sum|\Delta W|^r \leqslant (\max|\Delta W|)^{r-2}\sum(\Delta W)^2 \to 0$. 若 $0<r<2$, 则

$$\sum_j |\Delta W_j|^r \geqslant \frac{\sum_j (\Delta W_j)^2}{(\max_j |\Delta W_j|)^{2-r}} \longrightarrow \infty.$$

□

定理 12.2.1 路径的 Hölder 连续性与不可微性

布朗路径在任意紧时间区间上几乎必然满足所有指数 $0<\gamma<1/2$ 的 Hölder 连续性, 在任意非平凡区间上都不满足指数 $1/2$ 的 Hölder 界, 而且几乎必然处处不可微.

定理 12.2.2 多参数连续性准则

多参数, Banach 值情形的连续性准则如下: 若 $t\in[0,1]^d$, X_t 取值于可分 Banach 空间, 且 $\mathbb{E}\|X_t-X_s\|^\gamma\leqslant c|t-s|^{d+\varepsilon}$, 则存在修正 $\widetilde{X}$, 对每个 $0\leqslant\alpha<\varepsilon/\gamma$ 有

$$\mathbb{E}\left(\sup_{s\neq t}\frac{\|\widetilde{X}_t-\widetilde{X}_s\|}{|t-s|^\alpha}\right)^\gamma<\infty.$$

多参数准则的证明: 令 M_n 为 d 维二进网格第 n 层所有相邻边上增量范数的最大值. 该层有至多 C_d2^{nd} 条边, 每边长度为 2^{-n}, 所以

$$\mathbb{E}M_n^\gamma\leqslant\sum_{\text{相邻边}(s,t)}\mathbb{E}\|X_t-X_s\|^\gamma\leqslant C2^{nd}2^{-n(d+\varepsilon)}=C2^{-n\varepsilon}.$$

固定 $0<\alpha<\varepsilon/\gamma$, 令 $K=\sum_{n\geqslant0}2^{n\alpha}M_n$. 若 $\gamma\geqslant1$, Minkowski 不等式给出

$$(\mathbb{E}K^\gamma)^{1/\gamma}\leqslant C\sum_n2^{n\alpha-n\varepsilon/\gamma}<\infty.$$

若 $0<\gamma<1$, 用 $(\sum a_n)^\gamma\leqslant\sum a_n^\gamma$ 也得到 $\mathbb{E}K^\gamma<\infty$. 多维网格中, 两点先降到与其距离同尺度的网格, 再逐层连线; 每层所需的相邻边条数有仅依赖 d 的上界. 因此与一维连续性准则相同的链式估计给出

$$\|X_t-X_s\|\leqslant C_{d,\alpha}K|t-s|^\alpha$$

在二进稠密集上成立. Banach 空间的完备性保证连续延拓, 原矩条件保证延拓为修正. 取 γ 次方的期望即得所述界. $\alpha=0$ 可由任意较小的正指数结论得到. □

布朗路径正则性结论的证明: 对任意整数 $p\geqslant1$, Gaussian 矩给出

$$\mathbb{E}|W_t-W_s|^{2p}=(2p-1)!!\,|t-s|^p.$$

在准则中取 $d=1,\gamma=2p,\varepsilon=p-1$, 得到所有 $\alpha<(p-1)/(2p)$ 的 Hölder 连续性. 令 $p\to\infty$, 覆盖任意 $\alpha<1/2$.
若某条路径在区间 $[a,b]$ 上满足 $|W_t-W_s|\leqslant C|t-s|^\alpha$ 且 $\alpha>1/2$, 则

$$\sum_j(\Delta W_j)^2\leqslant C^2\sum_j(\Delta t_j)^{2\alpha}\leqslant C^2(b-a)|\Pi|^{2\alpha-1}\longrightarrow0,$$

与二次变差为 $b-a$ 矛盾. 对临界 $\alpha=1/2$, 下述零点重对数律给出 $|W_t|/\sqrt{t}$ 在 $t\downarrow 0$ 时无界, 因此不可能有统一的 $1/2$ 次 Hölder 常数. 对任何有理起点后的布朗增量应用同一结论, 再取可数交, 可排除所有非平凡区间上的临界 Hölder 性.

最后单独证明处处不可微性, 避免把它误当作 Hölder 结论的直接推论. 固定 $K>0$, 令 $h=2^{-n}$, 考虑三个连续网格增量均不超过 Kh 的事件. 每个增量为 $N(0,h)$, 正态密度上界给出 $\mathbb{P}(|\Delta W|\leqslant Kh)\leqslant CK\sqrt{h}$. 三个增量独立, 因此在固定的长度为 1 的区间内, 存在这种三连增量的概率至多

$$Ch^{-1}(K\sqrt{h})^3=CK^3\sqrt{h}.$$

这对 n 可求和, 故几乎必然从某层起不存在这样的三连增量. 若路径在某点 t 可微, 则在某邻域有 $|W_s-W_t|\leqslant C_t|s-t|$. 对所有足够小的 h, 取 t 右侧紧邻的三个网格区间, 每个端点距 t 至多 $4h$, 故三个增量均不超过 $8C_th$, 与上述结论矛盾. 对正整数 K 及覆盖时间轴的可数个紧区间取交, 即排除全部时刻的可微性. □

定理 12.2.3 布朗运动的重对数律

几乎必然有

$$\varlimsup_{t\downarrow 0}\frac{W_t}{\sqrt{2t\log\log(1/t)}}=1,\qquad \varlimsup_{t\to\infty}\frac{W_t}{\sqrt{2t\log\log t}}=1,$$

相应下极限为 -1. 第一式中的 t 取充分小的正数. 此外 $W_t/t\to 0$ 几乎必然.

长时间强大数结论的证明: 整数时刻 $W_n=\sum_{k=1}^{n}(W_k-W_{k-1})$ 是独立标准正态增量之和, 故强大数定律给出 $W_n/n\to 0$. 令 $A_n=\sup_{0\leqslant u\leqslant 1}|W_{n+u}-W_n|$, 由 Doob 不等式和增量平稳性, $\mathbb{E}A_n^2\leqslant 4$. 所以

$$\sum_{n=1}^{\infty}\mathbb{P}(A_n>\varepsilon n)\leqslant\sum_{n=1}^{\infty}\frac{4}{\varepsilon^2n^2}<\infty,$$

从而 $A_n/n\to 0$ 几乎必然. 对 $n\leqslant t<n+1$,

$$\frac{|W_t|}{t}\leqslant\frac{|W_n|}{n}+\frac{A_n}{n}\longrightarrow 0.$$

这也证明时间反演过程在零点连续, 因为 $tW_{1/t}=W_u/u$, 其中 $u=1/t\to\infty$. 重对数律本身是更深的极限定理, 此处保留其完整陈述. □

第十三章　随机微分方程与 Itô 公式

13.1　白噪声

定义 13.1.1　白噪声

形式上写白噪声 $\xi(t)=\dot W_t$, 其协方差为 $\mathbb{E}\xi(t)\xi(s)=\delta(t-s)$. 白噪声应作为随机广义函数定义. 具体地, 对确定性 $\phi\in L^2$,

$$\xi(\phi)=\int \phi(t)\,\mathrm{d}W_t,\qquad \mathbb{E}\xi(\phi)\xi(\psi)=\int\phi(t)\psi(t)\,\mathrm{d}t.$$

白噪声是作用在测试函数上的随机线性泛函, 形式功率谱平坦, 在无限频带上的总功率无限. 因此常微分式 $\dot X=b(X,t)+\sigma(X,t)\xi(t)$ 应改写成积分方程

$$X_t=X_0+\int_0^t b(X_s,s)\,\mathrm{d}s+\int_0^t\sigma(X_s,s)\,\mathrm{d}W_s. \tag{13.1}$$

其中第二项是随机积分, 其定义决定了随机微分方程的解释.

在广义函数意义下, 这与形式微分的计算一致:

$$\mathbb{E}\dot W_t=\frac{\mathrm{d}}{\mathrm{d}t}\mathbb{E}W_t=0,\qquad \mathbb{E}\dot W_s\dot W_t=\partial_s\partial_t(s\wedge t)=\delta(t-s).$$

例如先对 t 求导得到 $\mathbf{1}_{t<s}$, 再对 s 作分布导数得到 $\delta(s-t)$. 自相关 $R(t)=\delta(t)$ 的 Fourier 变换为 $S(\omega)=1$, 所以功率谱不随频率变化; 有色噪声的功率谱则不平坦. 白噪声的 $\int_{\mathbb{R}}S(\omega)\,\mathrm{d}\omega=\infty$ 说明它是理想化极限, 而非具有有限点态方差的普通过程.

13.2　Itô 积分

例题 13.2.1　不同取值点对应的积分

普通 Riemann–Stieltjes 积分在积分器有界变差时, 对连续被积函数有稳定的路径定义. 其取值点无关性的关键估计是

$$\left|\sum_j (f_j-\widetilde f_j)(g(t_{j+1})-g(t_j))\right|\leqslant \max_j|f_j-\widetilde f_j|\,V(g;[0,T])\longrightarrow 0,$$

其中使用了 f 一致连续和 g 总变差有限. 布朗路径不满足后一个条件. 考虑 $\int_0^T W_t\,\mathrm{d}W_t$, 左端和满

足精确恒等式

$$\sum_j W_{t_j}\Delta W_j = \frac{1}{2}\left(W_T^2 - W_0^2 - \sum_j (\Delta W_j)^2\right) \longrightarrow \frac{1}{2}(W_T^2 - T).$$

右端和则趋于 $(W_T^2+T)/2$; 端点平均的梯形和恰好等于 $W_T^2/2$. 若使用时间中点值 $W_{(t_j+t_{j+1})/2}$, 它与端点平均之差是方差 $\Delta t_j/4$ 的独立桥波动; 乘以整段增量后求和的方差为 $\frac{1}{4}\sum_j \Delta t_j^2 \to 0$, 故也趋于 $W_T^2/2$. 从期望看, 三种取值的差异已很明显:

$$\begin{aligned}
\mathbb{E} I_N^{L} &= \sum_j \mathbb{E}[W_{t_j}\Delta W_j] = 0,\\
\mathbb{E} I_N^{R} &= \sum_j \mathbb{E}[(W_{t_j}+\Delta W_j)\Delta W_j] = \sum_j \Delta t_j = T,\\
\mathbb{E} I_N^{M} &= \sum_j \mathbb{E}[W_{(t_j+t_{j+1})/2}\Delta W_j] = \sum_j \frac{\Delta t_j}{2} = \frac{T}{2}.
\end{aligned}$$

最后一式把整段增量分成中点之前, 之后两部分, 后一部分与中点值独立, 前一部分贡献长度 $\Delta t_j/2$. 差别来自二次变差, 网格细化不会消除它.

定义 13.2.1 渐进可测性与可预测性

过程 f 称为**渐进可测**, 如果对每个 $t\geqslant 0$, 映射 $(s,\omega)\mapsto f_s(\omega)$ 在 $[0,t]\times\Omega$ 上关于 $\mathcal{B}([0,t])\otimes\mathcal{F}_t$ 可测. 由所有左连续适应过程生成的 $[0,T]\times\Omega$ 上的 σ-代数称为**可预测 σ-代数**, 关于它可测的过程称为**可预测过程**. 连续适应过程可预测; 可预测过程渐进可测. 阶梯过程在分点处的取值不影响下文的 $L^2(\mathrm{d}t\,\mathrm{d}\mathbb{P})$ 等价类.

定义 13.2.2 阶梯过程的 Itô 积分

令 $f(t)=\sum_{j=0}^{n-1} e_j \mathbf{1}_{[t_j,t_{j+1})}(t)$, 其中 e_j 对 $\mathcal{F}_{t_j}$ 可测且平方可积. 定义

$$I(f)=\int_0^T f(t)\,\mathrm{d}W_t = \sum_j e_j (W_{t_{j+1}}-W_{t_j}).$$

命题 13.2.1 Itô 等距

对上述阶梯过程 f, 有

$$\mathbb{E} I(f)=0, \qquad \mathbb{E}|I(f)|^2 = \sum_j \mathbb{E} e_j^2 \Delta t_j = \mathbb{E}\int_0^T |f(t)|^2\,\mathrm{d}t. \tag{13.2}$$

此式称为 Itô 等距, 可用于将积分延拓到一般平方可积过程.

证明: 由于 e_j 对 $\mathcal{F}_{t_j}$ 可测, 且 ΔW_j 独立于 $\mathcal{F}_{t_j}$, 有

$$\mathbb{E}(e_j\Delta W_j \mid \mathcal{F}_{t_j}) = 0, \qquad \mathbb{E}(e_j^2(\Delta W_j)^2 \mid \mathcal{F}_{t_j}) = e_j^2\Delta t_j.$$

对 $j<k$, $e_j\Delta W_j e_k$ 对 $\mathcal{F}_{t_k}$ 可测, 故先条件于 $\mathcal{F}_{t_k}$ 可得 $\mathbb{E}(e_j\Delta W_j e_k\Delta W_k)=0$. 对积分和取期望, 并展开其平方, 即得零均值与等距公式. □

定义 13.2.3 平方可积过程的 Itô 积分

记 $V[0,T]$ 为满足 $\mathbb{E}\int_0^T |f|^2\,\mathrm{d}t<\infty$ 的可预测过程类; 连续适应过程属于其中 (满足该矩条件时), 渐进可测过程也有相应积分版本. 可预测阶梯过程在此 $L^2(\mathrm{d}t\,\mathrm{d}\mathbb{P})$ 空间中稠密. 选 $f_n\to f$, 等距给出

$$\mathbb{E}|I(f_n)-I(f_m)|^2 = \mathbb{E}\int_0^T |f_n-f_m|^2\,\mathrm{d}t \to 0.$$

故 $I(f_n)$ 在 $L^2(\Omega)$ 中有唯一极限, 定义为 $\int f\,\mathrm{d}W$; 换一组逼近仍给同样极限. 等距, 零均值, 线性, 区间可加性随之延拓. 一般适应性本身不能替代所需的联合可测性条件.

稠密逼近, 唯一性和等距的延拓: 可预测 σ-代数由 $A\times(s,t](A\in\mathcal{F}_s)$ 及零时刻集合生成; 对应的指标过程就是可预测阶梯过程. 在有限测度 $\mathrm{d}t\,\mathrm{d}\mathbb{P}$ 下, 由简单函数逼近及单调类论证, 它们的线性包在可预测 L^2 中稠密. 连续适应 f 还有直接逼近: 先将它截断为有界过程, 再取左端阶梯近似, 路径一致连续与控制收敛给出 $L^2(\mathrm{d}t\,\mathrm{d}\mathbb{P})$ 收敛.
若 $f_n\to f$, $g_n\to f$ 是两组阶梯逼近, 则

$$\|I(f_n)-I(g_n)\|_{L^2(\Omega)} = \|f_n-g_n\|_{L^2(\mathrm{d}t\,\mathrm{d}\mathbb{P})} \leqslant \|f_n-f\|_2+\|g_n-f\|_2\to 0.$$

故极限与逼近选择无关. 零均值由

$$|\mathbb{E}I(f)| = |\mathbb{E}(I(f)-I(f_n))| \leqslant \|I(f)-I(f_n)\|_2\to 0$$

得到; 等距则由 Hilbert 空间中范数的连续性给出

$$\mathbb{E}|I(f)|^2 = \lim_n \mathbb{E}|I(f_n)|^2 = \lim_n \mathbb{E}\int |f_n|^2\,\mathrm{d}t = \mathbb{E}\int |f|^2\,\mathrm{d}t.$$

线性, 区间可加性和终点可测性同样由阶梯情形取 L^2 极限得到. □

命题 13.2.2 Itô 积分的连续鞅性质

令 $M_t=\int_0^t f\,\mathrm{d}W$. 阶梯情形先验证它是鞅, 再由 L^2 极限保持条件期望关系. 用式 (11.1),

$$\mathbb{E}\sup_{t\leqslant T}\left|\int_0^t (f_n-f_m)\,\mathrm{d}W\right|^2 \leqslant 4\mathbb{E}\int_0^T |f_n-f_m|^2\,\mathrm{d}t.$$

因此可以选子列得到一致的几乎必然极限, 从而获得连续鞅版本. $\int_0^T f\,\mathrm{d}W$ 对 $\mathcal{F}_T$ 可测; 中间时刻的积分才对相应 $\mathcal{F}_t$ 可测.

证明: 阶梯积分在 $[s,t]$ 上的每一项, 先条件于该项左端时刻的 σ-代数, 再条件于 $\mathcal{F}_s$, 得到 $\mathbb{E}(M_t - M_s \mid \mathcal{F}_s) = 0$. 一般情形利用条件期望的 L^2 收缩性, 令阶梯逼近取极限, 鞅等式仍成立.
对连续性, 选子列使 $\mathbb{E}\int |f_{n_{k+1}} - f_{n_k}|^2\,\mathrm{d}t \leqslant 2^{-4k}$. Doob 和 Markov 不等式给出

$$\mathbb{P}\left(\sup_{t\leqslant T} |M_t^{n_{k+1}} - M_t^{n_k}| > 2^{-k}\right) \leqslant 4\,2^{-2k}.$$

由 Borel–Cantelli, 连续过程 M^{n_k} 几乎必然一致 Cauchy, 故有连续极限. 每个固定时刻的极限与已定义的积分相同, 所以它是积分过程的连续版本. □

命题 13.2.3 多维 Itô 积分

对 m 维独立布朗运动及 $n\times m$ 矩阵过程 σ, 逐分量定义积分, 得到

$$\mathbb{E}\left|\int_0^T \sigma\,\mathrm{d}W\right|^2 = \mathbb{E}\int_0^T \|\sigma\|_F^2\,\mathrm{d}t, \qquad \left[\int \sigma\,\mathrm{d}W\right]_t^{ij} = \int_0^t (\sigma\sigma^{\mathrm{T}})_{ij}\,\mathrm{d}s.$$

证明: 先对标量被积过程 f, g, 不同布朗分量 W^r, W^s 的增量正交. 与一维等距相同的条件期望计算给出

$$\mathbb{E}\left[\left(\int_0^T f\,\mathrm{d}W^r\right)\left(\int_0^T g\,\mathrm{d}W^s\right)\right] = \delta_{rs}\mathbb{E}\int_0^T fg\,\mathrm{d}t.$$

注意 f, g 可以依赖全部过去噪声, 不必彼此独立. 对矩阵过程逐分量展开并对 r, s 求和, 即得 Frobenius 范数等距. 对分割上的乘积增量作同样的局部计算, 可得积分过程的二次协变差 $\int \sigma\sigma^{\mathrm{T}}\,\mathrm{d}t$; 一般被积过程由阶梯逼近及停止延拓. □

评注 局部随机积分 如果仅有 $\int_0^T |f|^2\,\mathrm{d}t < \infty$ 几乎必然, 可在该积分达到 n 时停止, 再拼接定义局部积分; 所得为局部鞅, 未必是真鞅, 零均值和全局等距须额外检查可积性.

13.3 Itô 公式

命题 13.3.1 加权二次变差

设 $f(t,\omega)$ 路径连续, 且存在确定常数 C 使 $|f(t,\omega)| \leqslant C$. 对任意确定分割和任意取值点 $t_j^* \in$

$[t_j, t_{j+1}]$, 有

$$\sum_j f(t_j^*, \omega)(\Delta W_j)^2 \longrightarrow \int_0^t f(s,\omega)\,\mathrm{d}s$$

依概率成立. 若 f 还适应, 则左端点取值的关键误差满足

$$\mathbb{E}\left|\sum_j f(t_j)[(\Delta W_j)^2 - \Delta t_j]\right|^2 = 2\sum_j \mathbb{E} f(t_j)^2 \Delta t_j^2.$$

证明: 先设 f 适应. 对 $j<k$, $f(t_j)f(t_k)[(\Delta W_j)^2-\Delta t_j]$ 对 $\mathcal{F}_{t_k}$ 可测, 而 $\mathbb{E}[(\Delta W_k)^2-\Delta t_k \mid \mathcal{F}_{t_k}]=0$, 故平方展开的交叉项为零. 对角项由 Gaussian 四阶矩给出 $2\mathbb{E}f(t_j)^2\Delta t_j^2$, 其和不超过 $2\|f\|_\infty^2 t|\Pi| \to 0$. 再由普通 Riemann 和收敛, 左端点结论成立. 任意取值点与左端点之差满足

$$\left|\sum_j [f(t_j^*)-f(t_j)](\Delta W_j)^2\right| \leqslant \max_j |f(t_j^*)-f(t_j)| \sum_j (\Delta W_j)^2 \to 0$$

依概率成立, 因为第一因子几乎必然趋零, 第二因子依概率趋于 t.
若不假设适应性, 不能对系数使用上述条件期望计算, 但命题仍可证明. 先在一个固定的粗时间网格上以随机常数逼近 f, 每个粗区间内的平方增量和依概率趋于该区间长度; 有限个有界随机系数不会影响此收敛. 再将粗网格加密, 误差仍由 f 的连续模乘以总二次变差控制. 跨粗网格端点的有限个增量随细网格趋零而消失. 先取细网格极限, 再取粗网格极限即得结论. □

定理 13.3.1 一维时空公式

设 $\mathrm{d}X_t = b_t\,\mathrm{d}t + \sigma_t\,\mathrm{d}W_t$, $f \in C^{1,2}$, 在局部可积条件下

$$\mathrm{d}f(t,X_t) = \left(f_t + b_t f_x + \frac{1}{2}\sigma_t^2 f_{xx}\right)(t,X_t)\,\mathrm{d}t + \sigma_t f_x(t,X_t)\,\mathrm{d}W_t. \tag{13.3}$$

证明: 先证明 $f=f(x)\in C^2$, b,σ 为有界适应阶梯过程的情形. 取包含其全部分点的细分割, 使每段上 $\Delta X_j = b_j\Delta t_j + \sigma_j \Delta W_j$. Taylor 公式给出

$$f(X_t)-f(X_0) = \sum_j f'(X_{t_j})\Delta X_j + \frac{1}{2}\sum_j f''(X_{t_j})(\Delta X_j)^2 + \sum_j R_j.$$

一阶项分成

$$\sum_j f'(X_{t_j})b_j\Delta t_j + \sum_j f'(X_{t_j})\sigma_j\Delta W_j \longrightarrow \int_0^t f'(X_s)b_s\,\mathrm{d}s + \int_0^t f'(X_s)\sigma_s\,\mathrm{d}W_s.$$

前一项是普通 Riemann 和, 后一项由 Itô 等距和被积过程的均方逼近得到.

平方项展开为

$$(\Delta X_j)^2 = b_j^2 \Delta t_j^2 + 2 b_j \sigma_j \Delta t_j \Delta W_j + \sigma_j^2 (\Delta W_j)^2.$$

在各系数及 f'' 有界时, 前两项求和的绝对值分别不超过

$$C \sum_j \Delta t_j^2 \leqslant C t |\Pi| \to 0, \qquad C \sum_j \Delta t_j |\Delta W_j| \leqslant C t \max_j |\Delta W_j| \to 0.$$

最后一项用加权二次变差得到

$$\sum_j f''(X_{t_j}) \sigma_j^2 (\Delta W_j)^2 \longrightarrow \int_0^t f''(X_s) \sigma_s^2 \, \mathrm{d}s.$$

阶梯系数只有有限个跳点, 可逐段使用前一命题.
为控制 Taylor 余项, 先停止在 $|X_s| \leqslant R$ 内, 记 f'' 在该紧区间稍大邻域上的连续模为 ω_R. 则

$$\sum_j |R_j| \leqslant \frac{1}{2} \omega_R(\max_j |\Delta X_j|) \sum_j (\Delta X_j)^2.$$

第一因子由连续性趋零, 第二因子由上述计算在概率意义下有界, 因此余项依概率趋零.
一般的 b, σ 先停止使 $\int |b| \, \mathrm{d}t$, $\int \sigma^2 \, \mathrm{d}t$ 及路径范围有控制, 再以有界阶梯过程分别在 $L^1(\mathrm{d}t \, \mathrm{d}\mathbb{P})$, $L^2(\mathrm{d}t \, \mathrm{d}\mathbb{P})$ 中逼近. 对应积分过程由普通积分估计和 Doob–Itô 等距在紧时间区间上一致依概率收敛. 停止后 f', f'' 有界且一致连续, 漂移项由 L^1 收敛, 随机积分项由等距收敛, 二阶项由 $\sigma_n^2 \to \sigma^2$ 的 L^1 收敛传到极限. 最后解除停止.
对 $f(t,x) \in C^{1,2}$, 逐步将 $f(t_{j+1}, X_{t_{j+1}}) - f(t_j, X_{t_j})$ 分成时间变化和空间变化; 时间变化的和趋于 $\int f_t \, \mathrm{d}t$, 空间部分按上述证明处理, 得到所述时空公式. 记号 $(\mathrm{d}W)^2 = \mathrm{d}t$ 正是这些求和极限的简写. □

定理 13.3.2　多维 Itô 公式

对 $X \in \mathbb{R}^n$, $W \in \mathbb{R}^m$, 令 $a = \sigma \sigma^{\mathrm{T}}$, 则

$$\mathrm{d}f(t, X_t) = \left(\partial_t f + \sum_i b_i \partial_i f + \frac{1}{2} \sum_{i,j} a_{ij} \partial_{ij} f \right) \mathrm{d}t + \sum_{i,k} \partial_i f \, \sigma_{ik} \, \mathrm{d}W_t^k.$$

证明: 多变量 Taylor 公式的二阶项为 $\frac{1}{2} \sum_{i,j} \partial_{ij} f \, \Delta X_i \Delta X_j$. 由于

$$\Delta X_i \Delta X_j = \sum_{k,l} \sigma_{ik} \sigma_{jl} \Delta W^k \Delta W^l + \text{含时间增量的项},$$

含时间增量的项与一维证明一样消失. 独立布朗分量的交叉二次变差为零, 单分量二次变差为时间,

因此保留下来的系数为

$$\sum_k \sigma_{ik}\sigma_{jk} = a_{ij}, \qquad \sum_{i,j,k} \sigma_{ik}\sigma_{jk}\partial_{ij} f = a : \nabla^2 f.$$

这正是公式中的二阶漂移项. 这里 $A : B = \operatorname{tr}(A^{\mathrm{T}} B)$; 当 Hessian 对称时也等于 $\sum_{i,j} a_{ij} b_{ji}$. □

推论 13.3.2　二次协变差与乘积公式

速记规则为 $\mathrm{d}t\,\mathrm{d}t = \mathrm{d}t\,\mathrm{d}W^i = 0$, $\mathrm{d}W^i\,\mathrm{d}W^j = \delta_{ij}\,\mathrm{d}t$. 乘积公式是

$$\mathrm{d}(XY) = X\,\mathrm{d}Y + Y\,\mathrm{d}X + \mathrm{d}[X,Y].$$

例如 $\mathrm{d}(tW_t) = W_t\,\mathrm{d}t + t\,\mathrm{d}W_t$, 故 $\int_0^t s\,\mathrm{d}W_s = tW_t - \int_0^t W_s\,\mathrm{d}s$; 对 $f(x) = x^2$ 则重新得到 $\int W\,\mathrm{d}W = (W_t^2 - t)/2$.

命题 13.3.3　Hermite 多项式与迭代积分

令 $h_n(x) = (-1)^n e^{x^2/2} \frac{\mathrm{d}^n}{\mathrm{d}x^n} \mathrm{e}^{-x^2/2}$, 生成函数为 $\mathrm{e}^{ux-u^2/2} = \sum_{n\geqslant 0} h_n(x) u^n/n!$. 定义 $H_n(x,a) = a^{n/2} h_n(x/\sqrt{a})(a > 0)$, $H_n(x,0) = x^n$, 其生成函数为 $\mathrm{e}^{ux-au^2/2}$. 于是 $\partial_a H_n + \frac{1}{2}\partial_{xx} H_n = 0$, $\partial_x H_n = nH_{n-1}$. Itô 公式给 $\mathrm{d}H_n(W_t,t) = nH_{n-1}(W_t,t)\,\mathrm{d}W_t$, 故

$$\int_{0<t_1<\cdots<t_n<t} \mathrm{d}W_{t_1} \cdots \mathrm{d}W_{t_n} = \frac{1}{n!} H_n(W_t,t).$$

证明: 先从 Rodrigues 公式推导生成函数. 在 x 处对 $\mathrm{e}^{-(x-u)^2/2}$ 作关于 u 的 Taylor 展开, 有

$$\mathrm{e}^{-(x-u)^2/2} = \sum_{n\geqslant 0} \frac{(-u)^n}{n!} \frac{\mathrm{d}^n}{\mathrm{d}x^n} \mathrm{e}^{-x^2/2}.$$

乘以 $\mathrm{e}^{x^2/2}$ 得到 $\mathrm{e}^{ux-u^2/2} = \sum h_n(x) u^n/n!$. 将 u 换为 $u\sqrt{a}$, x 换为 $x/\sqrt{a}$, 得到 H_n 的生成函数. 对该函数求导,

$$\left(\partial_a + \frac{1}{2}\partial_{xx}\right) \mathrm{e}^{ux-au^2/2} = 0, \qquad \partial_x e^{ux-au^2/2} = u e^{ux-au^2/2}.$$

比较 $u^n/n!$ 的系数即得两个多项式恒等式. 于是 Itô 公式中漂移恰好抵消, 得到

$$H_n(W_t,t) = n\int_0^t H_{n-1}(W_s,s)\,\mathrm{d}W_s \qquad (n \geqslant 1),$$

其中 $H_n(0,0) = 0$. 从 $H_0 = 1$ 出发归纳, 每次积分带出因子 n, 便得到 n 重迭代积分等于 $H_n(W_t,t)/n!$. □

例题 13.3.1 二重与三重 Itô 积分

二重积分为 $(W_t^2 - t)/2$. 三重积分可完全展开为

$$\begin{aligned}\int_0^t \left(\int_0^s W_u \,\mathrm{d}W_u\right) \mathrm{d}W_s &= \frac{1}{2}\int_0^t (W_s^2 - s)\,\mathrm{d}W_s \\ &= \frac{1}{2}\left(\frac{W_t^3}{3} - \int_0^t W_s\,\mathrm{d}s\right) - \frac{1}{2}\left(tW_t - \int_0^t W_s\,\mathrm{d}s\right) \\ &= \frac{1}{6}(W_t^3 - 3tW_t).\end{aligned}$$

第二行分别使用 $\mathrm{d}W_t^3 = 3W_t^2\,\mathrm{d}W_t + 3W_t\,\mathrm{d}t$ 及乘积公式 $\int_0^t s\,\mathrm{d}W_s = tW_t - \int_0^t W_s\,\mathrm{d}s$. 这些正是高阶数值方法中的随机 Taylor 项.

13.4 随机微分方程

13.4.1 适定性

定理 13.4.1 全局 Lipschitz 条件下的强解

设 b, σ 关于 (x,t) 可测, 对 x 全局 Lipschitz, 常数在 $t \in [0,T]$ 上一致, 并满足线性增长; X_0 对 $\mathcal{F}_0$ 可测且平方可积. 则式 (13.1) 存在唯一连续适应强解, 并有

$$\mathbb{E}\sup_{t\leqslant T}|X_t|^2 \leqslant C_T(1 + \mathbb{E}|X_0|^2).$$

定义 13.4.1 强解与弱解

“强解” 指在预先给定的概率空间, 布朗运动和初值上构造解. 弱解允许连概率空间与驱动布朗运动一起寻找; 这与数值方法里的强误差, 弱误差是两组不同概念.

证明: 使用 Picard 迭代 $X_t^{(0)} = X_0$,

$$X_t^{(k+1)} = X_0 + \int_0^t b(X_s^{(k)}, s)\,\mathrm{d}s + \int_0^t \sigma(X_s^{(k)}, s)\,\mathrm{d}W_s.$$

Cauchy–Schwarz, Doob 不等式和 Lipschitz 条件给

$$\mathbb{E}\sup_{s\leqslant t}|X_s^{(k+1)} - X_s^{(k)}|^2 \leqslant C\int_0^t \mathbb{E}\sup_{r\leqslant s}|X_r^{(k)} - X_r^{(k-1)}|^2\,\mathrm{d}s.$$

具体地, 漂移差满足 $\mathbb{E}\sup_{u\leqslant t}|\int_0^u \Delta b_s\,\mathrm{d}s|^2 \leqslant tK^2\int_0^t \mathbb{E}|\Delta X_s|^2\,\mathrm{d}s$, 随机积分差由 Doob 与等距不超过 $4K^2\int_0^t \mathbb{E}|\Delta X_s|^2\,\mathrm{d}s$. 记上述差的左端为 $D_k(t)$, 则 $D_{k+1}(t) \leqslant C_T\int_0^t D_k(s)\,\mathrm{d}s$, 第一步由线性增长有

$D_1(t) \leqslant C_T(1+\mathbb{E}|X_0|^2)t$. 归纳得到

$$D_k(T) \leqslant C_T(1+\mathbb{E}|X_0|^2)\frac{C_T^{k-1}T^k}{k!}.$$

因 $\sum_k D_k(T)^{1/2} < \infty$, 迭代序列在 $L^2(\Omega; C[0,T])$ 中 Cauchy. Lipschitz 条件和等距使两项积分均可传到极限, 因此极限满足积分方程, 并保持连续适应性.
若 X, Y 是相同初值, 相同布朗运动驱动的两个解, 同一估计给

$$F(t) := \mathbb{E}\sup_{u\leqslant t}|X_u - Y_u|^2 \leqslant C_T\int_0^t F(s)\,\mathrm{d}s.$$

Gronwall 引理给 $F=0$, 即路径唯一. 最后对解本身估计, 使用 $(a+b+c)^2 \leqslant 3(a^2+b^2+c^2)$ 和线性增长,

$$\mathbb{E}\sup_{u\leqslant t}|X_u|^2 \leqslant 3\mathbb{E}|X_0|^2 + C_T\int_0^t\left(1+\mathbb{E}\sup_{r\leqslant s}|X_r|^2\right)\mathrm{d}s.$$

再用 Gronwall 得到所述矩界; 必要时先停止, 再用 Fatou 引理解除停止. □

局部 Lipschitz 只能保证爆炸时刻之前的唯一解; 还需线性增长或 Lyapunov 条件等来排除有限时爆炸.

13.4.2 扩散过程

命题 13.4.1 扩散过程的局部条件矩

确定系数且具有适当唯一性的 SDE 解是连续 Markov 过程: 给定 X_s 后, 未来由 s 后的新布朗增量决定. 其局部条件矩为

$$\mathbb{E}[X_{t+h}-X_t \mid X_t = x] = b(x,t)h + o(h), \quad \mathbb{E}[(X_{t+h}-X_t)(X_{t+h}-X_t)^{\mathrm{T}} \mid X_t = x] = a(x,t)h + o(h).$$

因此 b 控制瞬时平均速度, $a = \sigma\sigma^{\mathrm{T}}$ 控制瞬时协方差增长. 即使 SDE 良好定义, 转移分布也不一定有密度; 非退化性或其他正则化条件才支持后续经典密度方程的写法.

证明: 从 $X_t = x$ 出发, 记短时增量为 $A_h + M_h$, 其中 $A_h = \int_t^{t+h} b(X_s,s)\,\mathrm{d}s$, $M_h = \int_t^{t+h}\sigma(X_s,s)\,\mathrm{d}W_s$. 随机积分条件均值为零, 所以

$$\frac{1}{h}\mathbb{E}_x(X_{t+h}-x) = \frac{1}{h}\int_t^{t+h}\mathbb{E}_x b(X_s,s)\,\mathrm{d}s \longrightarrow b(x,t).$$

在连续系数和局部矩界下, $\mathbb{E}|A_h|^2 = O(h^2)$, $\mathbb{E}|M_h|^2 = O(h)$. 交叉项由 Cauchy–Schwarz 为 $O(h^{3/2})$, 除以 h 后消失, 而矩阵形式的等距给出

$$\frac{1}{h}\mathbb{E}_x(M_h M_h^{\mathrm{T}}) = \frac{1}{h}\int_t^{t+h}\mathbb{E}_x[\sigma\sigma^{\mathrm{T}}](X_s,s)\,\mathrm{d}s \longrightarrow a(x,t).$$

这证明两个局部条件矩公式. 若转移密度存在, 也可写成

$$\lim_{u\downarrow s}\frac{1}{u-s}\int (x-y)p(x,u\mid y,s)\,\mathrm{d}x = b(y,s),$$

以及以 $(x-y)(x-y)^{\mathrm{T}}$ 替代一阶增量的矩阵公式. 局部扩散定义还可先把积分限于 $|x-y|<\varepsilon$, 再令 $\varepsilon\downarrow 0$; 在足以忽略大跳尾项的条件下, 两种写法一致. □

13.4.3 简单的 SDE

例题 13.4.1 Ornstein–Uhlenbeck 过程

Ornstein–Uhlenbeck(OU) 方程为 $\mathrm{d}X_t=-\gamma X_t\,\mathrm{d}t+\sigma\,\mathrm{d}W_t$. 对 $\mathrm{e}^{\gamma t}X_t$ 应用乘积公式, 因 $\mathrm{e}^{\gamma t}$ 是确定有界变差函数, 没有二次协变差项, 故

$$\mathrm{d}(\mathrm{e}^{\gamma t}X_t)=\gamma \mathrm{e}^{\gamma t}X_t\,\mathrm{d}t+\mathrm{e}^{\gamma t}\,\mathrm{d}X_t=\sigma \mathrm{e}^{\gamma t}\,\mathrm{d}W_t.$$

从 0 积分并乘以 $\mathrm{e}^{-\gamma t}$ 得

$$X_t=\mathrm{e}^{-\gamma t}X_0+\sigma\int_0^t e^{-\gamma(t-s)}\,\mathrm{d}W_s.$$

若 X_0 与未来增量独立, 则

$$\mathbb{E}X_t=\mathrm{e}^{-\gamma t}\mathbb{E}X_0,\quad \operatorname{Var}(X_t)=\mathrm{e}^{-2\gamma t}\operatorname{Var}(X_0)+\frac{\sigma^2}{2\gamma}(1-\mathrm{e}^{-2\gamma t}).$$

方差中的积分由等距计算: $\sigma^2\int_0^t e^{-2\gamma(t-s)}\,\mathrm{d}s=\sigma^2(1-\mathrm{e}^{-2\gamma t})/(2\gamma)$. 当 $s\leqslant t$ 时, 从 s 开始的同一解式给出

$$X_t=\mathrm{e}^{-\gamma(t-s)}X_s+\sigma\int_s^t e^{-\gamma(t-u)}\,\mathrm{d}W_u.$$

后一项与 X_s 独立, 因此 $\operatorname{Cov}(X_s,X_t)=\mathrm{e}^{-\gamma(t-s)}\operatorname{Var}(X_s)$. $\gamma>0$ 时平稳分布为 $N(0,\sigma^2/(2\gamma))$, 平稳协方差为 $\sigma^2\mathrm{e}^{-\gamma|t-s|}/(2\gamma)$. 若初值不是 Gaussian, 有限时刻解通常也不是 Gaussian; 确定初值或 Gaussian 初值时才可直接这样说.

例题 13.4.2 几何布朗运动

几何布朗运动 $\mathrm{d}N_t=rN_t\,\mathrm{d}t+\alpha N_t\,\mathrm{d}W_t$, $N_0>0$, 对 $\log N$ 应用 Itô 公式, 得到

$$N_t=N_0\mathrm{e}^{(r-\alpha^2/2)t+\alpha W_t},\quad \mathbb{E}N_t=N_0\mathrm{e}^{rt},\quad \operatorname{Var}(N_t)=N_0^2\mathrm{e}^{2rt}(\mathrm{e}^{\alpha^2 t}-1).$$

其对数变换的二阶修正为

$$\mathrm{d}\log N_t=\frac{1}{N_t}\,\mathrm{d}N_t-\frac{1}{2N_t^2}(\mathrm{d}N_t)^2=\left(r-\frac{\alpha^2}{2}\right)\mathrm{d}t+\alpha\,\mathrm{d}W_t.$$

> 严格地可先停止在 N_t 离零有正距离时, 再验证所给指数解始终为正, 因而全局有效. 利用 Gaussian 矩生成函数 $\mathbb{E}\mathrm{e}^{aW_t}=\mathrm{e}^{a^2t/2}$,
>
> $$\mathbb{E}N_t^2 = N_0^2\mathrm{e}^{(2r-\alpha^2)t}\mathrm{e}^{2\alpha^2 t} = N_0^2\mathrm{e}^{(2r+\alpha^2)t},$$
>
> 减去 $(\mathbb{E}N_t)^2$ 即得方差. 平均增长率是 r, 典型路径的长期对数增长率是 $r-\alpha^2/2$; 二者因涨落的非线性影响而不同.

13.4.4 物理布朗运动

Langevin 方程写为

$$\mathrm{d}x_t = v_t\,\mathrm{d}t, \qquad m\,\mathrm{d}v_t = (-\gamma v_t - \nabla V(x_t))\,\mathrm{d}t + \sqrt{2\sigma}\,\mathrm{d}W_t, \qquad \sigma = k_BT\gamma.$$

先不预设 σ 与 γ 的关系. 自由粒子的速度满足 $\mathrm{d}v_t=-(\gamma/m)v_t\,\mathrm{d}t+(\sqrt{2\sigma}/m)\,\mathrm{d}W_t$, 其每分量平稳方差由 OU 公式为 $\sigma/(m\gamma)$. 三维平稳平均动能因而为

$$\frac{1}{2}m\mathbb{E}|v|^2 = \frac{3\sigma}{2\gamma}.$$

令它等于平衡热力学的 $3k_BT/2$, 得到涨落–耗散关系 $\sigma=k_BT\gamma$, 于是每分量方差为 k_BT/m. 平稳速度自协方差为 $(k_BT/m)\mathrm{e}^{-\gamma|t-s|/m}$, 所以

$$\mathbb{E}|x_t-x_0|^2 = 2dD\left[t-\frac{m}{\gamma}(1-\mathrm{e}^{-\gamma t/m})\right], \qquad D=\frac{k_BT}{\gamma}.$$

在初始速度已经平稳时, 由 $x_t-x_0=\int_0^t v_s\,\mathrm{d}s$,

$$\begin{aligned}
\mathbb{E}|x_t-x_0|^2 &= \int_0^t\int_0^t \mathbb{E}(v_s\cdot v_r)\,\mathrm{d}r\,\mathrm{d}s \\
&= \frac{2dk_BT}{m}\int_0^t\int_0^s e^{-\gamma(s-r)/m}\,\mathrm{d}r\,\mathrm{d}s \\
&= \frac{2dk_BT}{\gamma}\int_0^t(1-\mathrm{e}^{-\gamma s/m})\,\mathrm{d}s \\
&= \frac{2dk_BT}{\gamma}\left[t-\frac{m}{\gamma}(1-\mathrm{e}^{-\gamma t/m})\right].
\end{aligned}$$

除以 $2dt$ 并令 $t\to\infty$, 即得 Einstein 关系; 其他具有有限矩的初始速度只改变衰减的瞬态项. 短时为惯性主导的 t^2, 长时为扩散的 t; $D=k_BT/\gamma$ 是 Einstein 关系.

小质量或适当高阻尼极限消去快速度变量, 得到 Smoluchowski 近似

$$\mathrm{d}X_t = -\frac{1}{\gamma}\nabla V(X_t)\,\mathrm{d}t + \sqrt{\frac{2k_BT}{\gamma}}\,\mathrm{d}W_t.$$

直观上是速度迅速局部平衡, 严格极限则需要时间尺度和系数条件.

13.5 Stratonovich 积分

定义 13.5.1 Stratonovich 积分

对适当连续半鞅被积过程, Stratonovich 积分由梯形和定义, 满足

$$\int_0^t f_s \circ \mathrm{d}W_s = \int_0^t f_s \,\mathrm{d}W_s + \frac{1}{2}[f, W]_t.$$

命题 13.5.1 积分约定与漂移修正

若 $\mathrm{d}X = b_S(X,t)\,\mathrm{d}t + \sigma(X,t) \circ \mathrm{d}W$, 则 $[\sigma(X,\cdot), W]_t = \int_0^t \sigma_x \sigma \,\mathrm{d}s$, 因此等价的 Itô 漂移为

$$b_I = b_S + \tfrac{1}{2}\sigma\sigma_x.$$

在多维情形, 记 $c_i = (\nabla_x \sigma : \sigma)_i = \sum_{j,k} \partial_k \sigma_{ij} \sigma_{kj}$, 于是 $b_I = b_S + c/2$. 若以右端点和定义积分, 对应完整的二次协变差修正, 漂移变成 $b_I = b_R + c$.

证明: 梯形和与左端和的差为

$$\frac{1}{2}\sum_j [f(t_{j+1}) - f(t_j)]\Delta W_j,$$

其极限是 $[f, W]_t/2$. 这先给出两种积分的一般换算. 现设待求的 Itô 形式为 $\mathrm{d}X = \alpha\,\mathrm{d}t + \beta\,\mathrm{d}W$, 对 $\sigma(X_t, t)$ 用 Itô 公式, 只需保留与 $\mathrm{d}W$ 的二次协变差部分, 得到

$$\mathrm{d}[\sigma(X,\cdot), W]_t = \partial_x \sigma(X_t, t)\beta_t \,\mathrm{d}t.$$

因此原 Stratonovich 方程等价于

$$\mathrm{d}X_t = \left(b_S + \frac{1}{2}\sigma_x \beta\right)\mathrm{d}t + \sigma\,\mathrm{d}W_t.$$

比较随机部分先得 $\beta = \sigma$, 再比较漂移得 $\alpha = b_S + \sigma_x\sigma/2$. 这说明修正中的两个 σ 分别来自被积函数的空间导数和过程本身的噪声系数.
多维时, 第 i 个方程的第 j 个噪声被积系数是 σ_{ij}, 其与 W^j 的协变差为

$$\mathrm{d}[\sigma_{ij}(X,\cdot), W^j]_t = \sum_k \partial_k \sigma_{ij}\, \sigma_{kj} \,\mathrm{d}t.$$

对 j 求和就得到 c_i. 右端点和减去左端点和没有 $1/2$, 所以给出完整修正 c. □

命题 13.5.2 Stratonovich 链式法则

Stratonovich 形式满足普通链式法则

$$\mathrm{d}f(t,X_t)=\partial_t f\,\mathrm{d}t+\nabla f\cdot b_S\,\mathrm{d}t+\nabla f\cdot\sigma\circ\mathrm{d}W_t.$$

把每个 Stratonovich 项转回 Itô 项即可验证, 二阶修正已经包含在圆圈积分中. 因此它一般不具有 Itô 积分的零均值和等距性质; $\int_0^T W\circ\mathrm{d}W=W_T^2/2$ 就有均值 $T/2$.

证明: 一维情况下, 将右端的圆圈积分转换为 Itô 积分,

$$\begin{aligned}f'(X)\sigma(X)\circ\mathrm{d}W&=f'\sigma\,\mathrm{d}W+\frac{1}{2}\partial_x(f'\sigma)\sigma\,\mathrm{d}t\\&=f'\sigma\,\mathrm{d}W+\frac{1}{2}(f''\sigma^2+f'\sigma'\sigma)\,\mathrm{d}t.\end{aligned}$$

与 $f'b_S\,\mathrm{d}t$ 合并, 正好等于对 Itô 漂移 $b_S+\sigma\sigma'/2$ 使用 Itô 公式的结果. 时间变量加上 $f_t\,\mathrm{d}t$ 即可. 多维逐分量计算产生同样的 Hessian 与漂移修正, 故普通形式的链式法则成立. □

评注 Wong–Zakai 近似 Wong–Zakai 现象解释其物理来源: 把布朗路径用标准的分段线性等光滑近似代替, 再解普通微分方程, 适当条件下极限是 Stratonovich SDE. 多维噪声时, 仅说近似路径一致趋于布朗路径还不够, 迭代积分的面积也必须正确逼近; 特殊近似可产生额外漂移. 有限相关时间的平滑噪声在相应极限中常给出这种解释, 但建模时仍要依据实际极限过程选择约定.

第十四章　与偏微分方程的联系

14.1　Liouville 方程

命题 14.1.1　Liouville 方程

设粒子满足 $\dot{X}_i = b(X_i, t)$, 经验测度为 $\mu_N = N^{-1}\sum_i \delta_{X_i}$. 在极限存在并具有密度 ψ 时, 密度在分布意义下满足 $\partial_t \psi + \nabla \cdot (b\psi) = 0$.

证明:　对光滑紧支测试函数 ϕ,

$$\frac{\mathrm{d}}{\mathrm{d}t}\int \phi \,\mathrm{d}\mu_N = \frac{1}{N}\sum_i \nabla\phi(X_i)\cdot b(X_i,t) = \int b\cdot\nabla\phi \,\mathrm{d}\mu_N.$$

若初始经验测度及流足以保证极限密度 ψ 存在, 把极限带入, 得到 $\frac{\mathrm{d}}{\mathrm{d}t}\int \phi\psi = \int b\cdot\nabla\phi\,\psi$. 由于 ϕ 紧支, 边界项为零,

$$\int b\cdot\nabla\phi\,\psi\,\mathrm{d}x = -\int \phi\,\nabla\cdot(b\psi)\,\mathrm{d}x.$$

因此 $\int \phi[\partial_t\psi + \nabla\cdot(b\psi)]\,\mathrm{d}x = 0$ 对所有测试函数成立, 得到

$$\partial_t\psi + \nabla\cdot(b\psi) = 0.$$

先对测试函数写式子, 避免直接对 Dirac 质量逐点求导. 若 $\nabla\cdot b = 0$, 方程简化为 $\partial_t\psi + b\cdot\nabla\psi = 0$, 密度沿轨线不变; 一般则沿轨线满足 $\frac{\mathrm{d}}{\mathrm{d}t}\psi(X_t,t) = -(\nabla\cdot b)\psi$, 反映流的压缩或膨胀. □

14.2　Fokker–Planck 方程

命题 14.2.1　Fokker–Planck 方程

考虑 $\mathrm{d}X = b(X,t)\,\mathrm{d}t + \sigma(X,t)\,\mathrm{d}W$, 令 $a = \sigma\sigma^{\mathrm{T}}$, 定义后向生成算子

$$L\phi = b\cdot\nabla\phi + \frac{1}{2}\sum_{i,j} a_{ij}\partial_{ij}\phi.$$

Itô 公式取期望后为 $\frac{\mathrm{d}}{\mathrm{d}t}\mathbb{E}\phi(X_t) = \mathbb{E}L\phi(X_t)$. 若密度 p 足够正则, 对漂移分部积分一次, 对扩散分部积

分两次, 即得

$$\partial_t p = L^* p = -\sum_i \partial_{\mathrm{i}}(b_i p) + \frac{1}{2}\sum_{i,j} \partial_{ij}(a_{ij} p). \tag{14.1}$$

即使不存在经典密度, 这个测试函数关系仍可作为测度解的弱形式. 条件转移密度 $p(x,t \mid y,s)$ 对终点变量 (x,t) 满足同一个前向方程, 初值为 δ_y; 与初始分布积分后得到边缘密度的演化. 标准 d 维布朗运动的密度为 $(2\pi t)^{-d/2}\mathrm{e}^{-|x-y|^2/(2t)}$, 维数不能只改指数里的范数而保留一维归一化常数.

证明: 固定起点 $X_s = y$. 将 Itô 公式从 s 积分到 t, 随机积分在可积条件下均值为零, 故

$$\mathbb{E}_{y,s} f(X_t) - f(y) = \int_s^t \mathbb{E}_{y,s}(L_\tau f)(X_\tau)\,\mathrm{d}\tau.$$

若转移密度存在, 这就是

$$\int f(x) p(x,t \mid y,s)\,\mathrm{d}x - f(y) = \int_s^t \int (L_\tau f)(x) p(x,\tau \mid y,s)\,\mathrm{d}x\,\mathrm{d}\tau.$$

下面把导数从测试函数移到密度. 对漂移部分,

$$\int b_{\mathrm{i}}(\partial_i f) p\,\mathrm{d}x = -\int f \partial_{\mathrm{i}}(b_i p)\,\mathrm{d}x.$$

对扩散部分, 第一次分部积分产生负号, 第二次再产生一个负号,

$$\int a_{ij} p\,\partial_{ij} f\,\mathrm{d}x = -\int \partial_{\mathrm{i}}(a_{ij} p)\partial_j f\,\mathrm{d}x = \int f \partial_{j\mathrm{i}}(a_{ij} p)\,\mathrm{d}x.$$

对指标求和便得 $(Lf, p) = (f, L^* p)$. 代回弱积分式, 对时间微分, 得到 $\partial_t p = L^* p$; $t \downarrow s$ 时 $X_t \to y$, 故初值为 δ_y. 注意当 a 随位置变化时, 两个导数作用于整个乘积 $a_{ij} p$, 不能只作用于 p.
若起始密度为 $p_0(y)$, 则边缘密度为 $p(x,t) = \int p(x,t \mid y,0) p_0(y)\,\mathrm{d}y$; 联合密度为 $p(x,t;y,s) = p(x,t \mid y,s) p(y,s)$. L_x^* 只作用于终点变量, 因而这两类密度也满足相同的前向方程. □

命题 14.2.2 自由能耗散

对 Brownian dynamics, 式 (14.1) 变为

$$\partial_t p = \frac{1}{\gamma}\nabla \cdot (p \nabla V + k_B T \nabla p).$$

定义自由能泛函

$$F[p] = \int (V p + k_B T p \log p)\,\mathrm{d}x, \qquad \mu = \frac{\delta F}{\delta p} = V + k_B T(1 + \log p).$$

概率流为 $j=-p\nabla\mu/\gamma$. 在衰减, 周期或无流边界条件下, 分部积分给

$$\frac{\mathrm{d}}{\mathrm{d}t}F[p(t)]=\int\mu\partial_t p=-\frac{1}{\gamma}\int p|\nabla\mu|^2\,\mathrm{d}x\leqslant 0.$$

这把随机动力学的平衡趋向与自由能耗散联系起来.

证明: 对光滑扰动 $p+\varepsilon\eta$, 在可微与可积条件下,

$$\left.\frac{\mathrm{d}}{\mathrm{d}\varepsilon}F[p+\varepsilon\eta]\right|_{\varepsilon=0}=\int[V+k_BT(1+\log p)]\eta\,\mathrm{d}x,$$

故变分导数为给出的化学势 μ. 令迁移速度 $u=-\nabla\mu/\gamma$, 则

$$j=pu=-\frac{p}{\gamma}\nabla[V+k_BT\log p]=-\frac{1}{\gamma}(p\nabla V+k_BT\nabla p).$$

代入质量守恒 $\partial_t p+\nabla\cdot j=0$, 得到 Smoluchowski 方程. 最后

$$\frac{\mathrm{d}F}{\mathrm{d}t}=-\int\mu\nabla\cdot j\,\mathrm{d}x=\int\nabla\mu\cdot j\,\mathrm{d}x=-\frac{1}{\gamma}\int p|\nabla\mu|^2\,\mathrm{d}x.$$

这里分别需要衰减, 周期抵消或 $j\cdot n=0$, 使边界项消失. □

若原 SDE 采用 Stratonovich 漂移 b, 先加入 $c/2$ 转为 Itô, 整理后得到

$$\partial_t p=-\partial_{\mathrm{i}}(b_i p)+\frac{1}{2}\partial_i\big[\sigma_{ik}\partial_j(\sigma_{jk}p)\big],$$

本式重复指标求和. 一维若采用右端点漂移 b_R, 则 $b_I=b_R+\sigma\sigma'$, 前向方程可写为 $\partial_t p=-\partial_x(b_Rp)+\frac{1}{2}\partial_x(\sigma^2\partial_x p)$. 这些方程不同, 是因为同样写作 b,σ 时代表的过程不同; 正确转换后描述同一过程的方程一致.

具体的指标整理如下. 令 $c_i=\partial_j\sigma_{ik}\sigma_{jk}$, Stratonovich 方程的扩散相关部分为

$$\begin{aligned}&\frac{1}{2}\partial_i\partial_j(\sigma_{ik}\sigma_{jk}p)-\frac{1}{2}\partial_{\mathrm{i}}(c_ip)\\&\quad=\frac{1}{2}\partial_i\left[(\partial_j\sigma_{ik})\sigma_{jk}p+\sigma_{ik}\partial_j(\sigma_{jk}p)-(\partial_j\sigma_{ik})\sigma_{jk}p\right]\\&\quad=\frac{1}{2}\partial_i[\sigma_{ik}\partial_j(\sigma_{jk}p)].\end{aligned}$$

若采用右端点解释, 则漂移为 b_R+c, 一般多维公式为

$$\partial_t p=-\partial_i[(b_{R,i}+c_i)p]+\frac{1}{2}\partial_i\partial_j[(\sigma\sigma^{\mathrm{T}})_{ij}p].$$

一维中, $\frac{1}{2}\partial_x^2(\sigma^2p)-\partial_x(\sigma\sigma'p)=\frac{1}{2}\partial_x(\sigma^2\partial_x p)$, 因而得到前面的散度形式.

14.3 边界条件

把式 (14.1) 写为连续性方程 $\partial_t p + \nabla \cdot j = 0$, 其中

$$j_i = b_i p - \frac{1}{2}\sum_j \partial_j (a_{ij} p).$$

对区域 R 积分, $\frac{\mathrm{d}}{\mathrm{d}t}\int_R p = -\int_{\partial R} j \cdot n$, 因此 $j \cdot n$ 表示向外的净概率流. 它与离散链边上的净流 $\mu_i p_{ij} - \mu_j p_{ji}$, 连续时间链的 $\mu_i q_{ij} - \mu_j q_{ji}$ 对应.

为从转移概率理解这个通量, 设 R_1, R_2 分割整个状态空间 (或其外边界没有流出), 共同界面为 S_{12}. 记

$$P_{1\to 2}(h) = \int_{R_2} \mathrm{d}x \int_{R_1} \mathrm{d}y\, p(x, t+h; y, t),$$
$$P_{2\to 1}(h) = \int_{R_1} \mathrm{d}x \int_{R_2} \mathrm{d}y\, p(x, t+h; y, t).$$

将粒子按时间 t 与 $t+h$ 所在区域分类, 留在 R_1 内的概率相消, 得到精确质量平衡

$$P_{2\to 1}(h) - P_{1\to 2}(h) = \int_{R_1} [p(x, t+h) - p(x, t)]\, \mathrm{d}x.$$

除以 h 取极限, 再用连续性方程和散度定理. 若 n 指向从 R_2 到 R_1, 它与 R_1 在界面上的外法向相反, 所以

$$J_{2\to 1} = \lim_{h\downarrow 0} \frac{P_{2\to 1}(h) - P_{1\to 2}(h)}{h} = \int_{S_{12}} j \cdot n\, \mathrm{d}S.$$

单方向穿越量可能含更大的短时项, 净流才是这个有限极限.

反射边界要求 $j \cdot n = 0$, 保持总质量; 有漂移或变扩散系数时, 它不等价于 $\partial_n p = 0$. 相应路径模型需要加入边界局部时间推动的反射项, 而不是让普通无约束 SDE 自然 “反弹”. 吸收边界对非退化扩散通常写 $p|_{\partial D} = 0$, 剩余质量就是尚未出界的概率; 周期边界把对面的流与密度匹配, 表示在环面上运动. 具体退化扩散的边界分类更细, 不能强加同一边界公式.

14.4 后向方程

命题 14.4.1 后向 Kolmogorov 方程

固定终点时刻 t 和终值函数 f, 令 $u(y, s) = \mathbb{E}_{y,s} f(X_t)$. 由 Markov 性, $u(y, s) = \mathbb{E}_{y,s} u(X_{s+h}, s+h)$. 对右侧用 Itô 公式展开, 常数项相消后得到

$$\partial_s u + L_s u = 0, \qquad u(y, t) = f(y).$$

由于 $u(y, s) = \int f(x) p(x, t \mid y, s)\, \mathrm{d}x$, 转移密度对起点变量满足

$$\partial_s p(x, t \mid y, s) + L_{y,s} p(x, t \mid y, s) = 0.$$

前向方程作用于分布的终点变量, 用 L^*; 后向方程作用于起点处的观测期望, 用 L. 若改用经过的时

长 $r=t-s$, 符号相应变为 $\partial_r u = Lu$, 这并非两种理论矛盾.

证明: 固定终点 t, 对 $s<s+h<t$, Markov 性与塔式性质给

$$\mathbb{E}_{y,s}u(X_{s+h},s+h)=\mathbb{E}_{y,s}\mathbb{E}[f(X_t)\mid\mathcal{F}_{s+h}]=\mathbb{E}_{y,s}f(X_t)=u(y,s).$$

另一方面, 对 $u(X_r,r)$ 在 $[s,s+h]$ 上使用 Itô 公式并取期望,

$$0=\int_s^{s+h}\mathbb{E}_{y,s}[(\partial_r+L_r)u](X_r,r)\,\mathrm{d}r.$$

除以 h, 在相应连续性与局部矩控制下令 $h\downarrow 0$, 得到 $u_s+L_s u=0$. 将 $u=\int f(x)p(x,t\mid y,s)\,\mathrm{d}x$ 代入, 导数只作用于 y,s, 因此

$$\int f(x)[\partial_s+L_{y,s}]p(x,t\mid y,s)\,\mathrm{d}x=0.$$

由 f 任意得到密度后向方程, 终值 $p(x,t\mid y,t)=\delta(x-y)$ 来自零时长转移. □

14.5 不变分布与详细平衡

定义 14.5.1 不变密度与详细平衡

不变密度 p_s 满足 $L^{*}p_s=0$, 即 $\nabla\cdot j_s=0$. 详细平衡在通常可逆扩散框架中对应 $j_s=0$, 条件更强. 例如圆周上的常漂移扩散有均匀不变密度, 但存在绕圆的恒定非零概率流, 所以不具时间反演对称性.

例题 14.5.1 Gibbs 平衡态

对 Brownian dynamics, 令 $j_s=0$ 得

$$p_s\nabla V+k_BT\nabla p_s=0,\qquad p_s=Z^{-1}\mathrm{e}^{-V/(k_BT)}.$$

推导时先在 $p_s>0$ 的区域除以 p_s, 得到 $\nabla\log p_s=-\nabla V/(k_BT)$, 积分即得 $\log p_s=-V/(k_BT)+C$, 归一化确定 $\mathrm{e}^{C}=1/Z$. 只有 $Z<\infty$ 才是概率密度. 形式上解出一个指数函数不等于已经存在归一化平衡态. 适当边界下, 可逆性等价于 L 在 $L^2(p_s)$ 内积中自伴; 例如

$$-\int fLg\,p_s\,\mathrm{d}x=\frac{k_BT}{\gamma}\int\nabla f\cdot\nabla g\,p_s\,\mathrm{d}x.$$

14.6 扩散过程的进一步主题

14.6.1 半群与后向方程

定义 14.6.1 Markov 半群与 Feller 半群

对时间齐次扩散, 定义 $T_tf(x)=\mathbb{E}_xf(X_t)$. Markov 性给 $T_{t+s}=T_tT_s$, $T_0=I$, 且 T_t 保正, 保持常数并在上确界范数下收缩. 若它在 $C_0(\mathbb{R}^d)$ 上强连续, 称 Feller 半群; C_0 指在无穷远趋零的连续函数, 不是 “紧支函数集合”, 尽管紧支连续函数在其中稠密.

定义 14.6.2 无穷小生成元

生成元定义在极限存在的函数上: $Af=\lim_{t\downarrow0}(T_tf-f)/t$, 这里是相应函数空间的范数极限. 对足够好的扩散和 $f\in C_c^2$, Itô 公式表明 $Af=Lf$. 半群恒等式导出 $\partial_tT_tf=AT_tf=T_tAf$(对定义域和正则性满足要求的 f), 所以 $u=T_tf$ 解 $u_t=Au$, $u(0)=f$.

半群性质与生成元方程: Markov 性及时间齐次性给出

$$T_tT_sf(x)=\mathbb{E}_x[(T_sf)(X_t)]=\mathbb{E}_x\mathbb{E}[f(X_{t+s})\mid\mathcal{F}_t]=T_{t+s}f(x).$$

保正性与收缩性直接来自期望, $|T_tf|\leqslant\|f\|_\infty$. 在 b,σ 有界且 Lipschitz 时, 解对初值的均方连续依赖保证 T_tf 连续; 有界系数又给出统一的 $\mathbb{E}_x|X_t-x|^2\leqslant C(t+t^2)$, 所以当 $|x|\to\infty$, 到达任意固定紧集的概率趋零, T_tf 仍在无穷远趋零.
由于 $f\in C_0$ 一致连续, 对任意 $\delta>0$,

$$|T_tf(x)-f(x)|\leqslant\omega_f(\delta)+2\|f\|_\infty\mathbb{P}_x(|X_t-x|>\delta)\leqslant\omega_f(\delta)+\frac{C\|f\|_\infty(t+t^2)}{\delta^2}.$$

先令 $t\downarrow0$ 再令 $\delta\downarrow0$, 得到上确界范数下的强连续性.
对 $f\in C_c^2$, Itô 公式给 $T_tf-f=\int_0^tT_sLf\,\mathrm{d}s$. 由强连续性, 除以 t 后趋于 Lf, 故 $Af=Lf$. 对任意 $f\in D(A)$,

$$\frac{T_hT_tf-T_tf}{h}=T_t\frac{T_hf-f}{h}\longrightarrow T_tAf.$$

所以 $T_tf\in D(A)$ 且 $AT_tf=T_tAf$; 同一个差商又是 ∂_tT_tf, 故得到后向初值方程. □

14.6.2 Feynman–Kac 公式

定理 14.6.1 Feynman–Kac 公式

对有界连续 q, 有界适当 f, 令

$$v(x,t)=\mathbb{E}_x\left[\mathrm{e}^{\int_0^tq(X_s)\,\mathrm{d}s}f(X_t)\right].$$

则在经典解所需的系数正则性下,

$$\partial_t v = Av + qv, \qquad v(x,0) = f(x). \tag{14.2}$$

证明: 先从概率表达式导出方程. 记 $Z_t = \exp(\int_0^t q(X_r)\,\mathrm{d}r)$. Markov 性使

$$\mathbb{E}_x v(X_h, t) = \mathbb{E}_x\left[\mathrm{e}^{\int_h^{t+h} q(X_r)\,\mathrm{d}r} f(X_{t+h})\right] = \mathbb{E}_x[Z_{t+h} f(X_{t+h}) \mathrm{e}^{-\int_0^h q(X_r)\,\mathrm{d}r}].$$

因此

$$\begin{aligned}\frac{T_h v(x,t) - v(x,t)}{h} &= \frac{v(x,t+h) - v(x,t)}{h} \\ &\quad + \mathbb{E}_x\left[Z_{t+h} f(X_{t+h}) \frac{\mathrm{e}^{-\int_0^h q(X_r)\,\mathrm{d}r} - 1}{h}\right].\end{aligned}$$

路径连续性及 q 连续给出最后的差商趋于 $-q(x)$; q, f 有界使其被可积常数控制. 若系数正则性保证 v 属于相应经典解或生成元定义域, 令 $h \downarrow 0$, 得到

$$Av = \partial_t v - q(x) v,$$

也就是所述方程, 且 $v(x,0) = f(x)$.
反过来, 若 v 为有界经典解, 固定终点时长 t, 令

$$M_s = \exp\left(\int_0^s q(X_r)\,\mathrm{d}r\right) v(X_s, t-s), \qquad 0 \leqslant s \leqslant t.$$

指数因子是有限变差过程, 故无交叉二次变差. 乘积公式展开为

$$\begin{aligned}\mathrm{d}M_s &= \mathrm{e}^{\int_0^s q(X_r)\,\mathrm{d}r}[-v_t + Av + qv](X_s, t-s)\,\mathrm{d}s \\ &\quad + \mathrm{e}^{\int_0^s q(X_r)\,\mathrm{d}r} \nabla v(X_s, t-s)\sigma(X_s)\,\mathrm{d}W_s.\end{aligned}$$

漂移为零, 停止后是鞅; 有界 v 和有界上方的 q 使停止值在固定时间区间上一致有界, 可解除停止. 因此 $M_0 = \mathbb{E}_x M_t$, 给出相同概率表示并保证该类解的唯一性. 若 $q = -c \leqslant 0$, 指数可解释为存活或贴现权重.
若没有噪声, X_s 是确定性特征线, 期望退化为单个值 $\mathrm{e}^{\int_0^t q(X_s)\,\mathrm{d}s} f(X_t)$; 有噪声时则对随机特征线平均. □

评注 指数权重的可积性 当指数写成 $+\int q$ 时, 控制其上界或指数可积性才有助于保证期望有限. 只给 q 一个下界, 不足以保证该 Feynman–Kac 期望存在.

推论 14.6.1 带源项的终值问题

带源项的后向终值问题 $u_s + Lu - cu = -g$, $u(\cdot, T) = f$, 相应表示为

$$u(x,s) = \mathbb{E}_{x,s}\left[\mathrm{e}^{-\int_s^T c(X_r,r)\,\mathrm{d}r} f(X_T) + \int_s^T e^{-\int_s^r c(X_v,v)\,\mathrm{d}v} g(X_r,r)\,\mathrm{d}r\right].$$

它由同样的乘积公式加入积分补偿项得到, 统一了贴现, 累积成本和终值收益.

14.6.3 首次出界时间

命题 14.6.2 有限平均出界时间

令 $\tau_D = \inf\{t \geqslant 0 : X_t \notin D\}$. 在有界光滑区域, 系数有界且一致椭圆的条件下, $\mathbb{E}_x\tau_D < \infty$.

证明: 取 $h(x) = -C\mathrm{e}^{\lambda x_1}$: 因 $a_{11} \geqslant \kappa > 0$, 足够大的 λ 使

$$Ah = -Ce^{\lambda x_1}(\lambda b_1 + \tfrac{1}{2}\lambda^2 a_{11}) \leqslant -1$$

在 D 内成立. 具体地, 若 $|b_1| \leqslant B$, 取 $\lambda > 2B/\kappa$, 则 $\lambda b_1 + \lambda^2 a_{11}/2 \geqslant -\lambda B + \lambda^2\kappa/2 > 0$; 再增大 C 使整个乘积至少为 1. h 及其导数在有界区域上有界, 故在 $t \wedge \tau_D$ 的随机积分平方可积, 其期望为零. 于是

$$\mathbb{E}_x h(X_{t\wedge\tau_D}) - h(x) = \mathbb{E}_x \int_0^{t\wedge\tau_D} Ah(X_s)\,\mathrm{d}s \leqslant -\mathbb{E}_x(t \wedge \tau_D).$$

因此 $\mathbb{E}_x(t \wedge \tau_D) \leqslant h(x) - \inf_{\bar{D}} h \leqslant \sup_{\bar{D}} h - \inf_{\bar{D}} h$. 单调收敛给出 $\mathbb{E}_x\tau_D < \infty$, 从而 $\tau_D < \infty$ 几乎必然. □

定理 14.6.2 Dynkin 公式与边值问题

停止的 Itô 公式给 Dynkin 公式

$$\mathbb{E}_x f(X_\tau) - f(x) = \mathbb{E}_x \int_0^\tau Af(X_s)\,\mathrm{d}s,$$

先对有界停止时和局部化过程成立, 放开停止需有界性或一致可积控制. 若 $Au = 0$ 于 D 且边界值为 f, 则 $u(x) = \mathbb{E}_x f(X_{\tau_D})$. 若 $Au = -g$, 边界值为 f, 则

$$u(x) = \mathbb{E}_x\left[f(X_{\tau_D}) + \int_0^{\tau_D} g(X_s)\,\mathrm{d}s\right].$$

证明: 先说明 Dynkin 公式的停止步骤. 若 $f \in C_c^2$, 系数局部有界且 $\mathbb{E}_x\tau < \infty$, 则 Af 及 $\nabla f\sigma$ 有

界. 对 $\tau\wedge n$ 应用停止的 Itô 公式, 随机积分满足

$$\mathbb{E}_x\left|\int_0^{\tau\wedge n}\nabla f(X_s)\sigma(X_s)\,\mathrm{d}W_s\right|^2\leqslant C\mathbb{E}_x\tau<\infty.$$

它的期望为零, 故公式对 $\tau\wedge n$ 成立. f 有界使左端可用控制收敛, $|\int_0^{\tau\wedge n}Af\,\mathrm{d}s|\leqslant\|Af\|_\infty\tau$ 使右端也可用控制收敛, 得到 τ 的公式.

对于边值问题, 假设 D 有界, 边界 C^2, 系数在 $\bar D$ 上 Lipschitz, a 一致椭圆, 且 $u\in C^2(D)\cap C(\bar D)$ 解 $Au=-g$, $u|_{\partial D}=f$, 其中 f,g 连续有界. 取光滑紧内区域 $D_k\uparrow D$, 令 τ_k 为其出界时刻. 先对 $t\wedge\tau_k$ 使用 Itô 公式, 则

$$u(x)=\mathbb{E}_x u(X_{t\wedge\tau_k})+\mathbb{E}_x\int_0^{t\wedge\tau_k}g(X_s)\,\mathrm{d}s.$$

先令 $k\to\infty$, 再令 $t\to\infty$. 路径连续性给出 $X_{\tau_D}\in\partial D$; u 在闭包有界, 源项受 $\|g\|_\infty\tau_D$ 支配, 且前一命题已证明其可积, 因而得到所述表示. $g=0$ 即为调和边值问题. 对于标准 Brownian 生成元 $A=\Delta/2$, $Au=0$ 与 $\Delta u=0$ 等价, 故仍是边界数据在布朗出界点的期望. □

例题 14.6.1　区间的平均出界时间

取 $g=1,f=0$, 平均出界时间 T 满足 $AT=-1$, $T|_{\partial D}=0$. 对标准一维布朗运动, $A=\frac12\partial_{xx}$; 从 $(-a,a)$ 出界的平均时间为 a^2-x^2. 若使用 $A=D\partial_{xx}$, 则为 $(a^2-x^2)/(2D)$, 这个二倍因子不可遗漏.

第十五章　SDE 数值方法: 基础

15.1　数值格式

考虑标量自治方程 $\mathrm{d}X_t = b(X_t)\,\mathrm{d}t + \sigma(X_t)\,\mathrm{d}W_t$. 记

$$L^1 f = bf' + \tfrac{1}{2}\sigma^2 f'', \qquad L^2 f = \sigma f',$$

于是 $\mathrm{d}f(X_t) = (L^1 f)(X_t)\,\mathrm{d}t + (L^2 f)(X_t)\,\mathrm{d}W_t$. 在一个步长 $h = t_{n+1} - t_n$ 内, 对积分方程中的 $b(X_s), \sigma(X_s)$ 再用 Itô 公式, 得到

$$\begin{aligned} X_{t_{n+1}} = X_{t_n} &+ b(X_{t_n})h + \sigma(X_{t_n})\Delta W_n \\ &+ \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} (L^2\sigma)(X_r)\,\mathrm{d}W_r\,\mathrm{d}W_s \\ &+ \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} (L^1\sigma)(X_r)\,\mathrm{d}r\,\mathrm{d}W_s + \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} (L^2 b)(X_r)\,\mathrm{d}W_r\,\mathrm{d}s \\ &+ \int_{t_n}^{t_{n+1}} \int_{t_n}^{s} (L^1 b)(X_r)\,\mathrm{d}r\,\mathrm{d}s. \end{aligned}$$

继续迭代便得到 Itô–Taylor 展开. 第一项双重随机积分的均方根尺度为 h, 时间–随机混合项为 $h^{3/2}$, 纯时间双积分为 h^2; 不是把每个积分号都按同一个 h 计阶.

令 $W_t^0 = t, W_t^1 = W_t$, 特征指标 $i = (i_1, \cdots, i_k)$ 从外到内表示

$$I_{\mathrm{i}}(g) = \int_{t_n}^{t_{n+1}} \mathrm{d}W_{s_1}^{i_1} \int_{t_n}^{s_1} \mathrm{d}W_{s_2}^{i_2} \cdots \int_{t_n}^{s_{k-1}} g(X_{s_k})\,\mathrm{d}W_{s_k}^{i_k}.$$

这里指标 $0, 1$ 表示积分器, L^1, L^2 则表示前述两个微分算子. 若指标长度为 $l(i)$, 其中零的数目为 $n(i)$, 则对应均方根尺度为 $h^{[l(i)+n(i)]/2}$.

> **评注**　**四种显式格式**　Euler–Maruyama(EM) 保留最前面的冻结系数项:
>
> $$X_{n+1} = X_n + b(X_n)h + \sigma(X_n)\Delta W_n, \qquad \Delta W_n = \sqrt{h}\,\xi_n, \quad \xi_n \overset{\text{i.i.d.}}{\sim} N(0,1).$$
>
> Milstein 再保留 $L^2\sigma = \sigma\sigma'$ 的双重随机积分:
>
> $$X_{n+1} = X_n + bh + \sigma\Delta W_n + \tfrac{1}{2}\sigma\sigma'[(\Delta W_n)^2 - h].$$

这一修正项可直接计算. 对 $U_s = W_s - W_{t_n}$ 使用 Itô 公式,

$$\mathrm{d}(U_s^2) = 2U_s\,\mathrm{d}W_s + \mathrm{d}s, \qquad \int_{t_n}^{t_{n+1}}\int_{t_n}^{s} \mathrm{d}W_r\,\mathrm{d}W_s = \frac{1}{2}[(\Delta W_n)^2 - h].$$

因此只需一个正态增量就能精确生成这个二重积分.
本节未注明时系数在 X_n 处取值. 无导数的 Runge–Kutta 型替代为

$$\widehat{X}_n = X_n + \sigma(X_n)\sqrt{h},$$

$$X_{n+1} = X_n + b(X_n)h + \sigma(X_n)\Delta W_n + \frac{\sigma(\widehat{X}_n) - \sigma(X_n)}{2\sqrt{h}}[(\Delta W_n)^2 - h].$$

Taylor 展开给出

$$\sigma(\widehat{X}_n) - \sigma(X_n) = \sigma'(X_n)\sigma(X_n)\sqrt{h} + \frac{1}{2}\sigma''(X_n)\sigma(X_n)^2 h + O(h^{3/2}).$$

除以 $2\sqrt{h}$ 后, 首项正是 Milstein 的系数 $\sigma\sigma'/2$, 其余系数误差为 $O(\sqrt{h})$. 再乘均方根为 $O(h)$, 条件均值为零的 $[(\Delta W_n)^2 - h]$, 局部新增随机误差为 $O(h^{3/2})$. 这说明差商替代的来源.
继续展开得到以下高阶格式

$$\begin{aligned} X_{n+1} = X_n &+ bh + \sigma\Delta W_n + \tfrac{1}{2}\sigma\sigma'[(\Delta W_n)^2 - h] \\ &+ \sigma b'\Delta Z_n + \tfrac{1}{2}(bb' + \tfrac{1}{2}\sigma^2 b'')h^2 \\ &+ (b\sigma' + \tfrac{1}{2}\sigma^2\sigma'')(h\Delta W_n - \Delta Z_n) \\ &+ \tfrac{1}{6}\sigma[\sigma\sigma'' + (\sigma')^2][(\Delta W_n)^3 - 3h\Delta W_n]. \end{aligned} \tag{15.1}$$

各项的系数及积分分别来自

$$L^2 b = \sigma b', \qquad L^1 b = bb' + \tfrac{1}{2}\sigma^2 b'',$$
$$L^1\sigma = b\sigma' + \tfrac{1}{2}\sigma^2\sigma'', \qquad L^2 L^2\sigma = \sigma[(\sigma')^2 + \sigma\sigma''].$$

纯时间双积分等于 $h^2/2$; 三重纯随机积分则为

$$\int_{t_n}^{t_{n+1}}\int_{t_n}^{s}\int_{t_n}^{r} \mathrm{d}W_u\,\mathrm{d}W_r\,\mathrm{d}W_s = \frac{1}{6}[(\Delta W_n)^3 - 3h\Delta W_n].$$

例如对 $U_s^3 - 3(s - t_n)U_s$ 用 Itô 公式, 其微分为 $3[U_s^2 - (s - t_n)]\,\mathrm{d}W_s$, 再代入二重积分公式即得此式.
其中 $\Delta Z_n = \int_{t_n}^{t_{n+1}} (W_s - W_{t_n})\,\mathrm{d}s$. 交换确定性–随机积分得 $\Delta Z_n = \int_{t_n}^{t_{n+1}} (t_{n+1} - r)\,\mathrm{d}W_r$, 所以它和 ΔW_n 联合 Gaussian,

$$\mathrm{Var}(\Delta Z_n) = \int_{t_n}^{t_{n+1}} (t_{n+1} - r)^2\,\mathrm{d}r = \frac{h^3}{3}, \qquad \mathrm{Cov}(\Delta Z_n, \Delta W_n) = \int_{t_n}^{t_{n+1}} (t_{n+1} - r)\,\mathrm{d}r = \frac{h^2}{2}.$$

因 $\Delta Z_n - \frac{h}{2}\Delta W_n$ 与 ΔW_n 的协方差为零, 且其方差为 $h^3/3 - h^3/4 = h^3/12$, 二者由联合 Gaussian

性相互独立. 用独立标准正态 ξ_n,η_n 可精确联合生成

$$\Delta W_n=\sqrt{h}\xi_n,\qquad \Delta Z_n=\frac{h}{2}\Delta W_n+\sqrt{\frac{h^3}{12}}\eta_n.$$

另一种混合积分为 $\int_{t_n}^{t_{n+1}}(s-t_n)\,\mathrm{d}W_s=h\Delta W_n-\Delta Z_n$; 不能独立抽这三个量, 因为它们共享同一段布朗路径.

定义 15.1.1 强收敛与弱收敛

若用同一布朗运动耦合数值解和真解, 并有

$$\max_{t_n\leqslant T}(\mathbb{E}|X_n-X_{t_n}|^2)^{1/2}\leqslant Ch^{\alpha},$$

称强 α 阶; 若对适当光滑测试函数 f,

$$\max_{t_n\leqslant T}|\mathbb{E}f(X_n)-\mathbb{E}f(X_{t_n})|\leqslant C_f h^{\beta},$$

称弱 β 阶. 对连续插值也可给相应时间上确界版本, 须说明插值方式. 这里 $\sup_t\mathbb{E}|e_t|^2$ 与 $\mathbb{E}\sup_t|e_t|^2$ 是不同指标. Lipschitz f 下强误差给 $|\mathbb{E}f(X_n)-\mathbb{E}f(X_{t_n})|\leqslant \mathrm{Lip}(f)(\mathbb{E}|e_n|^2)^{1/2}$, 所以至少保证相同的弱误差上界; 弱误差常因正负抵消具有更高阶.

命题 15.1.1 Itô–Taylor 截断规则

在足够的导数界, 增长与矩条件下, 强 Taylor 截断使用

$$S_\alpha=\{i:l(i)+n(i)\leqslant 2\alpha\}\cup\{i:l(i)=n(i)=\alpha+\tfrac12\},\quad \alpha=\tfrac12,1,\tfrac32,\cdots.$$

第二部分仅在该长度为整数时有项, 补足有非零平均的纯时间贡献. 弱 Taylor 截断可按 $W_\beta=\{i:l(i)\leqslant\beta\}$ 构造; 用更便宜的离散随机变量替代迭代积分时, 还要满足相应联合矩匹配条件. 一般定理与细致正则条件见 Kloeden–Platen[23], 这些条件同时保证展开余项可积及解的矩估计.

格式	一般强阶	一般弱阶
Euler–Maruyama	1/2	1
标量 Milstein	1	1
上述无导数 Runge–Kutta 型格式	1	1
式 (15.1)	3/2	2

评注 高阶格式的收敛阶 上述高阶格式的一般强收敛阶为 3/2, 弱收敛阶为 2. 例如一般乘性噪声还存在四重纯随机积分, 其单步均方根为 h^2; 它在式 (15.1) 中未被保留, 跨 $O(h^{-1})$ 步累积后通常限制全局强阶为 3/2.

例题 15.1.1 高阶格式的强误差

以下用 $\mathrm{d}X = X\,\mathrm{d}W$, $X_0 = 1$ 验证这一收敛阶. 其真解为 $X_T = \mathrm{e}^{W_T - T/2}$, 式 (15.1) 每步乘以

$$R_h = 1 + \Delta W + \tfrac{1}{2}[(\Delta W)^2 - h] + \tfrac{1}{6}[(\Delta W)^3 - 3h\Delta W].$$

记 $H_0 = 1$, $H_1 = \Delta W$, $H_2 = (\Delta W)^2 - h$, $H_3 = (\Delta W)^3 - 3h\Delta W$. Gaussian 矩或 Hermite 正交性给

$$\mathbb{E} H_j H_k = \mathbf{1}_{j=k} k! h^k, \qquad \mathrm{e}^{\Delta W - h/2} = \sum_{k=0}^{\infty} \frac{H_k(\Delta W, h)}{k!}.$$

因此求平方期望或与完整指数相乘时, 交叉项均消失, 得到 $\mathbb{E}R_h^2 = 1 + h + h^2/2 + h^3/6 =: P_3(h)$, 且 $\mathbb{E}[\mathrm{e}^{\Delta W - h/2} R_h] = P_3(h)$. 对 $N = T/h$ 个独立步求乘积, 得到精确的全局均方误差

$$\mathbb{E}|X_N - X_T|^2 = \mathrm{e}^T - P_3(h)^{T/h} \sim \frac{T\mathrm{e}^T}{24} h^3.$$

具体地, $\mathbb{E}X_T^2 = \mathrm{e}^T$, $\mathbb{E}X_N^2 = P_3(h)^N$, $\mathbb{E}X_N X_T = P_3(h)^N$, 三项相减即为上式. 又有

$$P_3(h) = \mathrm{e}^h - \frac{h^4}{24} + O(h^5), \qquad \log P_3(h) = h - \frac{h^4}{24} + O(h^5),$$

所以 $P_3(h)^{T/h} = \mathrm{e}^T[1 - Th^3/24 + O(h^4)]$. 取平方根恰为 $h^{3/2}$, 从而在这个简单反例上已排除一般强二阶的说法.

评注 多维迭代随机积分 多维 Milstein 含 $\int (W_s^j - W_{t_n}^j)\,\mathrm{d}W_s^k$. 同分量可化为平方增量, 不同分量含 Lévy 面积, 不能仅由终点增量恢复; 但可以用专门算法近似, 并非数学上不能模拟. 噪声向量场满足交换条件时, 反对称面积项可抵消, 格式明显简化.

15.2 强收敛

本节先考虑加性噪声方程

$$\mathrm{d}X_t = b(X_t)\,\mathrm{d}t + \mathrm{d}W_t, \qquad |b(x) - b(y)| \leqslant L|x - y|, \quad |b(x)|^2 \leqslant L(1 + |x|^2).$$

初值满足 $\mathbb{E}|X_0|^2 < \infty$. 为简化下标, 先取等步长 h; 一般网格可将每一步的 h 换成 h_n, 最后用最大步长估计.

定义 15.2.1 Euler–Maruyama 连续插值

数值解与真解使用相同初值和布朗运动, 定义

$$\bar{X}_t = X_n + b(X_n)(t - t_n) + W_t - W_{t_n}, \qquad t_n \leqslant t < t_{n+1}.$$

于是 $\bar X_{t_n}=X_n$, 每段上 $\mathrm{d}\bar X_t=b(X_n)\,\mathrm{d}t+\mathrm{d}W_t$. 对 $f\in C^2$, Itô 公式具体写成

$$f(\bar X_t)=f(X_n)+\int_{t_n}^{t}\Big[f'(\bar X_s)b(X_n)+\frac12 f''(\bar X_s)\Big]\,\mathrm{d}s+\int_{t_n}^{t}f'(\bar X_s)\,\mathrm{d}W_s.$$

这就是连续数值插值所满足的离散 Itô 公式, 漂移系数冻结在 X_n, 测试函数的导数仍在 $\bar X_s$ 处计算.

引理 15.2.1　二阶矩与增量估计

存在与步长无关的 $K_1(T),K_2(T)$, 使

$$\sup_{t\leqslant T}\mathbb{E}|X_t|^2\leqslant K_1(T),\qquad \mathbb{E}|X_t-X_{t_n}|^2\leqslant K_2(T)h\quad(t_n\leqslant t\leqslant t_{n+1}).$$

证明: 对 X_t^2 用 Itô 公式并取期望, 随机积分经停止后均值为零, 得到

$$\begin{aligned}\mathbb{E}|X_t|^2&=\mathbb{E}|X_0|^2+2\int_0^t\mathbb{E}[X_sb(X_s)]\,\mathrm{d}s+t\\&\leqslant\mathbb{E}|X_0|^2+T+\int_0^t\mathbb{E}|X_s|^2\,\mathrm{d}s+L\int_0^t(1+\mathbb{E}|X_s|^2)\,\mathrm{d}s.\end{aligned}$$

Gronwall 不等式给出可取的常数

$$K_1(T)=(\mathbb{E}|X_0|^2+T+LT)\mathrm{e}^{(L+1)T}.$$

这些界也使停止时可趋于无穷. 另一方面, 积分方程给

$$X_t-X_{t_n}=\int_{t_n}^{t}b(X_s)\,\mathrm{d}s+W_t-W_{t_n}.$$

由 $|a+b|^2\leqslant 2|a|^2+2|b|^2$ 及积分 Cauchy–Schwarz 不等式,

$$\begin{aligned}\mathbb{E}|X_t-X_{t_n}|^2&\leqslant 2(t-t_n)\int_{t_n}^{t}\mathbb{E}|b(X_s)|^2\,\mathrm{d}s+2(t-t_n)\\&\leqslant 2Lh^2(1+K_1(T))+2h.\end{aligned}$$

若 $h\leqslant h_0$, 可取 $K_2(T)=2Lh_0(1+K_1(T))+2$, 从而常数不依赖实际网格. □

命题 15.2.2　基本强误差估计

在上述条件下, Euler–Maruyama 格式满足

$$\max_{t_n\leqslant T}\mathbb{E}|X_{t_n}-X_n|^2\leqslant Ch.$$

证明: 令 $e_n = X_{t_n} - X_n$. 真解和数值解的噪声增量相消, 故

$$e_{n+1} = e_n + R_n, \qquad R_n = \int_{t_n}^{t_{n+1}} [b(X_t) - b(X_n)]\,\mathrm{d}t.$$

先将平方的交叉项按 $2ab \leqslant ha^2 + h^{-1}b^2$ 估计, 再对时间积分使用 Cauchy–Schwarz:

$$\begin{aligned}
|e_{n+1}|^2 &\leqslant (1+h)|e_n|^2 + (1+h^{-1})|R_n|^2 \\
&\leqslant (1+h)|e_n|^2 + L^2(1+h)\int_{t_n}^{t_{n+1}} |X_t - X_n|^2\,\mathrm{d}t \\
&\leqslant [1 + h + 2L^2(1+h)h]|e_n|^2 + 2L^2(1+h)\int_{t_n}^{t_{n+1}} |X_t - X_{t_n}|^2\,\mathrm{d}t.
\end{aligned}$$

上一个引理于是给出

$$\mathbb{E}|e_{n+1}|^2 \leqslant (1 + L_1 h)\mathbb{E}|e_n|^2 + L_2 h^2,$$

其中可取 $L_1 = 1 + 2L^2(1+h_0)$, $L_2 = 2L^2(1+h_0)K_2(T)$. 从 $e_0 = 0$ 迭代并求几何和,

$$\mathbb{E}|e_n|^2 \leqslant L_2 h^2 \sum_{j=0}^{n-1} (1 + L_1 h)^j = \frac{L_2}{L_1} h[(1 + L_1 h)^n - 1] \leqslant \frac{L_2}{L_1}(\mathrm{e}^{L_1 T} - 1)h.$$

这给出强 $1/2$ 阶估计. □

命题 15.2.3 加性噪声下的一阶强收敛

若进一步有 $b \in C^2$, b', b'' 有界, 则上述误差可加强为 $\max_n \mathbb{E}|e_n|^2 \leqslant Ch^2$.

证明: 将误差写成

$$e_{n+1} = a_n + D_n + M_n, \qquad a_n = e_n + h[b(X_{t_n}) - b(X_n)],$$

其中对 $b(X_s)$ 使用 Itô 公式并交换积分, 得到

$$\begin{aligned}
D_n &= \int_{t_n}^{t_{n+1}} (t_{n+1} - r)(L^1 b)(X_r)\,\mathrm{d}r, \\
M_n &= \int_{t_n}^{t_{n+1}} (t_{n+1} - r) b'(X_r)\,\mathrm{d}W_r.
\end{aligned}$$

由二阶矩界, $L^1 b = bb' + b''/2$ 的线性增长及 Itô 等距,

$$\mathbb{E}|D_n|^2 \leqslant Ch^4, \qquad \mathbb{E}|M_n|^2 \leqslant Ch^3, \qquad \mathbb{E}(M_n \mid \mathcal{F}_{t_n}) = 0.$$

又因 a_n 对 $\mathcal{F}_{t_n}$ 可测, $\mathbb{E}a_nM_n=0$, 且 $|a_n|\leqslant(1+Lh)|e_n|$. 因此

$$\begin{aligned}\mathbb{E}|e_{n+1}|^2&\leqslant\mathbb{E}|a_n|^2+2|\mathbb{E}a_nD_n|+2\mathbb{E}|D_n|^2+2\mathbb{E}|M_n|^2\\&\leqslant(1+h)\mathbb{E}|a_n|^2+(h^{-1}+2)\mathbb{E}|D_n|^2+2\mathbb{E}|M_n|^2\\&\leqslant(1+Ch)\mathbb{E}|e_n|^2+Ch^3.\end{aligned}$$

再求几何和即得 $\mathbb{E}|e_n|^2\leqslant Ch^2$. 提升一阶的关键是先利用随机余项的条件零均值; 若一开始对全部余项取绝对值, 就会失去这一抵消. □

评注　乘性噪声的强误差　一般全局 Lipschitz 系数下, 连续误差满足

$$e_t=\int_0^t[b(X_s)-b(X_{n_s})]\,\mathrm{d}s+\int_0^t[\sigma(X_s)-\sigma(X_{n_s})]\,\mathrm{d}W_s,$$

其中 n_s 满足 $t_{n_s}\leqslant s<t_{n_s+1}$, 第二个 X_{n_s} 表示数值节点. 将每个系数差拆成真解与插值的差, 插值与其左端值的差, 由积分 Cauchy–Schwarz, Doob 不等式及 $\mathbb{E}|\bar{X}_s-X_{n_s}|^2\leqslant Ch$, 得到

$$\mathbb{E}\sup_{r\leqslant t}|e_r|^2\leqslant C\int_0^t\mathbb{E}\sup_{u\leqslant s}|e_u|^2\,\mathrm{d}s+Ch.$$

Gronwall 给出一般 EM 的强 $1/2$ 阶. 加性情形中 $\sigma'=0$, EM 恰与 Milstein 一致, 因此在相应光滑条件下可取得前一命题的一阶精度.

15.3 弱收敛

命题 15.3.1　一步弱误差

仍设 $\sigma=1$. 真解的生成元与从 x 出发的冻结生成元分别为

$$Af(y)=b(y)f'(y)+\frac{1}{2}f''(y),\qquad A_xf(y)=b(x)f'(y)+\frac{1}{2}f''(y).$$

对足够光滑并满足增长条件的 b,f, 两种一步期望之差为 $O(h^2)$.

证明:　反复对 f,Af,A^2f 用 Itô 公式并取期望,

$$\begin{aligned}\mathbb{E}_xf(X_h)&=f(x)+\int_0^h\mathbb{E}_xAf(X_s)\,\mathrm{d}s\\&=f(x)+hAf(x)+\int_0^h\int_0^s\mathbb{E}_xA^2f(X_r)\,\mathrm{d}r\,\mathrm{d}s\\&=f(x)+hAf(x)+\frac{h^2}{2}A^2f(x)+R_h,\end{aligned}$$

其中

$$R_h = \int_0^h \int_0^s \int_0^r \mathbb{E}_x A^3 f(X_u)\,\mathrm{d}u\,\mathrm{d}r\,\mathrm{d}s.$$

若 $A^3 f$ 的相应矩在有限时域内有界, 则 $|R_h| \leqslant C(1+|x|^q)h^3$. 冻结过程 $Y_s = x + b(x)s + W_s$ 同理满足

$$\mathbb{E} f(Y_h) = f(x) + hA_x f(x) + \frac{h^2}{2} A_x^2 f(x) + O((1+|x|^q)h^3).$$

将导数逐项展开,

$$\begin{aligned} A^2 f &= (bb' + \tfrac{1}{2}b'')f' + (b^2 + b')f'' + bf''' + \tfrac{1}{4}f'''', \\ A_x^2 f(y) &= b(x)^2 f''(y) + b(x)f'''(y) + \tfrac{1}{4}f''''(y). \end{aligned}$$

一阶项在 $y = x$ 处相同, 故

$$\mathbb{E} f(Y_h) - \mathbb{E}_x f(X_h) = -\frac{h^2}{2}\left[(bb' + \tfrac{1}{2}b'')f' + b'f''\right](x) + O((1+|x|^q)h^3).$$

如果只需要 $O(h^2)$ 上界, 展开到二重积分并控制四阶导数即可, 不必假设六阶导数. 此处更高阶的余项形式用于显示首项系数. □

定义 15.3.1 多项式增长函数类

记 $C_P^m(\mathbb{R}^d, \mathbb{R})$ 为 C^m 函数中直到 m 阶的各偏导数均至多按多项式增长的函数类, 即存在 K, p 使

$$|\partial^j f(x)| \leqslant K(1+|x|^{2p}), \qquad |j| \leqslant m.$$

若测试函数不有界, 误差估计同时需要初值的足够高阶矩. 以下可取确定初值, 或假设 X_0 具有所有所用阶数的有限矩.

引理 15.3.2 高阶矩的统一界

在全局 Lipschitz, 线性增长条件下, 若 $\mathbb{E}|X_0|^{2r} < \infty$, 则对 $h \leqslant h_0$,

$$\sup_{t \leqslant T} \mathbb{E}|X_t|^{2r} + \max_{t_n \leqslant T} \mathbb{E}|X_n|^{2r} + \sup_{t \leqslant T} \mathbb{E}|\bar{X}_t|^{2r} \leqslant C_{r,T}.$$

证明: 真解对 $|x|^{2r}$ 用 Itô 公式, 漂移项为 $2rX^{2r-1}b(X) + r(2r-1)X^{2r-2}$. 由线性增长及 Young 不等式, 它不超过 $C(1+|X|^{2r})$; 停止, 取期望并用 Gronwall 得真解矩界.

对数值节点, 给定 $X_n = x$, 令 $a = x + hb(x)$, 则

$$\mathbb{E}[(a + \sqrt{h}\xi)^{2r} \mid X_n = x] = \sum_{j=0}^{r} \binom{2r}{2j} a^{2r-2j} h^j \mathbb{E}\xi^{2j},$$

奇数项因正态分布对称而为零. 由 $|b(x)| \leqslant C(1 + |x|)$ 和二项式展开, $|a|^{2r} \leqslant (1 + Ch)|x|^{2r} + Ch$; 其余项由 $h^j \leqslant Ch$ 及低阶幂的 Young 估计控制. 于是

$$\mathbb{E}|X_{n+1}|^{2r} \leqslant (1 + Ch)\mathbb{E}|X_n|^{2r} + Ch.$$

离散 Gronwall 得节点矩界. 插值在一个步长内也是 $X_n + (t - t_n)b(X_n) + \sqrt{t - t_n}\xi$, 同样的条件矩计算给出最后一项. □

引理 15.3.3 后向方程的正则性

设 $\beta \geqslant 2$ 为整数, $b, f \in C_P^{2\beta}$, 且 b 的 1 至 2β 阶导数一致有界. 则

$$u(x,t) = \mathbb{E}_x f(X_t), \qquad \partial_t u = b u_x + \frac{1}{2} u_{xx}, \quad u(x,0) = f(x),$$

在任意有限时域内具有连续时间导数, 且 $u(\cdot, t) \in C_P^{2\beta}$, 各增长界可取为关于 $t \leqslant T$ 一致的常数.

证明: 加性噪声下, 对每条连续噪声路径, 初值导数满足普通变分方程. 记 $J_k = \partial_x^k X_t^x$, 则

$$\begin{aligned}
\dot{J}_1 &= b'(X_t^x) J_1, & J_1(0) &= 1,\\
\dot{J}_2 &= b'(X_t^x) J_2 + b''(X_t^x) J_1^2, & J_2(0) &= 0,\\
\dot{J}_3 &= b' J_3 + 3b'' J_1 J_2 + b''' J_1^3, & J_3(0) &= 0,\\
\dot{J}_4 &= b' J_4 + 4b'' J_1 J_3 + 3b'' J_2^2 + 6b''' J_1^2 J_2 + b'''' J_1^4, & J_4(0) &= 0.
\end{aligned}$$

高阶方程由乘积法则继续得到; 每阶 J_k 只在线性项 $b' J_k$ 中出现, 其余项由低阶 J_j 与有界的 b 的导数组成. 由 $|J_1| \leqslant \mathrm{e}^{LT}$ 起递推使用 Gronwall, 可得全部 J_k 的路径一致界 $C_{k,T}$.
因此可在期望内对初值求导, 例如

$$\begin{aligned}
u_x &= \mathbb{E}[f'(X_t^x) J_1],\\
u_{xx} &= \mathbb{E}[f''(X_t^x) J_1^2 + f'(X_t^x) J_2],\\
u_{xxx} &= \mathbb{E}[f''' J_1^3 + 3 f'' J_1 J_2 + f' J_3],\\
u_{xxxx} &= \mathbb{E}[f'''' J_1^4 + 6 f''' J_1^2 J_2 + 3 f'' J_2^2 + 4 f'' J_1 J_3 + f' J_4].
\end{aligned}$$

差商的控制收敛由前一矩引理及导数的多项式增长保证, 所得导数仍按 x 的多项式增长. 最后由 Markov 性和 Itô 公式,

$$\frac{u(x,t+\delta)-u(x,t)}{\delta}=\frac{1}{\delta}\int_0^{\delta}\mathbb{E}_x[Au(\cdot,t)(X_s)]\,\mathrm{d}s\longrightarrow Au(x,t).$$

增长界允许取极限, 并保证所得时间导数连续. 一般维数可用多重指标作同样处理. □

定理 15.3.1 Euler–Maruyama 的一阶弱收敛

在以上正则性和所需初值矩条件下,

$$\max_{t_n\leqslant T}|\mathbb{E}f(X_n)-\mathbb{E}f(X_{t_n})|\leqslant C_f h.$$

证明: 固定终点 $t_N\leqslant T$, 设 $v(x,t)=u(x,t_N-t)$. 则

$$\widetilde{L}v:=v_t+b(x)v_x+\frac{1}{2}v_{xx}=0,\qquad v(x,t_N)=f(x).$$

对真解用 Itô 公式, 漂移为零, 故 $\mathbb{E}v(X_0,0)=\mathbb{E}f(X_{t_N})$. 对数值插值逐段用 Itô 公式并求和, 得到精确误差恒等式

$$e_N:=\mathbb{E}f(X_N)-\mathbb{E}f(X_{t_N})=\sum_{n=0}^{N-1}\int_{t_n}^{t_{n+1}}\mathbb{E}\{[b(X_n)-b(\bar{X}_s)]v_x(\bar{X}_s,s)\}\,\mathrm{d}s.$$

这里不能直接用 $\mathbb{E}|\bar{X}_s-X_n|=O(h^{1/2})$, 否则只得到半阶. 令 $g=bv_x$, $k=v_x$, 将被积式改写为

$$g(X_n,t_n)-g(\bar{X}_s,s)+b(X_n)[k(\bar{X}_s,s)-k(X_n,t_n)].$$

在第 n 个区间, 定义冻结时空算子

$$\mathcal{A}_n=\partial_t+b(X_n)\partial_x+\frac{1}{2}\partial_{xx}.$$

再次用 Itô 公式,

$$g(\bar{X}_s,s)-g(X_n,t_n)=\int_{t_n}^{s}(\mathcal{A}_n g)(\bar{X}_r,r)\,\mathrm{d}r+\int_{t_n}^{s}g_x(\bar{X}_r,r)\,\mathrm{d}W_r,$$

k 同理. 给定 $\mathcal{F}_{t_n}$, 两个随机积分均值为零; 乘上 $\mathcal{F}_{t_n}$ 可测的 $b(X_n)$ 后取总期望仍为零. 因而

$$e_N=\sum_{n=0}^{N-1}\int_{t_n}^{t_{n+1}}\int_{t_n}^{s}\mathbb{E}[-\mathcal{A}_n g(\bar{X}_r,r)+b(X_n)\mathcal{A}_n k(\bar{X}_r,r)]\,\mathrm{d}r\,\mathrm{d}s.$$

所需导数具体为

$$\mathcal{A}_n k = v_{xt} + b(X_n) v_{xx} + \tfrac{1}{2} v_{xxx},$$
$$\mathcal{A}_n g = b v_{xt} + b(X_n)(b' v_x + b v_{xx}) + \tfrac{1}{2}(b'' v_x + 2 b' v_{xx} + b v_{xxx}).$$

又由后向方程 $v_{xt} = -b' v_x - b v_{xx} - v_{xxx}/2$. 前面的正则性引理使这些项至多多项式增长, 高阶矩引理于是给出其期望绝对值的一致上界 C. 最终

$$|e_N| \leqslant C \sum_{n=0}^{N-1} \int_{t_n}^{t_{n+1}} (s - t_n)\, \mathrm{d}s = \frac{C}{2} N h^2 \leqslant \frac{CT}{2} h.$$

常数对所有 $t_N \leqslant T$ 一致, 所以得到全局一阶弱收敛. □

例题 15.3.1　OU 二阶矩的弱近似

设 $\mathrm{d}X = -\tfrac{1}{2} X\,\mathrm{d}t + \mathrm{d}W$, $X_0 = 0$, 目标 $u = \mathbb{E}X_1^2 = 1 - \mathrm{e}^{-1}$. 取 $h = 1/M$, EM 为 $X_{n+1,k} = (1 - h/2) X_{n,k} + \sqrt{h} R_{n,k}$, $R_{n,k}$ 独立标准正态. 最终估计 $u_{N,h} = N^{-1} \sum_k X_{M,k}^2$. 其数值分布方差可精确递推: 令 $a = 1 - h/2$, 则

$$\mathbb{E}X_M^2 = h \sum_{j=0}^{M-1} a^{2j} = \frac{h(1 - a^{2M})}{1 - a^2}.$$

这允许把时间离散偏差与抽样误差分开核对. 课程讲义给出的 $M = 2000$ 时的数值结果如下 [1].

N	100	200	300	400	500	600
$u_{N,h}$	.6586	.6563	.6785	.6234	.6407	.6320
报告的绝对误差	.0265	.0242	.0464	.0087	.0086	.0001

单次结果不随 N 单调改善, 这是随机抽样的正常现象. 验证弱阶应让抽样置信区间足够窄, 或使用本例的精确递推; 否则测到的主要是 $N^{-1/2}$ 噪声.

第十六章　SDE 数值方法: 进阶

16.1　隐式格式

刚性漂移常需要小步长才能保持显式格式稳定. 漂移隐式 Euler 为

$$X_{n+1} = X_n + b(X_{n+1})h + \sigma(X_n)\Delta W_n,$$

定义半隐式格式

$$X_{n+1} = X_n + [\alpha b(X_n) + (1-\alpha)b(X_{n+1})]h + \sigma(X_n)\Delta W_n.$$

α 是显式漂移权重, 不要与另一些文献的 θ 约定反过来. 隐式方程还需要唯一可解, 例如小步长下的压缩映射, 或单边 Lipschitz, 单调性等条件.

例题 16.1.1　右端点隐式格式

若连扩散也用右端点, 须先把 Itô 漂移变成右端约定的 $b-c$, 其中 $c_i = \sum_{j,k} \partial_k \sigma_{ij}\sigma_{kj}$:

$$X_{n+1} = X_n + [b(X_{n+1}) - c(X_{n+1})]h + \sigma(X_{n+1})\Delta W_n.$$

取 $b=0, \sigma(x)=x$, 则 $c(x)=x$, 正确代数结果为

$$X_{n+1} = \frac{X_n}{1+h-\Delta W_n}.$$

设 ΔW_n 的密度为 $p_h(z) = (2\pi h)^{-1/2}\mathrm{e}^{-z^2/(2h)}$. 在 $z_0 = 1+h$ 的一个邻域上, 连续正函数 p_h 有正下界 c, 从而对任意给定的 $X_n = x \neq 0$,

$$\mathbb{E}(|X_{n+1}| \mid X_n = x) = |x| \int_{\mathbb{R}} \frac{p_h(z)}{|1+h-z|}\,\mathrm{d}z \geqslant c|x| \int_{z_0-\delta}^{z_0+\delta} \frac{\mathrm{d}z}{|z_0 - z|} = \infty.$$

给定非零 X_n, Gaussian 密度在 $\Delta W_n = 1+h$ 附近严格正, 故绝对一阶矩含 $\int_{-\delta}^{\delta} |z|^{-1}\,\mathrm{d}z = \infty$. 问题是接近分母零点造成不可积, 并不是恰好等于零有正概率.

命题 16.1.1 均方稳定性

对 $\mathrm{d}X=\lambda X\,\mathrm{d}t+\mu X\,\mathrm{d}W$, 真解满足 $\mathbb{E}X_t^2=X_0^2\mathrm{e}^{(2\lambda+\mu^2)t}$, 均方稳定条件为 $2\lambda+\mu^2<0$. EM 一步平方均值放大因子为 $(1+\lambda h)^2+\mu^2 h$, 需小于 1; 漂移隐式格式则为 $(1+\mu^2 h)/(1-\lambda h)^2$. 当 $\lambda<0$ 且真系统均方稳定时, 后者对所有 $h>0$ 小于 1. 上述因子可逐项计算: EM 满足 $X_{n+1}=X_n(1+\lambda h+\mu\Delta W_n)$, 利用增量独立且 $\mathbb{E}\Delta W_n=0$, $\mathbb{E}(\Delta W_n)^2=h$ 即得平方均值因子. 隐式格式满足

$$X_{n+1}=\frac{1+\mu\Delta W_n}{1-\lambda h}X_n.$$

其稳定性由

$$(1-\lambda h)^2-(1+\mu^2 h)=-(2\lambda+\mu^2)h+\lambda^2h^2>0$$

给出. 真解的矩方程则为 $\frac{\mathrm{d}}{\mathrm{d}t}\mathbb{E}X_t^2=(2\lambda+\mu^2)\mathbb{E}X_t^2$. 这解释隐式漂移对刚性稳定性的改善, 但不意味着大步长仍有足够精度.

16.2 外推方法

命题 16.2.1 Richardson 外推

Talay–Tubaro 型弱误差展开在足够光滑与矩条件下写成

$$e(h)=\mathbb{E}g(X_T^h)-\mathbb{E}g(X_T)=C_{g,\beta}h^\beta+C_{g,\beta+1}h^{\beta+1}+O(h^{\beta+2}).$$

具体地,

$$\begin{aligned}2^\beta e(h/2)&=C_{g,\beta}h^\beta+\tfrac{1}{2}C_{g,\beta+1}h^{\beta+1}+O(h^{\beta+2}),\\ 2^\beta e(h/2)-e(h)&=-\tfrac{1}{2}C_{g,\beta+1}h^{\beta+1}+O(h^{\beta+2}).\end{aligned}$$

因此, 用步长 $h/2$ 的展开乘 2^β 再减去粗步长展开, 便消去了首项. 因此正确的 Richardson 外推期望是

$$\frac{2^\beta\mathbb{E}g(X_T^{h/2})-\mathbb{E}g(X_T^h)}{2^\beta-1}=\mathbb{E}g(X_T)+O(h^{\beta+1}).$$

上述系数使真值项的总系数等于 1. 只有 $O(h^\beta)$ 上界不能保证存在该渐近展开. 用随机样本实现时, 粗细路径应耦合以降低差值方差; 消除离散偏差不会自动消除抽样误差, 线性组合还可能放大它.

16.3 多层蒙特卡罗方法

设目标 $Y_E=\mathbb{E}f(X_T)$, 普通 EM–MC 为 $Y_{h,N}=N^{-1}\sum_{k=1}^N f(X_{T/h}^{(k)})$. 独立样本下有精确分解

$$\mathbb{E}|Y_{h,N}-Y_E|^2=|\mathbb{E}f(X_{T/h})-Y_E|^2+\frac{\mathrm{Var}(f(X_{T/h}))}{N}.$$

此恒等式来自写 $Y_{h,N}-Y_E=(Y_{h,N}-\mathbb{E}Y_{h,N})+(\mathbb{E}Y_{h,N}-Y_E)$; 平方后交叉项均值为零, 而独立样本平均的方差等于单样本方差除以 N. 弱一阶且方差一致有界时为 $O(h^2+N^{-1})$. 成本为 $O(Nh^{-1})$, 固定成本 K 时 $N\asymp Kh$, 最小化 $h^2+(Kh)^{-1}$ 得 $h\asymp K^{-1/3}$, MSE 为 $O(K^{-2/3})$. 更具体地, 若成本 $K=C_3Nh^{-1}$, 误差上界为 $C_1h^2+C_2N^{-1}$, 代入 $N=Kh/C_3$ 后对 h 求导得

$$2C_1h-\frac{C_2C_3}{Kh^2}=0,\qquad h^3=\frac{C_2C_3}{2C_1K}.$$

故 $h\asymp K^{-1/3}$, $N\asymp K^{2/3}$, 两种误差均为 $O(K^{-2/3})$. 达到均方根误差 ε 时, 需要 $h=O(\varepsilon)$, $N=O(\varepsilon^{-2})$, 因此成本为 $O(\varepsilon^{-3})$.

定义 16.3.1 多层蒙特卡罗估计

多层蒙特卡罗方法分别估计粗层期望及相邻层之间的期望差. 令 $h_l=TM^{-l}$, $F_l=f(X_{l,M^l})$, $F_{-1}=0$, 则

$$\mathbb{E}F_L=\sum_{l=0}^{L}\mathbb{E}(F_l-F_{l-1}),\qquad \widehat{Y}_L=\sum_{l=0}^{L}Y_l,\quad Y_l=\frac{1}{N_l}\sum_{k=1}^{N_l}(F_l^{(k)}-F_{l-1}^{(k)}).$$

同一对粗细路径使用同一布朗路径: 每个粗增量是相应 M 个细增量之和. 不同层的样本组独立; “层间独立” 与 “每层内部粗细高度相关” 必须同时满足. 记 $V_l=\mathrm{Var}(F_l-F_{l-1})$, 单样本成本 C_l, 则

$$\mathrm{Var}(\widehat{Y}_L)=\sum_l V_l/N_l,\qquad K=\sum_l N_lC_l.$$

若粗细独立生成, V_l 一般不会趋零, 方法的优势也就消失.

命题 16.3.1 最优层间样本分配

若各层 $V_l,C_l>0$, 将整数 N_l 放松为正实数, 则固定成本 K 时, 方差最小的分配为

$$N_l=\frac{K\sqrt{V_l/C_l}}{\sum_{j=0}^{L}\sqrt{V_jC_j}}.$$

等价地, 若方差预算为 $\varepsilon^2/2$, 成本最优分配为

$$N_l=\frac{2}{\varepsilon^2}\sqrt{\frac{V_l}{C_l}}\sum_{j=0}^{L}\sqrt{V_jC_j},\tag{16.1}$$

对应的最小连续成本为 $2\varepsilon^{-2}(\sum_l\sqrt{V_lC_l})^2$. 实际样本数向上取整.

证明: 固定成本时, Lagrange 函数为

$$\mathcal{L}(N,\nu)=\sum_l\frac{V_l}{N_l}+\nu\left(\sum_l N_lC_l-K\right).$$

逐个对 N_l 求导, 得 $-V_l/N_l^2+\nu C_l=0$, 即 $N_l=\nu^{-1/2}\sqrt{V_l/C_l}$. 代回约束,

$$\nu^{-1/2}\sum_l \sqrt{V_lC_l}=K,$$

从而得第一式. 其全局最优性还可由 Cauchy–Schwarz 直接验证:

$$\left(\sum_l \sqrt{V_lC_l}\right)^2=\left(\sum_l \sqrt{\frac{V_l}{N_l}}\sqrt{N_lC_l}\right)^2\leqslant\left(\sum_l \frac{V_l}{N_l}\right)K,$$

等号条件正是上述比例关系.
反过来, 在方差预算下写 $N_l=c\sqrt{V_l/C_l}$, 则

$$\sum_l \frac{V_l}{N_l}=\frac{1}{c}\sum_l \sqrt{V_lC_l}=\frac{\varepsilon^2}{2}.$$

解出 c 即得式 (16.1), 再代入 $\sum_l N_lC_l$ 得最小成本. 当 $C_l=h_l^{-1}$ 时, 第一式成为

$$N_l=\lambda\sqrt{V_lh_l},\qquad \lambda=K\left(\sum_{j=0}^{L}\sqrt{V_jh_j^{-1}}\right)^{-1}.$$

若某层方差为零, 其期望修正是常数, 可单独精确处理, 无须按上述公式分配随机样本. □

定理 16.3.1 EM 多层估计的成本

设 f Lipschitz, EM 满足强 1/2 阶和弱一阶误差界, 且单样本成本 $C_l\asymp h_l^{-1}$. 则存在样本分配, 使

$$\mathbb{E}|\widehat{Y}_L-Y_E|^2\leqslant\varepsilon^2,\qquad K=O(\varepsilon^{-2}(\log\varepsilon^{-1})^2).$$

证明: 同一层中的粗细近似与同一个真解耦合. 令 $F=f(X_T)$, 则

$$\begin{aligned}\operatorname{Var}(F_l-F)&\leqslant\mathbb{E}|F_l-F|^2\leqslant\operatorname{Lip}(f)^2\mathbb{E}|X_{l,M^l}-X_T|^2\leqslant Ch_l,\\ V_l&=\operatorname{Var}[(F_l-F)-(F_{l-1}-F)]\\ &\leqslant 2\operatorname{Var}(F_l-F)+2\operatorname{Var}(F_{l-1}-F)\leqslant C(h_l+h_{l-1})\leqslant C(1+M)h_l.\end{aligned}$$

粗层 $l=0$ 的有限方差也可并入常数. 取 L 为使 $C_bh_L\leqslant\varepsilon/\sqrt{2}$ 的最小整数, 即

$$L=\left\lceil\frac{\log(\sqrt{2}C_bT/\varepsilon)}{\log M}\right\rceil$$

(若右侧为负则取 0), 于是 $h_L\asymp\varepsilon$, 偏差平方不超过 $\varepsilon^2/2$.

因 $V_l \leqslant Ch_l$, 可明确选取

$$N_l = \left\lceil C_* \varepsilon^{-2}(L+1)h_l \right\rceil,$$

其中 C_* 足够大. 此时

$$\mathrm{Var}(\widehat{Y}_L) = \sum_{l=0}^{L} \frac{V_l}{N_l} \leqslant \sum_{l=0}^{L} \frac{C\varepsilon^2}{C_*(L+1)} \leqslant \frac{\varepsilon^2}{2}.$$

这与连续最优分配的尺度一致; 即使某些 V_l 更小, 该保守分配也能保证误差. 再用偏差–方差精确分解, 得到总均方误差不超过 ε^2. 成本满足

$$\begin{aligned} K &\leqslant C \sum_{l=0}^{L} [1 + C_* \varepsilon^{-2}(L+1)h_l] h_l^{-1} \\ &\leqslant C \sum_{l=0}^{L} h_l^{-1} + C\varepsilon^{-2}(L+1)^2 \\ &= O(\varepsilon^{-1}) + O(\varepsilon^{-2} \log^2 \varepsilon^{-1}). \end{aligned}$$

第一项是取整增加的成本, 低于第二项. 细层修正的方差较小, 因而较少的样本已足以估计其期望. □

命题 16.3.2 多层蒙特卡罗的复杂度

若偏差为 $O(h_L^\alpha)$, $V_l = O(h_l^\beta)$, $C_l = O(h_l^{-\gamma})$, 在标准兼容条件 $\alpha \geqslant \frac{1}{2}\min(\beta, \gamma)$ 下, MLMC 成本为

$$K = \begin{cases} O(\varepsilon^{-2}), & \beta > \gamma, \\ O(\varepsilon^{-2} \log^2 \varepsilon^{-1}), & \beta = \gamma, \\ O(\varepsilon^{-2-(\gamma-\beta)/\alpha}), & \beta < \gamma. \end{cases}$$

证明: 选 $h_L \asymp \varepsilon^{1/\alpha}$ 使偏差为 $O(\varepsilon)$, 则 $L = O(\log \varepsilon^{-1})$. 最优连续成本的上界由

$$\varepsilon^{-2} \left(\sum_{l=0}^{L} h_l^{(\beta-\gamma)/2} \right)^2$$

控制. 若 $\beta > \gamma$, 这是公比小于 1 的几何和, 一致有界; 若 $\beta = \gamma$, 各项为 1, 平方为 $(L+1)^2$; 若 $\beta < \gamma$, 几何和由最细层控制, 其平方为

$$O(h_L^{\beta-\gamma}) = O(\varepsilon^{-(\gamma-\beta)/\alpha}).$$

三种情形分别给出所述成本. 取整额外增加 $\sum_l C_l = O(h_L^{-\gamma}) = O(\varepsilon^{-\gamma/\alpha})$; 兼容条件 $\alpha \geqslant \frac{1}{2}\min(\beta, \gamma)$ 正好保证该项不超过相应主成本.

实际可先估计 V_l, C_l 与偏差衰减再确定层数和样本数. 路径依赖或不光滑测试函数会改变这些速率, 不能直接套用光滑 Lipschitz 情形. 该框架及 SDE 应用见 Giles 的原始论文和综述 [26, 27]. □

第十七章　路径积分

路径积分把前面的有限维 Gaussian 积分, Wiener 测度与 SDE 变换联系起来.

17.1　Wiener 测度

定义 17.1.1　Wiener 测度与柱泛函

在典范空间 $C_0([0,T])=\{w\in C[0,T]:w(0)=0\}$ 上, Wiener 测度 $P^*=\mu_W$ 是使坐标过程成为标准布朗运动的概率测度. 对只依赖有限个时刻的泛函 $F(w)=f(w(t_1),\cdots,w(t_n))$,

$$\int F(w)\mu_W(\mathrm{d}w)=\int_{\mathbb{R}^n} f(w_1,\cdots,w_n)Z_n^{-1}\exp\left[-\frac{1}{2}\sum_j\frac{(w_j-w_{j-1})^2}{t_j-t_{j-1}}\right]\prod_j \mathrm{d}w_j.$$

这里小写 w_t 表示路径积分的变量, 大写 W_t 表示随机过程, 且

$$Z_n=(2\pi)^{n/2}\prod_{j=1}^n(t_j-t_{j-1})^{1/2},\qquad I_n(w)=\frac{1}{2}\sum_{j=1}^n\left(\frac{w_j-w_{j-1}}{t_j-t_{j-1}}\right)^2(t_j-t_{j-1}),$$

$t_0=0,w_0=0$. 这由各独立增量 $W_{t_j}-W_{t_{j-1}}$ 的 Gaussian 密度相乘, 再作行列式为 1 的三角变量变换得到.

记分段线性插值为 $w^{(n)}$, 则有限维作用量恰好是

$$I_n(w)=\frac{1}{2}\int_0^T|\dot{w}^{(n)}(t)|^2\,\mathrm{d}t.$$

对一般可积泛函, 由测度论极限延拓. 把增量商形式地看作导数, 会写成

$$\mu_W(\mathrm{d}w)\text{ 形式上记作 }Z^{-1}\exp\left(-\frac{1}{2}\int_0^T|\dot{w}(t)|^2\,\mathrm{d}t\right)\mathcal{D}w,\qquad w(0)=0.$$

若不预先限制路径起点, 也有人在式中加入 $\delta(w(0))$. 这里 $\mathcal{D}w$ 不是无限维 Lebesgue 测度, Z 也不能按有限维体积常数直接处理.

在 $[0,1]$ 上取等分网格时, $Z_n=(2\pi/n)^{n/2}\to 0$. 另一方面, 若在二进网格上取布朗样本值, 则二次变差给出

$$\sum_{j=1}^n(W_{j/n}-W_{(j-1)/n})^2\longrightarrow 1,\qquad I_n(W)=\frac{n}{2}\sum_{j=1}^n(\Delta W_j)^2\longrightarrow\infty$$

几乎必然成立. 因此不能将 Z_n^{-1} 与 e^{-I_n} 的极限分别代入并当作普通函数之积; 有意义的是归一化后的有限维概率测度及其路径空间极限. 形式记号

$$I[w]=\frac{1}{2}\int_0^1 \dot w_t^2\,\mathrm{d}t,\qquad \frac{DP^*}{Dw}=\frac{1}{Z}\mathrm{e}^{-I[w]}\delta(w_0),\qquad P^*(A)=\int_A \frac{1}{Z}e^{-I[w]}\delta(w_0)\mathcal{D}w$$

必须按这种有限维逼近理解, 而不能视为相对于某个无限维 Lebesgue 测度的 Radon–Nikodym 导数.

命题 17.1.1　无限维空间中平移不变体积的不存在性

无限维可分 Hilbert 空间上, 不存在非零, 平移不变, 局部有限且具有通常体积性质的 Borel 测度.

证明: 局部有限性先给一个有限测度球 $B_R(0)$; 取正交单位向量 e_n, 球 $B_{R/8}((R/2)e_n)$ 两两不交而全落在该球内. 平移不变使它们有相同质量; 若小球质量正则大球质量无限, 若小球质量零, 可分性又使全空间被可数个这样半径的球覆盖而测度为零. □

而且布朗路径几乎必然没有平方可积导数, 形式作用量 $\frac12\int|\dot w|^2$ 对典型路径不是有限数. 它的有限能量路径类将作为 Cameron–Martin 空间出现, 表达的是平移方向的几何结构.

17.2 Wiener 泛函的期望

再次考虑

$$M=\mathbb{E}\exp\left(-\frac12\int_0^1 W_t^2\,\mathrm{d}t\right).$$

先用 KL 展开计算, 以便核对路径积分的结果. 取

$$W_t=\sum_{k=1}^{\infty}\sqrt{\lambda_k}\alpha_k\varphi_k(t),\qquad \lambda_k=\frac{4}{(2k-1)^2\pi^2},\quad \alpha_k\overset{\text{i.i.d.}}{\sim}N(0,1).$$

由 $L^2[0,1]$ 中的 Parseval 等式,

$$\int_0^1 W_t^2\,\mathrm{d}t=\sum_{k=1}^{\infty}\lambda_k\alpha_k^2.$$

有限个独立系数的期望可相乘, 且

$$\mathbb{E}\mathrm{e}^{-\lambda_k\alpha_k^2/2}=\frac{1}{\sqrt{2\pi}}\int_{\mathbb{R}}\mathrm{e}^{-(1+\lambda_k)x^2/2}\,\mathrm{d}x=(1+\lambda_k)^{-1/2}.$$

令部分和趋于无穷, 指数在 $[0,1]$ 内, 控制收敛给出

$$M=\prod_{k=1}^{\infty}(1+\lambda_k)^{-1/2}.$$

利用无穷乘积

$$\cosh x = \prod_{k=1}^{\infty} \left(1 + \frac{4x^2}{(2k-1)^2\pi^2}\right),$$

得到 $M = (\cosh 1)^{-1/2} = \sqrt{2\mathrm{e}/(1+\mathrm{e}^2)}$. 路径积分方法的严格起点是离散化: 令 $h = 1/n$, $x_j = W_{jh}$, $A = I_n$, 则泛函近似 $\mathrm{e}^{-hx^{\mathrm{T}}Ax/2}$, Wiener 有限维权重的精度矩阵为 hB, 其中

$$B = h^{-2}\begin{pmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 1 \end{pmatrix}.$$

事实上, 令 D 为对角元 1, 下一条对角线为 -1 的下双对角矩阵, 则

$$Dx = (x_1, x_2 - x_1, \cdots, x_n - x_{n-1})^{\mathrm{T}}, \qquad B = h^{-2}D^{\mathrm{T}}D.$$

故 $\det D = 1$, $\det B = h^{-2n}$, 且

$$\frac{h}{2}x^{\mathrm{T}}Bx = \frac{1}{2h}\sum_{j=1}^{n}(x_j - x_{j-1})^2.$$

末端对角元为 1, 因为终点是自由积分而非固定为零. Gaussian 积分比为

$$M_n = \frac{\int \mathrm{e}^{-hx^{\mathrm{T}}(A+B)x/2}\,\mathrm{d}x}{\int \mathrm{e}^{-hx^{\mathrm{T}}Bx/2}\,\mathrm{d}x} = \sqrt{\frac{\det B}{\det(A+B)}}.$$

这里用到正定矩阵 C 的 Gaussian 积分公式

$$\int_{\mathbb{R}^n} \mathrm{e}^{-x^{\mathrm{T}}Cx/2}\,\mathrm{d}x = (2\pi)^{n/2}(\det C)^{-1/2}.$$

证明是先正交对角化 $C = Q\Lambda Q^{\mathrm{T}}$, 令 $y = Q^{\mathrm{T}}x$, 再将积分分成 n 个一维积分. 分别取 $C = h(A+B)$ 和 $C = hB$, 公共因子 $(2\pi/h)^{n/2}$ 相消, 便得到上述行列式比.

布朗连续路径使 Riemann 和趋于 $\int W^2$, 且指数值在 $[0,1]$, 控制收敛给 $M_n \to M$.

还可直接核对有限维谱与连续谱. $Bv = \lambda v$ 的内点方程为

$$-v_{j-1} + 2v_j - v_{j+1} = h^2\lambda v_j.$$

首端相当于 $v_0 = 0$, 末端的对角元 1 相当于 $v_{n+1} = v_n$. 令 $v_j = \sin(j\theta)$, 则

$$h^2\lambda = 2 - 2\cos\theta, \qquad \sin((n+1)\theta) = \sin(n\theta).$$

因此可取 $\theta_k=(2k-1)\pi/(2n+1)$, 并得到

$$\lambda_{k,n}^B=4n^2\sin^2\frac{(2k-1)\pi}{4n+2},\qquad M_n=\prod_{k=1}^n\left(1+\frac{1}{\lambda_{k,n}^B}\right)^{-1/2}.$$

固定 k 时, $\lambda_{k,n}^B\to[(k-1/2)\pi]^2$. 又由 $\sin u\geqslant 2u/\pi(0\leqslant u\leqslant\pi/2)$,

$$\lambda_{k,n}^B\geqslant\frac{4}{9}(2k-1)^2,\qquad 0\leqslant\log\left(1+\frac{1}{\lambda_{k,n}^B}\right)\leqslant\frac{9}{4(2k-1)^2}.$$

右侧可求和, 故对数级数可控制收敛, 严格得到与 KL 方法相同的无穷乘积.

从作用量的二次型也能看出端点条件: 对 $u(0)=0$ 的光滑路径,

$$\int_0^1|u'|^2\,\mathrm{d}t=-\int_0^1u''u\,\mathrm{d}t+u'(1)u(1).$$

首端已经固定, 末端自由, 消去边界项的自然条件是 $u'(1)=0$. 相应特征方程

$$-u''=\lambda u,\qquad u(0)=0,\quad u'(1)=0$$

先由 $u(0)=0$ 得 $u(t)=c\sin(\sqrt{\lambda}t)$, 再由 $u'(1)=0$ 得 $\cos\sqrt{\lambda}=0$, 所以 $\lambda=[(k-1/2)\pi]^2$.

连续极限中的精度算子是 $B=-\frac{\mathrm{d}^2}{\mathrm{d}t^2}$, 边界条件为 $u(0)=0,u'(1)=0$; 其特征值 $[(k-1/2)\pi]^2$ 正是协方差特征值的倒数. 单独的 $\det B$, $\det(A+B)$ 在无限维通常没有普通意义, 但比值可解释为迹类协方差算子的 Fredholm 行列式 $\det(I+K)^{-1/2}$. 负号保证该精度算子在上述边界条件下为正算子.

命题 17.2.1

对 $q>0$, 有

$$\mathbb{E}_x\exp\left(-\frac{q}{2}\int_0^tW_s^2\,\mathrm{d}s\right)=\frac{\exp[-\frac{1}{2}\sqrt{q}\tanh(\sqrt{q}\,t)x^2]}{\sqrt{\cosh(\sqrt{q}\,t)}}.$$

当 $q=0$ 时, 左侧恒为 1.

证明: 对 $q\geqslant 0$, 设 $v(x,t)=\mathbb{E}_x\exp[-\frac{q}{2}\int_0^tW_s^2\,\mathrm{d}s]$. 它满足 $v_t=\frac{1}{2}v_{xx}-\frac{q}{2}x^2v$, $v(x,0)=1$. 试取 $v=A(t)\mathrm{e}^{-B(t)x^2/2}$, 比较常数和 x^2 系数得到

$$B'=q-B^2,\quad B(0)=0,\qquad A'/A=-B/2,\quad A(0)=1.$$

这些等式来自

$$\frac{v_t}{v}=\frac{A'}{A}-\frac{B'}{2}x^2,\qquad\frac{v_{xx}}{v}=B^2x^2-B.$$

分离变量解第一条 Riccati 方程,

$$\int_0^{B(t)} \frac{\mathrm{d}z}{q-z^2} = t \quad \Longrightarrow \quad \frac{1}{\sqrt{q}} \operatorname{artanh} \frac{B(t)}{\sqrt{q}} = t,$$

故 $B(t) = \sqrt{q}\tanh(\sqrt{q}\,t)$. 再积分

$$\log A(t) = -\frac{1}{2}\int_0^t B(s)\,\mathrm{d}s = -\frac{1}{2}\log\cosh(\sqrt{q}\,t),$$

得到 $A(t) = \cosh(\sqrt{q}\,t)^{-1/2}$. 所得 v 在 $[0,1]$ 内, 停止后使用 Feynman–Kac 并以控制收敛去掉停止, 即可验证它确是所求期望. 在 $x=0, t=1, q=1$ 恢复同一结果, 也得到一般时间和系数的推广. $q=0$ 由极限读取. □

17.3 Girsanov 变换

先考虑单位扩散的标量方程

$$\mathrm{d}X_t = b(X_t,t)\,\mathrm{d}t + \mathrm{d}W_t, \qquad X_0 = 0.$$

它将驱动路径 W 映为解路径 $X=\Phi(W)$, 并把 Wiener 测度推前为 μ_X. 下面先在有限维网格上求密度, 再说明连续极限所需的条件.

命题 17.3.1 离散路径的变量变换

令 $t_0=0$, $h_j = t_j - t_{j-1}$, Euler 离散满足

$$x_j = x_{j-1} + b(x_{j-1},t_{j-1})h_j + w_j - w_{j-1}, \qquad j=1,\cdots,n.$$

从节点向量 x 到 w 的变换 Jacobian 行列式为 1, 因而离散漂移路径的密度为 $Z_n^{-1}\mathrm{e}^{-\widetilde{I}_n(x)}$, 其中

$$\begin{aligned}\widetilde{I}_n(x) &= \frac{1}{2}\sum_{j=1}^{n}\frac{[x_j - x_{j-1} - b(x_{j-1},t_{j-1})h_j]^2}{h_j} \\ &= I_n(x) + \frac{1}{2}\sum_{j=1}^{n} b(x_{j-1},t_{j-1})^2 h_j - \sum_{j=1}^{n} b(x_{j-1},t_{j-1})(x_j - x_{j-1}).\end{aligned}$$

证明: 本节用 B 表示下双对角差分矩阵, 对角元为 1, 次对角元为 -1, 则离散方程为

$$Bx - (b(x_0,t_0)h_1,\cdots,b(x_{n-1},t_{n-1})h_n)^{\mathrm{T}} = Bw.$$

逐次求和得到逆变换

$$w_j = x_j - \sum_{k=1}^{j} b(x_{k-1},t_{k-1})h_k.$$

它对 x_j 的偏导为 1, 对 $x_k(k>j)$ 的偏导为零, 所以 Jacobian 为对角元全为 1 的下三角矩阵, 行列式等于 1. 代入 Wiener 节点密度并展开平方即得结论.
对柱泛函 F, 记 $b_j=b(W_{t_{j-1}},t_{j-1})$, 有限维变量代换因而给出

$$\begin{aligned}\mathbb{E}F(X_{t_1}^{(n)},\cdots,X_{t_n}^{(n)})&=\int_{\mathbb{R}^n}F(x)Z_n^{-1}\mathrm{e}^{-\widetilde{I}_n(x)}\,\mathrm{d}x\\&=\mathbb{E}\left[F(W_{t_1},\cdots,W_{t_n})\exp\left(\sum_j b_j\Delta W_j-\frac{1}{2}\sum_j b_j^2h_j\right)\right].\end{aligned}$$

这里将积分哑变量 x 改写为 w 并不改变积分. 左端点和在连续极限中对应 Itô 积分; 单凭形式代换并不能保证指数权重也在 L^1 中收敛. □

若上述极限及相应可积性成立, 便得到

$$\begin{aligned}\mathbb{E}F(X)&=\mathbb{E}\left[F(W)\exp\left(\int_0^T b(W_t,t)\,\mathrm{d}W_t-\frac{1}{2}\int_0^T b(W_t,t)^2\,\mathrm{d}t\right)\right],\\\frac{\mathrm{d}\mu_X}{\mathrm{d}\mu_W}(w)&=\exp\left(\int_0^T b(w_t,t)\,\mathrm{d}w_t-\frac{1}{2}\int_0^T b(w_t,t)^2\,\mathrm{d}t\right).\end{aligned}$$

在形式路径记号下, 同一运算写成

$$\frac{1}{2}\int_0^T(\dot{x}_t-b(x_t,t))^2\,\mathrm{d}t=\frac{1}{2}\int_0^T\dot{x}_t^2\,\mathrm{d}t+\frac{1}{2}\int_0^T b(x_t,t)^2\,\mathrm{d}t-\int_0^T b(x_t,t)\,\mathrm{d}x_t,$$

其中最后一项仍须按左端点的 Itô 约定解释. 下述测度变换定理为这种计算提供严格依据.

命题 17.3.2 Cameron–Martin 公式

若确定性函数 $\phi(0)=0$, 绝对连续且 $\dot{\phi}\in L^2[0,T]$, 则 $X_t=W_t+\phi(t)$ 的路径分布满足

$$\frac{\mathrm{d}\mu_X}{\mathrm{d}\mu_W}(w)=\exp\left(\int_0^T\dot{\phi}(t)\,\mathrm{d}w_t-\frac{1}{2}\int_0^T|\dot{\phi}(t)|^2\,\mathrm{d}t\right).$$

这些函数构成 Cameron–Martin 空间. 积分是确定性被积函数的 Wiener 积分.

证明: 先看有限维正态向量 $Z\sim N(0,I_n)$. 平移 $Z+\mu$ 的密度与标准正态密度之比为

$$\frac{\mathrm{e}^{-|z-\mu|^2/2}}{\mathrm{e}^{-|z|^2/2}}=\mathrm{e}^{\mu^{\mathrm{T}}z-|\mu|^2/2}.$$

若 $\dot{\phi}$ 是确定阶梯函数, 取 $Z_j=\Delta W_j/\sqrt{h_j}$, $\mu_j=\dot{\phi}_j\sqrt{h_j}$, 独立增量密度相乘便给出所述公式; 对任意有限组观察时刻, 可先把它们加入分割, 再计算每个子区间的密度, 因此等式适用于所有柱泛函.
一般情形取阶梯函数 $a_n\to\dot{\phi}$ 于 L^2, 并令 $\phi_n(t)=\int_0^t a_n(s)\,\mathrm{d}s$. Cauchy–Schwarz 给

$$\sup_{t\leqslant T}|\phi_n(t)-\phi(t)|\leqslant\sqrt{T}\|a_n-\dot{\phi}\|_2\to0,$$

而 Wiener 等距给 $\int a_n \,\mathrm{d}W \to \int \dot{\phi}\,\mathrm{d}W$ 于 L^2. 相应密度 $D_n = \exp(\int a_n \,\mathrm{d}W - \|a_n\|_2^2/2)$ 依概率趋于 D, 且对任意固定 $p > 1$,

$$\mathbb{E}D_n^p = \exp\left(\frac{p(p-1)}{2}\|a_n\|_2^2\right)$$

一致有界, 故 $D_n \to D$ 于 L^1. 对有界连续泛函取极限, 得到 $\mathbb{E}F(W+\phi) = \mathbb{E}[F(W)D]$. 两边都是路径空间上的概率测度, 连续函数决定测度, 故等式延拓到所有有界可测泛函. □

还可把同一个正态平移解释成改变概率空间上的测度. 令 $\widetilde{Z}_k = Z_k + \mu_k$, 定义

$$\frac{\mathrm{d}\widetilde{P}}{\mathrm{d}P} = \exp\left(-\sum_{k=1}^n \mu_k Z_k - \frac{1}{2}\sum_{k=1}^n \mu_k^2\right).$$

在新坐标 $\tilde{z} = z + \mu$ 下, 其联合密度的指数为

$$-\mu^{\mathrm{T}}(\tilde{z}-\mu) - \frac{1}{2}|\mu|^2 - \frac{1}{2}|\tilde{z}-\mu|^2 = -\frac{1}{2}|\tilde{z}|^2.$$

所以 $\widetilde{Z}_k$ 在 $\widetilde{P}$ 下重新成为独立标准正态. 取 $\mu_k = \phi_k\sqrt{h_k}$, 这个公式提示: $\widetilde{W}_t = W_t + \int_0^t \phi_s \,\mathrm{d}s$ 可在一个新测度下成为布朗运动. 连续情形允许 ϕ 依赖过去的随机信息, 但需要保证密度的总质量为 1.

引理 17.3.3 Novikov 判据

设 ϕ_t 可预测, $A_t = \int_0^t |\phi_s|^2 \,\mathrm{d}s$, 且

$$\mathbb{E}\mathrm{e}^{A_T/2} < \infty.$$

则随机指数

$$Z_t = \exp\left(-M_t - \frac{1}{2}A_t\right), \qquad M_t = \int_0^t \phi_s \cdot \mathrm{d}W_s,$$

为均值为 1 的正鞅.

证明: Itô 公式给 $\mathrm{d}Z_t = -Z_t\phi_t \cdot \mathrm{d}W_t$, 故它是正局部鞅, 从而是超鞅, $\mathbb{E}Z_T \leqslant 1$. 下面证明反向不等式.
先对 A_t 在达到 n 时停止. 平方恒等式

$$\mathrm{e}^{-2M_t - A_t} = \mathrm{e}^{-2M_t - 2A_t}\mathrm{e}^{A_t}$$

说明停止后的密度在进一步的局部化下具有统一的 L^2 界 e^n, 因为第一因子是正局部鞅, 期望不超过 1. 因此停止后的密度是真鞅.
对 $0 < r < 1$ 考虑缩小后的指数 $Z_t^{(r)} = \mathrm{e}^{-rM_t - r^2A_t/2}$. 选 $q > p > 1$, 由 Hölder 不等式, 停止时

$\tau_n = \inf\{t : A_t \geqslant n\} \wedge T$ 处有

$$\begin{aligned}\mathbb{E}(Z_{\tau_n}^{(r)})^p &= \mathbb{E}\left[(\mathrm{e}^{-qrM_{\tau_n} - q^2r^2A_{\tau_n}/2})^{p/q}\mathrm{e}^{pr^2(q-1)A_{\tau_n}/2}\right] \\ &\leqslant \left(\mathbb{E}\exp\left[\frac{pqr^2(q-1)}{2(q-p)}A_T\right]\right)^{(q-p)/q}.\end{aligned}$$

第一 Hölder 因子的期望为 1, 因为其二次变差已停止. 令 $p = 1+\delta^2, q = 1+\delta$, 则 $pq(q-1)/(q-p) \to 1$; 固定 $r < 1$ 后可选充分小的 δ, 使上式指数系数不超过 $1/2$. Novikov 条件因此给出关于 n 一致的 L^p 界. 于是 $Z_{\tau_n}^{(r)}$ 一致可积, 令 $n \to \infty$ 得 $\mathbb{E}Z_T^{(r)} = 1$.
最后注意

$$Z_T^{(r)} = Z_T^r \mathrm{e}^{r(1-r)A_T/2}.$$

再次用 Hölder 不等式,

$$1 = \mathbb{E}Z_T^{(r)} \leqslant (\mathbb{E}Z_T)^r(\mathbb{E}\mathrm{e}^{rA_T/2})^{1-r} \leqslant (\mathbb{E}Z_T)^r(\mathbb{E}\mathrm{e}^{A_T/2})^{1-r}.$$

令 $r \uparrow 1$, 得到 $\mathbb{E}Z_T \geqslant 1$. 正超鞅在整个时域内的期望于是恒为 1; 其条件超鞅不等式的非负差期望为零, 故实际上是鞅. □

定理 17.3.1 Girsanov 定理 I

设 W 为 m 维标准布朗运动, ϕ 可预测并满足 Novikov 条件. 在 $\mathcal{F}_T$ 上定义

$$Z_t = \exp\left(-\int_0^t \phi_s \cdot \mathrm{d}W_s - \frac{1}{2}\int_0^t |\phi_s|^2\,\mathrm{d}s\right), \qquad \widetilde{P}(A) = \mathbb{E}_P[Z_T\mathbf{1}_A].$$

则 $\widetilde{P}$ 是与 P 等价的概率测度, 且

$$\widetilde{W}_t = W_t + \int_0^t \phi_s\,\mathrm{d}s$$

在 $\widetilde{P}$ 下为标准布朗运动, $0 \leqslant t \leqslant T$.

证明: 前一引理保证 $\mathbb{E}Z_T = 1$, 而 $Z_T > 0$ 几乎必然, 故新测度有总质量 1 且与原测度等价. 对每一分量作乘积微分,

$$\begin{aligned}\mathrm{d}(Z_t\widetilde{W}_t^i) &= \widetilde{W}_t^i\,\mathrm{d}Z_t + Z_t\,\mathrm{d}\widetilde{W}_t^i + \mathrm{d}[Z, \widetilde{W}^i]_t \\ &= -Z_t\widetilde{W}_t^i\phi_t \cdot \mathrm{d}W_t + Z_t\,\mathrm{d}W_t^i + Z_t\phi_t^i\,\mathrm{d}t - Z_t\phi_t^i\,\mathrm{d}t.\end{aligned}$$

漂移相消. 结合 Bayes 条件期望公式

$$\mathbb{E}_{\widetilde{P}}(U \mid \mathcal{F}_s) = \frac{\mathbb{E}_P(Z_tU \mid \mathcal{F}_s)}{Z_s} \qquad (U \in L^1(\widetilde{P}),\ U \text{ 对}\mathcal{F}_t \text{ 可测}),$$

并先在 $Z, Z^{-1}, \widetilde{W}, A$ 有界的停止区间上运用, 得到 $\widetilde{W}$ 在 $\widetilde{P}$ 下是连续局部鞅. 有限变差项不贡献二次协变差, 所以

$$[\widetilde{W}^i, \widetilde{W}^j]_t = [W^i, W^j]_t = \delta_{ij} t.$$

为直接识别其分布, 固定 s 与 $\xi \in \mathbb{R}^m$, 对

$$U_t = \exp\left(\mathrm{i}\xi \cdot (\widetilde{W}_t - \widetilde{W}_s) + \frac{1}{2}|\xi|^2 (t-s) \right), \qquad t \geqslant s,$$

用 Itô 公式, 漂移同样相消. 其模在有限时域内有确定上界, 故局部鞅是真鞅. 于是

$$\mathbb{E}_{\widetilde{P}} \left[\mathrm{e}^{\mathrm{i}\xi \cdot (\widetilde{W}_t - \widetilde{W}_s)} \mid \mathcal{F}_s \right] = \mathrm{e}^{-|\xi|^2 (t-s)/2}.$$

右侧是与过去无关的 $N(0, (t-s) I_m)$ 特征函数, 说明增量具有该 Gaussian 分布并独立于 $\mathcal{F}_s$. 再加上连续路径和零初值, 便得到布朗运动的定义. □

评注　两种密度公式的符号　Cameron–Martin 公式描述平移过程在原测度下的分布, 其指数中随机积分取正号; Girsanov 定理改变样本空间上的测度, 使带正漂移的过程重新成为布朗运动, 密度取负号. 以确定性 ϕ 为例, $\mathrm{d}W = \mathrm{d}\widetilde{W} - \phi \, \mathrm{d}t$ 给出

$$Z_T = \exp\left(-\int_0^T \phi_s \, \mathrm{d}\widetilde{W}_s + \frac{1}{2} \int_0^T \phi_s^2 \, \mathrm{d}s \right).$$

它恰是平移路径密度在 $\widetilde{W}$ 处的倒数, 因而

$$\mathbb{E}_{\widetilde{P}} F(\widetilde{W}) = \mathbb{E}_P [Z_T F(\widetilde{W})] = \mathbb{E}_P F(W).$$

对随机漂移应使用前述适应性和密度条件, 不能直接当作确定平移代换.

定理 17.3.2　Girsanov 定理 II: 漂移变换

设在 P 下, $X, Y \in \mathbb{R}^n$ 满足

$$\mathrm{d}X_t = b(X_t, t) \, \mathrm{d}t + \sigma(X_t, t) \, \mathrm{d}W_t, \qquad \mathrm{d}Y_t = [b(Y_t, t) + \gamma_t] \, \mathrm{d}t + \sigma(Y_t, t) \, \mathrm{d}W_t,$$

且 $X_0 = Y_0 = x$, $W \in \mathbb{R}^m$, $\sigma \in \mathbb{R}^{n \times m}$. 若有可预测的 ϕ_t 满足

$$\sigma(Y_t, t) \phi_t = \gamma_t$$

并满足 Novikov 条件, 则使用定理 I 的 $Z, \widetilde{P}, \widetilde{W}$ 后, Y 在 $\widetilde{P}$ 下满足基准方程

$$\mathrm{d}Y_t = b(Y_t, t) \, \mathrm{d}t + \sigma(Y_t, t) \, \mathrm{d}\widetilde{W}_t.$$

若基准方程弱唯一, 则 Y 在 $\widetilde{P}$ 下与 X 在 P 下具有相同的路径分布.

证明: 代入 $\mathrm{d}W_t = \mathrm{d}\widetilde{W}_t - \phi_t\,\mathrm{d}t$, 修正漂移成为 $\gamma_t - \sigma(Y_t,t)\phi_t = 0$. 定理 I 已证明 $\widetilde{W}$ 是新测度下的布朗运动, 因此由弱唯一性识别两者的路径分布, 并得到

$$\mathbb{E}_P F(X) = \mathbb{E}_{\widetilde{P}} F(Y) = \mathbb{E}_P[Z_T F(Y)].$$

条件等式必须沿 Y 评价, 才能在 Y 的方程中消去漂移. 若 σ 为可逆方阵, 可取 $\phi_t = \sigma(Y_t,t)^{-1}\gamma_t$; 矩形或退化情形须检查 γ_t 是否位于 $\sigma(Y_t,t)$ 的值域, 但不必要求代数解唯一. □

评注　路径分布的 Radon–Nikodym 导数 更常见的状态依赖修正为 $\gamma_t = \gamma(Y_t,t)$. 在基准过程 X 上选 ϕ_t^X 满足 $\sigma(X_t,t)\phi_t^X = \gamma(X_t,t)$, 并验证正号指数

$$D_T = \exp\left(\int_0^T \phi_t^X \cdot \mathrm{d}W_t - \frac{1}{2}\int_0^T |\phi_t^X|^2\,\mathrm{d}t\right)$$

是均值为 1 的鞅密度. 定理 I 对 $-\phi^X$ 表明, 新测度下 $\widehat{W} = W - \int \phi^X\,\mathrm{d}t$ 为布朗运动, 而 X 的漂移变为 $b+\gamma$. 若该方程弱唯一, 则

$$\mathbb{E}_P F(Y) = \mathbb{E}_P[D_T F(X)], \qquad \frac{\mathrm{d}\mu_Y}{\mathrm{d}\mu_X}(X) = \mathbb{E}_P(D_T \mid \sigma(X)).$$

若 D_T 本身可由整条 X 路径确定, 条件期望即为 D_T. 例如可逆 σ 时, $\mathrm{d}W = \sigma(X,t)^{-1}(\mathrm{d}X - b(X,t)\,\mathrm{d}t)$ 可恢复噪声, 便得到常见的路径指数密度公式. 若含有不可从 X 恢复的噪声分量, 则不能省去这个条件期望.

Novikov 是充分条件而非必要条件. 仅有 $\int_0^T |\phi|^2\,\mathrm{d}t < \infty$ 几乎必然, 一般只能保证正局部鞅, 可能出现 $\mathbb{E}Z_T < 1$. 无限时域还须证明密度族一致可积, 不能只凭每个有限时域的结论直接取 $T=\infty$. 改变扩散系数通常也会改变路径的二次变差, 不属于单纯的漂移测度变换.

17.4 再看 Feynman–Kac 公式

对 $v_t = \frac{1}{2}\Delta v + qv$, $v(\cdot,0) = f$, 前面已严格得到

$$v(x,t) = \mathbb{E}_x\left[\exp\left(\int_0^t q(W_s)\,\mathrm{d}s\right) f(W_t)\right].$$

取 $h = t/n$, $w_0 = x$, 时间切片给出

$$v_n(x,t) = \int_{\mathbb{R}^n} f(w_n)\prod_{j=1}^{n}\frac{1}{\sqrt{2\pi h}}\exp\left[-\frac{(w_j - w_{j-1})^2}{2h} + hq(w_{j-1})\right]\mathrm{d}w_1\cdots\mathrm{d}w_n.$$

对有界连续 q, f, 路径连续性使势能 Riemann 和收敛, 而积分权重由 $\mathrm{e}^{t\|q\|_\infty}\|f\|_\infty$ 控制, 故 $v_n \to v$. 较一般情形用停止和相应指数可积性处理. 把有限维表达式形式缩写为

$$v(x,t) = \int \delta(w_0 - x)\frac{1}{Z}\exp\left[-\int_0^t \left(\frac{1}{2}\dot{w}_s^2 - q(w_s)\right)\mathrm{d}s\right] f(w_t)\mathcal{D}w.$$

也可将起点平移到零, 写成

$$v(x,t) = \int f(x + w(t))\exp\left[-\int_0^t \left(\frac{1}{2}|\dot{w}(s)|^2 - q(x + w(s))\right)\mathrm{d}s\right]\frac{\mathcal{D}w}{Z}, \quad w(0) = 0.$$

严格含义仍是对 Wiener 测度取带指数权重的期望, 不是在所有路径上另造一个平坦测度. 有限维时间切片, KL 展开以及 PDE 都能为具体计算提供合法解释.

评注　虚时间变换　量子力学 Schrödinger 方程为

$$\mathrm{i}\hbar\partial_t\psi = -\frac{\hbar^2}{2m}\Delta\psi + V\psi.$$

其形式路径表示为

$$\psi(x,t) = \int \delta(w_0 - x)\frac{1}{Z}\exp\left(\frac{\mathrm{i}}{\hbar}I[w]\right)\psi_0(w_t)\mathcal{D}w, \qquad I[w] = \int_0^t \left(\frac{m}{2}\dot{w}_s^2 - V(w_s)\right)\mathrm{d}s.$$

这里 I 是经典作用量; 实时间权重 $\mathrm{e}^{\mathrm{i}I/\hbar}$ 是振荡复权重, 不是概率密度. 形式上把 $m = 1, \hbar = -i$ 代入, Schrödinger 方程即成为 $\partial_t\psi = \frac{1}{2}\Delta\psi + V\psi$, 同时 $\mathrm{e}^{\mathrm{i}I/\hbar} = \mathrm{e}^{-I}$, 对应 $q = V$ 的热方程表示. 这只是两个公式之间的代数联系; 通常保持物理参数为实数而变换时间. 用适当的虚时间代换 $t = -\mathrm{i}\tau$ 得

$$\partial_\tau\psi = \frac{\hbar}{2m}\Delta\psi - \frac{V}{\hbar}\psi,$$

为核对符号, 令 $u(x,\tau) = \psi(x, -\mathrm{i}\tau)$, 则

$$\partial_\tau u = -i\partial_t\psi = -\frac{1}{\hbar}\left(-\frac{\hbar^2}{2m}\Delta u + Vu\right).$$

因此, 虚时间方程对应扩散常数 $\hbar/(2m)$, 势项 $-V/\hbar$ 的 Feynman–Kac 公式. 实时间的振荡路径积分须另行定义.

参考文献

[1] 李铁军. *Lecture Notes on Applied Stochastic Analysis*. LASA–2025 课程页面及所链接讲义, `https://math.pku.edu.cn/teachers/litj/LASA-2025.htm`.

[2] P. Billingsley. *Probability and Measure*. Wiley.

[3] K. L. Chung. *A Course in Probability Theory*. Academic Press.

[4] C. W. Gardiner. *Handbook of Stochastic Methods*. Springer.

[5] B. Øksendal. *Stochastic Differential Equations: An Introduction with Applications*. Springer.

[6] I. Karatzas, S. E. Shreve. *Brownian Motion and Stochastic Calculus*. Springer.

[7] P. Mörters, Y. Peres. *Brownian Motion*. Cambridge University Press, 2010. 作者公开草稿: `https://www.stat.berkeley.edu/users/aldous/205B/bmbook.pdf`.

[8] W. H. Press et al. *Numerical Recipes: The Art of Scientific Computing*. Cambridge University Press.

[9] D. E. Knuth. *The Art of Computer Programming, Vol. 2: Seminumerical Algorithms*. Addison–Wesley.

[10] G. Marsaglia. Random numbers fall mainly in the planes. *PNAS*, 61:25–28, 1968.

[11] M. Matsumoto, T. Nishimura. Mersenne Twister: A 623-dimensionally equidistributed uniform pseudo-random number generator. *ACM TOMACS*, 8:3–30, 1998.

[12] C. P. Robert, G. Casella. *Monte Carlo Statistical Methods*. Springer.

[13] P. Glasserman. *Monte Carlo Methods in Financial Engineering*. Springer, 2004.

[14] R. E. Caflisch. Monte Carlo and quasi-Monte Carlo methods. *Acta Numerica*, 7:1–49, 1998.

[15] N. Metropolis et al. Equation of state calculations by fast computing machines. *Journal of Chemical Physics*, 21:1087–1092, 1953.

[16] W. K. Hastings. Monte Carlo sampling methods using Markov chains and their applications. *Biometrika*, 57:97–109, 1970.

[17] R. H. Swendsen, J.-S. Wang. Nonuniversal critical dynamics in Monte Carlo simulations. *Physical Review Letters*, 58:86–88, 1987.

[18] U. Wolff. Collective Monte Carlo updating for spin systems. *Physical Review Letters*, 62:361–364, 1989.

[19] E. Marinari, G. Parisi. Simulated tempering: A new Monte Carlo scheme. *Europhysics Letters*, 19:451–458, 1992.

[20] A. B. Bortz, M. H. Kalos, J. L. Lebowitz. A new algorithm for Monte Carlo simulation of Ising spin systems. *Journal of Computational Physics*, 17:10–18, 1975.

[21] S. Kirkpatrick, C. D. Gelatt, M. P. Vecchi. Optimization by simulated annealing. *Science*, 220:671–680, 1983.

[22] G. Winkler. *Image Analysis, Random Fields and Dynamic Monte Carlo Methods*. Springer, 1995.

[23] P. E. Kloeden, E. Platen. *Numerical Solution of Stochastic Differential Equations*. Springer, 1992. 强, 弱 Taylor 格式的指标规则与条件见第 10, 14 章.

[24] D. J. Higham. An algorithmic introduction to numerical simulation of stochastic differential equations. *SIAM Review*, 43:525–546, 2001. `https://doi.org/10.1137/S0036144500378302`.

[25] D. Talay, L. Tubaro. Expansion of the global error for numerical schemes solving stochastic differential equations. *Stochastic Analysis and Applications*, 8:483–509, 1990.

[26] M. B. Giles. Multilevel Monte Carlo path simulation. *Operations Research*, 56:607–617, 2008.

[27] M. B. Giles. Multilevel Monte Carlo methods. *Acta Numerica*, 24:259–328, 2015. `https://arxiv.org/abs/1304.5472`; 作者资料页: `https://people.maths.ox.ac.uk/gilesm/mlmc.html`.

[28] R. Wang. *An Introduction to Probability Theory*. Peking University Press, 1998.

[29] B. Kisacanin. *Mathematical Problems and Proofs: Combinatorics, Number Theory, and Geometry*. Kluwer, 2002.

[30] J. S. Liu. *Monte Carlo Strategies in Scientific Computing*. Springer, 2001.

[31] R. Durrett. *Probability: Theory and Examples*. Cambridge University Press, 2010.

[32] P.-T. de Boer et al. A tutorial on the cross-entropy method. *Annals of Operations Research*, 134:19–67, 2005.

[33] C. M. Bender, S. A. Orszag. *Advanced Mathematical Methods for Scientists and Engineers: Asymptotic Methods and Perturbation Theory*. Springer, 1999.

[34] R. S. Ellis. *Entropy, Large Deviations, and Statistical Mechanics*. Springer, 1985.

[35] R. T. Rockafellar. *Convex Analysis*. Princeton University Press, 1970.

[36] R. T. Rockafellar, R. J.-B. Wets. *Variational Analysis*. Springer.

[37] I. Beichl, F. Sullivan. The Metropolis algorithm. *Computing in Science & Engineering*, 2:65–69, 2000.

[38] L. Onsager. Crystal statistics. I. A two-dimensional model with an order-disorder transition. *Physical Review*, 65:117–149, 1944.

[39] C. N. Yang. The spontaneous magnetization of a two-dimensional Ising model. *Physical Review*, 85:808–816, 1952.

[40] C. J. Geyer. Markov chain Monte Carlo maximum likelihood. *Computing Science and Statistics: Proceedings of the 23rd Symposium on the Interface*, 156–163, 1991.

[41] C. J. Geyer, E. A. Thompson. Annealing Markov chain Monte Carlo with applications to ancestral inference. *Journal of the American Statistical Association*, 1995.

[42] J. S. Liu, C. Sabatti. Simulated sintering: Markov chain Monte Carlo with spaces of varying dimensions. *Bayesian Statistics 6*. Oxford University Press.

[43] D. M. Higdon. Auxiliary variable methods for Markov chain Monte Carlo with applications. *Journal of the American Statistical Association*, 93:585–595, 1998.

[44] L. Kang. *Non-Numerical Parallel Algorithms: Simulated Annealing Algorithms*. Science Press, 1994.

[45] S. Chandrasekhar. Stochastic problems in physics and astronomy. *Reviews of Modern Physics*, 15:1–89, 1943.

[46] A. N. Shiryaev. *Probability*. Springer, 1996.

[47] R. J. Adler. *The Geometry of Random Fields*. Wiley, 1981.

[48] R. H. Cameron, W. T. Martin. The orthogonal development of nonlinear functionals in series of Fourier–Hermite functionals. *Annals of Mathematics*, 385–392, 1947.

[49] J. Lamperti. *Stochastic Processes: A Survey of the Mathematical Theory*. Springer, 1977.

[50] P. D. Lax. *Functional Analysis*. Wiley, 2002.

[51] D. Revuz, M. Yor. *Continuous Martingales and Brownian Motion*. Springer, 3rd edition.

[52] F. Riesz, B. Sz.-Nagy. *Functional Analysis*. Blackie & Son, 1956.

[53] D. F. Walnut. *An Introduction to Wavelet Analysis*. Birkhäuser, 2002.

[54] N. Wiener. Differential space. *Journal of Mathematics and Physics*, 2:131–174, 1923.

[55] D. Xiu, G. Karniadakis. The Wiener–Askey polynomial chaos for stochastic differential equations. *SIAM Journal on Scientific Computing*, 619–644, 2002.

[56] I. M. Gelfand, G. E. Shilov. *Generalized Functions*. Academic Press.

[57] T. Hida, Si Si. *Lectures on White Noise Functionals*. World Scientific, 2008.

[58] N. Ikeda, S. Watanabe. *Stochastic Differential Equations and Diffusion Processes*. North-Holland, 1981.

[59] K. Itô. Stochastic integral. *Proceedings of the Imperial Academy*, 20:519–524, 1944.

[60] P. R. Kramer, A. J. Majda. Stochastic mode reduction for particle-based simulation methods for complex microfluid systems. *SIAM Journal on Applied Mathematics*, 64:401–422, 2003.

[61] R. Kubo. The fluctuation-dissipation theorem. *Reports on Progress in Physics*, 29:255, 1966.

[62] P. E. Protter. *Stochastic Integration and Differential Equations*. Springer, 2nd edition, 2004.

[63] H. J. Sussmann. On the gap between deterministic and stochastic ordinary differential equations. *Annals of Probability*, 1978.

[64] E. Wong, M. Zakai. On the convergence of ordinary integrals to stochastic integrals. *Annals of Mathematical Statistics*, 36:1560–1564, 1965.

[65] O. Kallenberg. *Foundations of Modern Probability*. Springer, 1997.

[66] K. Yosida. *Functional Analysis*. Springer, 6th edition.

[67] M. B. Giles. Multilevel Monte Carlo methods. *Monte Carlo and Quasi-Monte Carlo Methods 2012*, 79–98. Springer, 2014.

[68] B. R. Hunt, T. Sauer, J. A. Yorke. Prevalence: a translation-invariant "almost every" on infinite-dimensional spaces. *Bulletin of the American Mathematical Society*, 27:217–238, 1992.

[69] R. P. Feynman. Space-time approach to non-relativistic quantum mechanics. *Reviews of Modern Physics*, 20:367–387, 1948.